





Análise e Previsão do Estado Fisiológico de Trabalhadores em Obra através de Gémeos Digitais Humanos e Aprendizagem Automática

Carlos Alejandro Freitas Teixeira

Aluno nº: 1240521

Dissertação para obtenção do Grau de Mestre em Engenharia de Inteligência Artificial

Orientador: Diogo Emanuel Pereira Martinho, Professor Auxiliar do Instituto Superior de Engenharia do Porto, Universidade Técnica do Porto

Júri:
Presidente:
Joaquim Filipe Peixoto dos Santos, Professor Associado do Instituto Superior de Engenharia do Porto, Universidade Técnica do Porto

Arguente:
José Alberto da Silva Freitas, Professor Associado com Agregação da Faculdade de Medicina da Universidade do Porto
Orientador:
Diogo Emanuel Pereira Martinho, Professor Auxiliar do Instituto Superior de Engenharia do Porto, Universidade Técnica do Porto

Porto, 9 de outubro de 2026

Declaração de Integridade

Declaro ter conduzido este trabalho académico com integridade.

Não plagiei ou apliquei qualquer forma de uso indevido de informações ou falsificação de resultados ao longo do processo que levou à sua elaboração.

Portanto, o trabalho apresentado neste documento é original e de minha autoria, não tendo sido utilizado anteriormente para nenhum outro fim. Durante a elaboração desta dissertação, foram utilizadas ferramentas de Inteligência Artificial, nomeadamente o GitHub Copilot, exclusivamente como apoio à redação, à tradução de conteúdos para português e ao aperfeiçoamento linguístico de ideias previamente definidas pelo autor. Estas ferramentas não foram utilizadas para substituir a autoria, definir a metodologia, produzir os resultados, realizar a análise científica ou formular as conclusões do trabalho. O autor manteve a responsabilidade pela seleção, verificação e validação de todo o conteúdo apresentado.

Declaro ainda que tenho pleno conhecimento do Código de Conduta Ética do P.PORTO.

ISEP, Porto, 27 de setembro de 2026

Dedicatória

“A perseverança é a virtude pela qual todas as outras virtudes dão o seu fruto.”

— *Arturo Graf*

À minha mãe e à minha avó, por serem a minha força, pelo vosso amor incondicional e por me ensinarem a perseverar e a nunca desistir.

Resumo

Esta dissertação insere-se no âmbito da Inteligência Artificial, com particular enfoque na aplicação de técnicas de aprendizagem automática à monitorização de estados psicofisiológicos em ambientes laborais de alto risco. No contexto da construção civil, onde o desempenho humano assume um papel crítico para a segurança operacional, a crescente complexidade destes ambientes, marcada pela interação entre trabalhadores, máquinas e sistemas inteligentes, reforça a necessidade de soluções capazes de apoiar a monitorização das condições fisiológicas dos trabalhadores.

Neste contexto, e em alinhamento com os princípios da Indústria 5.0, esta dissertação procura avaliar em que medida modelos de aprendizagem automática podem ser utilizados para caracterizar e estimar estados psicofisiológicos relevantes para a segurança, a partir de dados recolhidos por sensores portáteis. Estados como o stress, a fadiga e o cansaço podem não ser conscientemente percecionados pelo próprio trabalhador e constituem fatores relevantes para a ocorrência de situações de risco e acidentes. Para este trabalho, foram analisados dados provenientes da banda Polar H10 e do relógio Empatica EmbracePlus, recorrendo a modelos de aprendizagem supervisionada e a técnicas de agrupamento não supervisionado.

A abordagem proposta explora o conceito de gémeo digital humano, integrando dados fisiológicos em tempo real com modelos preditivos capazes de capturar a dinâmica temporal dos sinais e inferir o estado interno do trabalhador. O objetivo é contribuir para o desenvolvimento de sistemas de monitorização inteligentes e centrados no ser humano, que apoiem a prevenção de riscos laborais e a tomada de decisão em tempo real em contextos de elevada exigência operacional.

Palavras-chave: Aprendizagem Automática, Gémeo Digital, Modelos Preditivos, Previsão Fisiológica, Tecnologias Emergentes, Trabalhadores de Alto Risco

Abstract

This dissertation falls within the field of Artificial Intelligence, with a particular focus on the application of machine learning techniques to the monitoring of psychophysiological states in high-risk work environments. In the context of construction, where human performance plays a critical role in operational safety, the increasing complexity of these environments, characterized by the interaction between workers, machinery, and intelligent systems, reinforces the need for solutions capable of supporting the monitoring of workers' physiological conditions.

In this context, and in alignment with Industry 5.0 principles, this dissertation seeks to assess the extent to which machine learning models can be used to characterize and estimate psychophysiological states relevant to safety, based on data collected by wearable sensors. States such as stress, fatigue, and tiredness may not be consciously perceived by the worker and are relevant factors in the occurrence of risk situations and accidents. For this work, data from the Polar H10 chest strap and the Empatica EmbracePlus watch were analyzed using supervised learning models and unsupervised clustering techniques.

The proposed approach explores the concept of the human digital twin by integrating real-time physiological data with predictive models capable of capturing the temporal dynamics of signals and inferring the worker's internal state. The objective is to contribute to the development of intelligent, human-centered monitoring systems that support the prevention of occupational risks and real-time decision-making in demanding operational contexts.

Keywords: Digital Twin, Emerging Technologies, High-Risk Workers, Machine Learning, Physiological Prediction, Predictive Models

Agradecimentos

Em primeiro lugar, gostaria de expressar a minha profunda gratidão ao Professor Diogo Martinho, pela orientação, paciência e pelo acompanhamento constante ao longo de toda esta dissertação. Os seus conhecimentos e disponibilidade foram fundamentais para superar os desafios técnicos e científicos deste trabalho. Deixo ainda uma palavra de agradecimento a todos os docentes que, de alguma forma, contribuíram para a minha formação académica, especialmente ao longo destes dois últimos anos no Instituto Superior de Engenharia do Porto (ISEP).

Estendo o meu agradecimento ao GECAD, centro de investigação do ISEP, pelo ambiente de partilha e colaboração que me proporcionou. Foi neste espaço que encontrei não apenas os recursos e o conhecimento necessários para o desenvolvimento deste projeto, mas também colegas e amigos que tornaram a experiência de investigação muito mais enriquecedora e estimulante.

Gostaria também de expressar o meu profundo agradecimento ao projeto CRIARTE e a todos os seus integrantes, pela oportunidade de trabalhar com uma equipa multidisciplinar de profissionais e especialistas em Engenharia e noutras áreas. Os conhecimentos partilhados, o apoio prestado e a possibilidade de contribuir para um projeto com um potencial tão significativo foram fundamentais para o meu desenvolvimento académico e profissional. Agradeço, em particular, à Garcia, Garcia, S.A., parceira da equipa do CRIARTE, que dirigiu os cenários de simulação e recolheu grande parte dos dados fisiológicos posteriormente utilizados neste trabalho de investigação. O seu apoio, disponibilidade e contributos foram fundamentais para a realização desta dissertação.

Por fim, à minha família, dedico um agradecimento especial pelo apoio incondicional. Mesmo sem dominarem a área técnica do meu trabalho, o interesse constante e o incentivo que demonstraram em cada fase foram o combustível necessário para continuar. Agradeço de forma especial à minha mãe e à minha avó por serem o meu porto seguro, por acreditarem em mim mesmo nos momentos de maior incerteza e por me ajudarem a perseverar sempre. Sem o vosso amor e paciência, esta conquista não seria possível. Esta dissertação também é vossa.

Índice

Lista de Algoritmos **xviii**

Lista de Código **xviii**

Lista de Acrónimos **xxi**

1 Introdução **1**
1.1 Contextualização . . . 1
1.2 Descrição do Problema . . . 2
1.3 Objetivos . . . 3
1.4 Ética e Implicações Sociais na Monitorização Humana . . . 5
1.4.1 Enquadramento Legal . . . 5
1.4.2 Análise Ética e Regulamentar da Solução de Gémeo Digital Humano 7
1.5 Estrutura do Documento . . . 7

2 Tecnologias Emergentes para a Monitorização e Previsão do Estado Fisiológico **9**
2.1 Metodologia de Pesquisa . . . 9
2.2 Questões de Pesquisa . . . 10
2.3 Fontes de Literatura Científica . . . 10
2.4 Termos de Pesquisa . . . 11
2.5 Critérios de Inclusão e Exclusão . . . 12
2.6 Diagrama PRISMA . . . 13
2.7 Avaliação de qualidade dos estudos adquiridos . . . 14
2.8 Resultados obtidos . . . 15
2.9 Análise dos resultados . . . 23
2.9.1 Respostas às perguntas de investigação . . . 23
2.9.2 Conclusões . . . 27

3 Métodos e Ferramentas **29**
3.1 Metodologia . . . 29
3.2 Arquitetura da Solução . . . 30
3.3 Ferramentas de Hardware . . . 31
3.3.1 Empatica EmbracePlus . . . 31
3.3.2 Polar H10 . . . 32
3.4 Ferramentas de Software . . . 33
3.4.1 Gestão de Investigação e Escrita . . . 33
3.4.2 Desenvolvimento Técnico e Inteligência Artificial . . . 34
3.4.3 Processamento de Dados e Modelação . . . 34
3.5 Protocolo de Recolha de Dados . . . 34

4 Desenvolvimento e Experimentação **37**

4.1 Preparação e Pré-processamento de Dados . . . 37
4.1.1 Descrição dos Dados Brutos (Raw Data) . . . 37
4.1.2 Tratamento de Dados em Falta e Limpeza de Ruído . . . 40
4.1.3 Engenharia e Seleção de Características . . . 43
4.2 Modelação do Problema e Definição dos Modelos . . . 47
4.2.1 Escolha do Algoritmo . . . 47
4.2.2 Definição de alvos para aprendizagem supervisionada . . . 49
4.2.3 Normalização / Scaling de Features . . . 50
4.2.4 Divisão do Dataset . . . 51
4.3 Definição do Ambiente de Experimentação . . . 52
4.4 Avaliação Experimental . . . 53
4.4.1 Estratégia de Treino dos Modelos . . . 53
4.4.2 Métricas de Avaliação . . . 57
4.4.3 Performance dos Modelos, Comparação e Validação Externa . . . 59
4.5 Análise e Conclusões de Resultados . . . 94

5 Conclusões **101**
5.1 Resposta aos Objetivos de Investigação . . . 101
5.2 Contribuições da Investigação . . . 103
5.3 Limitações Identificadas . . . 104
5.4 Trabalho Futuro . . . 106
5.5 Reflexões Finais . . . 107

Bibliografia **109**

A Avaliação Detalhada dos Estudos Incluídos **117**

B Distribuições Temporais da Validação Externa do Relógio **121**

C Resultados Detalhados da Validação LOSO Polar H10 **127**

D Importância das Características nos Modelos de Classificação **135**

Lista de Figuras

1.1 Pirâmide de Riscos 6

2.1 Diagrama PRISMA 14
2.2 Frequência de utilização de sinais fisiológicos 16
2.3 Frequência de utilização de técnicas de aprendizagem automática e profunda. 18

3.1 Arquitetura da Solução 30

4.1 Sinais fisiológicos de um trabalhador durante uma jornada laboral, recolhidos pela banda Polar H10. 38
4.2 Evolução temporal de variáveis fisiológicas e comportamentais recolhidas pelo Empatica EmbracePlus. 39
4.3 Série temporal da variável PRV-RMSSD, evidenciando os períodos sem valores registados. 42
4.4 Série temporal da variável Respiratory Rate, evidenciando os períodos sem valores registados. 42
4.5 Divisão do conjunto de dados em treino, validação e teste. 51
4.6 Importância das Features na Regressão 61
4.7 Importância das Features na Classificação 63
4.8 Número total de janelas e número de janelas com valores em falta por trabalhador. 67
4.9 Importância relativa das características no XGBoost nos três cenários do estudo de ablação. 72
4.10 Previsões dos modelos para o registo de trabalho no computador com dados do Polar H10. 74
4.11 Previsões dos modelos para o registo de exercício e atividade física com dados do Polar H10. 74
4.12 Curvas do Bayesian Information Criterion (BIC) obtidas para o modelo GMM. 78
4.13 Curvas do cotovelo (Elbow Method) baseadas no WCSS obtidas para o Clustering Hierárquico. 79
4.14 Evolução do coeficiente de Silhouette para diferentes números de clusters (k). 80
4.15 Dendrograma - Dados Originais 81
4.16 Dendrograma - Janelas de 10 minutos 81
4.17 Árvore de Decisão treinada com base no índice de Gini usando os dados ao minuto. 82
4.18 Árvore de Decisão detalhada com critério de Gini usando os dados em janelas de 10 minutos. 82
4.19 Distribuição temporal diária dos clusters do GMM (dados ao minuto) ao longo de uma jornada. 85
4.20 Distribuição temporal diária dos clusters do GMM Restrito ($k = 4$, dados ao minuto) ao longo de uma jornada. 86

4.21 Distribuição temporal diária dos clusters do GMM ($k = 5$, janelas de 10 min) ao longo de uma jornada. 87
4.22 Distribuição temporal diária dos clusters do Clustering Hierárquico ($k = 5$, dados ao minuto) ao longo de uma jornada. 89
4.23 Distribuição temporal diária dos clusters do Clustering Hierárquico ($k = 5$, janelas de 10 min) ao longo de uma jornada. 90
4.24 Distribuição temporal das previsões do GMM ($k = 9$) durante o trabalho em computador. 92
4.25 Distribuição temporal das previsões do GMM ($k = 9$) durante a atividade física. 92
4.26 Distribuição temporal das previsões do GMM ($k = 9$) durante o período de sono. 92

5.1 Apresentação do artigo na conferência INISTA 2026, Guimarães, Portugal, 17 set 2026. 104

B.1 Distribuição temporal das previsões do GMM Restrito com dados originais ($k = 4$) durante as três atividades experimentais. 122
B.2 Distribuição temporal das previsões do GMM com janelas de 10 minutos ($k = 5$) durante as três atividades experimentais. 123
B.3 Distribuição temporal das previsões do Clustering Hierárquico com dados originais ($k = 5$) durante as três atividades experimentais. 124
B.4 Distribuição temporal das previsões do Clustering Hierárquico com janelas de 10 minutos ($k = 5$) durante as três atividades experimentais. 125

C.1.4 Matrizes de confusão do Random Forest por trabalhador de teste. 129
C.2.4 Matrizes de confusão do SVM por trabalhador de teste. 131
C.3.4 Matrizes de confusão da Regressão Logística por trabalhador de teste. . . . 133
C.4.1 Matrizes de confusão do XGBoost por trabalhador de teste. 134

D.2 Importância das características por permutação no SVM nos três cenários do estudo de ablação. 136
D.3 Importância média das características, em valor absoluto dos coeficientes, na Regressão Logística nos três cenários do estudo de ablação. 137
D.4 Importância relativa das características no Random Forest nos três cenários do estudo de ablação. 138

Lista de Tabelas

1.1 Objetivos específicos 3

2.1 Perguntas secundárias 10
2.2 Bases de dados utilizadas na revisão sistemática 11
2.3 Termos de pesquisa por âmbito temático 12
2.4 Critérios de inclusão 13
2.5 Critérios de exclusão 13
2.6 Perguntas de qualidade 15

3.1 Características Físicas e Design do Empatica EmbracePlus 31
3.2 Características Físicas e Design do Polar H10 33

4.1 Completude dos dados antes e depois das janelas de 30 segundos. 41
4.2 Percentagem de valores em falta nas variáveis do Empatica EmbracePlus. . 41
4.3 Limites fisiológicos utilizados para a deteção e tratamento de valores anómalos 43
4.4 Especificações de Hardware da Workstation 52
4.5 Especificações de Software e Bibliotecas 53
4.6 Hiperparâmetros utilizados nos modelos da banda Polar H10 54
4.7 Hiperparâmetros utilizados nos modelos do relógio Empatica EmbracePlus . 57
4.8 Resultados dos Modelos de Regressão 60
4.9 Resultados do XGBoost Classifier nos dois cenários de classificação 62
4.10 Classification Report por Classe do XGBoost Classifier 62
4.11 Matriz de Confusão do XGBoost Classifier nos dois cenários 62
4.12 Desempenho da Regressão Linear treinada com W01 e aplicada a diferentes trabalhadores 64
4.13 Número de janelas disponíveis por trabalhador. 66
4.14 Validação LOSO do modelo XGBoost Classifier. 68
4.15 Médias globais dos modelos de classificação da avaliação LOSO. 68
4.16 Classification Report por Classe do XGBoost na avaliação LOSO. 69
4.17 Matriz de Confusão Agregada dos Dez Folds da avaliação LOSO. 69
4.18 Comparação do desempenho dos modelos nos três cenários do estudo de ablação, com avaliação LOSO. 71
4.19 Conjuntos de dados analisados no novo participante. 73
4.20 Divisão temporal do registo de exercício e atividade física. 73
4.21 Distribuição das classes previstas pelos modelos nas duas condições experimentais. 75
4.22 Concordância das previsões com o contexto nos registos completos PC e EXERCISE. 75
4.23 Concordância das previsões com o contexto nos intervalos de caminhada e trote. 76
4.24 Métricas Estruturais dos Modelos de Clustering 77
4.25 Avaliação da Interpretabilidade através de Árvore de Decisão 81

4.26 Regras de Decisão para a Identificação de Clusters (Dados Originais) . . . 83
4.27 Regras de Decisão para a Identificação de Clusters (Janelas de 10 min) . . 83
4.28 Importância Relativa das Variáveis na Árvore de Decisão (Ordenada) 84
4.29 Assinatura Fisiológica e Sensibilidade dos Clusters para o GMM de Dados Originais ($k = 9$, Dados ao Minuto) 85
4.30 Assinatura Fisiológica dos Clusters para o GMM Restrito ($k = 4$, Dados ao Minuto) 86
4.31 Assinatura Fisiológica dos Clusters para o GMM ($k = 5$, Janelas de 10 min) 87
4.32 Assinatura Fisiológica dos Clusters para o Clustering Hierárquico ($k = 5$, Dados ao Minuto) 88
4.33 Assinatura Fisiológica dos Clusters para o Clustering Hierárquico ($k = 5$, Janelas de 10 min) 89
4.34 Accuracy da validação externa para as diferentes configurações dos modelos. 93

A.1 Avaliação da qualidade dos estudos incluídos (Parte 1) 117
A.2 Avaliação da qualidade dos estudos incluídos (Parte 2) 118
A.3 Avaliação da qualidade dos estudos incluídos (Parte 3) 119
A.4 Avaliação da qualidade dos estudos incluídos (Parte 4) 120

C.1.1 Validação LOSO do modelo Random Forest. 127
C.1.2 Relatório de Classificação por Classe (Classification Report) do modelo Random Forest na avaliação LOSO. 128
C.1.3 Matriz de Confusão Agregada dos Dez Folds do Random Forest na avaliação LOSO. 128
C.2.1 Validação LOSO do modelo SVM. 130
C.2.2 Relatório de Classificação por Classe (Classification Report) do modelo SVM na avaliação LOSO. 130
C.2.3 Matriz de Confusão Agregada dos Dez Folds do SVM na avaliação LOSO. 130
C.3.1 Validação LOSO do modelo de Regressão Logística. 132
C.3.2 Relatório de Classificação por Classe (Classification Report) da Regressão Logística na avaliação LOSO. 132
C.3.3 Matriz de Confusão Agregada dos Dez Folds da Regressão Logística na avaliação LOSO. 132

D.1 Importância das características no XGBoost nos três cenários. 135
D.2 Importância por permutação das características no SVM nos três cenários. 136
D.3 Importância média absoluta dos coeficientes da Regressão Logística nos três cenários. 137
D.4 Importância das características no Random Forest nos três cenários. 138

Lista de Símbolos

Símbolo	Descrição
x	Valor original de uma característica numa janela temporal
z	Valor estandardizado (*z-score*)
μ	Média de uma característica
σ	Desvio padrão de uma característica
μ_{baseline}	Média da característica no período de referência
σ_{baseline}	Desvio padrão da característica no período de referência
$x_{i,f}$	Valor da característica f na janela i
$\mu_{w,f}$	Média da característica f no baseline do trabalhador w
$\sigma_{w,f}$	Desvio padrão da característica f no baseline do trabalhador w
i	Índice da janela temporal
f	Índice da característica fisiológica ou temporal
w	Índice do trabalhador
C	Parâmetro de regularização do SVM e da regressão logística
γ	Coeficiente do kernel do SVM
ϵ	Margem de tolerância do SVR
R^2	Coeficiente de determinação
k	Número de clusters
K	Número de classes
j	Índice da característica avaliada
$\beta_{k,j}$	Coeficiente da característica j na classe k
S	*Balanced accuracy* do modelo
I_j	Importância da característica j

Lista de Acrónimos

ACC	Acelerometria.
AI	Artificial Intelligence (Inteligência Artificial).
ANN	Artificial Neural Network (Rede Neuronal Artificial).
BIC	Bayesian Information Criterion (Critério de Informação Bayesiano).
BIM	Building Information Modeling (Modelação da Informação da Construção).
BLE	Bluetooth Low Energy.
BR	Breathing Rate (Frequência Respiratória).
CBT	Core Body Temperature (Temperatura Corporal Central).
CNN	Convolutional Neural Network (Rede Neuronal Convolucional).
CRIARTE	Construção com Robótica Inteligente e Arquitetura Revolucionária de Tecnologias Emergentes.
CSV	Comma-Separated Values.
DBSCAN	Density-Based Spatial Clustering of Applications with Noise.
DL	Deep Learning (Aprendizagem Profunda).
ECG	Eletrocardiograma.
EDA	Electrodermal Activity (Atividade Eletrodérmica).
EEG	Eletroencefalograma.
EMG	Eletromiografia.
EOG	Eletrooculografia.
FAIR	Findable, Accessible, Interoperable and Reusable.
GECAD	Grupo de Engenharia e Computação Inteligente para a Inovação e o Desenvolvimento.
GMM	Gaussian Mixture Model (Modelo de Mistura Gaussiana).
GNN	Graph Neural Network (Rede Neuronal de Grafos).

GSR	Galvanic Skin Response (Resposta Galvânica da Pele).
HR	Heart Rate (Frequência Cardíaca).
HRV	Heart Rate Variability (Variabilidade da Frequência Cardíaca).
IA	Inteligência Artificial.
IMU	Inertial Measurement Unit (Unidade de Medição Inercial).
IoT	Internet of Things (Internet das Coisas).
IQR	Interquartile Range (Intervalo Interquartil).
ISEP	Instituto Superior de Engenharia do Porto.
KNN	K-Nearest Neighbors (K Vizinhos Mais Próximos).
LOSO	Leave-One-Subject-Out.
LSTM	Long Short-Term Memory.
MET	Metabolic Equivalent of Task (Equivalente Metabólico de Tarefa).
ML	Machine Learning (Aprendizagem Automática).
NN	Neural Network (Rede Neuronal).
PCA	Principal Component Analysis (Análise de Componentes Principais).
PGF	Portable Graphics Format.
pNN50	Percentagem de intervalos NN com diferença superior a 50 ms.
PPG	Photoplethysmography (Fotopletismografia).
PRISMA	Preferred Reporting Items for Systematic Reviews and Meta-Analyses.
PRV	Pulse Rate Variability (Variabilidade do Ritmo de Pulso).
RGPD	Regulamento Geral sobre a Proteção de Dados.
RNN	Recurrent Neural Network (Rede Neuronal Recorrente).
RR	R-R Interval (Intervalo entre batimentos R-R).
SDNN	Standard Deviation of NN intervals (Desvio Padrão dos Intervalos NN).
sEMG	Surface Electromyography (Eletromiografia de Superfície).
SVC	Support Vector Classification.

SVM	Support Vector Machine (Máquina de Vetores de Suporte).
SVR	Support Vector Regression.
TS	Time Series (Série Temporal).
VR	Virtual Reality (Realidade Virtual).

Capítulo 1

Introdução

1.1 Contextualização

Nos últimos anos, a crescente complexidade dos ambientes laborais, especialmente em setores de alto risco como a indústria, a construção, a energia ou os serviços de emergência, tem aumentado a necessidade de soluções tecnológicas orientadas para a segurança e o bem-estar dos trabalhadores. Nestes contextos, fatores como a fadiga, o stress, a sobrecarga fisiológica e a diminuição da atenção têm um impacto direto no desempenho humano e estão estreitamente relacionados com a ocorrência de acidentes laborais e erros críticos. Neste quadro, o projeto insere-se na **Indústria 5.0**, que representa a evolução da Indústria 4.0 para sistemas mais inteligentes, centrados na cooperação entre humanos e máquinas.

> "A Indústria 5.0 foi proposta para alcançar uma indústria centrada no ser humano, sustentável e resiliente. O enfoque centrado no ser humano coloca os requisitos, preferências e interesses dos trabalhadores no centro do processo de fabrico, passando de um paradigma impulsionado pela tecnologia para um centrado no ser humano e na sociedade."Leng 2024 [39].

A Indústria 5.0 caracteriza-se pela integração de modelos multimodais e o uso de sensores avançados que recolhem dados fisiológicos, de **dispositivos portáteis** e do ambiente, com o objetivo de oferecer uma previsão cada vez mais precisa e próxima do estado do trabalhador, potenciando a segurança, a eficiência e o bem-estar laboral. Este enfoque procura melhorar a relação humano-máquina, permitindo que as tecnologias não só automatizem processos, mas também colaborem ativamente com os trabalhadores e adaptem o seu funcionamento às suas necessidades e capacidades.

Paralelamente, o avanço dos dispositivos portáteis e sensores biométricos tem permitido a monitorização contínua e não invasiva de variáveis fisiológicas em tempo real. Dispositivos como relógios inteligentes e bandas torácicas possibilitam a aquisição de sinais como a frequência cardíaca, a respiração e a atividade eletrodérmica, gerando grandes volumes de dados durante a jornada laboral. Estes dados constituem uma fonte de informação valiosa para inferir o estado interno do trabalhador e detetar situações de risco antes de se materializarem em incidentes.

Neste contexto, os conceitos de **gémeos digitais humanos** adquirem uma relevância crescente.

> "O gémeo digital é uma tecnologia que cria uma réplica digital de uma entidade física mediante o uso de dados em tempo real e modelos computacionais,

> permitindo que os objetos físicos alcancem maiores níveis de inteligência, automatização e gestão otimizada graças à integração de tecnologias como a Internet das Coisas e a inteligência artificial"Lin et al. 2024 [40].

Um gémeo digital humano permite modelar de forma dinâmica o estado fisiológico de uma pessoa, integrando dados em tempo real com modelos computacionais capazes de interpretar e antecipar a sua evolução. Neste cenário, a **inteligência artificial** desempenha um papel central, ao facilitar a análise de séries temporais complexas e a extração de padrões não triviais para a deteção e previsão de estados como o stress, a fadiga ou a carga de trabalho.

Neste enquadramento, a presente dissertação insere-se no âmbito do projeto CRIARTE (Construção com Robótica Inteligente e Arquitetura Revolucionária de Tecnologias Emergentes), que visa transformar o setor da construção através da integração de robótica, inteligência artificial e gémeos digitais, promovendo a colaboração segura entre trabalhadores humanos e sistemas autónomos. Em particular, esta dissertação foca-se no eixo do projeto relacionado com a monitorização da saúde e segurança dos trabalhadores, explorando a utilização de dados fisiológicos recolhidos por dispositivos portáteis para a análise e predição de estados associados ao cansaço, stress e fadiga, com vista ao apoio à prevenção de situações potencialmente perigosas em contexto real de obra.

Em resumo, a evolução para ambientes laborais cada vez mais complexos e centrados no ser humano evidencia a necessidade de soluções que permitam monitorizar e interpretar de forma contínua o estado fisiológico dos trabalhadores. A integração de sensores portáteis e modelos de inteligência artificial possibilita antecipar situações de risco e contribuir para a melhoria da segurança e do bem-estar laboral. Neste contexto, os gémeos digitais humanos surgem como uma abordagem integradora para apoiar a prevenção de riscos e a tomada de decisão em cenários laborais complexos.

1.2 Descrição do Problema

Em ambientes laborais de alto risco (como a construção, a indústria pesada ou os serviços de emergência), o desempenho e a segurança do trabalhador dependem da sua capacidade para manter níveis adequados de energia, atenção e bem-estar físico. O próprio trabalhador muitas vezes não percebe com clareza o seu estado físico (por exemplo, fadiga, stress ou sobrecarga), o que aumenta o risco de acidentes, erros críticos e diminuição do rendimento. Esta situação é especialmente relevante quando o trabalhador interage com outros ativos na obra (outras pessoas, robôs e maquinaria), onde um erro individual pode ter consequências catastróficas, podendo levar mesmo à morte do trabalhador.

Sistemas de monitorização que se centram principalmente em métricas isoladas ou em indicadores estáticos podem ser insuficientes para refletir a complexidade do estado fisiológico do trabalhador e antecipar situações de risco. A variabilidade dos sinais fisiológicos, a influência de fatores externos e as mudanças dinâmicas próprias do ambiente de trabalho fazem com que seja necessário contar com abordagens mais integradas e sofisticadas para a sua análise.

Neste contexto, surge a necessidade de desenvolver modelos computacionais capazes de analisar múltiplos sinais fisiológicos de maneira conjunta ao longo do tempo, assim como sistemas mais avançados, como um gémeo digital humano, que permitam inferir de maneira robusta o estado do trabalhador e apoiar a prevenção de riscos.

O problema central abordado nesta tese consiste em determinar em que medida os modelos de **aprendizagem automática e aprendizagem profunda** podem ser utilizados para prever estados fisiológicos de trabalhadores em ambientes de alto risco a partir de dados reais obtidos mediante sensores portáteis. Este problema inclui desafios como a seleção e o pré-processamento dos sinais fisiológicos, a segmentação temporal adequada, a escolha de arquiteturas de modelação apropriadas e a avaliação do desempenho dos modelos em cenários próximos da aplicação real. Resolver estes aspetos é essencial para permitir a integração de um módulo preditivo num sistema de gémeo digital humano que contribua de forma efetiva para a prevenção de riscos laborais e para o apoio à tomada de decisões em tempo real.

1.3 Objetivos

Os objetivos desta dissertação são definidos a partir da necessidade de desenvolver uma abordagem capaz de transformar dados fisiológicos recolhidos através de sensores portáteis em informação útil para a monitorização do estado fisiológico e cognitivo de trabalhadores em ambientes laborais de alto risco. Para tal, o trabalho considera de forma integrada as diferentes etapas envolvidas neste processo, desde a caracterização e preparação dos dados até ao desenvolvimento, avaliação e seleção de modelos preditivos, tendo em consideração os requisitos de funcionamento em cenários próximos de tempo real e a sua eventual integração num gémeo digital humano.

Objetivo geral

O objetivo principal desta tese é desenvolver e avaliar modelos de aprendizagem automática e aprendizagem profunda capazes de prever o estado fisiológico e cognitivo de trabalhadores em ambientes laborais de alto risco, a partir de dados fisiológicos obtidos mediante sensores portáteis, com o fim de contribuir para a segurança e o bem-estar do trabalhador no contexto de um **gémeo digital humano**.

Objetivos específicos

Para alcançar o objetivo geral, definem-se os seguintes objetivos específicos. Estes são apresentados na Tabela 1.1, estruturados através de uma abordagem sequencial que associa cada etapa do processo de investigação a uma questão fundamental. Esta organização permite alinhar as necessidades técnicas do projeto (perguntas-chave) com as ações científicas necessárias para a sua resolução (objetivos específicos), garantindo a rastreabilidade e a progressão lógica do trabalho, desde a análise de dados até à integração final no sistema de gémeo digital.

Tabela 1.1: Objetivos específicos

perguntas-chave	**objetivos específicos**
Que dados tenho?	Analisar e caracterizar os dados fisiológicos recolhidos em ambientes laborais reais, identificando os sinais relevantes e os seus principais padrões temporais.
Como os preparo?	Desenhar e aplicar técnicas de pré-processamento para sinais fisiológicos, incluindo normalização, filtragem, segmentação temporal e extração de características.

perguntas-chave	objetivos específicos
Que abordagens de modelação exploro?	Explorar diferentes abordagens de modelação para a previsão do estado fisiológico, abrangendo tanto métodos de aprendizagem automática clássica como abordagens de aprendizagem profunda.
Como se comportam essas abordagens?	Avaliar e comparar as abordagens de modelação consideradas mediante métricas adequadas, analisando a sua capacidade de generalização e a sua viabilidade em cenários próximos a tempo real.
Qual é viável em tempo real?	Selecionar o modelo ou abordagem mais adequada em função dos resultados obtidos e dos requisitos computacionais do sistema.
Como o integro no sistema final?	Integrar o modelo preditivo selecionado como um módulo dentro de um sistema de gémeo digital humano, orientado para a monitorização contínua e para a geração de alertas automáticos em contextos laborais de alto risco.

Discussão e Organização dos Objetivos

Os objetivos estão organizados para responder a um desafio central: transformar dados fisiológicos gerais em informação útil para acompanhar o estado de cada trabalhador. Para isso, é necessário começar por compreender os dados disponíveis e preparar uma representação adequada, antes de explorar diferentes abordagens de modelação e avaliar a sua capacidade de generalização e a sua compatibilidade com as limitações de uma aplicação próxima do tempo real.

Esta organização reflete, assim, uma sequência metodológica na qual cada etapa fornece a base para a etapa seguinte. A caracterização dos dados permite compreender as suas principais características e limitações; o pré-processamento procura obter uma representação adequada dos sinais; a exploração de diferentes modelos permite analisar diferentes estratégias de previsão; e a avaliação permite determinar não apenas o desempenho preditivo, mas também a sua viabilidade num contexto de utilização contínua. Por fim, a integração no gémeo digital humano procura transformar o modelo desenvolvido num componente funcional de um sistema orientado para a monitorização do trabalhador.

Para além destas etapas, existe uma dificuldade que não é resolvida apenas através da escolha do modelo: o problema de *cold start*, isto é, a dificuldade de produzir previsões úteis quando ainda existem poucos ou nenhuns dados sobre um novo utilizador [60]. Quando um novo trabalhador começa a utilizar o sistema, a ausência de dados individuais limita a capacidade de caracterizar o seu perfil fisiológico e de produzir previsões personalizadas. Este problema é particularmente relevante num contexto de monitorização contínua, no qual a informação disponível sobre cada trabalhador aumenta progressivamente ao longo do tempo.

Esta questão evidencia que a integração de um modelo preditivo num gémeo digital humano não corresponde apenas à incorporação de um algoritmo de previsão. É também necessário considerar como o sistema inicializa e atualiza o perfil fisiológico individual, como incorpora novos dados e como mantém as previsões ao longo do tempo. Assim, o desenvolvimento dos modelos e a sua integração no sistema devem ser entendidos como partes de um processo contínuo de adaptação às características de cada trabalhador.

Deste modo, os objetivos específicos estabelecem uma cadeia que parte da compreensão dos dados e conduz progressivamente à sua utilização num contexto de aplicação: **caracterizar, preparar, modelar, avaliar, analisar a viabilidade e integrar**.

1.4 Ética e Implicações Sociais na Monitorização Humana

A ética no desenvolvimento de tecnologias de monitorização humana vai além do simples funcionamento técnico e relaciona-se diretamente com a responsabilidade para com as pessoas. Ao propor sistemas capazes de recolher sinais biológicos em tempo real, como o ritmo cardíaco ou a temperatura corporal, entra-se num domínio sensível que exige uma base ética sólida. O objetivo principal não deve ser apenas melhorar a eficiência do sistema, mas também proteger o bem-estar do trabalhador e respeitar plenamente a sua dignidade e autonomia.

No contexto industrial e, em particular, na construção civil, a introdução destas tecnologias levanta dúvidas sobre a relação entre a empresa e o trabalhador. Existe o risco de que ferramentas concebidas para melhorar a segurança acabem por ser percecionadas como mecanismos de vigilância ou controlo do desempenho. Esta perceção pode gerar rejeição e desconfiança, dificultando a aceitação do sistema. Por isso, é fundamental que a recolha de dados fisiológicos se limite exclusivamente à proteção da saúde e da segurança, deixando claro que o trabalhador não é um conjunto de números, mas uma pessoa com direito à privacidade.

Outra questão social relevante está relacionada com a equidade e a inclusão. Estas soluções tecnológicas devem ser desenhadas de forma a não excluir determinados trabalhadores, seja por falta de competências digitais ou por diferenças fisiológicas naturais. Um sistema ético deve ser capaz de se adaptar à diversidade humana sem penalizar aqueles que se afastam dos valores considerados "normais". Além disso, explicar de forma clara que dados são recolhidos, como são utilizados e quem tem acesso à informação é fundamental para gerar confiança entre todos os envolvidos.

Por fim, a cibersegurança e a proteção da informação são aspetos essenciais do ponto de vista ético. Os dados biológicos são particularmente sensíveis e a sua utilização indevida pode ter consequências graves na vida pessoal e profissional dos trabalhadores. Por esta razão, a ética deve orientar o desenho do sistema desde o início, assegurando que a tecnologia atue como um apoio discreto, mas eficaz, sempre orientado para a proteção da segurança física e dos dados pessoais, acima de qualquer interesse técnico ou económico.

1.4.1 Enquadramento Legal

Como já foi referido, a necessidade de regulamentar a Inteligência Artificial é crucial, e o Regulamento da Inteligência Artificial da União Europeia (IA Act) [50] representa um marco histórico neste domínio. Este regulamento tem como objetivo impor requisitos e obrigações rigorosos aos fornecedores e desenvolvedores de tecnologias baseadas em IA, garantindo que os sistemas sejam seguros, éticos e fiáveis para os cidadãos europeus. Para tal, o IA Act classifica as utilizações da IA em quatro níveis de risco, tal como ilustrado na Figura 1.1:



Figura 1.1: Pirâmide de Riscos

Como se observa na pirâmide de risco, o IA Act organiza os diferentes usos da inteligência artificial de acordo com o nível de risco que podem representar. No topo encontram-se as aplicações de Risco Inaceitável, como a classificação social ou a análise de emoções no local de trabalho, que são proibidas por violarem direitos fundamentais. Abaixo situam-se os sistemas de Alto Risco, que incluem tecnologias críticas para a saúde, as infraestruturas e a gestão de trabalhadores. Seguem-se as aplicações de Risco Limitado, que exigem transparência, como os chatbots ou os conteúdos gerados por IA. Na base encontram-se as aplicações de Risco Mínimo, como os filtros de spam ou os videojogos, que podem ser utilizadas com menos restrições. O regulamento entrou em vigor a 1 de agosto de 2024 [20], estabelecendo prazos faseados para a sua aplicação, o que permite às organizações uma adoção responsável e estruturada. O IA Act é o primeiro ato legislativo do mundo focado especificamente na Inteligência Artificial, servindo como referência global, tal como aconteceu com o Regulamento Geral sobre a Proteção de Dados (RGPD) [49].

O RGPD define normas rigorosas sobre a recolha, o armazenamento e o tratamento de dados pessoais, garantindo a privacidade dos utilizadores. Ao contrário do IA Act, que se centra na lógica do algoritmo, o RGPD refere-se ao tratamento dos dados de todos os residentes na União Europeia, independentemente da localização da organização que utiliza essa informação. No contexto de tecnologias que recorrem a sinais biológicos, o RGPD é particularmente exigente, classificando os dados relativos à saúde como categorias especiais que requerem uma proteção reforçada.

Embora o IA Act e o RGPD demonstrem a preocupação da União Europeia em equilibrar o avanço tecnológico com os direitos das pessoas, estes regulamentos representam apenas um primeiro passo. No setor da construção e da segurança no trabalho, onde os riscos físicos e os acidentes podem ter consequências graves, torna-se necessário dispor de normas claras que permitam desenvolver e utilizar ferramentas inovadoras, como os Gémeos Digitais, sem comprometer a privacidade dos trabalhadores nem os princípios éticos no contexto laboral.

1.4.2 Análise Ética e Regulamentar da Solução de Gémeo Digital Humano

A solução proposta nesta dissertação, centrada na monitorização de sinais vitais para a segurança laboral na construção civil, insere-se num ecossistema regulamentar complexo que exige uma análise detalhada. O IA Act, descrito na secção anterior, classifica as aplicações de Inteligência Artificial em função do nível de risco, enquadrando o sistema desenvolvido na categoria de **Alto Risco**. Esta classificação deve-se ao impacto direto da tecnologia na saúde e segurança dos trabalhadores, bem como à sua utilização no contexto da gestão de recursos humanos.

Ao monitorizar a integridade física em ambientes de alto risco, onde a precisão na deteção de fadiga extrema ou stress é vital, a fiabilidade do sistema torna-se o pilar central da solução. Qualquer falha na análise dos dados fisiológicos poderia ter consequências graves para a vida do trabalhador, o que justifica a exigência de padrões rigorosos de segurança, robustez técnica e cibersegurança. Para cumprir os requisitos de alto risco, o design do Gémeo Digital garante a **supervisão humana** constante por parte do coordenador de segurança ou do próprio utilizador, assegurando que a tecnologia funcione como um suporte à decisão e nunca de forma autónoma.

Para assegurar a conformidade com o IA Act, destacam-se cinco requisitos de alto risco que são fundamentais e deveriam formar as bases do design da solução: a gestão de riscos (Art.º 9.º) e a governação de dados (Art.º 10.º) para garantir a fiabilidade técnica; a transparência (Art.º 13.º) e a supervisão humana (Art.º 14.º) para permitir o controlo total do utilizador sobre os alertas; e a precisão e cibersegurança (Art.º 15.º) para proteger a integridade da monitorização fisiológica contra falhas ou acessos indevidos.Tendo estes fatores em conta, a solução apresentada procura cumprir todas as regulamentações em vigor e mitigar os desafios éticos associados.

Relativamente ao RGPD, embora o sistema processe dados biométricos, como o ritmo cardíaco e a temperatura corporal, que pertencem a categorias especiais de dados, o seu design é orientado pelos princípios de privacy by design (a privacidade é integrada desde o início no design do sistema) e minimização de dados (só são recolhidos os dados estritamente necessários). A recolha de informação tem como único objetivo a proteção da vida, garantindo que os dados não sejam utilizados para fins de vigilância intrusiva. No que respeita ao IA Act, a solução afasta-se claramente de práticas classificadas como de Risco Inaceitável, como a inferência de emoções com fins punitivos, mantendo um enfoque estritamente preventivo e fisiológico.

Com supervisão humana e cumprindo os padrões exigidos, esta solução de Gémeo Digital pretende ser um apoio essencial para as equipas de segurança no trabalho. O seu objetivo é criar um ambiente de construção mais seguro e eficiente, combinando a inovação tecnológica com a responsabilidade ética e o respeito total pelos direitos dos trabalhadores.

1.5 Estrutura do Documento

O presente documento está estruturado de forma lógica e sequencial para facilitar a compreensão do problema abordado, da metodologia utilizada e dos resultados obtidos. De seguida, descreve-se brevemente o conteúdo de cada capítulo.

O **Capítulo 1**, Introdução, fornece o contexto geral da investigação em ambientes laborais de alto risco e a descrição do problema central. São apresentados os objetivos gerais e

específicos, que incluem o desenvolvimento de modelos preditivos e a avaliação de tecnologias emergentes. Adicionalmente, este capítulo aborda as considerações éticas e legais fundamentais no tratamento de dados e no uso de Inteligência Artificial (IA), finalizando com a descrição da estrutura do documento.

O **Capítulo 2**, Revisão Sistemática da Literatura, apresenta a metodologia PRISMA utilizada para realizar uma revisão sistemática da literatura sobre tecnologias emergentes para a monitorização fisiológica e previsão de estados humanos em contextos laborais, incluindo as questões de pesquisa e os resultados obtidos.

O **Capítulo 3**, Métodos e Ferramentas, explica a abordagem metodológica e os componentes técnicos do sistema. Apresenta a arquitetura do Gémeo Digital Humano, detalhando ferramentas de hardware e software, algoritmos de IA, e o ambiente experimental para recolha e tratamento de dados fisiológicos no contexto laboral.

O **Capítulo 4**, Desenvolvimento e Experimentação, descreve o processo de desenvolvimento técnico e a metodologia experimental para converter dados fisiológicos brutos em indicadores inteligentes do estado humano. Aborda a aquisição, pré-processamento e engenharia de características dos dados, bem como a arquitetura e avaliação dos modelos de aprendizagem automática para classificação de estados dos trabalhadores e suporte à tomada de decisões em tempo real no Gémeo Digital Humano.

O **Capítulo 5**, Conclusões, sintetiza os principais resultados da investigação e avalia o grau de concretização dos objetivos definidos. Apresenta as contribuições do trabalho, as limitações identificadas e as possibilidades de desenvolvimento futuro, com especial atenção à integração dos modelos num sistema de gémeo digital humano e à sua validação em contextos laborais reais.

Capítulo 2

Tecnologias Emergentes para a Monitorização e Previsão do Estado Fisiológico

2.1 Metodologia de Pesquisa

A presente revisão sistemática foi concebida com o objetivo de identificar e analisar a literatura científica mais relevante sobre tecnologias emergentes para a monitorização fisiológica, focando-se na previsão de estados humanos mediante técnicas de inteligência artificial e aprendizagem automática.

Para garantir o rigor e a reprodutibilidade do estudo, foi adotada a **metodologia PRISMA** (Preferred Reporting Items for Systematic Reviews and Meta-Analyses), que fornece um quadro estruturado para o planeamento, a execução e a apresentação de revisões sistemáticas. Esta abordagem permite documentar de forma transparente o processo de pesquisa, seleção, extração e síntese da informação, assegurando que os resultados obtidos sejam objetivos e comparáveis. Esta opção metodológica é igualmente adotada em revisões recentes, como a de Ribeiro, R., Martinho, D. et al. [55], sobre a utilização de dispositivos vestíveis na monitorização remota da saúde.

A revisão tem um alcance temporal dos últimos cinco anos (2020–2025), considerando estudos que apresentam aplicações reais ou experimentais de monitorização fisiológica mediante sensores portáteis e modelos preditivos. A análise centra-se em identificar tendências, técnicas e aplicações práticas relevantes, bem como desafios e limitações reportados na literatura.

A abordagem metodológica adotada inclui as seguintes fases principais: definição de perguntas principais e secundárias de investigação, identificação de fontes de informação e bases de dados académicas pertinentes, construção de estratégias de pesquisa, seleção de estudos relevantes segundo critérios de inclusão e exclusão pré-definidos, extração sistemática de dados e síntese de resultados. Este processo estruturado garante que a revisão proporcione um estado da arte sólido e fundamentado, que servirá como base para a posterior discussão e desenvolvimento do sistema de previsão do estado fisiológico no contexto do gémeo digital humano.

Cabe destacar que a metodologia e os resultados desta revisão sistemática foram também consolidados num artigo científico intitulado "*A Review of Physiological Monitoring and Prediction in Workers in High-Risk Construction Environments*" [23]. O artigo foi aceite e apresentado na conferência INISTA 2026 [29], constituindo um resultado de disseminação científica do processo de revisão da literatura apresentado neste capítulo.

2.2 Questões de Pesquisa

A presente revisão sistemática tem como objetivo analisar o estado da arte em tecnologias e modelos de inteligência artificial aplicados à monitorização fisiológica, com especial ênfase na interpretação e previsão do estado humano em ambientes de alto risco. Para orientar o processo de pesquisa e análise da literatura, foram definidas as seguintes questões de investigação.

Pergunta principal

QP1: Que tecnologias e modelos de inteligência artificial são atualmente empregues para a monitorização, interpretação e previsão do estado fisiológico de trabalhadores ou indivíduos em ambientes de alto risco, a partir de dados obtidos mediante sensores portáteis?

Perguntas secundárias

Tabela 2.1: Perguntas secundárias

ID	Pergunta
QS1	Que tipos de sinais fisiológicos são habitualmente recolhidos e utilizados na literatura para a monitorização do estado humano (HR, HRV, respiração, EEG, etc.)?
QS2	Que técnicas de aprendizagem automática e aprendizagem profunda são aplicadas com maior frequência para a análise e a previsão de estados como stress, fadiga, carga fisiológica ou nível de atenção?
QS3	Que arquiteturas e modelos são utilizados para a análise de séries temporais fisiológicas e quais são as suas principais vantagens e limitações?
QS4	Quais são as métricas de avaliação mais utilizadas para validar o desempenho dos modelos propostos em estudos de monitorização fisiológica?
QS5	Que limitações e desafios são identificados na literatura para a implementação de sistemas de previsão do estado humano em tempo real?
QS6	Que mecanismos de comunicação, notificação ou retroalimentação ao utilizador são descritos na literatura?

2.3 Fontes de Literatura Científica

Com o objetivo de garantir uma revisão sistemática completa e representativa do estado atual da investigação, foram selecionadas três bases de dados académicas amplamente reconhecidas pela sua relevância nas áreas de inteligência artificial, engenharia biomédica e ciências da saúde. Estas bases de dados permitem aceder a literatura científica revista por pares e de alto impacto, alinhada com os objetivos desta tese.

Tabela 2.2: Bases de dados utilizadas na revisão sistemática

ID	Database	URL
D1	PubMed	`https://pubmed.ncbi.nlm.nih.gov`
D2	IEEE Xplore	`https://ieeexplore.ieee.org`
D3	ScienceDirect	`https://www.sciencedirect.com`
D4	MDPI	`https://www.mdpi.com`

O PubMed foi selecionado pela sua especialização em ciências da saúde e medicina, proporcionando acesso a estudos relacionados com a monitorização fisiológica, bio-sinais e aplicações de sensores portáteis para a avaliação do estado humano. Esta base de dados é especialmente relevante para compreender o contexto fisiológico e biomédico dos sinais analisados.

O IEEE Xplore foi incluído devido ao seu forte enfoque em engenharia, informática e tecnologias emergentes. Esta base de dados oferece uma ampla coleção de trabalhos sobre inteligência artificial, aprendizagem automática, processamento de sinais e sistemas de monitorização em tempo real, aspetos chave para o desenvolvimento de modelos preditivos baseados em dados fisiológicos.

O ScienceDirect foi considerado pela sua cobertura em engenharia biomédica, saúde digital e análise de sinais, incluindo revistas de alto impacto relacionadas com sensores, dispositivos portáteis e aplicações de inteligência artificial em contextos de monitorização fisiológica.

O MDPI (Multidisciplinary Digital Publishing Institute), uma editora académica de acesso aberto, foi incluído como fonte complementar devido à relevância das suas revistas nas áreas de inteligência artificial, engenharia biomédica, sensores e análise de sinais fisiológicos. A pesquisa nesta plataforma permitiu identificar estudos recentes sobre técnicas de clustering e aprendizagem automática aplicadas à monitorização fisiológica.

A combinação destas fontes de literatura garante um equilíbrio adequado entre literatura técnica e biomédica, contribuindo para uma revisão sistemática robusta e alinhada com o alcance da presente investigação.

2.4 Termos de Pesquisa

Os termos de pesquisa foram definidos a partir das questões de investigação colocadas, com o objetivo de identificar estudos relevantes relacionados com a monitorização fisiológica baseada em sensores portáteis e o uso de técnicas de inteligência artificial para a interpretação e previsão do estado humano. Para garantir uma pesquisa estruturada e reprodutível, os termos foram organizados em diferentes *âmbitos* temáticos que refletem os principais eixos desta revisão sistemática: sinais fisiológicos, tecnologias de sensorização, técnicas de inteligência artificial e contexto de aplicação.

Tabela 2.3: Termos de pesquisa por âmbito temático

Âmbito	**Cadeia de pesquisa**
Sinais Fisiológicos e Cognitivos	("physiological signals"OR "heart rate"OR "HRV"OR "respiration"OR "EEG")
Sensores Portáteis	("wearable sensors"OR "wearable devices"OR "smartwatch"OR "chest strap"OR "physiological monitoring")
Técnicas de Inteligência Artificial	("AI"OR "artificial intelligence"OR "machine learning"OR "deep learning"OR "neural networks"OR "time series analysis"OR "digital twin"OR "clustering")
Previsão do Estado Humano	("stress"OR "fatigue"OR "attention"OR "human state")
Notificações e Alertas	("alerts"OR "warnings"OR "notifications"OR "feedback")
Contextos de Alto Risco	("worker safety"OR "human safety"OR "workplace monitoring"OR "industrial environments")

A combinação destes âmbitos permitiu construir cadeias de pesquisa adaptadas a cada base de dados, maximizando a cobertura de estudos relevantes e reduzindo a inclusão de trabalhos fora do alcance da investigação.

- O âmbito relacionado com **sinais fisiológicos** foi incluído para capturar os distintos tipos de variáveis biométricas empregues na monitorização do estado humano.
- O âmbito dos **sensores portáteis** permitiu identificar estudos baseados em dispositivos de aquisição de dados em contextos reais e não invasivos.
- O âmbito das **técnicas de inteligência artificial** foi definido para abranger tanto abordagens clássicas como métodos avançados de aprendizagem profunda aplicados à análise de dados fisiológicos.
- O âmbito da **previsão do estado humano** centrou-se nos objetivos finais dos sistemas analisados, como a deteção de stress, fadiga ou carga cognitiva.
- O âmbito das **notificações e alertas** foi incorporado para identificar como os sistemas comunicam a informação gerada ao utilizador final.
- Finalmente, o âmbito relativo a **contextos de alto risco** permitiu contextualizar os estudos em cenários onde a monitorização em tempo real tem um impacto direto na segurança e no desempenho humano.

2.5 Critérios de Inclusão e Exclusão

Os critérios de inclusão e exclusão foram definidos com o objetivo de garantir a seleção de estudos relevantes, coerentes com as questões de investigação e o alcance desta revisão sistemática. Estes critérios permitiram filtrar trabalhos que abordam a monitorização fisiológica mediante sensores portáteis e a aplicação de técnicas de inteligência artificial para a interpretação e previsão do estado humano, excluindo estudos fora deste contexto.

Foram incluídos estudos que cumprissem pelo menos um dos seguintes critérios:

Tabela 2.4: Critérios de inclusão

ID	Critério de Inclusão
IC1	Estudos que utilizem sinais fisiológicos adquiridos mediante sensores portáteis ou dispositivos.
IC2	Trabalhos que apliquem técnicas de IA de aprendizagem automática ou aprendizagem profunda para a interpretação, classificação ou previsão do estado humano.
IC3	Estudos orientados à monitorização de estados fisiológicos, como stress, fadiga, carga fisiológica ou nível de atenção.
IC4	Investigações aplicadas a ambientes laborais, industriais, de alto risco ou contextos comparáveis com monitorização contínua.
IC5	Estudos que descrevam ou implementem mecanismos de comunicação, interface ou sistemas de notificação e alertas para o utilizador final.

Foram excluídos estudos que cumprissem algum dos seguintes critérios:

Tabela 2.5: Critérios de exclusão

ID	Critério de exclusão
EC1	Publicações não redigidas em inglês.
EC2	Estudos publicados antes do ano 2020.
EC3	Publicações que não tenham sido revistas por pares, incluindo artigos de opinião, resumos, pósteres, patentes ou livros.
EC4	Estudos duplicados.
EC5	Estudos que não utilizem dados fisiológicos reais ou que se baseiem exclusivamente em dados simulados sem validação.
EC6	Trabalhos centrados unicamente no design de hardware ou sensores, sem análise do estado fisiológico mediante modelos de IA.

2.6 Diagrama PRISMA

O processo de seleção de estudos foi realizado seguindo as diretrizes do modelo PRISMA (Preferred Reporting Items for Systematic Reviews and Meta-Analyses), com o objetivo de garantir transparência, reprodutibilidade e rigor metodológico na revisão sistemática.

Na fase de **identificação**, foram localizados os estudos potencialmente relevantes mediante as cadeias de pesquisa definidas nas bases de dados selecionadas. No total, foram localizados 128 registos através das pesquisas no Science Direct (n = 57), IEEE Xplore (n = 59), PubMed (n = 8) e MDPI (n = 4). Posteriormente, foram eliminados os duplicados, confirmando que todos os registos eram únicos (n = 128).

Durante a fase de **crivo**, foram avaliados os títulos e resumos dos estudos, resultando na exclusão de 64 registos que não eram relevantes ou não estavam alinhados com o tema de investigação.

Na fase de **elegibilidade**, foram analisados os textos completos de 64 artigos para determinar a sua adequação ao alcance da revisão. Após a aplicação de critérios específicos (EC1, EC2, EC3, EC4, EC5, EC6, IC1, IC2, IC3, IC4, IC5), foram excluídos 23 estudos que não cumpriam os critérios estabelecidos.

Finalmente, a fase de **inclusão** contemplou 41 estudos que cumpriram todos os critérios de seleção e foram incorporados à análise qualitativa dos resultados.

O diagrama PRISMA que acompanha esta secção (2.1) ilustra de forma estruturada cada uma destas fases, apresentando claramente o fluxo de identificação, triagem, elegibilidade e inclusão dos estudos.

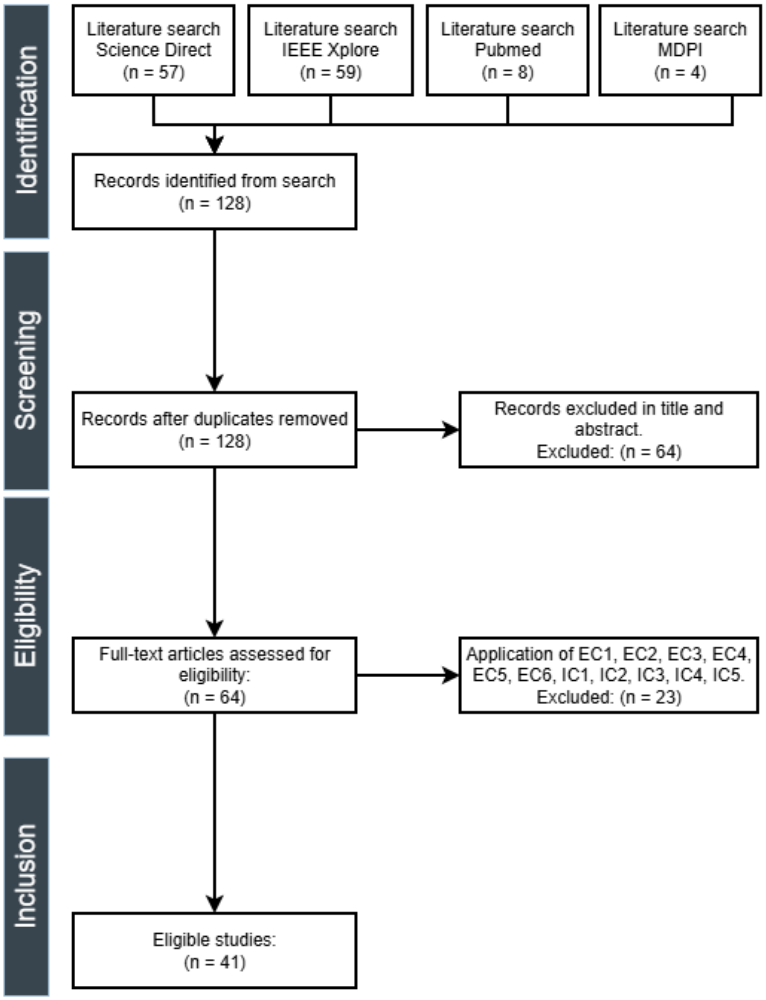


Figura 2.1: Diagrama PRISMA

2.7 Avaliação de qualidade dos estudos adquiridos

Para complementar a revisão sistemática, foi elaborada uma tabela de avaliação (Tabela 2.6) com o objetivo de priorizar os estudos mais relevantes para os objetivos desta tese. Esta etapa assume particular importância visto que, dada a natureza multidisciplinar do tema, é pouco frequente que um único estudo aborde simultaneamente todas as dimensões da

presente investigação (sensores portáteis, dados fisiológicos, modelos de IA, contextos de risco e mecanismos de alerta).

Desta forma, o processo de avaliação de qualidade surge como uma ferramenta metodológica necessária para destacar os trabalhos que melhor se enquadram no âmbito desta revisão, que se centra no desenvolvimento de um módulo preditivo baseado em gémeos digitais humanos para a previsão de estados fisiológicos em trabalhadores da construção. Cada estudo foi pontuado segundo quatro critérios chave: cada resposta afirmativa recebia um ponto, enquanto que as negativas não pontuavam, atribuindo-se 0.5 em casos intermédios ou parciais. Este ranking permitiu identificar os estudos com maior afinidade técnica, orientando a seleção de estratégias e arquiteturas a implementar no sistema final.

Tabela 2.6: Perguntas de qualidade

QA	Pergunta	Pontuação
QA1	O estudo utiliza sinais fisiológicos adquiridos mediante sensores portáteis ou dispositivos.	Sim (+1); Não (0)
QA2	Aplicam-se técnicas de IA de ML ou DL para interpretação, classificação ou previsão.	Sim (+1); Não (0)
QA3	O estudo monitoriza ou prevê estados fisiológicos como stress, fadiga, carga fisiológica ou atenção.	Sim (+1); Não (0)
QA4	A investigação aplica-se a ambientes de obra, ou ambientes de alto risco ou comparáveis.	Sim (+1); Não (0)

Com o objetivo de estabelecer uma base sólida para a entrega preliminar do presente trabalho, a exploração dos resultados e a resposta às perguntas de investigação centram-se especificamente no subconjunto de 14 artigos científicos que obtiveram a classificação máxima de 4 valores. Estes estudos foram selecionados como o núcleo central desta revisão por apresentarem um alinhamento total com os pilares técnicos e contextuais da tese.

Os restantes estudos integrados na revisão sistemática (com pontuações inferiores a 4) são utilizados como referencial de apoio, servindo para contextualizar tendências gerais, validar discussões específicas ou fornecer exemplos de abordagens complementares na literatura. Para uma análise detalhada da avaliação de todos os 41 artigos incluídos, a Tabela A.1 poderá ser consultada no **Apêndice A**.

2.8 Resultados obtidos

Nesta secção são apresentados de forma estruturada os resultados extraídos dos estudos incluídos na revisão sistemática. A partir dos trabalhos mais relevantes, sintetiza-se como a literatura responde de forma objetiva a cada uma das perguntas de investigação colocadas, destacando as tendências comuns, as diferenças entre abordagens e as contribuições mais significativas para a monitorização e previsão do estado fisiológico.

QS1: Que tipos de sinais fisiológicos são mais comummente recolhidos e utilizados na literatura para a monitorização do estado humano?

A revisão da literatura científica revela uma clara tendência para o uso de sistemas multimodais que combinam diversas métricas biológicas para obter uma visão integral do estado

do indivíduo. De maneira predominante, os sinais cardiovasculares posicionam-se como o indicador mais recorrente. Autores como Fasoyinu et al. (2025) e Wang et al. (2024) [22, 75] destacam que a frequência cardíaca (HR) e a variabilidade da frequência cardíaca (HRV) são pilares fundamentais para a monitorização em ambientes de alto risco, como a construção. Esta postura é apoiada por Thomas et al. (2025) e Sim et al. (2023)[66, 71], que focam o uso da HRV especificamente para a deteção de stress e saúde mental, utilizando métricas precisas como o RMSSD (Root Mean Square of Successive Differences), uma medida estatística usada na análise da variabilidade da frequência cardíaca (HRV).

Em segundo lugar, a atividade eletrodérmica (EDA), também referida como resposta galvânica da pele (GSR), aparece com frequência em estudos orientados para a fadiga e o stress térmico. Investigações como as de Umer et al. (2025) e Ojha et al. (2024) [47, 73] sublinham a importância de capturar tanto os componentes fásicos como tónicos da EDA para entender a resposta do sistema nervoso simpático. Por sua parte, Morillo et al. (2025) [3] defendem o uso da EDA e da temperatura da pele face a métodos mais invasivos, argumentando que permitem uma monitorização não intrusiva em ambientes industriais sob os princípios da Indústria 5.0.

A análise da atividade cerebral e muscular também ocupa um lugar relevante, embora a sua implementação varie segundo o contexto. Cheng et al. (2025) e Kakhi et al. (2025) [10, 32] coincidem no uso da electroencefalografia (EEG) para avaliar a fadiga mental e o risco de acidentes. Em contraste, para a avaliação da fadiga física e muscular, Anjum et al. (2025) e Karim et al. (2025) [4, 33] priorizam a electromiografia de superfície (sEMG), focando-se em grupos musculares específicos como o deltoides e o bíceps.

Finalmente, a literatura recente mostra a integração de sinais complementares para aumentar a precisão dos modelos. D. Goutham et al. (2025) e Fasoyinu et al. (2025) [22, 26] mencionam o uso da fotopletismografia (PPG), da oximetria de pulso e da temperatura corporal central. Adicionalmente, observa-se um interesse crescente em métricas comportamentais e biomecânicas; autores como Wang et al. (2024) e Karim et al. (2025) [33, 75] incorporam o seguimento ocular (piscar e diâmetro pupilar) e dados de acelerometria para correlacionar as mudanças fisiológicas com o movimento e a postura do trabalhador.

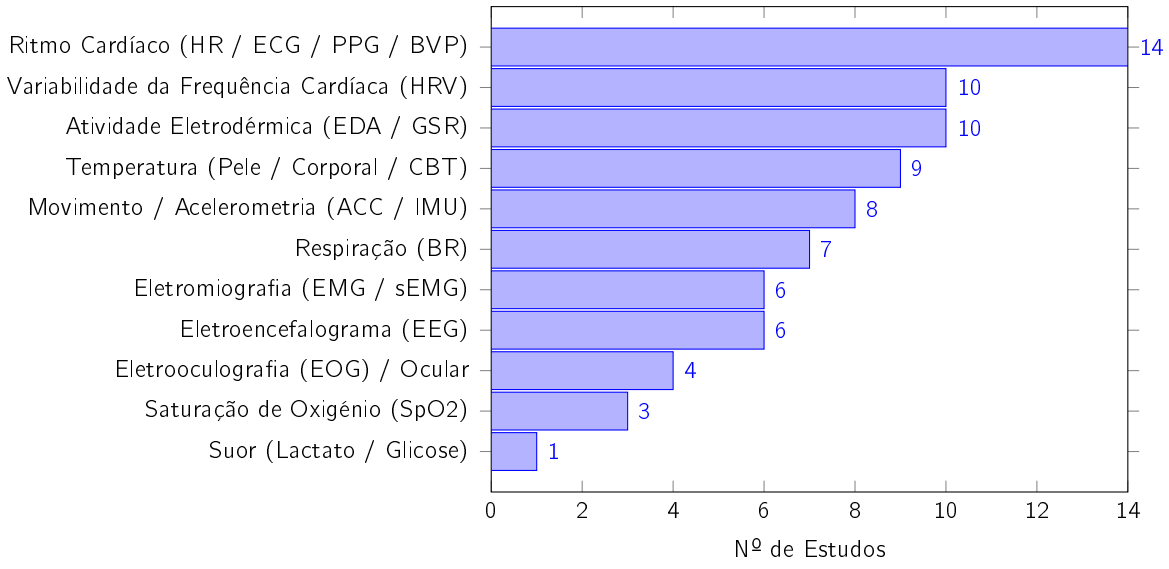


Figura 2.2: Frequência de utilização de sinais fisiológicos

A Figura 2.2 apresenta a distribuição e frequência dos sinais fisiológicos identificados no núcleo central de 14 estudos analisados nesta revisão, evidenciando as métricas utilizadas para diagnosticar estados como cansaço, fadiga ou stress. Como se pode observar, o Ritmo Cardíaco (14/14) assume-se como o sinal mais universal, sendo o indicador primário para a deteção de esforço físico e carga de trabalho, além de ser fundamental na avaliação de riscos como o stress térmico e quedas. Complementarmente, a Variabilidade da Frequência Cardíaca (HRV) (10/14) é utilizada para uma análise mais sensível, sendo crucial na transição entre estados de alerta e fadiga cognitiva ou stress mental.

A Atividade Eletrodérmica (EDA/GSR) (10/14) e a Temperatura (9/14) surgem como pilares na monitorização do stress psicológico e do esgotamento por calor, respetivamente, permitindo uma visão direta da ativação do sistema nervoso simpático e da carga térmica em ambientes industriais. No que respeita à contextualização física, o Movimento e Acelerometria (8/14) desempenha um papel duplo: identifica a intensidade da atividade e auxilia na filtragem de artefactos em sinais como PPG ou EDA.

Sinais mais específicos, como a Respiração (7/14) e a Eletromiografia (EMG) (6/14), são aplicados para medir o esforço metabólico e a fadiga muscular localizada em tarefas de manipulação manual. Por fim, a avaliação direta do estado mental e da vigilância é suportada pelo Eletroencefalograma (EEG) (6/14) e por Métricas Oculares (4/14), que permitem classificar o risco de acidentes baseados na carga cognitiva e na sonolência do trabalhador. Outras métricas, como a Saturação de Oxigénio (SpO2) (3/14) e os Biomarcadores no Suor, embora menos frequentes, oferecem uma compreensão molecular e metabólica detalhada da fadiga em condições extremas.

QS2: Que técnicas de aprendizagem automática e aprendizagem profunda são aplicadas para a análise e a previsão de estados humanos?

A literatura analisada demonstra uma convergência para o uso da Inteligência Artificial (IA) como motor principal para a interpretação de dados fisiológicos. As técnicas reportadas dividem-se principalmente em duas grandes vertentes: a Aprendizagem Automática (ML) clássica para ambientes com recursos computacionais limitados e a Aprendizagem Profunda (DL) para o tratamento de sinais temporais complexos.

Dentro da Aprendizagem Automática clássica, existe um consenso sobre a eficácia dos algoritmos baseados em conjuntos (ensembles). Thomas et al. (2025) e D. Goutham et al. (2025)[26, 71] destacam o algoritmo XGBoost como uma das ferramentas mais potentes para classificar níveis de stress e fadiga devido à sua elevada precisão e capacidade de tratar dados tabulares. De forma semelhante, autores como Fasoyinu et al. (2025), Wang et al. (2025) e Morillo et al. (2025)[3, 22, 75] reportam o uso frequente de Bosques Aleatórios (Random Forest), Máquinas de Vectores de Suporte (SVM) e K-Nearest Neighbors (KNN), salientando a sua versatilidade na classificação de atividades e na deteção de riscos.

No âmbito da Aprendizagem Profunda (DL), a abordagem desloca-se para arquiteturas capazes de capturar dependências temporais e espaciais nos sinais. Umer et al. (2025) e Karim et al. (2025)[33, 73] enfatizam o uso de redes recorrentes como LSTM (Long Short-Term Memory), Bi-LSTM e GRU (Gated Recurrent Units) para processar fluxos contínuos de dados fisiológicos. Por outro lado, a extração automática de características é abordada mediante Redes Neuronais Convolucionais (CNN), como o propõem Anjum et al. (2025) com o seu modelo personalizado FatigueNet e Ojha et al. (2024)[4, 47] através do uso de 1D-CNN em arquiteturas autoencoder.

Paralelamente aos métodos supervisionados, a literatura recente evidencia a adoção de técnicas de aprendizagem não supervisionada, como o *clustering* e a redução de dimensionalidade (PCA), para estruturar dados fisiológicos sem etiquetas prévias. Algoritmos como o K-Means, os Modelos de Mistura Gaussiana (GMM), o DBSCAN e o *Clustering* Hierárquico têm sido fundamentais para descobrir agrupamentos naturais associados ao stress e a respostas autónomas. Por exemplo, Georgiev et al. (2026)[24] destacam a utilidade do GMM para agrupar de forma exploratória respostas psicofisiológicas, enquanto Georgieva-Tsaneva et al. (2025)[25] aplicam abordagens não supervisionadas no reconhecimento de estados através da variabilidade da frequência cardíaca (HRV). Frequentemente, o *clustering* atua como um passo preparatório: Messaoud et al. (2025)[44] utilizam o K-Means para categorizar padrões de HRV, usando depois essas categorizações para treinar modelos supervisionados que preveem o risco de quedas. Finalmente, no contexto da monitorização contínua, o DBSCAN destaca-se pela sua robustez; autores como Arifin et al. (2025)[6] e Georgieva-Tsaneva et al. (2025)[25] utilizam-no não só para classificar atividades, mas também para identificar anomalias em tempo real e filtrar artefactos nos sensores.

Recentemente, a literatura começou a explorar modelos híbridos e técnicas avançadas para melhorar a robustez das previsões. Cheng et al. (2025) introduzem o uso de Redes Neuronais de Gráficos (GNN) para modelar variáveis dependentes do tempo, optimizadas mediante algoritmos metaheurísticos[10]. Da mesma forma, Kakhi et al. (2025) e Ojha et al. (2025)[32, 47] salientam o valor emergente da Aprendizagem por Transferência (Transfer Learning) e a adaptação de domínio, técnicas que permitem ajustar modelos pré-treinados à variabilidade individual de cada sujeito, superando assim uma das maiores barreiras na monitorização humana: a diferença nas respostas fisiológicas entre pessoas.

Finalmente, destaca-se a integração da Lógica Difusa (Fuzzy Logic), utilizada por Morillo et al. (2025) e Kakhi et al. (2025)[3, 32] não só como preditor, mas também como mecanismo de etiquetagem objetiva de estados subjetivos como a fadiga, permitindo uma transição mais suave entre níveis de risco (baixo, médio e alto) do que a classificação binária tradicional.

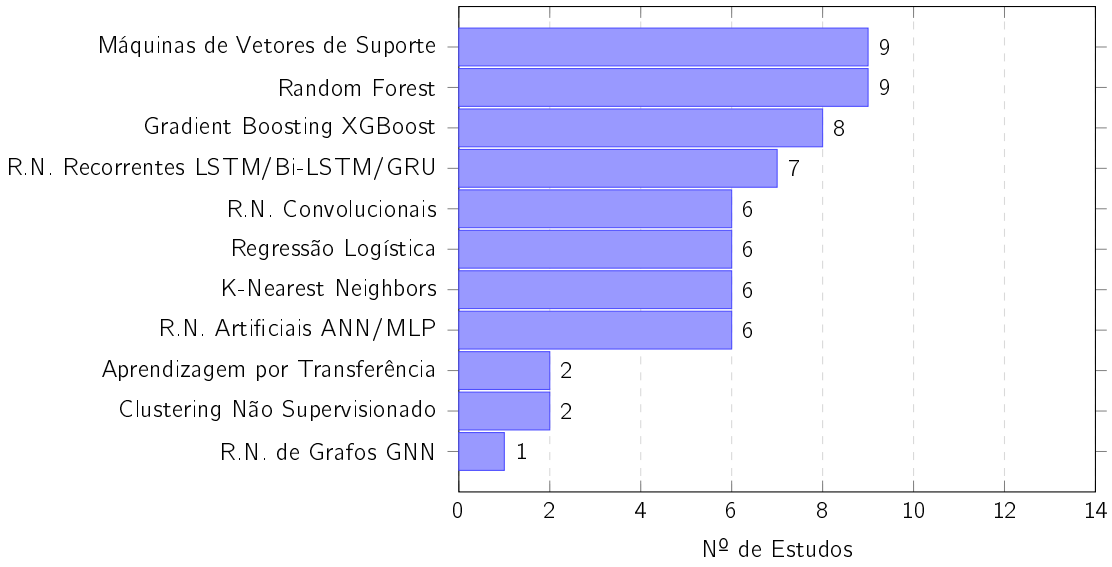


Figura 2.3: Frequência de utilização de técnicas de aprendizagem automática e profunda.

A Figura 2.3 apresenta a distribuição das técnicas de Inteligência Artificial aplicadas na

monitorização do estado humano, revelando as abordagens predominantes nos 14 estudos analisados. Observa-se uma utilização expressiva de modelos de Aprendizagem Automática (ML) clássicos, com as Máquinas de Vetores de Suporte (SVM) e Random Forest (RF) a serem reportadas em 64,3% dos casos (9/14). A preferência por estas técnicas deve-se à sua eficácia em conjuntos de dados de alta dimensão e à sua capacidade de lidar com dados não lineares e problemas de sobreajuste (overfitting), sendo frequentemente utilizadas para estabelecer linhas de base (baselines) de desempenho. Adicionalmente, algoritmos de Gradient Boosting, como o XGBoost (8/14), destacam-se pela sua superioridade em termos de precisão e escalabilidade no processamento de dados em tempo real.

No domínio da Aprendizagem Profunda (DL), as Redes Recorrentes (LSTM, GRU) (7/14) e as Convolucionais (CNN) (6/14) desempenham um papel fundamental na análise de séries temporais fisiológicas (como ECG e EEG), permitindo capturar dependências temporais de longo prazo e extrair automaticamente características complexas da fadiga acumulada. Verifica-se ainda uma utilização relevante de Regressão Logística e KNN (6/14), valorizados pela sua simplicidade e interpretabilidade em classificações binárias de estados de stress ou fadiga.

Por último, a Aprendizagem por Transferência (Transfer Learning) (2/14) surge como uma técnica emergente para adaptar modelos pré-treinados a novos utilizadores ou ambientes com dados limitados, ajudando a superar a variabilidade entre pessoas e melhorando a precisão de modelos em condições reais de trabalho. O Clustering Não Supervisionado (2/14) é utilizado como uma abordagem exploratória para identificar agrupamentos naturais nos dados fisiológicos, sem depender de rótulos previamente definidos, permitindo distinguir diferentes padrões ou estados fisiológicos. Adicionalmente, as Redes Neuronais de Grafos (GNN) (1/14) são aplicadas em abordagens híbridas para capturar relações complexas entre dados que mudam no tempo, como o ritmo cardíaco, e dados estáticos, sendo utilizadas especificamente para melhorar a classificação de riscos de quedas e estados de fadiga.

QS3: Que arquiteturas e modelos são utilizados para a análise de séries temporais fisiológicas e quais são as suas principais vantagens e limitações?

A análise de séries temporais fisiológicas requer arquiteturas capazes de gerir a natureza sequencial e dinâmica dos dados. Segundo a literatura consultada, as arquiteturas de Redes Neuronais Recorrentes (RNN), especificamente as variantes LSTM (Long Short-Term Memory) e GRU (Gated Recurrent Units), são as mais difundidas. Umer et al. (2025) e Fasoyinu et al. (2025)[22, 73] destacam que estas redes são ideais para superar o problema do desaparecimento do gradiente, permitindo reter informação de longo prazo. Em particular, a arquitetura Bi-LSTM é assinalada por Wang et al. (2024) e Karim et al. (2025)[33, 75] como a mais precisa (atingindo até 98.5% de exatidão), uma vez que processa a informação em ambas as direções temporais, capturando um contexto completo do sinal.

Por outro lado, o uso de Redes Neuronais Convolucionais (CNN) adaptou-se para identificar padrões espaciais e morfológicos nos sinais. Anjum et al. (2025) [4] propõem FatigueNet, uma CNN concebida para lidar com a complexidade de dados heterogéneos sem o sobreajuste típico de modelos mais simples. Da mesma forma, abordagens híbridas mais recentes, como o modelo SOS-NN-GNN apresentado por Cheng et al. (2025) [10], demonstram que as Redes de Gráficos (GNN) podem superar as LSTM ao capturar dependências espaço-temporais mais complexas, integrando dados estáticos e sequenciais de forma simultânea. Especificamente, esta arquitetura combina uma Rede Neuronal (NN) para processar variáveis estáticas, uma Rede Neuronal de Gráficos (GNN) para analisar dados sequenciais e

relacionais, e o algoritmo de Pesquisa de Organismos Simbióticos (SOS) para otimizar automaticamente os pesos e a estrutura do modelo. Segundo os autores, esta integração permite processar simultaneamente dados estáticos e sequenciais de forma muito mais eficaz do que os modelos tradicionais.

Quanto às vantagens, a literatura destaca a eficiência e a interpretabilidade. Modelos baseados em árvores como XGBoost e LightGBM são elogiados por D. Goutham et al. (2025) e Thomas et al. (2025)[26, 71] pela sua escalabilidade e rapidez, sendo LightGBM o candidato preferido para aplicações em tempo real devido ao seu baixo consumo de memória. Adicionalmente, Sim et al. (2023) [66] sublinham que a migração destas arquiteturas para o processamento na borda (edge computing) mediante modelos quantizados permite reduzir a latência significativamente e proteger a privacidade do utilizador.

No entanto, identificam-se limitações críticas. O desafio da "caixa negra"ou falta de interpretabilidade é uma preocupação constante para Kakhi et al. (2025) e Ojha et al. (2024)[32, 47], que argumentam que a complexidade das redes profundas dificulta a validação clínica das suas decisões. Além disso, existe uma sensibilidade inerente aos artefactos de movimento em sinais como EMG e ECG durante tarefas físicas intensas (Wang et al., 2024)[75]. Finalmente, Morillo et al. (2025) e Anjum et al. (2025)[3, 4] alertam para a baixa capacidade de **generalização** dos modelos quando se transferem de ambientes controlados de laboratório para a variabilidade extrema dos locais de obra reais, um problema que modelos como EnsmTrBoost tentam mitigar mediante a aprendizagem por transferência.

QS4: Quais são as métricas de avaliação mais utilizadas para validar o desempenho dos modelos propostos?

A validação do desempenho dos modelos de inteligência artificial no âmbito da monitorização fisiológica apoia-se num conjunto diverso de métricas que permitem medir a eficácia desde distintas dimensões. De forma unânime, todos os estudos consultados, incluindo os de Fasoyinu et al. (2025), Wang et al. (2024) e Cheng et al. (2025)[10, 22, 75], reportam a Exatidão (Accuracy) como a métrica base para determinar a percentagem de previsões corretas. No entanto, dado que os dados fisiológicos frequentemente apresentam um desequilíbrio de classes (por exemplo, mais dados de "estado normal"do que de "fadiga crítica"), a literatura atribui um peso significativo à Pontuação F1 (F1-score) e à Área sob a Curva (AUC-ROC).

Autores como D. Goutham et al. (2025) e Morillo et al. (2025)[3, 26] priorizam o uso do F1-score e do Recall (Sensibilidade) para assegurar que o sistema não ignore estados críticos, como a fadiga severa ou o stress agudo, o que é vital para a segurança do trabalhador. Em particular, Morillo et al. (2025) [3] empregam a pontuação F1 ponderada juntamente com intervalos de confiança de 95% obtidos mediante bootstrapping para robustecer a validade estatística dos seus achados. Por sua parte, Umer et al. (2025) e Anjum et al. (2025)[4, 73] complementam esta análise com o uso de matrizes de confusão, as quais permitem visualizar de forma detalhada os erros de classificação entre diferentes níveis de fadiga.

Em contextos onde a monitorização é abordada como um problema de previsão contínua e não apenas de classificação, utilizam-se métricas de erro de regressão. Karim et al. (2025), Kakhi et al. (2025) e Fasoyinu et al. (2024)[22, 32, 33] coincidem no uso da Raiz do Erro Quadrático Médio (RMSE) e do Erro Absoluto Médio (MAE) para quantificar o desvio das previsões relativamente aos valores fisiológicos reais.

No contexto da aprendizagem não supervisionada, a avaliação do desempenho exige métricas específicas focadas na estrutura dos agrupamentos (*clusters*). Para estimar o número ideal de clústeres, Messaoud et al. (2025)[44] e Georgiev et al. (2026)[24] recorrem ao Método do Cotovelo (Elbow Method), analisando a Soma dos Erros ao Quadrado (SSE). Adicionalmente, Georgiev et al. complementam esta otimização com o Critério de Informação de Akaike (AIC) e o Critério de Informação Bayesiano (BIC). Para a validação interna, que mede a coesão e a separação espacial dos grupos, tanto Messaoud et al. como Georgieva-Tsaneva et al. (2025)[25] destacam a eficácia do Coeficiente de Silhueta (Silhouette Score), enquanto Georgieva-Tsaneva et al. utilizam também o gráfico de distância K (*k-distance graph*) para calibrar a densidade no algoritmo DBSCAN.

Finalmente, estudos com abordagens metodológicas mais avançadas introduzem métricas de consistência e similitude estatística. Ojha et al. (2024)[47] destacam o uso da Divergência de Kullback-Leibler (KL) para avaliar as diferenças nas distribuições dos dados entre distintos sujeitos, assim como o desvio padrão da exatidão para medir a estabilidade do modelo perante novos utilizadores. Esta abordagem é crucial para validar a capacidade de generalização dos sistemas de monitorização em ambientes reais altamente variáveis.

QS5: Que limitações e desafios são identificados na literatura para a implementação de sistemas de previsão do estado humano em tempo real?

A transição de modelos de laboratório para aplicações industriais em tempo real apresenta desafios significativos que a literatura classifica em três dimensões principais: técnica, operativa e ética.

Na dimensão técnica e operativa, existe um consenso entre autores como Wang et al. (2024) e Kakhi et al. (2025)[32, 75] sobre a latência na transmissão de dados para a nuvem e a instabilidade das redes em ambientes de obra. Investigações como as de Sim et al. (2023) e Umer et al. (2025)[66, 73] salientam que, embora o edge computing seja uma solução promissora, os dispositivos portáteis possuem limitações críticas de memória, capacidade de processamento e, sobretudo, vida útil da bateria. Além disso, Fasoyinu et al. (2025)[22] alerta para a fragilidade do hardware perante condições ambientais hostis como o pó, a humidade e a interferência electromagnética de maquinaria pesada.

Relativamente à qualidade dos dados, a literatura identifica os "artefactos de movimento" como a barreira principal. Ojha et al. (2024) e Wang et al. (2024)[47, 75] explicam que atividades físicas intensas, o suor e o deslocamento dos eléctrodos geram ruído que compromete a fidelidade de sinais como o ECG e o EEG. A isto soma-se o problema da "mudança de domínio" (domain shift); Anjum et al. (2025) e Ojha et al. (2024)[4, 47] assinalam que a variabilidade fisiológica entre indivíduos (diferenças anatómicas, idade ou saúde) impede que um modelo generalizado funcione com precisão para todos os utilizadores sem um processo de calibração constante. Além disso, pessoas diferentes podem apresentar níveis de atividade física distintos, o que dificulta a criação de um único modelo capaz de classificar todos os casos, como mostram Crista, V., Martinho, D. et al. (2022)[11].

Finalmente, os desafios humanos e éticos são determinantes para a aceitação destas tecnologias. Fasoyinu et al. (2025) e Karim et al. (2025)[22, 33] sublinham a resistência dos trabalhadores devido ao temor pela vigilância da sua produtividade e a privacidade dos seus dados biométricos e de localização. A ergonomia também desempenha um papel crucial; dispositivos volumosos ou incómodos resultam impraticáveis para jornadas laborais extensas (Wang et al., 2024)[75]. Por último, Umer et al. (2025) e D. Goutham et al. (2025)[26, 73]

enfatizam a falta de interpretabilidade dos modelos de aprendizagem profunda, o que gera desconfiança tanto nos utilizadores como nos responsáveis pela segurança, ao não poderem explicar o porquê de um alerta de fadiga ou stress.

QS6: Que mecanismos de comunicação, notificação ou retroalimentação ao utilizador são descritos na literatura?

O sucesso dos sistemas de monitorização fisiológica não reside unicamente na precisão do diagnóstico, mas na eficácia dos seus **mecanismos de retroalimentação** para prevenir acidentes. A literatura identifica uma hierarquia de notificações que varia segundo a urgência do estado detetado e o papel do recetor (trabalhador ou supervisor).

Esta importância do feedback personalizado é também destacada por Ribeiro, R., Martinho, D. et al. [55], que associam mecanismos de retroalimentação adequados ao aumento do envolvimento e da adesão dos utilizadores. De forma complementar, Martinho, D. et al. [43] apresentam um sistema com um assistente virtual que interage com o utilizador, fornece feedback personalizado sobre o seu estado de saúde e utiliza técnicas de gamificação. No contexto desta tese, os alertas devem ter em consideração o estado fisiológico, a função e os valores de referência individuais de cada trabalhador. Isto permitirá adaptar os limiares de alerta, o conteúdo das notificações e o canal utilizado para as comunicar. Por exemplo, uma alteração moderada poderá gerar uma recomendação de pausa para um trabalhador que apresente sinais de fadiga, enquanto, para outro trabalhador, a mesma alteração poderá ser considerada parte do seu esforço habitual e exigir apenas um acompanhamento contínuo.

No nível individual, as alertas hápticas e tácteis são reportadas como as mais eficazes pela sua natureza não intrusiva. Fasoyinu et al. (2024) e Wang et al. (2024)[22, 75] descrevem o uso de motores de vibração integrados em cinturões, coletes ou relógios inteligentes que alertam o operador sobre fadiga crítica ou proximidade a zonas de perigo. Esta retroalimentação complementa-se com interfaces visuais em dispositivos móveis e óculos de realidade aumentada, onde se apresentam avisos gráficos sobre o estado de saúde atual (Kakhi et al., 2025)[32].

Por outro lado, autores como Thomas et al. (2025)[71] e Ojha et al. (2024)[47] destacam a implementação de intervenções sugeridas. Em vez de emitir apenas um alerta, os sistemas baseados em IoT enviam notificações personalizadas via SMS ou aplicações móveis recomendando ações específicas, tais como realizar exercícios de respiração, tomar uma micro-pausa de recuperação ou ingerir suplementos de electrólitos perante o stress térmico. Em casos de fadiga extrema ou sonolência, Wang et al. (2024)[75] menciona mesmo o uso de estímulos auditivos (música) para despertar ou reanimar o utilizador.

A nível de gestão, a literatura enfatiza a importância dos painéis de controlo (dashboards) e plataformas web. Cheng et al. (2025)[10] integram a monitorização com modelos BIM (Building Information Modeling) para visualizar em tempo real a localização e o nível de risco dos trabalhadores num ambiente 3D, permitindo aos engenheiros de segurança tomar decisões informadas sobre a rotação de tarefas. No entanto, Morillo et al. (2025)[3] sublinham que esta comunicação para os supervisores deve ser gerida sob esquemas pseudonimizados para proteger a privacidade do trabalhador, ativando apenas protocolos de intervenção assistida quando se deteta "fadiga pura".

Finalmente, observa-se o uso da retroalimentação bidireccional. Estudos como os de Anjum et al. (2025)[4], Sim et al. (2023)[66] e Umer et al. (2025)[73] utilizam avisos (prompts) nos dispositivos portáteis para que o utilizador valide subjetivamente o seu estado mediante

escalas como a Classificação de Fadiga (ROF). Este mecanismo não só serve como uma notificação de segurança, mas também atua como uma ferramenta de recalibração constante para os modelos de aprendizagem automática.

2.9 Análise dos resultados

Nesta secção aprofunda-se a interpretação dos resultados apresentados na secção anterior, procurando fechar e consolidar cada pergunta desde a perspetiva desta dissertação de tese, destacando as implicações práticas, as oportunidades de melhoria e a forma como estes achados orientam o design do gémeo digital humano proposto.

2.9.1 Respostas às perguntas de investigação

QS1: Que tipos de sinais fisiológicos são mais comummente recolhidos e utilizados na literatura para a monitorização do estado humano?

A análise dos resultados revela que a monitorização do estado humano em ambientes de risco assenta numa hierarquia clara de sinais, onde a frequência cardíaca (HR) e a sua variabilidade (HRV) surgem como os indicadores mais robustos e viáveis. Para os objetivos desta dissertação, este achado é fundamental, uma vez que valida a utilização de sensores wearables não intrusivos, como relógios inteligentes e bandas peitorais, que apresentam uma elevada aceitabilidade em contexto de obra. O predomínio destes sinais na literatura (14/14 estudos) confirma que as métricas cardiovasculares oferecem a sensibilidade necessária para detetar precocemente a fadiga e o stress, permitindo a criação de um sistema de alertas em tempo real que constitui o eixo central desta investigação.

Por outro lado, a literatura revista sugere que a eficácia dos modelos de IA aumenta significativamente quando se adota uma abordagem multimodal. Neste contexto, a elevada frequência de utilização da Atividade Eletrodérmica (EDA) e da Temperatura (10/14 estudos) indica que estes sinais fisiológicos são especialmente relevantes como fontes de informação complementares. Na perspetiva desta tese, a integração destes sinais secundários, disponíveis em sensores modernos, representa uma oportunidade para aumentar a precisão na previsão de estados críticos.

Embora sinais como a eletroencefalografia (EEG) ou a eletromiografia (EMG) ofereçam dados detalhados, a sua baixa adoção em ambientes industriais (devido à sua intrusividade e à sensibilidade ao ruído de movimento) reforça a decisão desta investigação de se focar em dados sequenciais provenientes de dispositivos portáteis.

Em suma, os achados orientam o design do gémeo digital proposto para uma arquitetura que prioriza sinais cardiovasculares e térmicos, complementados por medidas auxiliares como a acelerometria e a respiração, garantindo assim um equilíbrio entre o rigor científico do diagnóstico e a viabilidade prática da monitorização contínua em trabalhos de alto risco.

QS2: Que técnicas de aprendizagem automática e aprendizagem profunda são aplicadas com maior frequência para a análise e a previsão de estados como stress, fadiga, carga fisiológica ou nível de atenção?

A convergência da literatura para modelos de IA demonstra que a complexidade dos sinais fisiológicos recolhidos por wearables exige algoritmos que superem as análises estatísticas tradicionais, embora não requeiram necessariamente modelos de aprendizagem profunda em

todos os cenários. No contexto desta tese, a elevada prevalência de modelos clássicos como as Máquinas de Vetores de Suporte (SVM) e Random Forest (9/14 estudos) constitui um indicador crítico. Estes modelos são adequados para a implementação em dispositivos com recursos computacionais limitados, sugerindo que o gémeo digital proposto pode integrar classificadores robustos que garantam respostas rápidas em ambientes de obra, onde a latência na deteção de um estado crítico pode comprometer a segurança do trabalhador.

Por outro lado, a tendência para o uso de Aprendizagem Profunda (DL), especificamente redes LSTM e GRU, justifica a necessidade de tratar os dados dos sensores (frequência cardíaca e temperatura) como séries temporais contínuas e não como eventos isolados. Dado que esta investigação tem como objetivo prever a fadiga e o stress (estados que se acumulam ao longo do tempo), a capacidade destas redes para reter informação de longo prazo revela-se fundamental. A análise sugere que uma arquitetura híbrida, que combine a extração de características de modelos convolucionais com a memória temporal das redes recorrentes, poderá oferecer o equilíbrio necessário entre precisão diagnóstica e fiabilidade nas alertas.

Finalmente, a identificação na literatura de técnicas como a Aprendizagem por Transferência (Transfer Learning), o Clustering Não Supervisionado e a Lógica Difusa orienta esta dissertação para a resolução de três problemas práticos: a variabilidade biológica entre trabalhadores, a descoberta de padrões fisiológicos sem etiquetas prévias e a subjetividade dos estados de fadiga. A integração de lógica difusa permite que o sistema de alertas não seja apenas binário, mas que possa comunicar níveis de risco progressivos (baixo, moderado, elevado), o que é significativamente mais útil para a gestão de segurança em obra do que um simples estado de 'fadiga/não fadiga'. O clustering pode ainda funcionar como uma etapa exploratória e de preparação dos dados, contribuindo para identificar padrões naturais antes da aplicação de modelos preditivos. Em conclusão, os resultados apontam para um design de software que prioriza a robustez do machine learning clássico para o processamento imediato, a exploração não supervisionada dos dados e a profundidade do deep learning para a análise preditiva da evolução do estado do trabalhador.

QS3: Que arquiteturas e modelos são utilizados para a análise de séries temporais fisiológicas e quais são as suas principais vantagens e limitações?

A análise da literatura revela que a monitorização eficaz dos estados humanos não depende unicamente da escolha do algoritmo, mas também da sua capacidade para lidar com a natureza sequencial dos dados fisiológicos. Para os objetivos desta tese, a relevância das arquiteturas LSTM e Bi-LSTM constitui uma conclusão determinante. Estas redes recorrentes de aprendizagem profunda são essenciais para captar a memória temporal do sinal, permitindo ao sistema distinguir entre um esforço físico momentâneo e uma tendência de fadiga acumulada ao longo de várias horas.

Por outro lado, a literatura destaca as vantagens dos modelos de aprendizagem automática baseados em árvores, como o LightGBM. Embora este algoritmo tenha sido concebido para dados tabulares, a sua aplicação a séries temporais é possível através da extração de características (*feature extraction*), convertendo segmentos de sinais sequenciais em métricas estatísticas. Esta abordagem permite aproveitar a rapidez e o baixo consumo de memória do LightGBM, reforçando a viabilidade do Edge Computing. No contexto desta tese, isto significa que o processamento pode ocorrer localmente no dispositivo móvel ou wearable, garantindo respostas rápidas e a privacidade do trabalhador sem a necessidade de uma ligação constante à nuvem nos estaleiros.

Por fim, as limitações reportadas na literatura têm implicações diretas no desenho desta tese. Primeiro, a sensibilidade ao movimento significa que o sistema pode confundir sinais fracos ou distorcidos pelo movimento do trabalhador com sinais de fadiga; por isso, esta investigação dará prioridade a técnicas de filtragem de dados. Isto realça a importância de incluir uma camada prévia de limpeza e preparação dos dados antes de os submeter aos modelos, assegurando que apenas se processem sinais fisiológicos relevantes e reduzindo a possibilidade de falsos alertas. Segundo, a baixa capacidade de generalização indica que os modelos treinados em laboratório falham frequentemente em ambientes de obra reais. Para mitigar este problema, o Gémeo Digital proposto irá focar-se na robustez dos dados, utilizando dados reais de trabalhadores de obra para o treino dos modelos, assegurando que os alertas de segurança sejam fiáveis e baseados em variações fisiológicas reais.

QS4: Quais são as métricas de avaliação mais utilizadas para validar o desempenho dos modelos propostos em estudos de monitorização fisiológica?

O análise das métricas de avaliação revela que a eficácia de um Gémeo Digital para a segurança laboral não pode ser medida apenas pela Exactidão (Accuracy). Embora esta métrica seja a mais comum, a literatura alerta para o problema do desequilíbrio de classes nos dados fisiológicos, onde os estados de risco (fadiga severa ou stress agudo) são menos frequentes do que o estado normal. Para os objetivos desta tese, esta descoberta é crucial: o sistema de alertas deve ser validado prioritariamente através do F1-score e do Recall (Sensibilidade). Na perspetiva da segurança em obra, um valor elevado de Recall garante que o modelo minimize os falsos negativos, assegurando que nenhum estado de perigo real passe despercebido, o que é vital para a prevenção de acidentes.

Além disso, a inclusão de métricas de regressão como o MAE (Erro Absoluto Médio) e o RMSE (Root Mean Squared Error / Raiz do Erro Quadrático Médio) na literatura orienta o desenho desta investigação para uma monitorização proativa. Em vez de apenas classificar se o trabalhador "está ou não" fatigado, o uso destas métricas permite avaliar a precisão do sistema ao prever a tendência de evolução dos sinais vitais. Isto possibilita que o Gémeo Digital antecipe estados críticos antes de estes atingirem limiares perigosos.

Na aprendizagem não supervisionada, a avaliação exige métricas centradas na estrutura dos agrupamentos. O Método do Cotovelo (Elbow Method) estima o número adequado de clústeres através da Soma dos Erros ao Quadrado (SSE). Este procedimento pode ser complementado pelo Critério de Informação Bayesiano (BIC), que seleciona o modelo equilibrando a qualidade do ajuste e a complexidade. Após a definição dos agrupamentos, o Coeficiente de Silhueta (Silhouette Score) avalia a coesão interna e a separação entre grupos. Em conjunto, estas métricas permitem verificar se os padrões fisiológicos são consistentes, interpretáveis e úteis para detetar estados de stress e fadiga.

Por último, o uso da Divergência de Kullback-Leibler (KL) e do desvio padrão da exactidão, mencionados em estudos mais recentes, reforça a necessidade de testar a estabilidade do modelo entre diferentes indivíduos. A KL permite avaliar quanto se diferenciam os padrões fisiológicos de cada trabalhador relativamente aos dados médios do modelo, assegurando que o sistema seja capaz de se adaptar a diferentes variações individuais e não falhe com pessoas cujos sinais sejam pouco comuns. Por sua vez, o desvio padrão mede a consistência do modelo entre diferentes trabalhadores. Assim, a validação não se centra apenas na média de desempenho, mas na capacidade do modelo de manter resultados fiáveis e consistentes face à variabilidade individual, garantindo que o Gémeo Digital seja uma ferramenta de segurança robusta e não apenas um modelo estatístico de laboratório.

QS5: Que limitações e desafios são identificados na literatura para a implementação de sistemas de previsão do estado humano em tempo real?

A transposição das métricas de laboratório para o ambiente operativo de uma obra exige que o sistema desenhado nesta investigação possua uma arquitetura resiliente face a falhas de infraestrutura. Perante a instabilidade da rede e os problemas de latência reportados, esta tese propõe uma estratégia de computação descentralizada. Ao processar os algoritmos de deteção de fadiga localmente (edge computing), o Gémeo Digital garante que os alertas de segurança sejam disparados instantaneamente, limitando a dependência total de uma ligação estável à nuvem. Esta escolha técnica também resolve a limitação da duração da bateria, ao reduzir a frequência de transmissões de dados sem fios de alto consumo.

No que respeita à integridade dos dados em ambientes hostis, esta investigação aborda a fragilidade dos sensores através da utilização combinada de relógios inteligentes e bandas torácicas. Esta abordagem multimodal é estratégica: enquanto o relógio oferece versatilidade e sinais complementares (como temperatura e acelerometria), a banda torácica assegura uma medição do ritmo cardíaco mais precisa e menos vulnerável aos artefactos de movimento do que os sensores apenas de pulso. As fraquezas dos relógios são compensadas pela precisão das bandas torácicas e, por sua vez, as limitações destas últimas são equilibradas com a informação adicional fornecida pelos relógios. Adicionalmente, para abordar o problema da variabilidade fisiológica individual, poderia ser integrado um processo de calibração adaptativa no Gémeo Digital. Isto permitiria ajustar os limiares de alerta ao perfil base de cada trabalhador, transformando o desafio da generalização numa oportunidade para personalizar a segurança.

QS6: Que mecanismos de comunicação, notificação ou retroalimentação ao utilizador são descritos na literatura?

A análise dos mecanismos de comunicação sugere caminhos promissores para a interação entre o Gémeo Digital e o utilizador, procurando que a comunicação seja clara e gerível. Para esta tese, pode colocar-se a hipótese de explorar alertas hápticas (vibração) como canal prioritário. Num ambiente de obra, onde o ruído ambiental é elevado e a atenção visual é crítica para a tarefa, faz sentido considerar a vibração no relógio inteligente e na banda torácica como uma possibilidade menos intrusiva e potencialmente mais eficaz para notificações de fadiga ou stress.

Adicionalmente, existe a possibilidade de incorporar mecanismos de retroalimentação bidireccional. Este conceito permitiria que o trabalhador validasse subjetivamente o seu estado através do dispositivo, funcionando não apenas como um alerta, mas como uma ferramenta potencial para o ajuste e refinamento contínuo dos modelos de aprendizagem automática com base no feedback real do utilizador.

Por último, a literatura indica que a integração de camadas de informação visual ou dashboards constitui uma vantagem para a gestão da segurança. Pode considerar-se a inclusão de interfaces que apresentem níveis de risco processados, permitindo uma visualização clara dos estados críticos sem comprometer a privacidade dos dados fisiológicos brutos. Em suma, estas opções de comunicação e visualização representam caminhos a explorar no desenho do Gémeo Digital, com o objetivo de encontrar o equilíbrio ideal entre a prontidão da resposta e a viabilidade operacional no terreno.

2.9.2 Conclusões

A análise detalhada das questões de investigação permite concluir que o desenvolvimento de um Gémeo Digital Humano para a segurança na construção civil exige equilibrar a precisão de laboratório com a fiabilidade em condições reais. Os achados revistos indicam que uma arquitetura baseada em sensores não intrusivos (relógios e bandas torácicas) permite monitorizar continuamente indicadores de fadiga e stress de forma fiável para o trabalhador, evitando depender de sinais intrusivos e priorizando a robustez dos dispositivos wearables.

Além disso, a combinação de modelos híbridos de aprendizagem automática e processamento local (Edge Computing) surge como uma estratégia chave para garantir alertas imediatos e mitigar problemas de conectividade. Mais do que a simples exatidão, a atenção ao Recall e ao F1-score nas métricas de avaliação sublinha que o sucesso deste Gémeo Digital se medirá pela sua capacidade de não ignorar estados de risco, priorizando a salvaguarda da vida humana.

Por fim, a personalização mediante calibrações adaptativas e a utilização de alertas hápticos ou visuais identificam-se como mecanismos críticos para superar a variabilidade individual e o ruído ambiental. Em conjunto, estes achados fornecem as bases teóricas e técnicas que orientam o desenho do Gémeo Digital como uma ferramenta de segurança proativa, fiável e sustentável em ambientes reais de risco.

Capítulo 3

Métodos e Ferramentas

3.1 Metodologia

A metodologia proposta para esta investigação inicia-se com a análise de um problema crítico no setor da construção: a **monitorização ineficaz da saúde e segurança dos trabalhadores em tempo real**. A partir de uma revisão sistemática da literatura, foram identificados os tipos de dados fisiológicos mais utilizados, bem como diversos modelos de aprendizagem, desde o Machine Learning tradicional até ao Deep Learning. Além disso, encontraram-se estudos análogos em diferentes contextos laborais que servem de base teórica e ponto de partida para esta investigação. Com base nestas evidências, a metodologia foi estruturada para responder aos objetivos propostos, seguindo uma lógica de desenvolvimento e validação dividida em três etapas principais:

- **Arquitetura e Integração do Sistema:** fase dedicada ao desenho da infraestrutura do Gémeo Digital Humano, estabelecendo o fluxo de dados desde a recolha sensorial até à integração do módulo preditivo, garantindo que o sistema suporte a monitorização contínua e a geração de alertas automáticos.
- **Preparação e Caracterização de Dados:** etapa focada na análise dos sinais fisiológicos e na aplicação de técnicas de pré-processamento. Esta fase inclui a normalização, filtragem e segmentação temporal dos dados, bem como a extração de características fundamentais para alimentar os modelos de aprendizagem.
- **Modelação, Avaliação e Comparação de Algoritmos:** fase final dedicada à exploração de diferentes abordagens de Machine Learning e Deep Learning. Os modelos são treinados e avaliados recorrendo a métricas adequadas para comparar a sua capacidade de generalização e viabilidade em cenários próximos do tempo real, permitindo a seleção da solução mais robusta para o contexto de alto risco.

Deste modo, todos os testes foram realizados inicialmente num ambiente controlado, o que permitiu validar algoritmos e estratégias de forma segura, utilizando dados reais de trabalhadores para garantir a fiabilidade e a validade científica dos resultados. Apenas após a obtenção de resultados satisfatórios no treino e na comparação dos melhores modelos, é que estas provas seriam consideradas para uma eventual transferência para o ambiente real. Esta abordagem progressiva e iterativa assegura a reprodutibilidade dos testes e a robustez da solução final face aos requisitos de segurança e bem-estar do trabalhador

3.2 Arquitetura da Solução

A solução desenvolvida tem como objetivo principal monitorizar o estado fisiológico do trabalhador em tempo real, permitindo a deteção precoce de estados de fadiga, stress ou exaustão física. Este processo é suportado por uma arquitetura concebida para integrar de forma coerente a recolha de sinais biológicos, o processamento preditivo através de modelos de Inteligência Artificial e a representação virtual no contexto de um Gémeo Digital. Uma organização semelhante, embora aplicada ao acompanhamento de doentes com diabetes tipo 2, foi apresentada por Martinho et al. [42]. Esse trabalho é considerado aqui como antecedente metodológico para a separação entre recolha de dados, processamento inteligente e utilização da informação. A Figura 3.1 apresenta uma visão geral dos principais componentes e das interações estabelecidas entre eles.

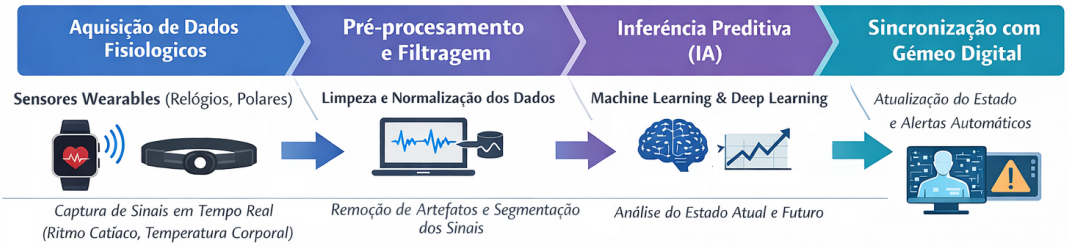


Figura 3.1: Arquitetura da Solução

De forma funcional, o processo pode ser descrito em quatro etapas fundamentais:

1. **Aquisição de Dados Fisiológicos:** os sensores wearables capturam sinais em tempo real (como ritmo cardíaco e temperatura corporal). Estes dados brutos são transmitidos para a unidade de processamento.
2. **Pré-processamento e Filtragem:** os dados recebidos são submetidos a algoritmos de limpeza para remover ruído e artefactos de movimento, sendo posteriormente normalizados e segmentados para facilitar a análise.
3. **Inferência Preditiva (IA):** os dados processados servem de entrada para os modelos de Machine Learning e Deep Learning treinados. O sistema analisa os padrões temporais para prever o estado atual e futuro do trabalhador.
4. **Sincronização com o Gémeo Digital:** Os resultados da predição e os sinais vitais são integrados na representação digital do trabalhador. Esta entidade virtual mantém o histórico e o estado atual de segurança, ativando protocolos de alerta automáticos sempre que os modelos detetem que os limiares de risco foram ultrapassados.

Deste modo, todos os testes foram realizados inicialmente num ambiente controlado, o que permitiu validar algoritmos e estratégias de forma segura, utilizando dados reais de trabalhadores para garantir a fiabilidade e a validade científica dos resultados. Apenas após a obtenção de resultados satisfatórios no treino e na comparação dos melhores modelos, é que estas provas seriam consideradas para uma eventual transferência para o ambiente real. Esta abordagem progressiva e iterativa assegura a reprodutibilidade dos testes e a robustez da solução final face aos requisitos de segurança e bem-estar do trabalhador.

3.3 Ferramentas de Hardware

Nesta secção, detalham-se os dispositivos utilizados para a recolha de dados biométricos. A escolha recaiu sobre ferramentas de elevada precisão, capazes de fornecer dados brutos (raw data) essenciais para o treino de modelos de Inteligência Artificial.

3.3.1 Empatica EmbracePlus

O *Empatica EmbracePlus* [18] é um smartwatch de grau médico com certificação CE Classe IIa, desenhado para a recolha contínua e passiva de dados fisiológicos em contextos de investigação e ensaios clínicos. [19] O dispositivo destaca-se pela sua capacidade de fornecer métricas precisas em ambientes reais.

Sensores Integrados:

- PPG (Fotopletismografia): Sensor ótico de quatro canais utilizado para a monitorização da frequência cardíaca (HR) e saturação de oxigénio (SpO2).
- EDA (Atividade Eletrodérmica): Sensor de condutância da pele que regista a atividade do sistema nervoso autónomo.
- Temperatura Digital: Sensor de alta precisão para o registo térmico cutâneo.
- Acelerómetro e Giroscópio (3D): Sensores de movimento para a captura de aceleração e velocidade angular.
- Biomarcadores Digitais Gerados: Através do processamento interno, o dispositivo gera métricas como a variabilidade da frequência cardíaca (HRV), a taxa respiratória, os níveis de intensidade de movimento e a monitorização de estados de sono e repouso.

Para além da sua capacidade sensorial, o dispositivo foi concebido para suportar as exigências físicas do trabalho de campo, conforme detalhado na Tabela 3.1.

Tabela 3.1: Características Físicas e Design do Empatica EmbracePlus

Característica	Descrição
Ecrã E-Ink	Tecnologia de tinta eletrónica always-on, que minimiza o consumo de energia e garante visibilidade ideal sob luz solar direta.
Robustez	Certificação IP67, garantindo resistência total a poeiras e proteção contra imersão em água.
Autonomia e Memória	Otimizado para gravação contínua de dados e sincronização via Bluetooth para armazenamento de longo prazo.
Ergonomia	Peso aproximado de 40g e bracelete de silicone hipoalergénica, desenhada para uso prolongado sem desconforto.

Fluxo de Dados e Sincronização:

O ecossistema do relógio inteligente integra-se com a plataforma cloud **Empatica Health Monitoring Platform**. Durante a recolha ativa, o dispositivo transmite continuamente os dados biológicos para a aplicação móvel instalada no smartphone do participante através de uma ligação sem fios via Bluetooth Low Energy (BLE). Esta aplicação atua como uma ponte de comunicação intermédia, encarregando-se de sincronizar e enviar as leituras em

intervalos regulares para os servidores cloud da Empatica. Através do portal online de gestão da plataforma, é possível monitorizar remotamente o funcionamento e conformidade de cada equipamento, gerir os perfis dos participantes e proceder ao descarregamento das séries temporais fisiológicas completas para posterior exportação e análise sob o formato de ficheiros CSV.

Utilização na Investigação:

A utilização do EmbracePlus nesta investigação é fundamental, uma vez que a sua capacidade de recolha passiva de dados de Atividade Eletrodérmica (EDA), Ritmo Cardíaco (HR), Temperatura Digital, entre outros sinais fisiológicos, permite identificar biomarcadores diretamente correlacionados com estados de stress, fadiga crónica e exaustão física. Além disso, o fornecimento de métricas pré-processadas, como a Variabilidade da Frequência Cardíaca (HRV) e os níveis de intensidade de movimento, constitui uma base de dados de elevada qualidade para o treino de modelos de Inteligência Artificial. Esta robustez na aquisição de múltiplos sinais garante que os algoritmos de predição sejam treinados com dados fidedignos dos trabalhadores, permitindo fundamentar tecnicamente a antecipação de situações de risco no ambiente de construção.

3.3.2 Polar H10

O Polar H10 é um sensor de banda peitoral amplamente reconhecido na comunidade científica e desportiva pela sua precisão eletrocardiográfica (ECG). Nesta investigação, o seu uso é fundamental para validar e complementar os dados recolhidos pelo relógio, servindo como a principal referência para o estado cardiovascular do trabalhador.

Sensores e Capacidades Técnicas:

- Eletrodos Pro de Alta Qualidade: Inclui elétrodos de interferência reduzida que garantem uma leitura precisa do sinal elétrico do coração, livre de artefactos de movimento.
- Monitorização ECG: Fornece a medição da frequência cardíaca com precisão laboratorial, sendo capaz de registar cada batimento individualmente (intervalos R-R).
- Memória Interna: Possui capacidade para armazenar uma sessão de treino completa, prevenindo a perda de dados em caso de falha na ligação Bluetooth.
- Acelerómetro: Integra um sensor de movimento que auxilia na correção de ruído e na análise da intensidade da atividade física.

Para além da sua elevada precisão, as características físicas do Polar H10 garantem fiabilidade em condições de trabalho intensas, conforme detalhado na Tabela 3.2.

Tabela 3.2: Características Físicas e Design do Polar H10

Característica	Descrição
Conetividade Dual	Suporte simultâneo para Bluetooth Low Energy (BLE) e ANT+, permitindo a ligação a múltiplos dispositivos de processamento.
Impermeabilidade	Resistente à água até 30 metros, sendo imune ao suor intenso e a condições de chuva no ambiente de obra.
Autonomia	Bateria recarregável com autonomia de 20-30 horas em uso contínuo; com vida útil de até 400 horas.
Conforto	Banda têxtil ajustável com pontos de silicone antiderrapantes, garantindo que o sensor permanece posicionado corretamente durante o esforço físico.

Utilização na Investigação:

A integração do Polar H10 nesta tese justifica-se pela necessidade de obter dados de frequência cardíaca com rigor médico-científico. Embora o smartwatch EmbracePlus seja o dispositivo central para a recolha multissensorial, a banda Polar H10 atua como um acompanhante fundamental devido à sua superior precisão eletrocardiográfica. Ao fornecer intervalos batimento-a-batimento (R-R) de alta fidelidade, este dispositivo permite um cálculo da Variabilidade da Frequência Cardíaca (HRV) muito mais refinado do que os sensores óticos convencionais. Esta utilização conjunta assegura uma redundância de dados que fortalece a robustez da análise, utilizando a banda como o padrão de referência para validar e elevar a confiança nas predições de fadiga e stress dos trabalhadores.

3.4 Ferramentas de Software

O desenvolvimento desta tese e a implementação da solução tecnológica exigiram a integração de diversas ferramentas de software. Estas foram selecionadas para garantir a eficiência na gestão documental, o rigor na análise de dados fisiológicos e a robustez no treino dos modelos de Inteligência Artificial, assegurando que todo o ecossistema do Gémeo Digital Humano seja replicável e estruturado.

3.4.1 Gestão de Investigação e Escrita

Para a elaboração do documento, utilizou-se o sistema de composição tipográfica *LaTeX*, baseado no motor *pdfLaTeX*, que garante um padrão de elevada qualidade e rigor para documentos científicos. A edição foi realizada no *Visual Studio Code* com a extensão *LaTeX Workshop*, permitindo uma escrita modular dividida por capítulos e uma gestão eficiente do processo de compilação do ficheiro final em PDF.

A gestão de referências bibliográficas foi processada através do motor *Biber* em conjunto com o pacote *Biblatex*, assegurando a normalização automática das citações e a integridade da bibliografia ao longo de todo o trabalho. No que respeita à fundamentação teórica, a plataforma *Rayyan* foi uma ferramenta determinante, servindo de suporte em todas as etapas do processo PRISMA da revisão sistemática do estado da arte (State of the Art - SoA) da investigação. Esta plataforma facilitou a triagem inicial, a exclusão de duplicados

e a aplicação de critérios de inclusão e exclusão, garantindo o rigor metodológico necessário na seleção dos estudos mais relevantes para dar resposta às perguntas de investigação estabelecidas.

3.4.2 Desenvolvimento Técnico e Inteligência Artificial

No domínio técnico, o desenvolvimento foi centrado na linguagem *Python*, tirando partido do seu vasto ecossistema de bibliotecas para Ciência de Dados e Inteligência Artificial. Utilizaram-se os ambientes *Visual Studio Code* e *Jupyter Notebook*, sendo este último fundamental para a análise exploratória, normalização de sinais e experimentação iterativa com os dados recolhidos pelo Empatica EmbracePlus e Polar H10. Para garantir a estabilidade do sistema e a reprodutibilidade dos resultados, a gestão de dependências foi efetuada através de ambientes virtuais (*venv*). O controlo de versões do código foi assegurado pelo *Git*, utilizando a interface *GitHub Desktop* para a gestão do fluxo de trabalho e o *GitHub* para o alojamento remoto, permitindo um acompanhamento detalhado de todas as fases de implementação da lógica preditiva.

3.4.3 Processamento de Dados e Modelação

O processamento dos sinais biológicos e o treino dos modelos de aprendizagem automática assentaram em bibliotecas de referência. As bibliotecas *Pandas* e *NumPy* foram essenciais para a manipulação de séries temporais, limpeza de ruído e alinhamento dos dados de Ritmo Cardíaco e EDA. Para a construção dos modelos preditivos de fadiga e stress, utilizou-se o *Scikit-learn* em algoritmos de aprendizagem clássica e o *TensorFlow* e *PyTorch* para o desenvolvimento de redes neuronais. Finalmente, as visualizações estatísticas foram suportadas por bibliotecas como *Matplotlib*, permitindo a tradução de dados complexos em alertas de segurança compreensíveis.

3.5 Protocolo de Recolha de Dados

A presente investigação fundamenta-se na análise de dados recolhidos no âmbito do projeto CRIARTE, um consórcio focado na colaboração entre humanos e robôs em ambientes de construção. A utilização destes dados segue um protocolo rigoroso que assegura não só a viabilidade técnica para o treino de modelos de Inteligência Artificial, mas também o cumprimento integral das normas éticas e legais vigentes.

A recolha de dados pelo projeto CRIARTE foi realizada sob o princípio da licitude, lealdade e transparência, garantindo o **consentimento informado** explícito de todos os trabalhadores participantes. Em conformidade com o Regulamento Geral sobre a Proteção de Dados (RGPD) e as diretrizes do AI Act, o protocolo adotou o princípio da minimização, assegurando que apenas os **dados estritamente necessários** para a monitorização fisiológica e segurança laboral fossem processados.

Para proteger a privacidade dos intervenientes, os dados pessoais foram sujeitos a processos de **anonimização e pseudonimização**. Esta camada de segurança garante que, embora os sinais biométricos sejam utilizados para prever estados de stress e fadiga, a identidade dos trabalhadores permanece protegida, impossibilitando a sua reidentificação direta.

Os dados foram capturados durante as jornadas reais de trabalho através dos dispositivos wearable detalhados anteriormente (Empatica EmbracePlus e Polar H10), encontrando-se organizados em ficheiros de formato Excel (.xlsx) com uma frequência de registo por minuto.

No caso do relógio EmbracePlus, o dataset consolidado inclui 22 colunas críticas para a deteção de estados emocionais e fisiológicos. Destacam-se os biomarcadores de ativação simpática como a condutância da pele (*eda_scl_usiemens*), a frequência cardíaca basal (*pulse_rate_bpm*) e indicadores de stress respiratório (*respiratory_rate_brpm*). Para a análise de fadiga e recuperação, o dataset fornece a variabilidade da frequência cardíaca (*prv_rmssd_ms*) e o gasto energético metabólico (*met*). O comportamento físico é detalhado através de variáveis de movimento como activity_counts, step_counts e a magnitude do vetor (*vector_magnitude*), além da classificação qualitativa da atividade (*activity_class*) e da sua intensidade (*activity_intensity*), que varia entre estados sedentários e de vigor físico. Adicionalmente, o dispositivo permite monitorizar a qualidade da recuperação do trabalhador através da coluna sleep_detection_stage, que identifica as fases de sono (*AWAKE*, *LIGHT*, *DEEP* e *REM*).

Complementarmente, os dados provenientes da banda Polar H10 fornecem métricas de alta precisão cardiovascular, incluindo o sinal de eletrocardiograma (*ECG*), frequência cardíaca (*HR*) e os intervalos entre batimentos (*RR*), fundamentais para validar e colmatar eventuais lacunas nos dados óticos do relógio.

Os dados brutos foram inicialmente armazenados em bases de dados seguras, seguindo as melhores práticas internacionais de integridade e segurança lógica. A gestão desta informação obedece aos princípios FAIR, garantindo que os dados sejam rastreáveis e seguros. Para os fins desta tese, o acesso a estes dados foi realizado de forma autorizada, utilizando os ficheiros consolidados que resultaram deste processo de aquisição profissional, garantindo assim uma base de dados de elevada qualidade para o treino dos algoritmos do Gémeo Digital. Estes dados serviram de base para a fase de experimentação, que compreende o pré-processamento, a engenharia de características e o treino e validação dos modelos de Inteligência Artificial, conforme detalhado no capítulo seguinte.

Capítulo 4

Desenvolvimento e Experimentação

Este capítulo descreve o processo de desenvolvimento técnico e a metodologia experimental utilizada para converter os dados fisiológicos brutos em indicadores inteligentes do estado humano. Explica-se o percurso dos dados desde a sua aquisição direta a partir dos sensores até ao seu processamento, passando por etapas de limpeza, tratamento de valores em falta e engenharia de características. Apresenta-se igualmente a arquitetura dos modelos de aprendizagem automática utilizados e os critérios de treino aplicados para a classificação dos estados dos trabalhadores. O principal objetivo desta experimentação é avaliar a capacidade dos algoritmos para identificar padrões psicofisiológicos e definir a lógica analítica que suporta a tomada de decisões em tempo real no ecossistema do Gémeo Digital Humano.

4.1 Preparação e Pré-processamento de Dados

Esta secção descreve os procedimentos adotados para organizar, limpar e estruturar os dados adquiridos através da banda peitoral Polar H10 e do Relógio Empatica EmbracePlus. O objetivo deste processo foi converter os registos brutos em conjuntos de dados normalizados, garantindo a integridade da informação necessária para as etapas de análise e modelação.

4.1.1 Descrição dos Dados Brutos (Raw Data)

A fase inicial do desenvolvimento focou-se na aquisição de dados biométricos a partir de duas fontes com características distintas: a banda peitoral **Polar H10** e o relógio inteligente **Empatica EmbracePlus**. Cada dispositivo apresenta especificidades próprias de taxa de amostragem, número de canais de sinal e estrutura de ficheiros.

Banda Peitoral Polar H10

Os dados brutos do Polar H10 foram organizados em pastas correspondentes a dez trabalhadores distintos, que utilizaram o dispositivo durante jornadas laborais completas ou meias jornadas, em dois dias distintos. Devido à elevada taxa de amostragem do equipamento, que realiza registos aproximadamente a cada 7,5 milissegundos (cerca de 130 amostras por segundo), o volume de informação gerado é elevado. Por este motivo, os registos de cada jornada encontram-se fragmentados em entre 5 e 10 ficheiros Excel, consoante a duração da recolha, uma vez que cada ficheiro atinge o limite prático de aproximadamente 450.000 registos.

A estrutura destas tabelas é composta pelas seguintes colunas fundamentais:

- **UNIX Timestamp:** Marcação temporal em nanosegundos, essencial para a sincronização dos eventos.
- **ECG:** Registo bruto do sinal de eletrocardiograma (medido em milivolts).
- **HR (Heart Rate):** Frequência cardíaca instantânea processada pelo dispositivo.
- **RR (R-R Interval):** Intervalo de tempo entre dois batimentos cardíacos sucessivos.
- **Marker:** Identificadores de eventos específicos inseridos durante a recolha. (Registos vazios por falta de anotações manuais)

Na Figura 4.1 pode observar-se uma representação temporal dos sinais anteriormente descritos, correspondente aos registos de um trabalhador ao longo de uma jornada laboral.

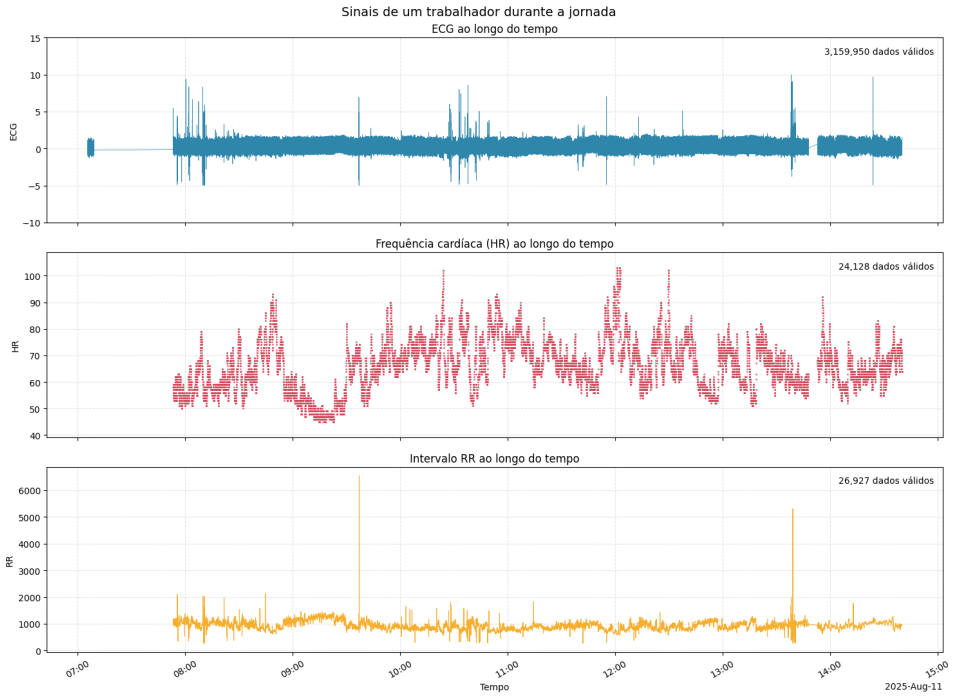


Figura 4.1: Sinais fisiológicos de um trabalhador durante uma jornada laboral, recolhidos pela banda Polar H10.

É importante notar que, embora o sensor de ECG opere a uma frequência de 130 Hz, as métricas de HR e RR são registadas apenas com uma cadência aproximada de 1 Hz (um registo por segundo). Esta discrepância de frequências resulta numa elevada densidade de entradas nulas (missing values) nas colunas HR e RR dentro dos ficheiros brutos, uma vez que estas linhas de dados apenas são preenchidas no momento exato em que o algoritmo interno do sensor deteta um novo batimento ou calcula a frequência cardíaca.

Relógio Empatica EmbracePlus

Os dados provenientes do relógio inteligente **Empatica EmbracePlus** foram obtidos diretamente a partir da plataforma cloud oficial do fabricante em formato CSV. Esta plataforma centraliza a receção dos dados sincronizados pelo dispositivo móvel associado, permitindo a extração dos registos estruturados das variáveis fisiológicas necessárias para a experimentação.

Ao contrário do Polar H10, em que os sinais são armazenados numa única estrutura temporal com elevada frequência de amostragem, o EmbracePlus organiza a informação em **múltiplos ficheiros CSV independentes**, correspondendo cada ficheiro a uma variável fisiológica ou comportamental distinta. Neste trabalho foi utilizado um único relógio, que foi usado pelo mesmo trabalhador durante vários dias de atividade laboral, permitindo acompanhar continuamente a evolução dos seus indicadores fisiológicos ao longo das diferentes jornadas.

A utilização de um único dispositivo e de um único participante constitui uma **limitação** deste conjunto de dados. Esta opção resultou das condições específicas do projeto, cujos dados foram recolhidos em simulações de obra e envolveram a participação remunerada de trabalhadores, bem como do **custo elevado** do relógio Empatica EmbracePlus, que condicionou a disponibilidade de equipamentos. Reconhece-se que a utilização do dispositivo por vários participantes permitiria obter uma maior diversidade interindividual e avaliar de forma mais robusta a capacidade de generalização dos modelos. A recolha de dados de um número maior de participantes constitui uma melhoria importante para trabalho futuro.

Cada dia de recolha origina um conjunto de **16 ficheiros CSV**, contendo aproximadamente **1441 registos**, correspondentes a uma resolução temporal de **1 minuto** ao longo das 24 horas do dia (00:00–23:59). De forma geral, todos os ficheiros apresentam uma estrutura semelhante, composta pelas seguintes colunas:

- **timestamp_unix:** marcação temporal em formato UNIX;
- **timestamp_iso:** representação da data e hora em formato ISO 8601;
- **participant_full_id:** identificador único do participante;
- **Variável fisiológica ou comportamental:** correspondente ao nome do respetivo ficheiro CSV.

Na Figura 4.2 apresentam-se alguns exemplos de dados fisiológicos e comportamentais recolhidos pelo Empatica EmbracePlus ao longo de um dia.

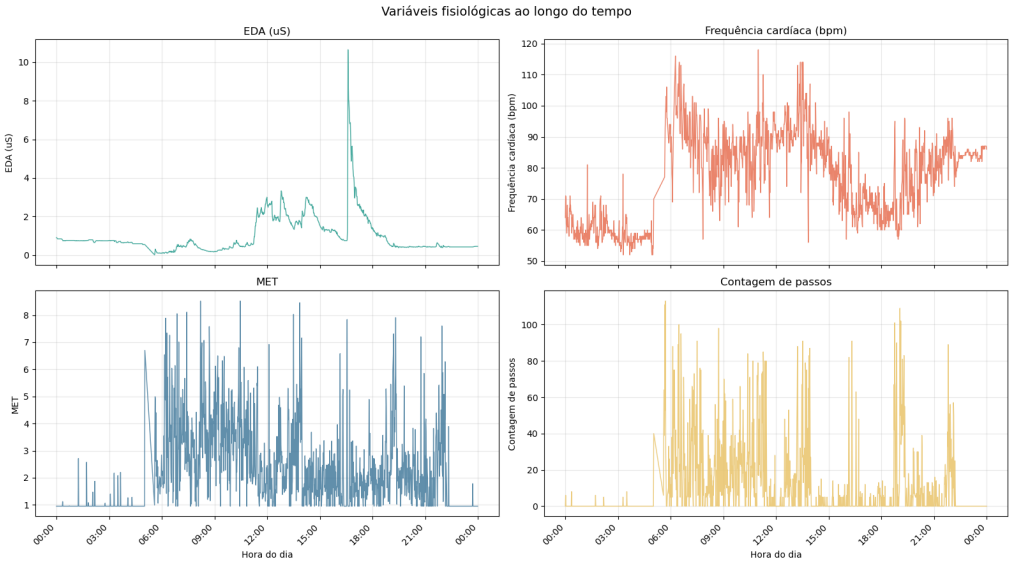


Figura 4.2: Evolução temporal de variáveis fisiológicas e comportamentais recolhidas pelo Empatica EmbracePlus.

Entre as variáveis disponibilizadas pela plataforma encontram-se diversos indicadores de atividade física, movimento corporal, resposta fisiológica e comportamento, incluindo métricas derivadas do acelerómetro, frequência cardíaca, atividade eletrodérmica (EDA), temperatura cutânea, taxa respiratória, variabilidade da frequência cardíaca (PRV/HRV), intensidade de atividade, gasto energético (MET), número de passos, deteção de sono e utilização do dispositivo.

É importante salientar que algumas variáveis apresentam limitações inerentes ao algoritmo de processamento do próprio dispositivo. Em particular, as métricas de **Pulse Rate Variability (PRV)** e **Respiratory Rate** apenas são estimadas quando o utilizador se encontra em repouso ou durante o período de sono. Consequentemente, durante a maior parte da jornada laboral estas variáveis permanecem sem valores válidos, originando uma elevada percentagem de *missing values*. Esta característica foi posteriormente considerada durante a fase de pré-processamento e seleção das variáveis utilizadas no modelo.

4.1.2 Tratamento de Dados em Falta e Limpeza de Ruído

A presença de dados ruidosos, artefactos de movimento e períodos com ausência de sinal é comum na monitorização fisiológica em ambientes industriais reais. O tratamento e limpeza diferem consoante o tipo de dispositivo e as variáveis medidas de forma a assegurar a qualidade dos dados para os modelos.

Banda Peitoral Polar H10

Como já se mencionou, os sinais de ECG apresentavam registos constantes, enquanto os de frequência cardíaca (HR) e intervalos R-R (RR) registavam apenas um valor por segundo, gerando muitas lacunas aparentes. Esta situação não representava um erro dos dados, mas sim a natureza da aquisição. No entanto, verificaram-se períodos de várias horas em que estas medições estavam ausentes, provavelmente devido a ruído ou falhas temporárias nos sensores, limitando a quantidade de dados disponíveis. Considerando estas circunstâncias, não foi adequada a imputação de valores médios ou de qualquer outra técnica de preenchimento. Em vez disso, à semelhança do procedimento adotado por Smiley et al. [68], nas experiências realizadas optou-se por agrupar os registos em janelas temporais de 30 ou 60 segundos, consoante a experiência, e calcular métricas agregadas, permitindo obter representações robustas de todas as variáveis e minimizar o efeito de lacunas e artefactos pontuais.

Esta agregação temporal revelou-se particularmente adequada para os algoritmos de aprendizagem automática utilizados, dado que a elevada frequência de amostragem do ECG (aproximadamente 130 Hz, um registo a cada 7 ms) combinada com HR e RR mais espaçados (cerca de 1 s) resultava em muitas linhas "vazias"para estas variáveis. As janelas temporais de 30 ou 60 segundos foram definidas com o objetivo de proporcionar uma representação mais consistente dos dados por instância, contribuindo para a estabilidade das características e para a análise da capacidade de generalização dos modelos. Esta diferença na completude dos dados pode ser observada na Tabela 4.1.

Tabela 4.1: Completude dos dados antes e depois das janelas de 30 segundos.

Fonte	Total de linhas	Linhas com algum dado em falta	Linhas completas	Percentagem de linhas com dados em falta
Dados brutos	3160177	3139392	20785	99,34%
Características processadas por janela	813	0	813	0,00%

Relógio Empatica EmbracePlus

Os dados provenientes do Empatica EmbracePlus apresentam uma estrutura temporal uniforme, com um registo por minuto para todas as variáveis disponibilizadas pela plataforma. Apesar desta uniformidade, foi realizada uma análise dos valores em falta (*missing values*), verificando-se que a maioria das variáveis fisiológicas e comportamentais apresentava apenas uma reduzida percentagem de registos ausentes (aproximadamente entre 2% e 4%). Em contrapartida, as variáveis PRV e Respiratory Rate apresentavam cerca de 75% e 74% de valores em falta, respetivamente, característica inerente aos algoritmos proprietários de processamento do Empatica EmbracePlus, pelo que foram posteriormente excluídas durante a etapa de seleção de características. A distribuição detalhada dos valores em falta é apresentada na Tabela 4.2.

Tabela 4.2: Percentagem de valores em falta nas variáveis do Empatica EmbracePlus.

Sinal	Variável analisada	Valores em falta (%)
PRV	`prv_rmssd_ms`	74,86
Respiratory Rate	`respiratory_rate_brpm`	73,89
Pulse Rate	`pulse_rate_bpm`	3,54
Body Position	`body_position_right`, `body_position_left`	2,64; 2,64
Accelerometers-STD	`accelerometers_std_g`	2,57
Actigraphy Counts	`counts_y_axis`, `counts_x_axis`, `counts_z_axis`, `vector_magnitude`	2,57 (cada)
ActiCounts	`acticounts_z_axis`, `acticounts_y_axis`, `acticounts_x_axis`	2,57 (cada)
Activity Counts	`activity_counts`	2,57
EDA	`eda_scl_usiemens`	2,57
Activity Intensity	`activity_intensity`	2,57
Activity Classification	`activity_class`	2,57
MET	`met`	2,57
Sleep Detection	`sleep_detection_stage`	2,57
Step Counts	`step_counts`	2,57
Temperature	`temperature_celsius`	2,57
Wearing Detection	`wearing_detection_percentage`	2,57

As Figuras 4.3 e 4.4 ilustram visualmente os períodos sem valores válidos observados nas variáveis PRV e Respiratory Rate, respetivamente. Estes intervalos prolongados ajudam a explicar a elevada percentagem de valores em falta apresentada na Tabela 4.2.

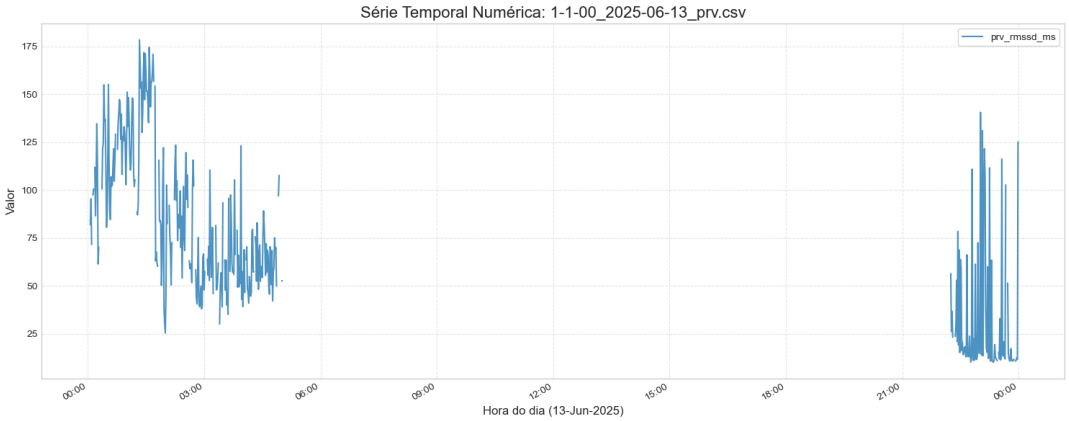


Figura 4.3: Série temporal da variável PRV-RMSSD, evidenciando os períodos sem valores registados.

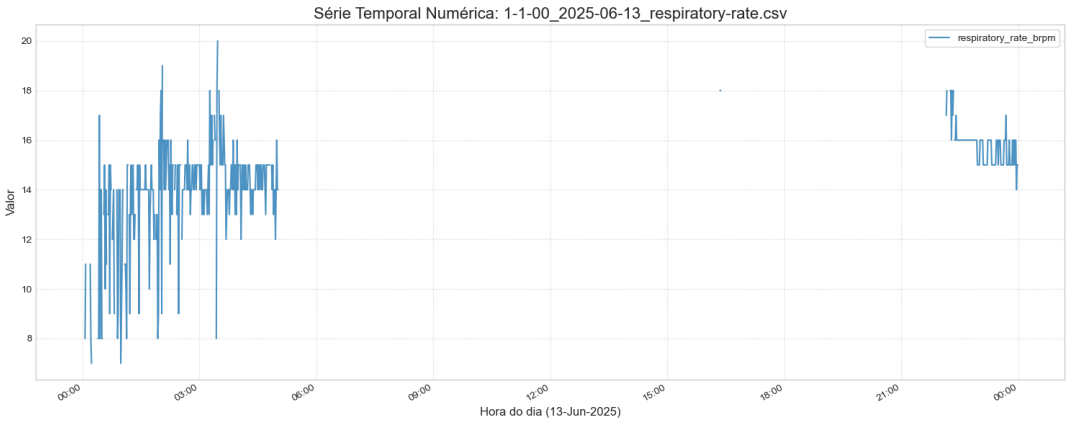


Figura 4.4: Série temporal da variável Respiratory Rate, evidenciando os períodos sem valores registados.

Considerando que as restantes variáveis apresentavam apenas pequenas lacunas temporais, foi aplicada uma estratégia de imputação diferenciada de acordo com a natureza dos dados. Para as variáveis numéricas contínuas (EDA, Pulse Rate, MET, Activity Counts, Step Counts, Temperature e Vector Magnitude) foi utilizada **interpolação linear (Linear Interpolation)**, que estima os valores em falta a partir da tendência definida pelos registos imediatamente anteriores e posteriores, permitindo preservar a continuidade temporal dos sinais fisiológicos.

Por sua vez, para as variáveis categóricas Activity Intensity e Sleep Detection Stage foi aplicado o método **preenchimento progressivo (Forward Fill)**, que consiste em propagar o último valor válido observado até ao instante em que um novo valor esteja disponível. Esta abordagem revelou-se adequada, uma vez que estas variáveis representam estados discretos que tendem a manter-se durante períodos consecutivos, tornando inadequada a utilização de métodos de interpolação numérica.

Adicionalmente, procedeu-se à deteção e tratamento de valores anómalos (*outliers*) nas variáveis utilizadas no treino dos modelos. Em vez de recorrer a métodos estatísticos, como o intervalo interquartil (*Interquartile Range* – IQR) ou o *Z-score*, optou-se por uma

abordagem heurística baseada em limites fisiologicamente plausíveis para cada biomarcador. Para o tratamento destes valores foi utilizada a técnica de clipping, que consiste em limitar os valores de uma variável a um intervalo previamente definido, substituindo apenas os valores inferiores ao limite mínimo pelo respetivo limite inferior e os valores superiores ao limite máximo pelo limite superior, preservando assim todas as observações do conjunto de dados. Os limites adotados para cada variável são apresentados na Tabela 4.3.

Os limites adotados foram estabelecidos com base em referências clínicas e biomecânicas. Por exemplo, o estudo PainFREE Rx II [76] analisou episódios de taquicardia ventricular rápida entre 188 e 250 bpm, sustentando a definição de 250 bpm como limite superior para a variável Pulse Rate; o estudo de Štuhec et al. [69], centrado no desempenho de Usain Bolt no sprint, serviu de referência para definir o limite de 300 passos/min para a variável Step Counts. Para as restantes medidas, nomeadamente EDA, MET, Activity Counts e Vector Magnitude, aplicou-se o mesmo princípio, definindo limites compatíveis com a natureza e a escala de cada variável para controlar valores implausíveis ou resultantes de artefactos.

Após o tratamento dos dados em falta, obteve-se um conjunto de dados consistente e sem valores ausentes nas variáveis consideradas para o treino dos modelos, garantindo a qualidade necessária para as etapas seguintes de engenharia de características e aprendizagem automática.

Tabela 4.3: Limites fisiológicos utilizados para a deteção e tratamento de valores anómalos

Variável	Limite mínimo	Limite máximo	Unidade
Pulse Rate	0	250	bpm
EDA	0	50	µS
MET	0,5	20	MET
Step Counts	0	300	passos/min
Activity Counts	0	100000	contagens
Vector Magnitude	0	50000	unidades

4.1.3 Engenharia e Seleção de Características

Após a conclusão das etapas anteriores, procedeu-se à engenharia e seleção de características. Este processo envolveu tanto a criação de novas métricas quantitativas a partir dos sinais fisiológicos brutos quanto a filtragem das variáveis mais relevantes para descrever o estado dos trabalhadores. Esta fase é determinante para converter dinâmicas corporais complexas em entradas estruturadas, otimizando o desempenho e a capacidade de generalização dos modelos de aprendizagem automática.

Características da Banda Peitoral Polar H10

As características utilizadas nos modelos foram obtidas através de um processo de engenharia de características aplicado aos sinais do Polar H10. Para além das variáveis de identificação, de tempo e de atividade, foram calculadas características de qualidade do sinal, métricas derivadas do ECG, indicadores de variabilidade da frequência cardíaca e variáveis temporais. As variáveis de identificação e de tempo, como `Trabajador`, `UNIX Timestamp`, `DateTime` e

`Actividad`, foram mantidas para organizar os registos, sincronizar as observações e contextualizar cada janela, não constituindo, por si só, características fisiológicas de entrada dos modelos.

Variáveis de Qualidade e ECG: Do sinal de ECG agregaram-se métricas estatísticas em cada janela temporal de 30 ou 60 segundos, dependendo da experiência, incluindo:

- **Média (ECG_mean):** valor médio do sinal, que representa o nível geral da atividade elétrica cardíaca.
- **Desvio padrão (ECG_std):** variabilidade do sinal dentro da janela, permitindo capturar instabilidade cardíaca.
- **Amplitude ou alcance (ECG_range):** diferença entre valor máximo e mínimo, indicando variações abruptas.
- **Energia do sinal (ECG_energy):** soma dos quadrados dos valores do sinal, correlacionando-se com intensidade do batimento [48].
- **Entropia amostral (ECG_samp_ent):** mede a complexidade do sinal e irregularidades que podem indicar stress ou fadiga [56].
- **Número de picos perdidos (ECG_missing_peaks):** indica falhas na detecção de batimentos, útil para identificar artefactos ou irregularidades fisiológicas [54].
- **HR_valid:** indicador da validade ou disponibilidade do valor de frequência cardíaca na respetiva janela.

Variáveis de HRV e Frequência Cardíaca: A partir dos intervalos R-R calcularam-se métricas clássicas de HRV em cada janela, nomeadamente SDNN, RMSSD e pNN50, cujas definições podem ser consultadas em [63]:

- **SDNN:** desvio padrão dos intervalos RR, indicador de variabilidade geral.
- **RMSSD:** raiz quadrada da média dos quadrados das diferenças sucessivas, sensível ao sistema nervoso parassimpático.
- **pNN50:** percentagem de diferenças consecutivas superiores a 50 ms, outro marcador de HRV.
- **HR_mean, HR_max, HR_min:** valores médio, máximo e mínimo da frequência cardíaca, fornecendo informação sobre esforço e recuperação.

Variáveis Temporais: Para representar a evolução dos sinais ao longo do tempo, foram ainda calculadas as seguintes variáveis, inspiradas no estudo [58]:

- **HR_mean_ultimos_5min:** média da frequência cardíaca nas cinco janelas anteriores, permitindo incorporar informação recente.
- **cambio_HR_vs_baseline:** diferença entre a frequência cardíaca observada e o valor de referência do trabalhador.
- **tendencia_HR:** direção da evolução da frequência cardíaca ao longo das janelas temporais.
- **cambio_RMSSD:** variação da RMSSD relativamente ao valor de referência.

A escolha e criação destas características baseia-se em estudos sobre stress e fadiga fisiológica [5, 21, 35]. As métricas calculadas a partir do ECG refletem a intensidade e complexidade da atividade elétrica do coração, enquanto as métricas de HRV e frequência cardíaca fornecem informação sobre a resposta autonómica e o equilíbrio entre esforço e recuperação. As variáveis temporais acrescentam contexto sobre a evolução recente dos sinais e sobre os desvios relativamente ao baseline individual. A agregação em janelas de 30 ou 60 segundos garante que cada instância de treino contenha dados suficientes para representar de forma robusta o estado do trabalhador, minimizando o efeito de lacunas ou artefactos pontuais.

Variáveis Estandardizadas: Para além das versões originais, cada variável fisiológica e temporal utilizada pelos modelos possui uma versão estandardizada com o sufixo `_z`. Estas versões foram calculadas relativamente ao baseline do registo, através da Equação 4.1:

$$z = \frac{x - \mu_{baseline}}{\sigma_{baseline}} \tag{4.1}$$

em que x representa o valor da variável na janela, $\mu_{baseline}$ corresponde à média da variável no baseline e $\sigma_{baseline}$ ao respetivo desvio padrão no baseline. Esta transformação coloca as variáveis numa escala comparável e permite avaliar cada observação relativamente ao padrão fisiológico de referência do trabalhador. Assim, por exemplo, `HR_mean` possui a correspondente versão `HR_mean_z`; o mesmo princípio aplica-se às restantes variáveis fisiológicas e temporais utilizadas.

Estas features servem de base para o FatigueIndex, que combina várias métricas normalizadas para gerar um valor contínuo representativo do estado de fadiga. Este índice é utilizado posteriormente como target em tarefas de regressão ou categorização.

Características do Relógio Empatica EmbracePlus

Ao contrário da banda peitoral Polar H10, na qual foi necessário criar novas características a partir dos poucos sinais extraídos de ECG e HR, o Relógio Empatica EmbracePlus disponibiliza um conjunto de variáveis fisiológicas e comportamentais previamente processadas pelos algoritmos proprietários da plataforma. Consequentemente, a etapa de engenharia de características centrou-se sobretudo na seleção das variáveis mais relevantes, na codificação das variáveis categóricas e na agregação temporal dos dados, de forma a obter um conjunto de características adequado para os modelos de aprendizagem automática.

Inicialmente, a plataforma disponibilizava um conjunto alargado de variáveis, tal como destacado nas secções anteriores. Contudo, verificou-se que várias destas métricas poderiam ser redundantes, apresentar pouca relevância para a deteção dos estados psicofisiológicos pretendidos ou, inclusive, conter uma elevada percentagem de valores em falta que inviabilizaria a continuidade da análise.

Em particular, as variáveis PRV-RMSSD (*Pulse Rate Variability*) e Respiratory Rate apresentavam aproximadamente 75% de valores em falta. Esta elevada proporção de dados ausentes está relacionada com as condições específicas em que o algoritmo do EmbracePlus disponibiliza estas métricas, nomeadamente períodos de repouso e sono, resultando numa cobertura temporal substancialmente inferior à das restantes variáveis analisadas. Consequentemente,

a sua inclusão conduziria a uma redução significativa do número de observações efetivamente disponíveis para análise e a uma menor comparabilidade com as restantes medidas fisiológicas, sobretudo durante os períodos de atividade laboral.

Além disso, a ausência destes valores está condicionada ao estado comportamental e fisiológico do participante. Assim, a aplicação de métodos convencionais de imputação poderia introduzir pressupostos pouco adequados sobre a evolução destas variáveis e potencialmente enviesar os resultados. Face a estas limitações de disponibilidade e cobertura temporal, optou-se por excluir a PRV-RMSSD e a Respiratory Rate das análises finais, privilegiando variáveis com maior completude e maior consistência na cobertura dos períodos de interesse do estudo.

Após esta análise, foi definido um conjunto reduzido de variáveis consideradas mais representativas para a deteção de estados fisiológicos associados à fadiga, incluindo:

- **EDA (eda_scl_usiemens):** indicador da atividade eletrodérmica, diretamente associado à ativação do sistema nervoso simpático e frequentemente utilizado como biomarcador de stress.
- **Pulse Rate (pulse_rate_bpm):** frequência cardíaca média, representando a resposta cardiovascular do trabalhador.
- **MET:** estimativa do gasto energético metabólico durante a atividade.
- **Activity Counts:** indicador global do nível de atividade física.
- **Step Counts:** número de passos realizados em cada minuto.
- **Vector Magnitude:** magnitude do movimento corporal obtida a partir do acelerómetro.
- **Activity Class:** classificação automática do tipo de atividade realizada.
- **Activity Intensity:** nível de intensidade da atividade física.
- **Sleep Detection Stage:** indicador do estado de vigília ou sono.

As variáveis categóricas foram posteriormente transformadas em formato numérico para permitir a sua utilização pelos algoritmos de aprendizagem automática. A variável **Activity Class** foi codificada através de **One-Hot Encoding**, originando uma coluna binária para cada categoria (*STILL*, *WALKING* e *GENERIC*). Esta abordagem foi escolhida porque estas categorias representam estados independentes, sem qualquer relação de ordem entre si, evitando que o modelo interprete artificialmente uma categoria como superior ou inferior a outra.

Por outro lado, as variáveis **Activity Intensity** e **Sleep Detection Stage** foram convertidas recorrendo a **Ordinal Encoding**. No caso da intensidade da atividade, existe uma progressão natural entre os diferentes níveis (*Sedentary*, *LPA*, *MPA* e *VPA*), permitindo representá-los pelos valores 0, 1, 2 e 3. De forma semelhante, a variável **Sleep Detection Stage** foi simplificada para distinguir apenas entre estado de vigília e estado de sono, agrupando as diferentes fases de sono numa única categoria, uma vez que o objetivo do estudo não era analisar a arquitetura do sono, mas apenas identificar períodos de descanso e recuperação fisiológica.

Finalmente, a fase experimental considerou dois níveis de granularidade temporal. Numa primeira abordagem, utilizaram-se os registos originais do EmbracePlus (amostragem de um

minuto), totalizando cerca de 1440 observações por dia. Na segunda, aplicou-se uma agregação em janelas de 10 minutos através do cálculo da média, reduzindo o volume para 144 registos diários. Esta estratégia visou estabilizar os sinais fisiológicos, permitindo identificar tendências de maior duração e avaliar o impacto da resolução temporal no desempenho dos modelos.

4.2 Modelação do Problema e Definição dos Modelos

Nesta secção, explicam-se os modelos de Inteligência Artificial escolhidos para prever os estados de fadiga e stress dos trabalhadores. O foco foi selecionar algoritmos capazes de analisar as variações dos sinais ao longo do tempo para identificar padrões de comportamento. Além da descrição de cada modelo, apresentam-se as estratégias de treino e os resultados obtidos, demonstrando como o sistema consegue transformar dados técnicos em alertas úteis para a segurança no trabalho através do Gémeo Digital.

4.2.1 Escolha do Algoritmo

A seleção dos algoritmos baseou-se no estado da arte apresentado no Capítulo 2. Como mostram os artigos analisados, os problemas supervisionados com dados fisiológicos e uma variável-alvo recorrem a XGBoost, Random Forest, SVM e modelos lineares [3, 26, 71]. Na ausência de etiquetas, estudos específicos recorrem a métodos não supervisionados, como GMM, K-Means e *clustering* hierárquico [24, 25]. Assim, a escolha considerou a natureza dos dados e a existência de um alvo em cada dispositivo.

Consequentemente, a metodologia foi definida em função da natureza e da disponibilidade dos dados, procurando simultaneamente explorar abordagens de ambas as famílias de aprendizagem. Em ambos os dispositivos não existia uma variável-alvo previamente definida para identificar diretamente os estados de fadiga. No caso do Polar H10, o conjunto de dados era mais limitado e centrado principalmente em variáveis numéricas cardiovasculares, pelo que foi construído o *FatigueIndex* a partir das características fisiológicas extraídas, cujo cálculo é explicado na secção seguinte, permitindo utilizá-lo como variável-alvo e formular o problema como uma tarefa de **aprendizagem supervisionada**, através de modelos de regressão e classificação.

Por outro lado, o Empatica EmbracePlus disponibilizava um conjunto de dados mais diversificado, incluindo variáveis de diferentes dimensões fisiológicas e comportamentais. Neste caso, optou-se por não definir previamente uma variável-alvo, explorando a estrutura dos dados através de uma abordagem de **aprendizagem não supervisionada**, baseada em *clustering*, permitindo identificar possíveis padrões ou perfis nos dados sem impor previamente classes de fadiga. Assim, as duas abordagens permitiram analisar o problema de forma complementar.

Algoritmos para a Banda Peitoral Polar H10

Para a banda Polar H10, focada na análise da fadiga e do esforço físico através de regressão e classificação, foram selecionados cinco algoritmos principais:

- **Regressão Linear:** escolhida pela sua simplicidade e interpretabilidade. Permite avaliar relações lineares diretas entre as features e o target, funcionando como baseline para comparação com modelos mais complexos.

- **XGBoost (Regressor e Classifier):** modelos baseados em árvores que capturam relações não lineares e interações complexas entre as variáveis. O Regressor permite prever valores contínuos, enquanto o Classifier trabalha com labels categóricos. XGBoost foi escolhido pela sua robustez, capacidade de generalização e bom desempenho em dados com variabilidade e ruído.
- **Support Vector Machine (SVM) com kernel RBF:** modelo não linear que projeta os dados num espaço de alta dimensão para encontrar fronteiras de decisão complexas. O kernel RBF permite capturar padrões subtis que não seriam detectáveis por modelos lineares, sendo útil tanto para regressão (SVR) como para classificação (SVC).
- **Logistic Regression:** modelo linear utilizado para classificação, que estima a probabilidade de pertença de cada observação às diferentes classes de fadiga. A sua simplicidade e interpretabilidade permitem comparar o desempenho de uma abordagem linear com os modelos não lineares.
- **Random Forest:** ensemble de árvores de decisão que combina as previsões de várias árvores treinadas com diferentes amostras e subconjuntos de características. Este algoritmo permite modelar relações não lineares e reduzir a dependência de uma única árvore, sendo adequado para dados com interações entre variáveis fisiológicas.

Em conjunto, estes modelos abrangem diversos níveis de complexidade, desde abordagens lineares a modelos baseados em árvores e máquinas de vetores de suporte. Esta diversidade permite comparar o desempenho de cada técnica na análise da fadiga e do esforço físico, avaliando o impacto da complexidade na precisão e capacidade de generalização das previsões.

Algoritmos para o Relógio Empatica EmbracePlus

Devido à natureza multidimensional dos dados do Empatica EmbracePlus, que integra múltiplos indicadores fisiológicos e comportamentais, e à inexistência de um label que representasse diretamente os estados de fadiga, a exploração centrou-se em algoritmos de clustering. O objetivo foi identificar padrões naturais nos dados, permitindo identificar diferentes estados fisiológicos e comportamentais sem a necessidade de categorias previamente definidas.

- **Gaussian Mixture Model (GMM):** modelo probabilístico adequado para dados fisiológicos, permitindo representar transições graduais entre diferentes estados através de probabilidades de pertença aos clusters. O número de clusters foi determinado com base no *Bayesian Information Criterion* (BIC), selecionando a configuração que apresentou o melhor equilíbrio entre qualidade do ajuste e complexidade do modelo.
- **Clustering Hierárquico Aglomerativo:** método que organiza progressivamente as observações numa estrutura hierárquica (dendrograma), facilitando a interpretação das relações entre os diferentes grupos. Neste trabalho foi utilizada a estratégia de ligação Ward com distância euclidiana. A seleção do número de clusters foi suportada pela análise do dendrograma, complementada pelo *Silhouette Score* e pela curva do cotovelo (*Elbow Method*).

O algoritmo K-Means foi utilizado apenas na fase exploratória para apoiar a análise da curva do cotovelo e determinar o número de clusters. Adicionalmente, compararam-se os resultados da seleção automática com configurações de clusters previamente definidas, permitindo validar a estrutura dos agrupamentos.

A combinação destas abordagens permite explorar os dados fisiológicos sob perspetivas probabilísticas e estruturais complementares. Esta sinergia facilita a identificação de padrões complexos captados pelo relógio inteligente e a sua associação a diferentes níveis de ativação do utilizador.

4.2.2 Definição de alvos para aprendizagem supervisionada

Como os dados brutos e as características extraídas dos dispositivos portáteis não contêm classificações prévias diretas (etiquetas ou labels) para estados psicofisiológicos complexos como a fadiga ou o nível de stress, tornou-se imperativo definir targets analíticos para supervisionar o treino dos modelos.

Cálculo da Variável Alvo para o Polar H10

Os dados adquiridos através da banda Polar H10 não continham um label direto que identificasse estados complexos como fadiga, cansaço ou stress. As variáveis disponíveis, como ECG, HR e HRV, fornecem apenas sinais fisiológicos brutos, que por si só não indicam de forma explícita o estado subjetivo do trabalhador. Por conseguinte, tornou-se necessário criar uma representação quantitativa que pudesse servir como target para os modelos de aprendizagem automática.

FatigueIndex: contínuo Uma abordagem possível foi a construção manual de um *label* contínuo, designado como *FatigueIndex*, através de uma combinação heurística de características fisiológicas extraídas dos sinais de frequência cardíaca (HR), variabilidade da frequência cardíaca (HRV) e eletrocardiograma (ECG), seguindo uma abordagem semelhante à utilizada por Karthikeyan et al. [35], que propuseram uma anotação heurística de fadiga baseada em características fisiológicas derivadas do ECG e da HRV. No presente trabalho, esta abordagem foi adaptada às características disponíveis e aos objetivos da investigação.

Para a construção do *FatigueIndex*, as *features* foram previamente estandardizadas utilizando o *z-score*, de forma a colocar as diferentes características numa escala comum, com média igual a 0 e desvio padrão igual a 1. A estandardização é calculada segundo a Equação 4.2:

$$z = \frac{x - \mu}{\sigma} \tag{4.2}$$

onde:

x é o valor original da feature, μ é a média da feature, σ é o desvio padrão da feature.

O FatigueIndex é calculado como uma combinação linear ponderada dos z-scores das features normalizadas, conforme mostrado no seguinte código Python:

```
fatigue_index = (
        1.2 * z_scores['HR_mean'] -
        1.0 * z_scores['RMSSD'] -
        0.8 * z_scores['SDNN'] -
        0.8 * z_scores['pNN50'] +
        0.6 * z_scores['ECG_energy'] +
        0.4 * z_scores['ECG_samp_ent'] +
        0.5 * z_scores['ECG_missing_peaks']
    )
```

Listing 4.1: Cálculo do FatigueIndex

Os coeficientes refletem a importância fisiológica estimada de cada métrica:

- **HR_mean** contribui positivamente, já que frequências cardíacas elevadas indicam maior esforço ou tensão [41].
- **RMSSD**, **SDNN** e **pNN50** contribuem negativamente, dado que uma maior variabilidade cardíaca está associada a uma maior capacidade de recuperação e a menor fadiga [51].
- **ECG_energy**, **ECG_samp_ent** e **ECG_missing_peaks** adicionam informação sobre intensidade, complexidade e eventuais irregularidades no ECG.

O resultado é um valor contínuo que representa de forma relativa o nível de fadiga de cada janela temporal de 30 ou 60 segundos, dependendo da experiência.

FatigueIndex: categórico Para os modelos de classificação que requerem *labels* categóricos, o *FatigueIndex* contínuo foi convertido em três classes através da utilização dos percentis 33 e 66 como pontos de corte. Esta abordagem foi inspirada em trabalhos anteriores que utilizaram estes percentis para transformar variáveis contínuas relacionadas com *wellness* e fadiga em três categorias destinadas a problemas de classificação [57]. A utilização destes dois pontos de corte corresponde à divisão da distribuição em três grupos de dimensão aproximadamente semelhante, permitindo definir categorias relativas de baixa, média e elevada fadiga sem recorrer a limiares absolutos previamente definidos.

- Valores abaixo do percentil P33 foram classificados como fadiga baixa;
- Valores entre os percentis P33 e P66 foram classificados como fadiga média;
- Valores acima do percentil P66 foram classificados como fadiga elevada.

Desta forma, foi possível criar um conjunto de dados com targets tanto contínuos como categóricos, permitindo utilizar diferentes tipos de modelos de aprendizagem automática com o objetivo de prever diferentes estados de atividade ou fadiga, conforme a tarefa de regressão ou classificação.

Cálculo da Variável Alvo para o Relógio Empatica EmbracePlus

Dada a ausência de etiquetas pré-definidas, a abordagem para o relógio Empatica EmbracePlus delegou a identificação de estados aos algoritmos de *clustering*. Esta estratégia de aprendizagem não supervisionada permite que o sistema agrupe os registos com base na sua semelhança estatística, identificando padrões naturais nos dados sem a imposição de fórmulas heurísticas ou um viés analítico prévio.

4.2.3 Normalização / Scaling de Features

A normalização (*feature scaling*) consiste na transformação das variáveis para uma escala comum, de forma a eliminar o efeito das diferenças de magnitude entre as *features*. Neste trabalho foi utilizada a técnica `StandardScaler` [61], que realiza uma estandardização do tipo *z-score*, transformando cada variável de modo a apresentar média igual a 0 e desvio padrão igual a 1.

Esta etapa revelou-se particularmente importante para os algoritmos baseados em distâncias ou na geometria do espaço de características, como o *Support Vector Machine* (SVM), utilizado no processamento dos dados da banda Polar H10, bem como para os algoritmos de

clustering aplicados aos dados do relógio inteligente Empatica EmbracePlus. Em algoritmos sensíveis à escala, a ausência de normalização pode fazer com que variáveis com amplitudes superiores dominem o cálculo das distâncias, influenciando indevidamente a formação dos *clusters* ou a definição das fronteiras de decisão; a importância desta etapa no treino dos modelos é também discutida e confirmada por Shao et al. [64].

Por outro lado, é amplamente reconhecido que os modelos baseados em árvores de decisão, como o XGBoost, são pouco sensíveis à escala das variáveis, uma vez que efetuam divisões com base em limiares e não em métricas de distância [62]. Ainda assim, a estandardização foi mantida sempre que necessária para garantir consistência entre as diferentes etapas do processamento e dos modelos experimentais.

4.2.4 Divisão do Dataset

Banda Peitoral Polar H10

Para avaliar corretamente o desempenho dos modelos de aprendizagem automática treinados com os dados de um único trabalhador, o conjunto de dados desse trabalhador foi dividido em três partes distintas: **treino**, **validação** e **teste**. Do total de dados disponíveis, 60% foram utilizados para o treino dos modelos, 20% para validação e 20% para teste, seguindo uma estratégia de divisão em três subconjuntos semelhante à utilizada por Tsao et al. [72], que treinaram modelos de aprendizagem automática com dados fisiológicos utilizando esta divisão. O conjunto de treino foi usado para aprender os padrões presentes nos dados, o conjunto de validação para ajustar e comparar diferentes modelos, e o conjunto de teste para avaliar o desempenho final em dados nunca vistos. Esta divisão permite avaliar a capacidade de generalização dos modelos, reduzindo o risco de sobreajuste (overfitting) e garantindo uma estimativa mais fiável do desempenho em novos dados. Como já mencionado anteriormente na Subsecção 4.1.2, os dados foram agregados em janelas temporais de 30 segundos. As divisões utilizadas podem ser consultadas na Figura 4.5.

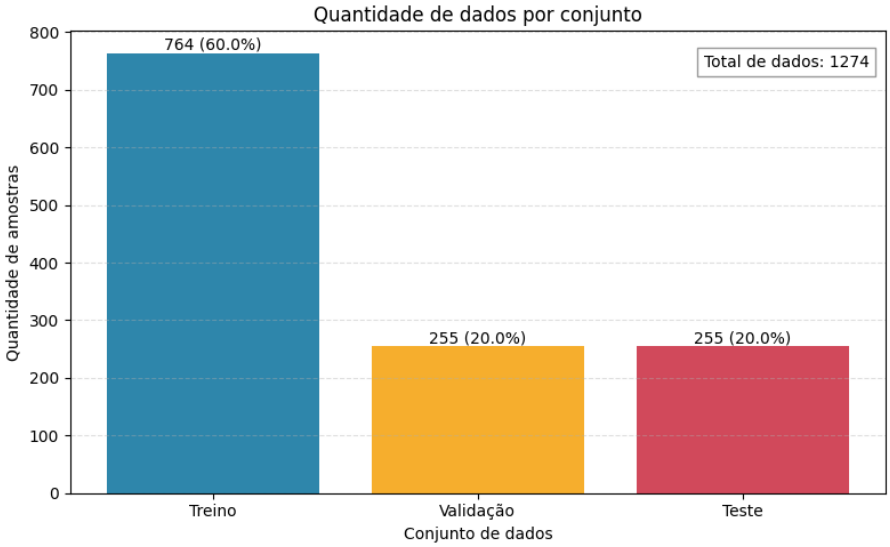


Figura 4.5: Divisão do conjunto de dados em treino, validação e teste.

Para os modelos treinados com dados de vários trabalhadores, foi utilizada uma validação cruzada *Leave-One-Subject-Out* (LOSO). Em cada iteração, os dados de um trabalhador

foram reservados para teste, enquanto os dados dos restantes trabalhadores foram utilizados para o treino. A seleção dos hiperparâmetros foi realizada através de uma validação cruzada interna estratificada de cinco partições, aplicada exclusivamente aos dados de treino. Esta abordagem foi inspirada em trabalhos como o de Behradfar e Nuamah [8], que utilizaram uma estratégia de validação cruzada LOSO aninhada para avaliar a generalização de modelos de aprendizagem automática aplicados a características derivadas de sinais ECG. Este procedimento permitiu avaliar a capacidade de generalização dos modelos para trabalhadores não observados durante o treino, reduzindo o risco de sobreajuste e evitando a utilização de informação do trabalhador de teste durante o processo de aprendizagem.

Relógio Empatica EmbracePlus

Ao contrário da abordagem supervisionada adotada para a banda Polar H10, os algoritmos de clustering aplicados aos dados do Empatica EmbracePlus não requerem uma divisão do conjunto de dados em treino, validação e teste, uma vez que o seu objetivo consiste em identificar padrões e agrupamentos naturais existentes nos dados, sem um alvo conhecido a prever. Deste modo, os algoritmos foram aplicados sobre o conjunto completo de dados previamente pré-processado, permitindo explorar toda a informação disponível durante o processo de agrupamento. A seleção do número de clusters foi efetuada com base em critérios internos de avaliação adequados a cada algoritmo.

Esta abordagem permitiu avaliar a qualidade e a consistência dos agrupamentos com base na estrutura interna dos dados, em vez da capacidade preditiva sobre um conjunto de teste independente.

4.3 Definição do Ambiente de Experimentação

Para garantir a reprodutibilidade dos testes e validar o desempenho dos modelos propostos, apresentam-se as especificações detalhadas do ambiente experimental. A configuração de hardware utilizada para o processamento dos dados e treino dos algoritmos é descrita na Tabela 4.4, enquanto a Tabela 4.5 detalha o ecossistema de software, incluindo as versões da linguagem de programação e das bibliotecas fundamentais.

A gestão das dependências foi realizada através de um ambiente virtual isolado (venv), assegurando que todos os pacotes e frameworks mantivessem a consistência necessária entre execuções, evitando conflitos de versões e garantindo que os resultados possam ser replicados em sistemas com configurações equivalentes.

Tabela 4.4: Especificações de Hardware da Workstation

Componente	Especificação
CPU (Processador)	Intel(R) Core(TM) Ultra 7 165H
Memória RAM	32 GB
FPU	Integrada na arquitetura CPU Intel Ultra 7
Armazenamento	1 TB NVMe SSD (Partição GPT)
Sistema Operativo	Windows 10 Pro

Tabela 4.5: Especificações de Software e Bibliotecas

Componente / Biblioteca	Versão
Python	3.10.11
Pandas	2.3.3
NumPy	2.2.6
Scikit-learn	1.7.2
XGBoost	3.1.3
SciPy	1.15.3
Antropy	0.1.9
Matplotlib	3.10.8

4.4 Avaliação Experimental

Nesta secção descreve-se a metodologia utilizada para treinar, avaliar e comparar os modelos de Inteligência Artificial desenvolvidos para os dois dispositivos em estudo. Para a banda peitoral Polar H10, são apresentados os resultados obtidos nas tarefas de regressão, utilizando o FatigueIndex contínuo como variável-alvo, e de classificação, recorrendo ao FatigueIndex categórico. Para o relógio inteligente Empatica EmbracePlus, é avaliado o desempenho das abordagens de aprendizagem não supervisionada, centradas na identificação de agrupamentos (clusters) representativos de diferentes estados fisiológicos. Em ambos os casos, são descritas as estratégias de treino, os critérios de avaliação e a comparação dos resultados obtidos.

4.4.1 Estratégia de Treino dos Modelos

A estratégia de treino adotada procurou equilibrar capacidade preditiva e generalização, recorrendo diferentes algoritmos com níveis de complexidade distintos para mapear e classificar os estados dos trabalhadores.

Modelos Treinados com Dados da Banda Peitoral Polar H10

Para este dispositivo, os modelos foram configurados e treinados conforme detalhado a seguir:

Regressão Linear. A regressão linear foi utilizada como modelo de referência (*baseline*), devido à sua simplicidade e interpretabilidade. Nas diferentes provas realizadas, foi utilizada a configuração por defeito do modelo, sem ajuste de hiperparâmetros, uma vez que este apresenta baixa complexidade e reduzida propensão ao overfitting. O seu desempenho serviu como ponto de comparação para avaliar os ganhos obtidos com modelos mais sofisticados.

XGBoost (Regressão e Classificação). Os modelos baseados em árvores de decisão foram treinados utilizando o algoritmo XGBoost, tanto na variante de regressão como de classificação. Nas diferentes provas realizadas, foram utilizadas configurações fixas ou diferentes combinações do número de árvores, da profundidade máxima e da taxa de aprendizagem, consoante o objetivo de cada avaliação. Na regressão, foi utilizada a avaliação por RMSE, enquanto na classificação foi adotada a função de perda *multiclass log-loss*. Para mitigar o overfitting, foi utilizada a técnica de *early stopping*, monitorizando o desempenho no conjunto de validação e interrompendo o treino quando não se verificavam melhorias após um

número consecutivo de iterações. No caso da regressão, o erro quadrático médio foi utilizado como métrica de avaliação durante o treino, enquanto na classificação foi adotada a função de perda *multiclass log-loss*. Para o modelo de classificação, o índice contínuo de fadiga (*FatigueIndex*) foi transformado em três classes (Baixo, Médio e Alto), com base em percentis calculados a partir do conjunto de treino.

Máquinas de Vetores de Suporte (SVM). Nas diferentes provas realizadas, o SVM foi utilizado tanto na variante de regressão, através do modelo SVR, como na variante de classificação, através do modelo SVC. Foram testadas diferentes configurações dos hiperparâmetros C, γ e *kernel*, permitindo comparar fronteiras lineares e não lineares nos dados. Devido à sensibilidade deste algoritmo à escala das variáveis, foi aplicado escalado das características antes do treino. O objetivo principal foi avaliar a capacidade do SVM em generalizar padrões temporais presentes nos sinais fisiológicos.

Logistic Regression. O modelo de Logistic Regression foi utilizado como abordagem linear para classificar as três classes do FatigueIndex. Devido à sensibilidade deste modelo à escala das variáveis, foi aplicado o escalado das características antes do treino. Foram testados diferentes valores do hiperparâmetro C, permitindo avaliar diferentes níveis de regularização e selecionar a configuração com melhor capacidade de generalização.

Random Forest. O modelo Random Forest foi utilizado para classificar as três classes do FatigueIndex. Através da combinação das previsões de múltiplas árvores de decisão, este modelo permite capturar relações não lineares e interações entre as características. Foram testadas diferentes combinações do número de árvores (`n_estimators`), da profundidade máxima (`max_depth`) e do número mínimo de amostras por folha (`min_samples_leaf`). Por se tratar de um modelo baseado em árvores, não foi necessário aplicar escalado às características.

A seleção dos hiperparâmetros foi realizada através da experimentação de diferentes combinações de valores. As configurações e grelhas utilizadas nos modelos encontram-se resumidas na Tabela 4.6.

Tabela 4.6: Hiperparâmetros utilizados nos modelos da banda Polar H10

Modelo	Hiperparâmetros experimentados
Regressão Linear*	`LinearRegression()` com os parâmetros por defeito: `fit_intercept=True`, `copy_X=True`, `n_jobs=None` e `positive=False`
SVM Regression*	`SVR(kernel='rbf')` com os parâmetros por defeito: $C = 1.0$, $\epsilon = 0.1$, $\gamma =$ `'scale'`, `coef0=0.0`, `degree=3`, `shrinking=True`, `tol=0.001` e `max_iter=-1`
XGBoost Regression*	`n_estimators=100`, `early_stopping_rounds=10`, `eval_metric='rmse'` e `random_state=42`; os restantes parâmetros ficaram por defeito
XGBoost Classification*	`n_estimators=100`, `early_stopping_rounds=10`, `eval_metric='mlogloss'` e `random_state=42`; os restantes parâmetros ficaram por defeito
Logistic Regression**	C: `[0.01, 0.1, 1, 10, 100, 300, 1000,` **`3000`**`, 10000]`; `class_weight: [None,` **`balanced`**`]`
Random Forest**	`n_estimators: [100, 200,` **`300`**`, 500]`; `max_depth: [None, 10,` **`20`**`, 30]`; `min_samples_leaf: [`**`1`**`, 2, 4]`
SVM Classification**	C: `[0.1, 1, 10, 100,` **`500`**`]`; γ: `['scale', 0.01,` **`0.1`**`, 0.5]`; *kernel*: `['`**`rbf`**`', 'linear']`
XGBoost Classification**	`n_estimators: [100, 200,` **`300`**`, 500]`; `max_depth: [`**`3`**`, 5, 7, 9]`; `learning_rate: [0.1,` **`0.2`**`, 0.5, 0.8]`

*Configuração utilizada na experiência com dados de um único trabalhador.
**Configuração utilizada na experiência com dados de todos os trabalhadores.
Os hiperparâmetros **assinalados** correspondem à configuração que apresentou o melhor desempenho na validação de cada modelo.

Adicionalmente, foi realizado um **estudo de ablação** (*ablation study*) para os modelos de regressão e classificação. Este procedimento consiste na remoção controlada de subconjuntos de características, com o objetivo de avaliar o impacto de diferentes grupos de variáveis no desempenho e na capacidade de generalização dos modelos. Esta abordagem foi inspirada num trabalho de avaliação de fadiga através de sinais ECG, no qual foram comparadas diferentes combinações de características fisiológicas através de estudos de ablação, de forma a analisar a contribuição de cada grupo de características para o desempenho dos modelos [21].

Foram considerados dois cenários de ablação. No primeiro cenário, o modelo foi treinado apenas com as características de frequência cardíaca e dos intervalos RR, nomeadamente `HR_mean`, `HR_max`, `HR_min`, `SDNN`, `RMSSD`, `pNN50` e `HR_valid`, bem como com as características temporais derivadas destas variáveis: `HR_mean_ultimos_5min`, `cambio_HR_vs_baseline`, `tendencia_HR` e `cambio_RMSSD`.

No segundo cenário, o modelo foi treinado apenas com as características derivadas do sinal ECG, nomeadamente `ECG_mean`, `ECG_std`, `ECG_range`, `ECG_energy`, `ECG_samp_ent` e `ECG_missing_peaks`, sendo esta última utilizada como indicador da qualidade da deteção dos picos ECG.

Estes dois cenários foram comparados com o modelo completo, que utilizou simultaneamente as características derivadas do ECG, as características de HR/RR e as variáveis temporais. Mantendo inalteradas as restantes condições de treino e os hiperparâmetros, esta abordagem permitiu avaliar a contribuição de cada grupo de características e verificar a robustez dos modelos na identificação de padrões associados à fadiga e ao esforço físico.

Modelos Treinados com Dados do Relógio Empatica EmbracePlus

Para este dispositivo, os modelos foram configurados e treinados conforme detalhado a seguir. Foram considerados dois algoritmos principais de clustering, complementados por uma abordagem baseada em janelas temporais (windowing) e por uma Árvore de Decisão para interpretação dos agrupamentos obtidos.

Gaussian Mixture Model (GMM). O *Gaussian Mixture Model (GMM)* é um algoritmo de aprendizagem não supervisionada que assume que os dados podem ser representados como uma combinação de várias distribuições Gaussianas. Ao contrário de métodos que atribuem cada observação a um único grupo de forma rígida, o GMM calcula a probabilidade de cada amostra pertencer a cada *cluster*, permitindo representar transições graduais entre diferentes estados fisiológicos.

O modelo foi treinado sobre o conjunto de dados previamente pré-processado, após a seleção das variáveis relevantes, remoção das observações com valores em falta e estandardização das *features* através do *StandardScaler*. Posteriormente, foi aplicada uma etapa de redução da dimensionalidade utilizando *Principal Component Analysis (PCA)*, preservando aproximadamente *90% da variância* dos dados. Neste modelo foi utilizada a configuração *covariance_type = full*, permitindo que cada componente Gaussiana possuísse a sua própria matriz de covariância, ou seja, que cada *cluster* pudesse apresentar diferentes dispersões e correlações entre as variáveis, tornando o modelo mais flexível na representação da distribuição dos dados. A inicialização dos componentes foi mantida com o valor por defeito da biblioteca *Scikit-learn*, recorrendo ao método *k-means*, sendo igualmente utilizado *random_state = 42* para garantir a reprodutibilidade dos resultados.

Durante a fase de treino foram avaliados modelos com diferentes números de *clusters* (*n_components* entre *2* e *9*). A configuração final foi selecionada com base no *Bayesian Information Criterion (BIC)*, um critério estatístico que avalia simultaneamente a qualidade do ajuste e a complexidade do modelo, penalizando soluções excessivamente complexas. Desta forma, foi possível selecionar objetivamente o número de *clusters* que melhor representava a estrutura dos dados sem incorrer em sobreajuste.

Clustering Hierárquico Aglomerativo. O *Clustering Hierárquico Aglomerativo* é um algoritmo de aprendizagem não supervisionada que constrói progressivamente uma hierarquia de agrupamentos, iniciando o processo com cada observação como um cluster independente e fundindo sucessivamente os grupos mais semelhantes até formar uma estrutura hierárquica. Neste modelo, foi utilizada a estratégia de ligação (*linkage*) *Ward*, que seleciona, em cada etapa, a fusão entre os dois clusters que provoca o menor aumento da variabilidade interna, favorecendo a formação de grupos mais compactos e homogéneos. A proximidade entre as observações foi calculada utilizando a distância euclidiana, por ser uma métrica amplamente utilizada para variáveis numéricas contínuas.

Após o pré-processamento dos dados, foi construída a matriz de ligação (*linkage matrix*), que regista, em cada etapa do algoritmo, quais os clusters que foram fundidos, a distância entre eles e o número de observações resultantes dessa fusão. Esta matriz serviu de base para a construção do dendrograma, permitindo visualizar a organização hierárquica dos dados e a forma como os agrupamentos evoluem ao longo do processo de agregação.

A determinação do número de clusters foi suportada por diferentes critérios. O *Silhouette Score* foi utilizado para avaliar simultaneamente a coesão interna e a separação entre os agrupamentos, enquanto a curva do cotovelo (*Elbow Method*), obtida através do algoritmo *K-Means*, permitiu analisar a evolução da variabilidade intra-cluster para diferentes valores de *k*. Durante esta fase exploratória foram avaliadas configurações entre 2 e 9 clusters.

Árvore de Decisão para Interpretação dos Clusters. Após a obtenção dos agrupamentos, foi treinada uma Árvore de Decisão, um algoritmo de aprendizagem supervisionada que constrói um conjunto de regras hierárquicas para classificar observações com base nas características de entrada. Neste caso, as variáveis fisiológicas e comportamentais originais foram utilizadas como atributos de entrada, enquanto as etiquetas produzidas pelos algoritmos de clustering aglomerativo constituíram a variável-alvo. O modelo foi configurado com o critério de divisão Gini (`criterion = gini`), uma profundidade máxima de 10 níveis (`max_depth = 10`), um mínimo de 10 amostras por folha (`min_samples_leaf = 10`) e `random_state = 42`, garantindo a reprodutibilidade dos resultados. O objetivo desta etapa não consistiu na criação de um novo modelo preditivo, mas sim na extração de regras de decisão simples e interpretáveis, permitindo identificar quais as variáveis mais relevantes para distinguir cada cluster e facilitar a interpretação dos diferentes estados fisiológicos identificados.

Análise Temporal por Janelas (Windowing). Adicionalmente, foi implementada uma variante baseada em janelas temporais, com o objetivo de reduzir a variabilidade dos sinais fisiológicos e captar padrões mais estáveis ao longo do tempo. Para este efeito, os dados foram agrupados em janelas consecutivas de 10 minutos (10 amostras), sem sobreposição, sendo cada janela representada pela média das variáveis que a compõem. Esta abordagem permitiu suavizar flutuações momentâneas e reduzir o efeito do ruído inerente aos sinais fisiológicos, evidenciando tendências temporais mais consistentes. O novo conjunto de dados agregado foi posteriormente utilizado para treinar novamente tanto o **GMM** como o **Clustering Hierárquico**, permitindo comparar o comportamento e a interpretabilidade de

ambos os algoritmos quando aplicados aos *dados originais com resolução temporal de um minuto* e aos *dados agregados em janelas temporais de 10 minutos*.

As configurações e os hiperparâmetros utilizados nos modelos treinados com os dados do relógio encontram-se resumidos na Tabela 4.7.

Tabela 4.7: Hiperparâmetros utilizados nos modelos do relógio Empatica EmbracePlus

Modelo	Hiperparâmetros experimentados
GMM*	Número de clusters `k=2..9`, `covariance_type='full'`, `n_init=10`, `random_state=42` e PCA a 90%. **Melhor seleção:** `k=9`**, segundo o modelo utilizado posteriormente e o BIC mínimo.**
Clustering hierárquico*	`k=2..9`, `linkage='ward'` e distância euclidiana. Foram avaliados WCSS e *Silhouette Score*. **Melhor** `k` **automático pelo Silhouette Score:** `k=8`**. Configuração final do clustering:** `k=5`**, selecionada manualmente.**
Decision Tree*	`max_depth=10`, `min_samples_leaf=10`, `criterion='gini'` e `random_state=42`. Validação cruzada com `cv=5`.
GMM com janela**	Janelas de 10 linhas, `k=2..9`, `covariance_type='full'`, `n_init=5` durante a pesquisa e `n_init=10` no modelo final. **Melhor seleção:** `k=5`**, segundo o modelo utilizado posteriormente e o BIC mínimo.**
Clustering hierárquico com janela**	Janelas de 10 linhas, `k=2..9` e `linkage='ward'`. Foram avaliados WCSS e *Silhouette Score*. **Melhor** `k` **automático pelo Silhouette Score:** `k=2`**. Configuração final do clustering:** `k=5`**, fixada manualmente.**
Decision Tree com janela**	`max_depth=10`, `min_samples_leaf=10`, `criterion='gini'` e `random_state=42`. Validação com `cv=5`.

*Configuração utilizada na experiência com os dados originais, com resolução temporal de um minuto.
**Configuração utilizada na experiência com dados agregados em janelas fixas de 10 minutos.

4.4.2 Métricas de Avaliação

Para avaliar e comparar o desempenho dos modelos desenvolvidos, selecionaram-se métricas específicas para a natureza de cada tarefa. Esta secção descreve os critérios utilizados tanto para a monitorização **supervisionada** da banda peitoral como para a análise **não supervisionada** do relógio inteligente. A seleção destas métricas foi orientada pelos resultados da revisão do estado da arte apresentada no Capítulo 2, nomeadamente pela resposta à QS4, dedicada às métricas mais utilizadas na avaliação de modelos aplicados à monitorização fisiológica.

Métricas de Avaliação para a Banda Peitoral Polar H10

Os modelos alimentados com os dados do Polar H10 foram avaliados tanto na experiência original quanto no *estudo de ablação* (sem características derivadas de HR e RR). Atendendo às duas abordagens supervisionadas propostas, a avaliação dividiu-se de acordo com o tipo de tarefa. A avaliação de tarefas supervisionadas de monitorização fisiológica deve combinar métricas de erro para previsões contínuas com métricas de desempenho e de equilíbrio entre classes para classificação. Por esse motivo, foram selecionadas as métricas descritas nos parágrafos seguintes, com base nas práticas reportadas na literatura.

- *Regressão:* Para os modelos de regressão (XGBoost, Regressão Linear e SVM), o desempenho foi avaliado utilizando o Mean Squared Error (MSE), o Root Mean Squared Error (RMSE), o Mean Absolute Error (MAE) e o Coeficiente de Determinação (R^2). A utilização de métricas como o RMSE e o MAE é consistente com a prática identificada na revisão do estado da arte, na qual Karim et al., Kakhi et al. e Fasoyinu et al. [22, 32, 33] recorrem a estas métricas para quantificar o desvio entre os valores previstos e os valores de referência. O MSE quantifica o erro quadrático médio das previsões, penalizando de forma mais acentuada os erros de maior magnitude, enquanto o RMSE corresponde à raiz quadrada do MSE, permitindo interpretar o erro na mesma escala da variável alvo. O MAE mede o erro absoluto médio e apresenta menor sensibilidade a valores extremos (*outliers*) do que o MSE. Por sua vez, o R^2 indica a proporção da variância do *FatigueIndex* explicada pelo modelo, complementando as métricas de erro com uma medida da capacidade explicativa dos modelos.
- *Classificação:* Para os modelos de classificação (Regressão Logística, Random Forest, SVM e XGBoost), o desempenho foi avaliado utilizando *Accuracy*, *Balanced Accuracy* e *Macro-F1*, complementadas pela precisão, *recall* por classe e matrizes de confusão. A *Accuracy* mede a proporção global de previsões corretas, enquanto a *Balanced Accuracy* corresponde à média dos *recalls* das três classes, permitindo considerar igualmente cada nível de fadiga. A *Macro-F1* corresponde à média dos F1-Scores por classe, sendo particularmente útil quando existe desequilíbrio entre classes. A utilização destas métricas é consistente com a prática identificada na revisão do estado da arte, na qual a *Accuracy* é frequentemente complementada pelo *F1-score* e *recall* para avaliar o desempenho em cada classe [3, 10, 22, 26, 75]. A matriz de confusão foi igualmente utilizada, seguindo a prática reportada por Umer et al. e Anjum et al. [4, 73], permitindo visualizar diretamente as previsões corretas e os erros entre os diferentes níveis de fadiga. Na validação cruzada interna, a *Balanced Accuracy* foi utilizada para selecionar os hiperparâmetros, enquanto o desempenho final foi avaliado através da estratégia *Leave-One-Subject-Out* (LOSO), à semelhança da abordagem utilizada por Behradfar e Nuamah [8].

Métricas de Avaliação para o Relógio Empatica EmbracePlus

Ao contrário das tarefas supervisionadas, os modelos aplicados aos dados do relógio Empatica EmbracePlus basearam-se em aprendizagem não supervisionada (sem etiquetas de referência), avaliando-se a qualidade dos agrupamentos através dos seguintes critérios, selecionados também com base nas práticas reportadas na literatura:

- *Gaussian Mixture Model (GMM):* Para determinar o número mais adequado de componentes, à semelhança do procedimento utilizado por Georgiev et al. no seu estudo [24], utilizou-se o *Bayesian Information Criterion* (BIC), que permite comparar modelos com diferentes níveis de complexidade, penalizando aqueles que utilizam um maior número de parâmetros e privilegiando, consequentemente, modelos com menor valor de BIC. Como complemento, seguindo a abordagem de Georgieva et al. [25], foi utilizado o *Silhouette Score*, uma métrica que avalia simultaneamente a coesão dos agrupamentos e a separação entre diferentes *clusters*. O seu valor varia entre -1 e 1, sendo que valores mais elevados indicam agrupamentos mais compactos e melhor separados. A utilização conjunta destes critérios segue a abordagem identificada no SOA, permitindo considerar tanto a qualidade do ajuste e a complexidade do modelo como a qualidade da separação dos agrupamentos.

- *Clustering Hierárquico Aglomerativo:* A seleção do número de *clusters* baseou-se na análise do dendrograma, uma representação gráfica que mostra, de forma hierárquica, como os diferentes grupos são progressivamente agregados. A altura das uniões representa a distância entre grupos, permitindo identificar divisões naturais através da definição de um nível de corte. À semelhança da abordagem adotada por Messaoud et al. no seu estudo [44], esta análise foi complementada pelo método do cotovelo (*Elbow Method*), baseado na *Within-Cluster Sum of Squares* (WCSS), que mede a dispersão das amostras dentro de cada *cluster*. À medida que o número de grupos aumenta, a WCSS diminui, sendo selecionado o ponto onde esta redução deixa de ser significativa, correspondendo ao "cotovelo". Adicionalmente, de forma semelhante ao procedimento utilizado por Georgieva et al. no seu estudo [25], foi calculado o *Silhouette Score* para quantificar a coesão interna e o distanciamento entre *clusters*, permitindo complementar a análise do número de grupos com uma medida da qualidade da separação dos agrupamentos. A utilização conjunta destes critérios permite considerar tanto a estrutura hierárquica e a dispersão dos agrupamentos como a qualidade da sua separação.
- *Árvore de Decisão para Interpretação dos Clusters:* A árvore de decisão foi utilizada como ferramenta interpretativa para descrever, através de regras simples, as decisões tomadas pelos algoritmos de agrupamento. A sua avaliação foi realizada recorrendo à *Accuracy* e à validação cruzada de 5 *folds*. Neste contexto, estas métricas não medem a capacidade preditiva do modelo sobre novos dados, mas sim o grau de fidelidade com que a árvore consegue reproduzir a atribuição dos *clusters*, permitindo avaliar a consistência das regras extraídas.
- *Análise Exploratória e Interpretação Fisiológica dos Clusters:* À semelhança do procedimento adotado por Shim, Fleisch e Barata no seu estudo [65], a interpretação fisiológica dos grupos foi baseada na caracterização estatística das variáveis de cada *cluster*, através da média e do desvio padrão. Neste trabalho, foi aplicada uma estratégia própria de interpretação, inspirada nessa abordagem de caracterização dos agrupamentos por perfis de variáveis. Para facilitar a análise, as médias foram classificadas de forma relativa em *LOW*, *MED* e *HIGH*, utilizando os percentis 33 e 66 da distribuição global. Esta abordagem permitiu identificar diferenças fisiológicas entre grupos e relacioná-las com a distribuição temporal dos *timestamps*, contribuindo para a interpretação dos diferentes estados fisiológicos observados ao longo da jornada de trabalho.

4.4.3 Performance dos Modelos, Comparação e Validação Externa

Para avaliar o desempenho e validar a robustez de cada abordagem na identificação de estados associados à fadiga, ao esforço físico ou ao stress, os modelos desenvolvidos foram submetidos aos respetivos processos de extração de métricas de performance. Enquanto os algoritmos supervisionados da banda peitoral Polar H10 foram avaliados através de conjuntos de teste isolados, os modelos de agrupamento não supervisionados do relógio Empatica EmbracePlus foram analisados com base na qualidade e consistência interna da estrutura dos clusters gerados sobre a totalidade dos dados.

Resultados das Experiências com a Banda Peitoral Polar H10

Inicialmente, optou-se por realizar as experiências com os dados de um único trabalhador. Esta abordagem permitiu estabelecer um caso de referência mais controlado e avaliar o funcionamento dos modelos antes de introduzir a variabilidade associada às diferenças fisiológicas e comportamentais entre trabalhadores. O objetivo desta primeira análise consistiu em verificar se as características obtidas através da engenharia de dados continham informação suficiente para prever, com precisão, diferentes estados de atividade e fadiga no mesmo indivíduo.

Neste contexto, foi igualmente analisada a utilidade potencial do *FatigueIndex* como indicador analítico do estado fisiológico do trabalhador. Consideraram-se tanto a sua representação numérica, utilizada nas tarefas de regressão, como a sua representação categórica, utilizada nas tarefas de classificação. Esta etapa permitiu avaliar se o índice calculado a partir das características fisiológicas e temporais conseguia produzir uma medida consistente e útil para distinguir diferentes níveis de fadiga e de atividade física, bem como comparar o comportamento dos modelos perante os dados resultantes do processo de engenharia de características.

Os modelos de regressão (XGBoost, Regressão Linear e SVM) e classificação (XGBoost Classifier) alimentados com os dados do Polar H10 foram avaliados conforme os dois cenários do estudo de ablação (com todas as características e sem características de HR/HRV).

Métricas de Modelos de Regressão:

A Tabela 4.8 apresenta os resultados obtidos na estimativa do índice contínuo de fadiga (*FatigueIndex*) para ambos os cenários.

Tabela 4.8: Resultados dos Modelos de Regressão

Modelo	Cenário	Árvores	MSE	RMSE	MAE	R^2
XGBoost Regression	Original	27	0.0757	0.2750	0.1076	0.9914
XGBoost Regression	Estudo de ablação	10	1.4947	1.2226	0.3415	0.8307
Regressão Linear	Original	–	0.0000	0.0000	0.0000	1.0000
Regressão Linear	Estudo de ablação	–	0.2659	0.5157	0.2336	0.9699
SVM	Original	–	0.6956	0.8340	0.2082	0.9212
SVM	Estudo de ablação	–	1.1517	1.0732	0.3588	0.8695

Os resultados mostram que todos os modelos apresentam um desempenho preditivo elevado no cenário original, utilizando todas as características disponíveis. A Regressão Linear apresenta um desempenho perfeito nos dados de teste ($R^2 = 1.0000$), com MSE, RMSE e MAE iguais a zero, indicando que, neste cenário, as características utilizadas permitem reproduzir exatamente os valores do FatigueIndex. O XGBoost Regression apresenta também um desempenho elevado ($R^2 = 0.9914$), com erros reduzidos, enquanto o SVM obtém um desempenho ligeiramente inferior ($R^2 = 0.9212$).

No *estudo de ablação*, a remoção das características derivadas de HR e RR provoca uma redução do desempenho dos três modelos, evidenciando a sua contribuição para a predição do FatigueIndex. A Regressão Linear mantém o melhor desempenho ($R^2 = 0.9699$), apesar do aumento dos erros (MSE = 0.2659; RMSE = 0.5157; MAE = 0.2336). O SVM apresenta uma redução mais moderada ($R^2 = 0.8695$), enquanto o XGBoost apresenta a maior diminuição do desempenho ($R^2 = 0.8307$), acompanhada por um aumento significativo dos

erros. Estes resultados sugerem que, embora as características derivadas de HR e RR contribuam de forma relevante para o desempenho dos modelos, as restantes características derivadas do ECG ainda contêm informação suficiente para obter estimativas consistentes do FatigueIndex.

A Figura 4.6 ilustra a importância relativa das features utilizadas no modelo de regressão XGBoost, destacando quais variáveis contribuem mais para as previsões do FatigueIndex.

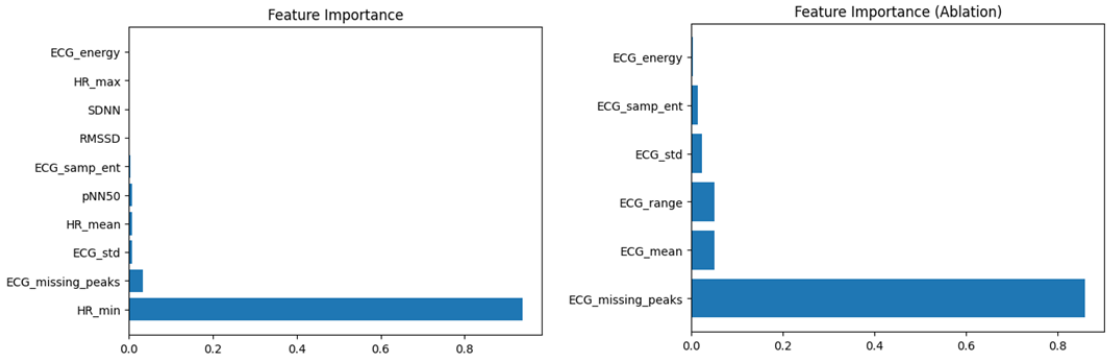


Figura 4.6: Importância das Features na Regressão

Comparação da importância das características no modelo de regressão, considerando todas as features e após a remoção das features derivadas de HR e HRV (*estudo de ablação*). Com todas as features, `HR_min` e `ECG_missing_peaks` são as mais determinantes. Após a remoção das features de HR e HRV, outras métricas derivadas do ECG ganham relevância, mas `ECG_missing_peaks` continua a ser a característica principal, evidenciando a sua contribuição crítica para o desempenho do modelo. Em conjunto com os resultados apresentados na tabela, esta análise sugere que as características selecionadas contêm informação suficiente para produzir previsões adequadas do FatigueIndex, mesmo após a remoção das características derivadas de HR e RR.

Os resultados obtidos na regressão indicam que as características utilizadas contêm informação suficiente para modelar o *FatigueIndex*, tanto no cenário original como no *estudo de ablação*, apresentando um desempenho particularmente elevado quando consideradas as observações de um único trabalhador ao longo da sua jornada. No entanto, o objetivo deste trabalho não se limita à estimação do valor numérico do índice, incluindo também a análise da sua representação categórica. Para esse efeito, o *FatigueIndex* foi convertido numa variável categórica através dos percentis P33 e P66, conforme descrito nas secções anteriores, dando origem a três rótulos analíticos definidos para este estudo (LOW, MEDIUM e HIGH). Estes rótulos resultam exclusivamente da discretização do índice construído e não correspondem a níveis clínicos ou a avaliações diretas de fadiga. Assim, torna-se pertinente avaliar se os modelos são igualmente capazes de distinguir entre estas categorias, conduzindo à análise dos modelos de classificação apresentada de seguida.

Métricas do Modelo de Classificação:

As Tabelas 4.9, 4.10 e 4.11 mostram que o desempenho do modelo XGBoost Classifier é praticamente idêntico nos dois cenários. Embora o número de árvores tenha sido ligeiramente reduzido no *estudo de ablação* (de 17 para 14), a *accuracy*, o F1-Score e a distribuição das classificações por classe permanecem inalterados. Estes resultados indicam que o modelo reproduz de forma consistente os rótulos analíticos definidos a partir do *FatigueIndex*, mesmo sem as características derivadas de HR e HRV. As métricas extraídas diretamente do ECG parecem, assim, conter informação suficiente para distinguir as três categorias analíticas utilizadas no estudo, sem que essa distinção constitua uma avaliação clínica ou direta de fadiga.

A Tabela 4.9 apresenta os resultados dos modelos de classificação para ambos os cenários.

Tabela 4.9: Resultados do XGBoost Classifier nos dois cenários de classificação

Modelo	Cenário	Número de Árvores	Accuracy
XGBoost Classifier	Original	17	97.65%
XGBoost Classifier	Estudo de ablação	14	97.65%

A *accuracy* manteve-se em 97,65% nos dois cenários. A remoção das características derivadas de HR e RR não alterou, portanto, o desempenho global do modelo, apesar da redução do número de árvores de 17 para 14.

A Tabela 4.10 apresenta o *Classification Report* por classe do XGBoost Classifier.

Tabela 4.10: Classification Report por Classe do XGBoost Classifier

Classe	Precision	Recall	F1-Score	Support
0	1.00	0.96	0.98	81
1	0.96	0.98	0.97	92
2	0.98	0.99	0.98	82
Accuracy			0.98	255
Macro Avg	0.98	0.98	0.98	255
Weighted Avg	0.98	0.98	0.98	255

O desempenho por classe é elevado, com valores de F1-Score entre 0,97 e 0,98 e médias macro e ponderada de 0,98. As diferenças entre classes são reduzidas, embora a classe 0 apresente menor *recall* (0,96) e a classe 1 menor *precision* (0,96).

A Tabela 4.11 apresenta a matriz de confusão.

Tabela 4.11: Matriz de Confusão do XGBoost Classifier nos dois cenários

	Predito 0	Predito 1	Predito 2
Real 0	78	3	0
Real 1	0	90	2
Real 2	0	1	81

A matriz de confusão confirma o elevado desempenho do modelo, uma vez que os erros se concentram apenas entre classes adjacentes. Não se observam confusões diretas entre as classes 0 e 2.

A Figura 4.7 ilustra a importância relativa das features utilizadas no modelo de classificação XGBoost, destacando quais variáveis contribuem mais para as previsões do FatigueIndex.

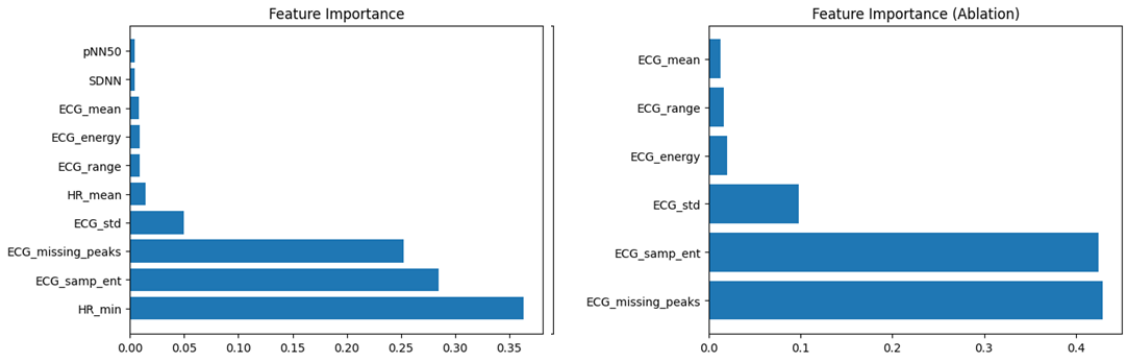


Figura 4.7: Importância das Features na Classificação

Comparação da importância das características no modelo XGBoost Classifier, considerando todas as features e após a remoção das features derivadas de HR e RR (*estudo de ablação*). Com todas as features, `HR_min` e `ECG_missing_peaks` apresentam a maior relevância na decisão do modelo. Após a remoção das features de HR e RR, outras métricas derivadas do ECG, como `ECG_samp_ent`, ganham importância, mas `ECG_missing_peaks` mantém-se como a característica mais influente, destacando a sua contribuição para a capacidade do modelo em reproduzir corretamente os rótulos analíticos definidos a partir do *FatigueIndex*.

Os resultados obtidos mostram que o XGBoost Classifier é capaz de reproduzir com elevada precisão as categorias analíticas (LOW, MEDIUM e HIGH) definidas a partir do *FatigueIndex*, tanto no cenário original como no *estudo de ablação*. Em conjunto com os resultados da regressão, estes resultados sugerem que as características fisiológicas utilizadas contêm informação suficiente para representar o estado fisiológico codificado pelo índice e permitir a sua estimação, quer como uma variável contínua, quer como uma variável categórica. No entanto, estes resultados foram obtidos considerando as observações de um único trabalhador, pelo que não permitem concluir que os modelos sejam capazes de generalizar para indivíduos diferentes.

Para avaliar esta questão, foi realizada uma experiência adicional na qual os modelos treinados com os dados do trabalhador W01 foram aplicados a outros trabalhadores, nomeadamente W02 e W03. A Tabela 4.12 apresenta os resultados desta análise para a Regressão Linear. Embora o modelo apresente um desempenho praticamente perfeito no próprio W01 ($R^2 = 1.0000$), este resultado não se mantém quando o modelo é aplicado a outros trabalhadores. No W02, o modelo no cenário original explica aproximadamente 32.45% da variabilidade do *FatigueIndex* ($R^2 = 0.3245$), enquanto no W03 explica apenas 17.33% ($R^2 = 0.1733$). Estes resultados evidenciam que o elevado desempenho observado no W01 não representa, por si só, uma medida da capacidade de generalização do modelo. Esta limitação é particularmente relevante considerando que o *FatigueIndex* foi construído a partir das próprias características fisiológicas utilizadas como variáveis preditoras. Assim, o modelo pode aprender relações muito específicas entre as características e os padrões fisiológicos de um determinado trabalhador que não se mantêm necessariamente para outros indivíduos.

Tabela 4.12: Desempenho da Regressão Linear treinada com W01 e aplicada a diferentes trabalhadores

Trabalhador	Cenário	MSE	RMSE	MAE	R^2
W01	Normal, todas as características	1.3045e-28	1.1421e-14	5.4600e-15	1.0000
W01	Ablação, sem HR/RR	0.2659	0.5157	0.2336	0.9699
W02	Normal, todas as características	6.1492	2.4798	1.6308	0.3245
W02	Ablação, sem HR/RR	5.0589	2.2492	1.7092	0.4442
W03	Normal, todas as características	9.9222	3.1499	2.9195	0.1733
W03	Ablação, sem HR/RR	12.6095	3.5510	2.9059	-0.0506

A diferença observada entre trabalhadores pode estar relacionada com a variabilidade individual das respostas fisiológicas, uma vez que valores semelhantes de uma característica podem representar estados fisiológicos distintos em indivíduos diferentes. Fatores como as características individuais, o nível habitual de atividade e as condições de registo dos sinais podem influenciar estas relações. Assim, embora os modelos demonstrem capacidade para aprender uma representação consistente do estado fisiológico codificado pelo índice dentro de um trabalhador, permanece em aberto a sua capacidade de generalizar para indivíduos não observados durante o treino. Esta questão é fundamental para o objetivo do estudo, que pretende desenvolver modelos capazes de estimar indicadores de ativação ou fadiga em diferentes trabalhadores, apesar das diferenças entre os seus padrões fisiológicos. Por este motivo, foram realizadas experiências adicionais com o objetivo de explorar diferentes métodos de treino e modelos que permitissem melhorar a capacidade de generalização entre trabalhadores. Os resultados dessas experiências são apresentados nas secções seguintes.

Avaliação para Melhorar a Generalização dos Modelos

Com o objetivo de melhorar a capacidade de generalização dos modelos entre trabalhadores, foi realizada uma nova experiência utilizando conjuntamente os dados dos trabalhadores W00 a W09. Nesta experiência, foram mantidas as variáveis utilizadas no experimento anterior, mas o processamento foi aplicado de forma padronizada a todos os trabalhadores. A partir do sinal de ECG, foram calculadas as variáveis `ECG_mean`, `ECG_std`, `ECG_range`, `ECG_energy`, `ECG_samp_ent` e `ECG_missing_peaks`. A partir dos intervalos RR, foram calculadas as métricas de variabilidade da frequência cardíaca `SDNN`, `RMSSD` e `pNN50`, bem como as variáveis `HR_mean`, `HR_max` e `HR_min`, derivadas da conversão dos intervalos RR em frequência cardíaca. Finalmente, foram criadas as variáveis temporais `HR_mean_ultimos_5min`, `cambio_HR_vs_baseline`, `tendencia_HR` e `cambio_RMSSD`, que representam, respetivamente, a média da frequência cardíaca nas cinco janelas anteriores, a variação da frequência cardíaca relativamente ao *baseline*, a tendência temporal da frequência cardíaca e a variação do RMSSD entre janelas consecutivas.

Os dados foram organizados em janelas consecutivas de 60 segundos. Esta escolha teve dois objetivos principais: reduzir a influência de variações instantâneas, obtendo estimativas mais estáveis das características fisiológicas, e diminuir o impacto dos períodos em que os sinais de HR ou RR não apresentavam valores válidos. Ao aumentar a duração de cada janela, foi possível agregar um maior número de observações e aumentar a probabilidade de obter janelas com todas as características necessárias disponíveis, reduzindo assim a perda de dados durante o processamento. Ao mesmo tempo, a duração de 60 segundos manteve uma resolução temporal suficiente para acompanhar as alterações associadas às diferentes

atividades realizadas pelos trabalhadores. Foram também construídas características temporais a partir de janelas anteriores, permitindo representar a evolução dos sinais ao longo do tempo.

Para reduzir o efeito das diferenças fisiológicas entre indivíduos, foi definido um *baseline* individual para cada trabalhador. Foram utilizadas as primeiras 15 janelas completas, correspondentes aproximadamente aos primeiros 15 minutos após a colocação da banda Polar H10 e anteriores ao início da jornada de trabalho. Este período de preparação foi considerado, presumivelmente, uma referência relativamente estável e próxima do estado habitual do trabalhador, sem exposição às exigências da atividade laboral. A partir destas janelas foram calculadas, para cada característica, a média e o desvio padrão individuais, utilizados posteriormente para avaliar as alterações fisiológicas de cada trabalhador.

Esta calibração pode ser comparada ao ajuste de uma balança a zero antes de efetuar uma medição: o sistema estabelece uma referência própria para cada trabalhador, a partir da qual as alterações posteriores podem ser interpretadas. A analogia representa, portanto, a adaptação da medição ao padrão individual, e não a definição de um valor fisiológico universal.

A normalização das características foi realizada através de uma transformação *Z-score* baseada no *baseline* individual, conforme a Equação 4.3:

$$z_{i,f} = \frac{x_{i,f} - \mu_{w,f}}{\sigma_{w,f}} \tag{4.3}$$

onde $x_{i,f}$ corresponde ao valor da característica f na janela i, enquanto $\mu_{w,f}$ e $\sigma_{w,f}$ representam, respetivamente, a média e o desvio padrão dessa característica no *baseline* do trabalhador w. Assim, um valor $z = 0$ corresponde ao comportamento médio do trabalhador, enquanto valores positivos ou negativos representam desvios acima ou abaixo do respetivo estado basal. A normalização foi realizada individualmente para cada trabalhador, não sendo utilizada uma média global.

Esta estratégia permite representar as características em termos de alterações relativas ao estado habitual de cada indivíduo, reduzindo a influência das diferenças interindividuais. Para cada variável original foi criada uma versão normalizada através do *Z-score*, identificada pelo sufixo _z. Foram estas versões normalizadas que constituíram as entradas dos modelos, permitindo que estes aprendessem padrões associados às variações fisiológicas e não apenas aos valores absolutos característicos de cada trabalhador. O *FatigueIndex* não foi utilizado como entrada, sendo calculado posteriormente a partir das características normalizadas e utilizado exclusivamente como variável objetivo.

O *FatigueIndex* é calculado da mesma forma que na experiência anterior, conforme apresentado no Código 4.1, através de uma combinação linear ponderada das mesmas sete variáveis fisiológicas normalizadas. Nesta experiência, essas variáveis foram calculadas relativamente ao *baseline* individual de cada trabalhador, conforme descrito anteriormente.

O índice representa, portanto, uma combinação de desvios fisiológicos relativamente ao *baseline* individual de cada trabalhador. Importa salientar que não corresponde a uma medida clínica direta de fadiga, sendo utilizado neste estudo como uma variável sintética de referência para a definição das categorias do problema de classificação.

Posteriormente, o *FatigueIndex* contínuo foi convertido em três categorias (LOW, MED e HIGH), utilizando os percentis P33 e P66 como limiares. Valores inferiores a P33 foram

classificados como LOW, valores entre P33 e P66 como MED e valores iguais ou superiores a P66 como HIGH. Para avaliar a capacidade de generalização entre trabalhadores, foi utilizada a validação cruzada *Leave-One-Subject-Out* (LOSO). Nesta estratégia, cada trabalhador é considerado, de forma sucessiva, como um sujeito independente: em cada iteração, todos os dados de um trabalhador são excluídos do treino e utilizados exclusivamente como conjunto de teste, enquanto os dados dos restantes trabalhadores são utilizados para treinar o modelo. O procedimento é repetido até que todos os trabalhadores tenham sido utilizados uma vez como sujeitos de teste. Para cada iteração, os percentis P33 e P66 foram calculados exclusivamente com os valores do conjunto de treino e posteriormente aplicados ao trabalhador utilizado como teste. Este procedimento evita que a distribuição do trabalhador de teste influencie a definição das categorias e permite avaliar o desempenho do modelo em indivíduos não observados durante o treino, verificando a sua capacidade de generalização para novos trabalhadores, sem que o modelo tenha sido treinado especificamente com os dados desses indivíduos.

O conjunto de dados resultante continha 2,638 janelas, tendo sido atribuída a cada uma delas uma das três categorias do *FatigueIndex*: LOW, MED ou HIGH. A distribuição global das classes foi equilibrada, com 871 observações LOW (33,02%), 870 observações MED (32,98%) e 897 observações HIGH (34,00%). No entanto, o número de observações variou significativamente entre trabalhadores, como apresentado na Tabela 4.13.

Tabela 4.13: Número de janelas disponíveis por trabalhador.

Trabalhador	Janelas	% do total	LOW	MED	HIGH
W00	104	3,9%	84 (80,8%)	6 (5,8%)	14 (13,5%)
W01	637	24,1%	117 (18,4%)	270 (42,4%)	250 (39,3%)
W02	603	22,9%	106 (17,6%)	270 (44,8%)	227 (37,7%)
W03	407	15,4%	66 (16,2%)	40 (9,8%)	301 (74,0%)
W04	562	21,3%	365 (65,0%)	179 (31,9%)	18 (3,2%)
W05	74	2,8%	21 (28,4%)	32 (43,2%)	21 (28,4%)
W06	35	1,3%	20 (57,1%)	6 (17,1%)	9 (25,7%)
W07	67	2,5%	8 (11,9%)	16 (23,9%)	43 (64,2%)
W08	133	5,0%	79 (59,4%)	46 (34,6%)	8 (6,0%)
W09	16	0,6%	5 (31,3%)	5 (31,3%)	6 (37,5%)
Total	**2638**	**100,0%**	**871 (33,0%)**	**870 (33,0%)**	**897 (34,0%)**

Verifica-se que W01, W02 e W04 concentram o maior número de observações, representando, respetivamente, 24,1%, 22,9% e 21,3% do conjunto total. Em contrapartida, W06, W07 e W09 apresentam um número consideravelmente menor de janelas, correspondendo apenas a 1,3%, 2,5% e 0,6% do total, respetivamente. Para além desta assimetria no número de observações, verifica-se também uma distribuição distinta das categorias entre trabalhadores. Por exemplo, a classe HIGH representa 74,0% das observações de W03, enquanto a classe LOW corresponde a 80,8% das observações de W00. Estes resultados mostram que, apesar do equilíbrio global entre as três classes, a sua distribuição não é uniforme entre trabalhadores.

Esta variabilidade na quantidade de observações e na distribuição das classes torna necessário avaliar os modelos de forma a garantir que o desempenho obtido não resulta apenas das características dos trabalhadores com maior representação no conjunto de dados. Por esse motivo, os trabalhadores foram separados entre treino e teste, permitindo verificar se os modelos mantêm um desempenho adequado quando aplicados a indivíduos que não participaram no processo de treino.

Outro aspeto relevante deste conjunto de dados corresponde à presença de valores em falta. Foram identificadas 1,732 janelas com pelo menos um valor ausente, correspondendo a 65,66% do total. A Figura 4.8 apresenta a distribuição das janelas totais e das janelas com valores em falta por trabalhador. As variáveis de HR e HRV apresentaram a maior proporção de valores em falta, enquanto algumas das características temporais também apresentaram ausência de dados. Estes valores ocorrem principalmente nas janelas iniciais ou em segmentos onde não foi possível calcular determinadas métricas de HRV ou variáveis dependentes de observações anteriores. Para tratar estes valores, foi utilizado o método `SimpleImputer(strategy='median')`, integrado no *pipeline* do modelo. Assim, em cada *fold*, a mediana de cada variável foi calculada exclusivamente com os dados de treino e utilizada para preencher os valores em falta tanto no treino como no trabalhador reservado para teste. Desta forma, o trabalhador de teste não influencia o cálculo das medianas nem o processo de aprendizagem do modelo.

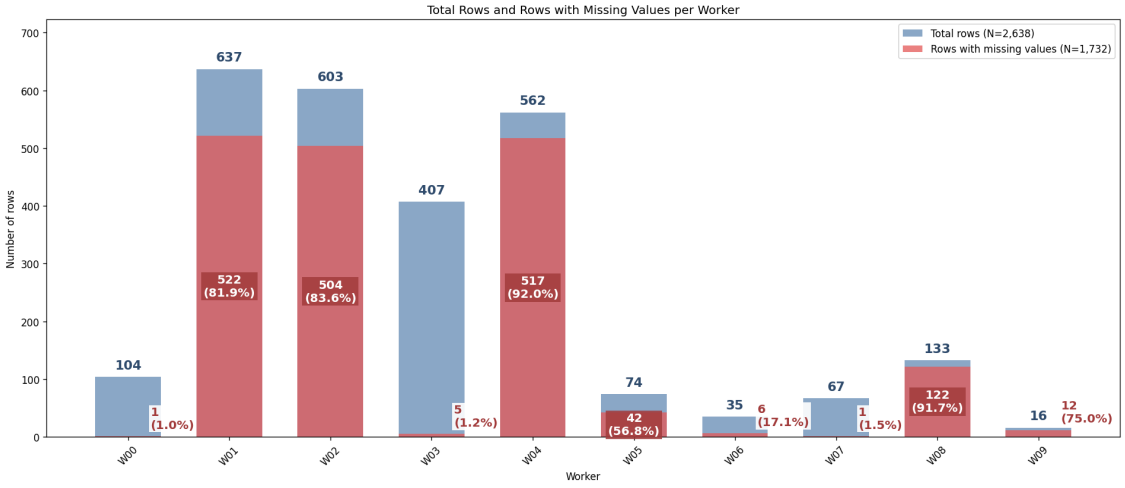


Figura 4.8: Número total de janelas e número de janelas com valores em falta por trabalhador.

A distribuição apresentada exige uma interpretação cautelosa dos resultados posteriormente obtidos. A disponibilidade desigual dos dados entre trabalhadores pode influenciar o desempenho dos modelos, uma vez que uma quantidade significativa de valores em falta pode comprometer a qualidade das características utilizadas. Estas falhas podem estar associadas, entre outros fatores, à colocação inadequada do dispositivo, a interrupções na transmissão dos dados ou a limitações temporárias na deteção dos sinais fisiológicos. Mesmo nos registos com menor quantidade de dados ausentes, é expectável uma percentagem residual de falhas durante a recolha. Por conseguinte, será necessário verificar, após a avaliação dos modelos, em que medida estas limitações poderão ter condicionado os resultados e confirmar a sua robustez em experiências futuras.

Por sua vez, foram avaliados quatro modelos de classificação: Regressão Logística, Random Forest, SVM e XGBoost. Os modelos receberam como entrada as características fisiológicas e temporais normalizadas e tiveram como objetivo distinguir entre as três categorias de fadiga. A seleção dos hiperparâmetros foi realizada através de validação cruzada interna estratificada no conjunto de treino, sem utilizar informação proveniente do trabalhador reservado para teste.

A avaliação da capacidade de generalização foi realizada através de *Leave-One-Subject-Out Cross-Validation* (LOSO). Em cada iteração, um trabalhador é completamente excluído do treino e utilizado exclusivamente como conjunto de teste, enquanto os restantes trabalhadores são utilizados para treinar o modelo. Neste processo, os limiares P33 e P66, o imputador e os restantes passos de transformação são determinados apenas a partir dos dados de treino, sendo posteriormente aplicados ao trabalhador excluído. O procedimento é repetido até que todos os trabalhadores tenham sido utilizados uma vez como conjunto de teste. Desta forma, a avaliação permite medir diretamente a capacidade do modelo para generalizar para um indivíduo não observado durante o treino.

A Tabela 4.14 apresenta, para o XGBoost, os resultados obtidos em cada uma das dez iterações da avaliação LOSO, permitindo analisar não apenas o desempenho médio do modelo, mas também a variabilidade dos resultados entre trabalhadores.

Tabela 4.14: Validação LOSO do modelo XGBoost Classifier.

Teste	Treino	Recall LOW	Recall MED	Recall HIGH	Accuracy	Balanced Accuracy	Macro-F1
W00	W01–W09	0,976190	0,833333	0,785714	0,942308	0,865079	0,854900
W01	W00, W02–W09	0,941748	0,921260	0,989286	0,954474	0,950764	0,948538
W02	W00–W01, W03–W09	0,895349	0,924460	0,933054	0,923715	0,917621	0,909651
W03	W00–W02, W04–W09	0,938462	0,760000	0,977918	0,958231	0,892127	0,903044
W04	W00–W03, W05–W09	0,968421	0,911392	1,000000	0,960854	0,959938	0,896447
W05	W00–W04, W06–W09	0,857143	0,937500	0,904762	0,905405	0,899802	0,907857
W06	W00–W05, W07–W09	1,000000	0,500000	1,000000	0,914286	0,833333	0,855472
W07	W00–W06, W08–W09	0,875000	0,250000	0,860465	0,716418	0,661822	0,580319
W08	W00–W07, W09	0,614458	0,372093	0,714286	0,541353	0,566946	0,454266
W09	W00–W08	1,000000	1,000000	1,000000	1,000000	1,000000	1,000000
Média	*Média dos folds*	0,906677	0,741004	0,916549	0,881704	0,854743	0,831049

Os resultados mostram alguma variabilidade no desempenho do XGBoost consoante o trabalhador utilizado como teste. Globalmente, este foi o modelo que apresentou o melhor desempenho. Nos trabalhadores W01, W02, W03 e W04, o modelo apresenta valores de Accuracy superiores a 0,92, enquanto em W07 e, sobretudo, W08, o desempenho é consideravelmente inferior. No caso de W08, a Accuracy é de 0,54 e o Macro-F1 de 0,45, indicando maior dificuldade em generalizar para este trabalhador. Em contrapartida, o fold correspondente a W09 apresenta desempenho perfeito, embora este resultado deva ser interpretado com cautela devido ao reduzido número de observações deste trabalhador.

De forma global, a média dos dez folds corresponde a uma Accuracy de 0,88, uma Balanced Accuracy de 0,85 e um Macro-F1 de 0,83. O recall foi de 0,91 para LOW, 0,74 para MED e 0,92 para HIGH. Estes resultados mostram que, apesar das diferenças observadas entre trabalhadores, o modelo mantém um desempenho global elevado quando aplicado a indivíduos que não foram utilizados no treino.

As tabelas detalhadas da avaliação LOSO para os modelos Random Forest, SVM e Regressão Logística podem ser consultadas no **Apêndice C**. Para facilitar a comparação entre os modelos, a Tabela 4.15 apresenta as principais métricas médias obtidas na avaliação LOSO.

Tabela 4.15: Médias globais dos modelos de classificação da avaliação LOSO.

Modelo	Recall LOW	Recall MED	Recall HIGH	Accuracy	Balanced Accuracy	Macro-F1
XGBoost	0,91	0,74	0,92	0,88	0,85	0,83
Random Forest	0,90	0,70	0,89	0,86	0,83	0,80
SVM	0,81	0,65	0,88	0,81	0,78	0,73
Regressão Logística	0,87	0,66	0,69	0,78	0,74	0,70

A comparação entre os modelos mostra que o XGBoost apresenta o melhor desempenho global, com os valores mais elevados de Accuracy (0,88), Balanced Accuracy (0,85) e Macro-F1 (0,83). O Random Forest apresenta resultados próximos, com uma Accuracy de 0,86, uma Balanced Accuracy de 0,83 e um Macro-F1 de 0,80. O SVM apresenta um desempenho inferior, com uma Accuracy de 0,81 e um Macro-F1 de 0,73. Por sua vez, a Regressão Logística obtém os valores mais baixos, com uma Accuracy de 0,78 e um Macro-F1 de 0,70.

A análise do recall mostra ainda que o XGBoost apresenta os melhores resultados nas três categorias, com valores de 0,91 para LOW, 0,74 para MED e 0,92 para HIGH. A classe MED apresenta o menor recall nos quatro modelos, indicando uma maior dificuldade na sua identificação. No caso da Regressão Logística, observa-se também uma redução mais acentuada no desempenho da classe HIGH, com um recall de 0,69.

Para aprofundar a análise do modelo com melhor desempenho, a Tabela 4.16 apresenta o *Classification Report* agregado do XGBoost na avaliação LOSO, incluindo o número de observações, o recall e a precisão obtidos para cada classe.

Tabela 4.16: Classification Report por Classe do XGBoost na avaliação LOSO.

Classe	Support	Recall	Precision
LOW	950	0,924	0,940
MED	744	0,867	0,874
HIGH	944	0,959	0,937

Neste contexto, o *recall* indica a proporção de observações reais de cada classe que foi corretamente identificada, enquanto a *precision* indica a proporção de previsões de uma classe que estava correta. As tabelas de classificação detalhadas dos restantes modelos podem ser consultadas no **Apêndice C**.

Os resultados do *Classification Report* mostram que o XGBoost apresenta um desempenho elevado nas três categorias. A classe HIGH apresenta o maior recall (0,959), seguida da classe LOW (0,924) e da classe MED (0,867). A precisão apresenta valores igualmente elevados, variando entre 0,874 e 0,940. Estes resultados indicam que o modelo consegue identificar de forma consistente as três categorias, embora a classe MED continue a apresentar um desempenho ligeiramente inferior às restantes.

Para analisar de forma mais detalhada os erros cometidos pelo modelo com melhor desempenho, foi construída a matriz de confusão agregada dos dez folds da avaliação LOSO para o XGBoost, apresentada na Tabela 4.17. As matrizes de confusão dos restantes modelos podem ser consultadas no **Apêndice C**.

Tabela 4.17: Matriz de Confusão Agregada dos Dez Folds da avaliação LOSO.

	Low	Medium	High
Low	878	63	9
Medium	47	645	52
High	9	30	905

A matriz de confusão mostra que a maioria das observações foi corretamente classificada pelo XGBoost. Das observações pertencentes à classe LOW, 878 foram corretamente identificadas, enquanto 63 foram classificadas como MED e 9 como HIGH. Para a classe MED, 645 observações foram corretamente classificadas, verificando-se 47 classificações como LOW e 52 como HIGH. Na classe HIGH, 905 observações foram corretamente identificadas, enquanto 9 foram classificadas como LOW e 30 como MED.

Os erros observados concentram-se sobretudo entre categorias adjacentes, sendo a classe MED a que apresenta maior dificuldade de identificação. Este comportamento é consistente com o menor recall obtido para esta categoria, uma vez que uma parte relevante das observações MED é classificada como LOW ou HIGH. Em contrapartida, as classes LOW e HIGH apresentam um número reduzido de classificações entre si, sugerindo que o modelo consegue distinguir de forma mais consistente os extremos do *FatigueIndex*.

Em conjunto, estes resultados mostram que a utilização de características normalizadas relativamente ao *baseline* individual, combinada com dados de vários trabalhadores e com uma avaliação LOSO, permite obter uma capacidade de generalização considerável. Apesar da variabilidade observada entre trabalhadores, o XGBoost apresentou o melhor desempenho médio entre os modelos avaliados, mantendo resultados elevados em vários dos trabalhadores utilizados como teste.

Esta abordagem representa uma evolução relativamente às experiências anteriores, nas quais o desempenho elevado era sobretudo observado quando os dados de treino e teste pertenciam ao mesmo trabalhador. Ao utilizar uma referência fisiológica individual e ao separar completamente os trabalhadores entre treino e teste, a avaliação aproxima-se mais das condições de aplicação pretendidas, nas quais o modelo deverá ser capaz de identificar os diferentes níveis do *FatigueIndex* em trabalhadores não observados durante o treino. Neste contexto, o XGBoost surge como o modelo com maior potencial para as análises desenvolvidas nas experiências seguintes.

Testes de Ablação dos Modelos Otimizados para Generalização

Após a análise da capacidade de generalização dos modelos, foi realizado um *estudo de ablação* para avaliar o contributo dos diferentes grupos de características para o desempenho da classificação. Foram consideradas características derivadas do ECG, de HR e dos intervalos R-R, bem como variáveis temporais delas derivadas, procurando determinar se seria possível reduzir o conjunto de entradas sem comprometer significativamente a capacidade de generalização.

Esta análise apresenta também interesse do ponto de vista prático, uma vez que as características derivadas de HR e R-R apresentam, em determinadas janelas, uma maior presença de valores em falta, devido às próprias características do processo de aquisição e cálculo destas medidas. Além disso, a sua utilização pode estar associada a limitações na deteção das medidas em determinadas condições de registo. Neste contexto, avaliar o impacto da sua remoção permite determinar se as características derivadas do ECG conseguem fornecer informação suficiente para manter um desempenho adequado, reduzindo simultaneamente a dependência de variáveis com maior ocorrência de valores em falta.

Para esta análise foram considerados três cenários experimentais. O cenário A, já apresentado na secção anterior, corresponde à utilização de todas as características. No cenário B, foram removidas as características derivadas diretamente do ECG, mantendo-se apenas as

características de HR/R-R e temporais. No cenário C, foram removidas as características de HR/R-R e temporais, sendo utilizadas exclusivamente as características derivadas do ECG.

Em todos os cenários, foram mantidas as condições de avaliação utilizadas anteriormente, nomeadamente a validação *Leave-One-Subject-Out Cross-Validation* (LOSO). Em cada iteração, um trabalhador foi reservado exclusivamente para teste, enquanto os restantes foram utilizados no treino. A definição das categorias, a imputação dos valores em falta e os restantes passos de transformação foram realizados sem utilizar informação do trabalhador de teste. Desta forma, foi possível comparar os diferentes conjuntos de características nas mesmas condições e avaliar simultaneamente a sua contribuição para a classificação e a capacidade de generalização para trabalhadores não observados durante o treino.

Os resultados dos cenários B e C são comparados com o cenário A, utilizado como referência, na Tabela 4.18. Desta forma, a análise centra-se no impacto da remoção de diferentes grupos de características.

Tabela 4.18: Comparação do desempenho dos modelos nos três cenários do estudo de ablação, com avaliação LOSO.

Modelo	Cenário	Accuracy	Balanced Accuracy	Macro-F1
Regressão Logística	A: Todas as características	0,7817	0,7426	0,7007
Regressão Logística	B: HR/R-R + temporais	0,5647	0,5309	0,4709
Regressão Logística	C: ECG	0,5974	0,5369	0,5012
Random Forest	A: Todas as características	0,8616	0,8291	0,8039
Random Forest	B: HR/R-R + temporais	0,6619	0,6436	0,6045
Random Forest	C: ECG	0,6636	0,6073	0,5728
SVM	A: Todas as características	0,8055	0,7799	0,7311
SVM	B: HR/R-R + temporais	0,6210	0,6213	0,5569
SVM	C: ECG	0,6133	0,5749	0,5296
XGBoost	A: Todas as características	0,8817	0,8547	0,8310
XGBoost	B: HR/R-R + temporais	0,6566	0,6413	0,5991
XGBoost	C: ECG	0,6783	0,6136	0,5892

A comparação entre os três cenários evidencia uma perda de desempenho quando parte das características é removida. Em todos os modelos, o cenário A, que combina as características de ECG, HR/R-R e temporais, apresenta os melhores resultados, confirmando o contributo complementar destas fontes de informação. No XGBoost, o cenário A produz uma Accuracy de 0,8817, uma Balanced Accuracy de 0,8547 e um Macro-F1 de 0,8310; no cenário B, baseado apenas em HR/R-R e variáveis temporais, estes valores descem para 0,6566, 0,6413 e 0,5991, respetivamente. Esta redução mostra que esse subconjunto não preserva o desempenho obtido com a combinação completa das variáveis.

No cenário C, baseado exclusivamente nas características derivadas do ECG, o XGBoost obtém uma Accuracy de 0,6783, uma Balanced Accuracy de 0,6136 e um Macro-F1 de 0,5892. Embora o ECG permita recuperar ligeiramente a Accuracy face ao cenário B, os valores inferiores de Balanced Accuracy e Macro-F1 mostram que essa vantagem não se distribui uniformemente pelas classes, mantendo-se os resultados claramente abaixo do cenário A. Os restantes modelos seguem a mesma tendência: no Random Forest, as Accuracies dos cenários B e C são semelhantes (0,6619 e 0,6636), mas o cenário B apresenta melhor Balanced Accuracy (0,6436 contra 0,6073) e Macro-F1 (0,6045 contra 0,5728); no SVM, a Accuracy diminui de 0,8055 no cenário A para 0,6210 no cenário B e 0,6133 no cenário C; e, na Regressão Logística, diminui de 0,7817 para 0,5647 e 0,5974, respetivamente.

A Figura 4.9 apresenta a importância relativa das características utilizadas pelo XGBoost nos três cenários do estudo de ablação.

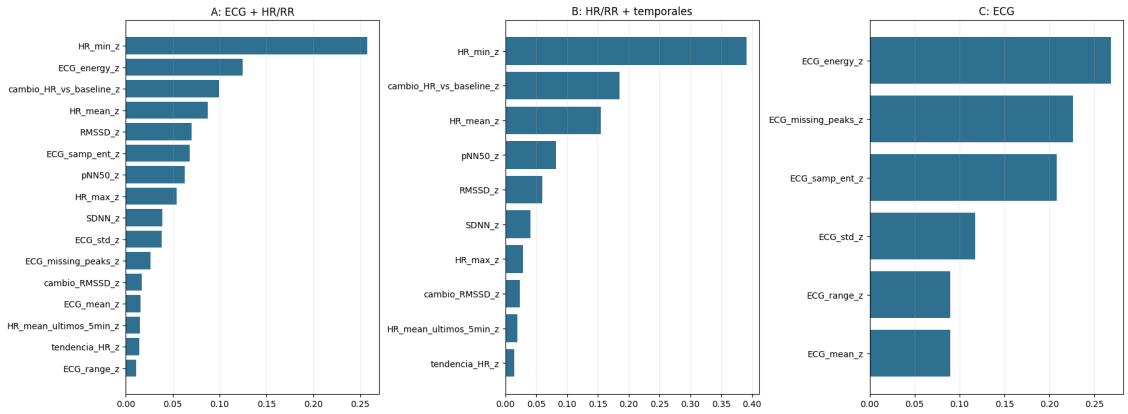


Figura 4.9: Importância relativa das características no XGBoost nos três cenários do estudo de ablação.

No cenário A, com todas as características, destacam-se `HR_min_z`, `ECG_energy_z` e `cambio_HR_vs_baseline_z`. No cenário B, sem características de ECG, `HR_min_z` e `cambio_HR_vs_baseline_z` mantêm-se entre as mais relevantes. No cenário C, sem características de HR/R-R e temporais, `ECG_energy_z` continua a ser a mais importante. Assim, embora a distribuição seja menos equilibrada, a hierarquia das características mantém alguma semelhança com o cenário completo. As figuras dos restantes modelos são apresentadas no **Apêndice D**.

Estes resultados mostram que, no contexto da generalização entre trabalhadores, a remoção de uma das fontes de informação provoca uma perda de desempenho relevante. Embora as características derivadas do ECG mantenham capacidade discriminativa quando utilizadas isoladamente, os resultados obtidos no cenário C indicam que estas não são suficientes para atingir o desempenho alcançado pela combinação das diferentes fontes. Por outro lado, a manutenção das características de HR/R-R e temporais sem as características de ECG também não permite preservar o desempenho observado no cenário completo.

A análise permite ainda estabelecer uma comparação com o estudo realizado anteriormente para um único trabalhador. Nesse cenário, a remoção das características de HR/R-R permitia manter um desempenho relativamente elevado utilizando so características derivadas do ECG. No entanto, os resultados obtidos com a avaliação LOSO mostram que esta capacidade não se mantém no mesmo nível quando o modelo é aplicado a trabalhadores não observados durante o treino. Assim, o desempenho anteriormente observado com um único trabalhador não pode ser diretamente generalizado para o cenário inter-trabalhador.

De forma geral, a combinação de características de ECG, HR/R-R e variáveis temporais revelou-se a abordagem mais adequada para generalizar a classificação entre trabalhadores. Embora as características de ECG mantenham capacidade discriminativa isoladamente, a sua utilização, tal como a utilização exclusiva de HR/R-R e variáveis temporais, implica uma perda significativa de desempenho. Entre os modelos avaliados, o XGBoost apresentou os melhores resultados nos três cenários, reforçando a importância de integrar diferentes fontes de informação fisiológica para classificar os níveis definidos pelo *FatigueIndex* em trabalhadores não observados durante o treino.

Validação Externa com Dados Experimentais do Polar H10

Após a avaliação da capacidade de generalização dos modelos através de LOSO e do *estudo de ablação*, foi realizada uma experiência adicional com o objetivo de observar o comportamento temporal dos modelos quando aplicados a um novo participante. Para esta análise foram utilizados os dados de um participante cujos dados não foram utilizados no treino dos modelos. Foram analisados dois registos correspondentes a condições experimentais distintas: um registo realizado durante **exercício e atividade física** e outro registo realizado durante **trabalho no computador**.

Nesta experiência foram utilizados os quatro modelos globais anteriormente treinados (Regressão Logística, Random Forest, SVM e XGBoost), utilizando o conjunto completo de características disponível, composto por variáveis derivadas do ECG, características relacionadas com HR e intervalos R-R e variáveis temporais. Os dados do Polar H10 foram submetidos ao mesmo pré-processamento e às mesmas etapas de *feature engineering* utilizadas durante o treino, incluindo a extração das características e a organização dos dados em janelas consecutivas de 60 segundos. Os modelos foram carregados a partir dos ficheiros previamente guardados e aplicados diretamente aos dados processados.

Como os registos não possuíam etiquetas previamente atribuídas, a atividade realizada foi utilizada como referência contextual para interpretar as previsões. No registo de exercício e atividade física, esperavam-se estados de maior ativação fisiológica, enquanto no registo de trabalho no computador se esperavam estados associados a uma menor intensidade física. A análise procurou ainda verificar se as previsões apresentavam uma evolução temporal coerente ao longo das janelas consecutivas.

A Tabela 4.19 apresenta o número de janelas analisadas e a duração aproximada de cada registo.

Tabela 4.19: Conjuntos de dados analisados no novo participante.

Registo	Nº de janelas	Duração aproximada	Intervalo temporal
PC	153	2 h 32 min	2:01 PM-4:33 PM
EXERCISE	119	1 h 58 min	7:40 PM-9:38 PM

O registo de exercício e atividade física foi dividido em dois períodos experimentais, correspondentes à caminhada na passadeira e ao trote. A Tabela 4.20 apresenta os intervalos temporais e o número de janelas considerados em cada período.

Tabela 4.20: Divisão temporal do registo de exercício e atividade física.

Registo	Nº de janelas	Duração aproximada	Intervalo temporal
CAMINHADA	40	20 min	9:05 PM-9:25 PM
TROTE	20	10 min	9:25 PM-9:35 PM

As Figuras 4.10 e 4.11 apresentam as previsões dos quatro modelos para os registos de trabalho no computador e de exercício e atividade física, respetivamente. Em cada gráfico, as classes Baixa, Média e Alta correspondem às categorias previstas pelos modelos ao longo das janelas temporais de 60 segundos.

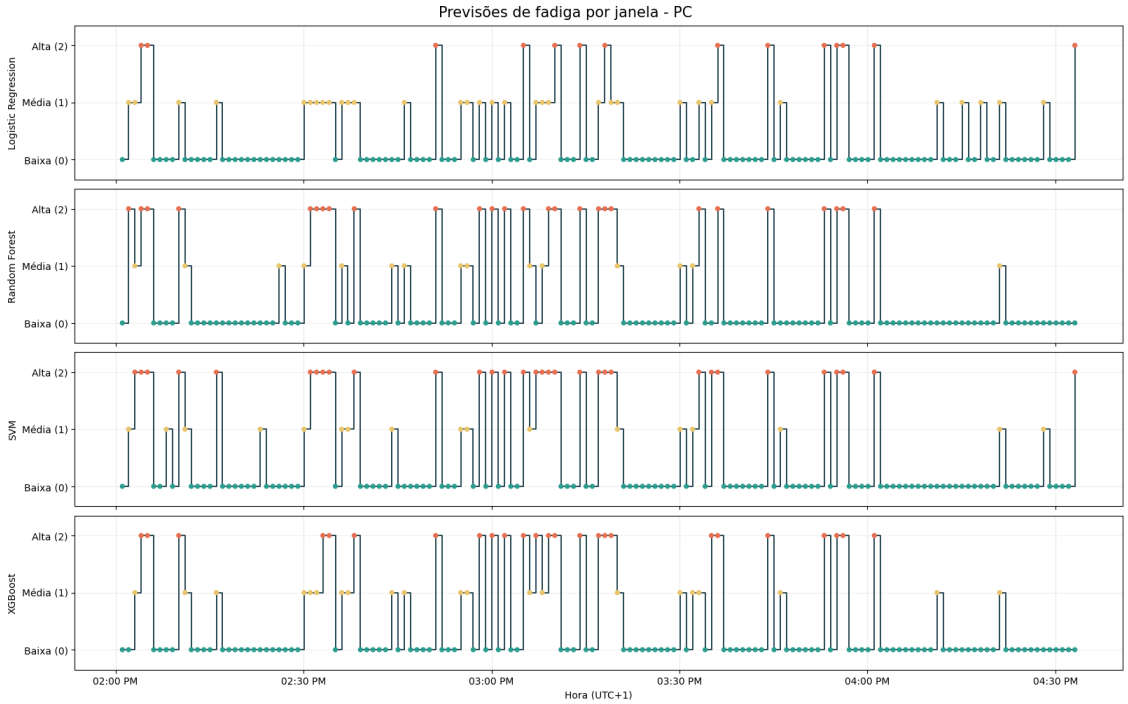


Figura 4.10: Previsões dos modelos para o registo de trabalho no computador com dados do Polar H10.

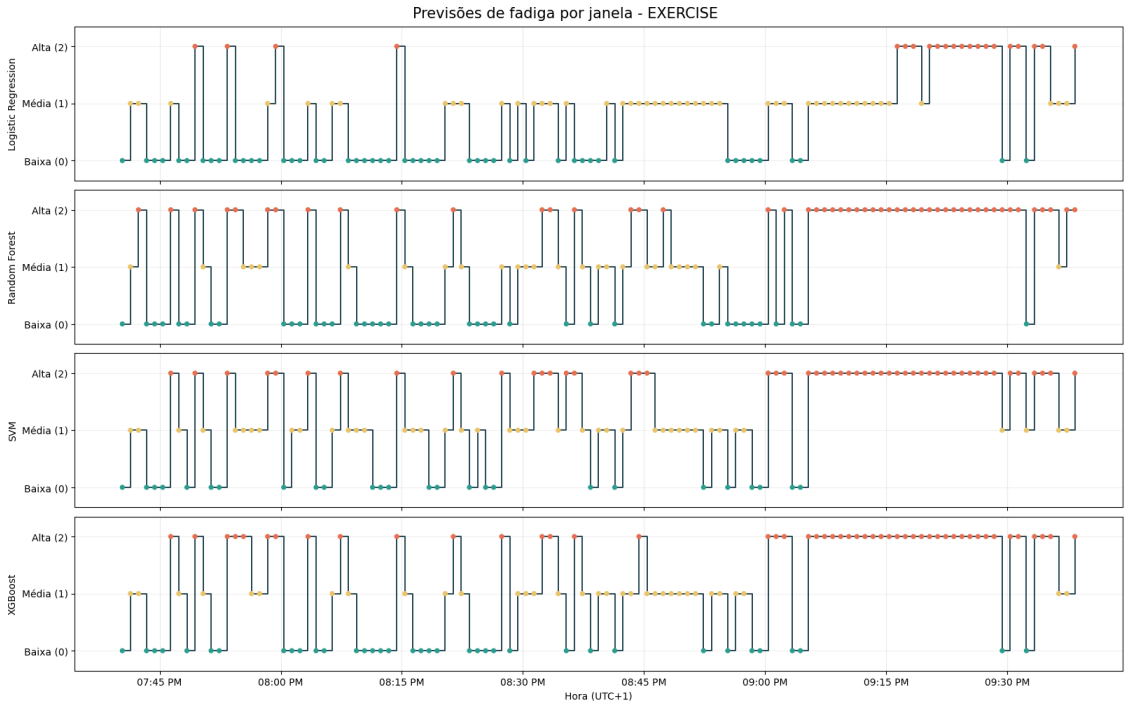


Figura 4.11: Previsões dos modelos para o registo de exercício e atividade física com dados do Polar H10.

Para complementar esta análise, a Tabela 4.21 apresenta o número de janelas classificadas como LOW, MED e HIGH por cada modelo em cada condição experimental.

Tabela 4.21: Distribuição das classes previstas pelos modelos nas duas condições experimentais.

Registo	Modelo	LOW	MED	HIGH
Trabalho no computador	Regressão Logística	106	33	14
Trabalho no computador	Random Forest	111	15	27
Trabalho no computador	SVM	104	17	32
Trabalho no computador	XGBoost	107	21	25
Exercício e atividade física	Regressão Logística	50	48	21
Exercício e atividade física	Random Forest	42	26	51
Exercício e atividade física	SVM	26	42	51
Exercício e atividade física	XGBoost	37	33	49

No registo de trabalho no computador (`PC`), verifica-se uma predominância clara da classe LOW em todos os modelos, com valores entre 104 e 111 janelas. A Regressão Logística apresenta o menor número de previsões HIGH, com 14 janelas (9,15%), enquanto o SVM apresenta o maior, com 32 janelas (20,92%). Os restantes modelos apresentam valores intermédios. Esta tendência é igualmente visível na Figura 4.10, onde as previsões HIGH surgem de forma pontual e intercalada com períodos de LOW e MED.

No registo de exercício e atividade física (`EXERCISE`), observa-se uma distribuição diferente das classes. Verifica-se um aumento das previsões MED e HIGH, sobretudo nos modelos Random Forest, SVM e XGBoost, que apresentam, respetivamente, 51, 51 e 49 janelas classificadas como HIGH. A Regressão Logística apresenta um comportamento mais conservador, com 50 janelas LOW, 48 MED e 21 HIGH. Esta diferença em relação ao registo `PC` é igualmente evidente na Figura 4.11, onde se observam períodos prolongados de previsões HIGH, particularmente na parte final do registo.

Para complementar esta análise, foi definido um critério contextual baseado na atividade realizada durante cada registo. Foram considerados quatro casos: o conjunto `PC` completo, o conjunto `EXERCISE` completo, o intervalo de caminhada na passadeira e o intervalo de trote. No conjunto `PC`, foram consideradas compatíveis com o contexto as previsões LOW e MED. No conjunto `EXERCISE` completo, foram consideradas compatíveis as previsões MED e HIGH. Nos intervalos específicos, foram consideradas compatíveis as previsões MED e HIGH durante a caminhada em passadeira, enquanto durante o trote foi considerada compatível apenas a classe HIGH. A Tabela 4.22 apresenta os resultados dos dois registos completos, e a Tabela 4.23 apresenta os resultados dos dois intervalos de exercício.

Tabela 4.22: Concordância das previsões com o contexto nos registos completos PC e EXERCISE.

Registo	Modelo	Janelas totais	Janelas compatíveis	Janelas não compatíveis	% compatível	% não compatível
PC	Regressão Logística	153	139	14	90,85	9,15
PC	Random Forest	153	126	27	82,35	17,65
PC	SVM	153	121	32	79,08	20,92
PC	XGBoost	153	128	25	83,66	16,34
EXERCISE	Regressão Logística	119	69	50	57,98	42,02
EXERCISE	Random Forest	119	77	42	64,71	35,29
EXERCISE	SVM	119	93	26	78,15	21,85
EXERCISE	XGBoost	119	82	37	68,91	31,09

No registo completo de trabalho no computador (PC), a Regressão Logística apresenta a maior concordância com o contexto, com 139 de 153 janelas compatíveis (90,85%). O SVM apresenta o valor mais baixo, com 121 janelas compatíveis (79,08%), enquanto o Random Forest e o XGBoost apresentam valores intermédios de concordância.

No registo completo de exercício e atividade física (EXERCISE), a concordância é inferior à observada no conjunto PC para a maioria dos modelos. O SVM apresenta o melhor resultado, com 93 de 119 janelas compatíveis (78,15%), enquanto a Regressão Logística apresenta o valor mais baixo, com 69 janelas compatíveis (57,98%). O Random Forest e o XGBoost apresentam valores intermédios.

Tabela 4.23: Concordância das previsões com o contexto nos intervalos de caminhada e trote.

Registo	Modelo	Janelas totais	Janelas compatíveis	Janelas não compatíveis	% compatível	% não compatível
CAMINHADA	Regressão Logística	20	20	0	100,0	0,0
CAMINHADA	Random Forest	20	20	0	100,0	0,0
CAMINHADA	SVM	20	20	0	100,0	0,0
CAMINHADA	XGBoost	20	20	0	100,0	0,0
TROTE	Regressão Logística	10	8	2	80,0	20,0
TROTE	Random Forest	10	9	1	90,0	10,0
TROTE	SVM	10	8	2	80,0	20,0
TROTE	XGBoost	10	8	2	80,0	20,0

Durante a caminhada em passadeira, os quatro modelos apresentam concordância total com o critério contextual definido, classificando todas as 20 janelas como MED ou HIGH. Este resultado corresponde a 100,0% de janelas compatíveis para todos os modelos.

Durante o trote, observa-se uma pequena redução dessa concordância. O Random Forest apresenta 9 de 10 janelas compatíveis (90,0%), enquanto a Regressão Logística, o SVM e o XGBoost apresentam 8 de 10 janelas compatíveis (80,0%). Assim, o Random Forest apresenta a maior concordância com o critério contextual nesta fase do exercício.

Embora a Regressão Logística não apresente o melhor resultado em todas as análises, as suas previsões revelam um comportamento mais conservador na atribuição da classe HIGH. Em comparação com os restantes modelos, tende a produzir mais previsões MED e menos previsões HIGH, o que pode ser vantajoso por reduzir a ocorrência de alertas excessivos ou a identificação de uma intensidade elevada durante atividades moderadas. Esta diferença é particularmente evidente durante a caminhada na passadeira, entre as 9:05 PM e as 9:25 PM, período em que a Regressão Logística foi o único modelo a classificar todas as janelas como MED, enquanto os restantes modelos atribuíram a maioria dessas janelas à classe HIGH. Considerando que este intervalo correspondia a exercício, mas não a uma situação de esforço máximo, este comportamento parece mais coerente com a intensidade esperada da atividade. Durante o trote, entre as 9:25 PM e as 9:35 PM, a Regressão Logística passou a atribuir a classe HIGH, acompanhando o comportamento geral dos restantes modelos perante uma atividade mais intensa.

Apesar destes resultados, o critério utilizado é apenas contextual e não constitui uma etiqueta independente do nível real de fadiga; por isso, as janelas "compatíveis" não devem ser interpretadas como classificações verdadeiramente corretas nem como métricas de desempenho. Ainda assim, a experiência mostra que os modelos globais podem produzir previsões em registos contínuos de um novo participante com o Polar H10, revelando predominância de

LOW no trabalho no computador, aumento de MED e HIGH durante o exercício e elevada concordância entre os modelos em vários períodos. Desta forma, a análise complementa os resultados de LOSO ao evidenciar o comportamento dos modelos perante diferentes condições experimentais.

Resultados das Experiências com o Relógio Empatica EmbracePlus

Os modelos desenvolvidos com os dados do relógio Empatica EmbracePlus foram avaliados em duas configurações distintas: utilizando os dados originais ao nível do minuto e utilizando dados agregados através de janelas temporais de 10 minutos. Em ambos os cenários foram analisados os algoritmos *Gaussian Mixture Model (GMM)* e *Clustering Hierárquico Aglomerativo*. Adicionalmente, os agrupamentos obtidos foram interpretados através de uma Árvore de Decisão, permitindo avaliar a consistência e a interpretabilidade das fronteiras entre clusters.

Resultados dos Modelos de Clustering A Tabela 4.24 apresenta as principais métricas obtidas para os modelos de clustering.

Tabela 4.24: Métricas Estruturais dos Modelos de Clustering

Algoritmo	Dados	Original / PCA	Critério de Seleção	Clusters (k)	Silhouette Score
GMM	Original	12 / 6	BIC	9	0.3475
GMM (Restrito)	Original	12 / 6	Heurístico*	4	0.3343
GMM	Janelas (10 min)	12 / 4	BIC	5	0.3742
Clustering Hierárquico	Original	12 / –	Silhouette + Elbow	5	0.3959
Clustering Hierárquico	Janelas (10 min)	12 / –	Silhouette + Elbow	5	0.4132

*Configuração alternativa forçada para limitar o número de estados a um patamar fisiologicamente interpretável, ignorando a recomendação teórica ideal do critério BIC.

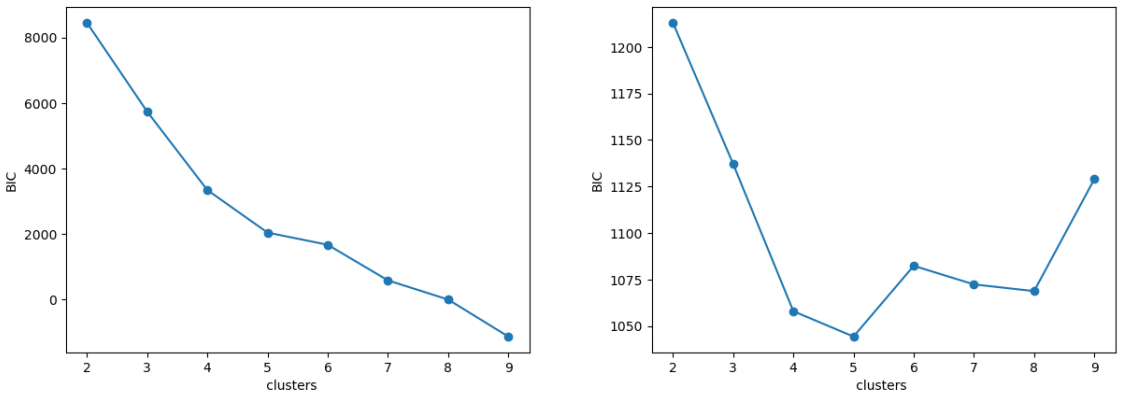
Os resultados evidenciam que a aplicação de etapas diferenciadas de engenharia e redução de características influenciou diretamente o desempenho e a estrutura dos agrupamentos obtidos em ambos os algoritmos:

- **Impacto do PCA e Dimensões de Entrada:** No modelo Gaussian Mixture Model (GMM), foi aplicada uma etapa de redução da dimensionalidade através de *Principal Component Analysis (PCA)* antes do treino. Esta abordagem permitiu reduzir a complexidade do espaço de características, preservando aproximadamente 90% da variância original dos dados. Nos dados ao nível do minuto, o PCA resultou em seis componentes principais, enquanto na abordagem baseada em janelas temporais foram obtidas quatro componentes. A redução da dimensionalidade contribuiu para simplificar a modelação probabilística do GMM, reduzindo o número de parâmetros a estimar e tornando o processo de aprendizagem mais estável. Em contraste, o Clustering Hierárquico Aglomerativo foi treinado diretamente sobre as features previamente normalizadas, sem aplicação de PCA, uma vez que o objetivo era preservar as relações de distância entre as variáveis originais utilizadas na construção do dendrograma.
- **Impacto do Ventaneamento Temporal (Janelas):** O Silhouette Score foi utilizado para avaliar a qualidade dos agrupamentos obtidos, medindo simultaneamente a coesão interna de cada cluster e a sua separação relativamente aos restantes. Esta métrica assume valores entre -1 e 1, sendo que valores mais próximos de 1 indicam agrupamentos mais compactos e bem separados, enquanto valores próximos de

0 sugerem sobreposição entre clusters e valores negativos apontam para classificações inadequadas.

A aplicação de janelas temporais de 10 minutos permitiu reduzir as flutuações fisiológicas instantâneas e o ruído presente nos sinais, produzindo representações mais estáveis do estado fisiológico dos participantes. Este efeito refletiu-se diretamente nos valores do Silhouette Score, que aumentaram em ambos os algoritmos. No Gaussian Mixture Model (GMM), a métrica evoluiu de 0.3475 para 0.3742, enquanto no Clustering Hierárquico Aglomerativo aumentou de 0.3959 para 0.4132. Embora o incremento seja moderado, demonstra que a agregação temporal favoreceu a formação de clusters mais consistentes e melhor definidos, facilitando a identificação de padrões fisiológicos representativos de diferentes estados de atividade e repouso.

- **Seleção Estrutural dos Clusters GMM (k):** No *Gaussian Mixture Model (GMM)*, o critério *Bayesian Information Criterion (BIC)* indicou como solução ótima a utilização de nove clusters para os dados ao nível do minuto e cinco clusters para os dados agregados em janelas de 10 minutos, conforme ilustrado graficamente na Figura 4.12. Apesar de apresentar o melhor compromisso entre qualidade de ajuste e complexidade do modelo, a solução com nove clusters revelou-se excessivamente fragmentada para uma interpretação fisiológica intuitiva. Por esse motivo, foi realizada uma experiência adicional, restringindo o modelo a $k = 4$ clusters (*GMM Restrito*), mantendo inalteradas as restantes configurações, incluindo as seis componentes principais obtidas através de PCA. Embora esta configuração tenha conduzido a uma ligeira redução do *Silhouette Score* (0.3343), produziu agrupamentos mais fáceis de interpretar no contexto dos diferentes estados fisiológicos observados.



(a) Dados Originais (ao minuto)

(b) Janelas de 10 Minutos

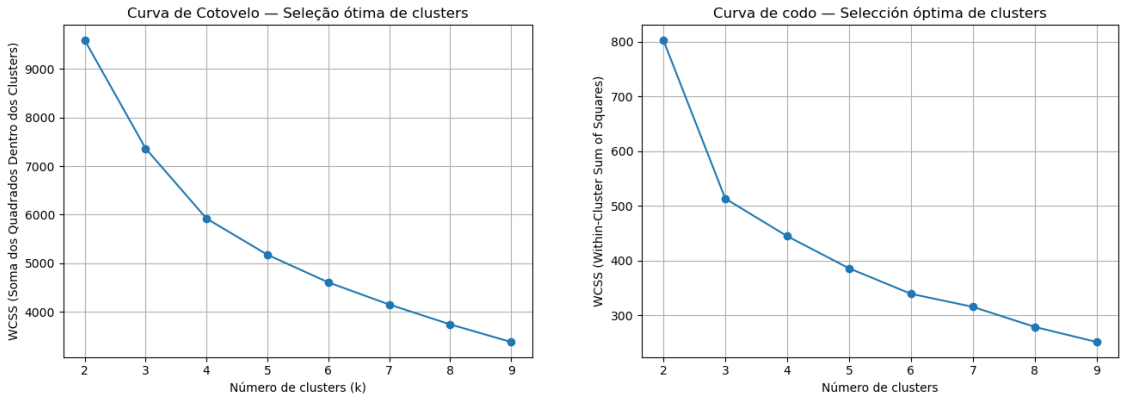
Figura 4.12: Curvas do Bayesian Information Criterion (BIC) obtidas para o modelo GMM.

O critério BIC penaliza a complexidade excessiva do modelo, sendo que valores inferiores indicam melhor adequação e separação teórica dos dados. Nas curvas da Figura 4.12, observa-se que, para os dados originais ao minuto (Figura 4.12a), o BIC decresce continuamente sugerindo 9 clusters. Contudo, teorias matemáticas à parte, esta partição gera uma fragmentação excessiva que compromete a utilidade prática dos estados. Este problema foi mitigado na versão com janelas de 10 minutos (Figura 4.12b), onde a suavização do ruído fisiológico revelou um mínimo global côncavo

claro em exatamente 5 clusters, definindo o ponto ideal de equilíbrio matemático e interpretabilidade.

- **Seleção Estrutural dos Clusters CHA (k):** No *Clustering Hierárquico Aglomerativo*, a configuração final de $k = 5$ também foi definida com base na análise conjunta do *Silhouette Score*, da curva do cotovelo (*Elbow Method*) e do dendrograma. Embora algumas métricas automáticas sugerissem um número inferior de clusters, a escolha de cinco agrupamentos representou o melhor compromisso entre qualidade estrutural e interpretabilidade fisiológica dos estados identificados.

  A Figura 4.13 exibe as **curvas do cotovelo** obtidas para o modelo de Clustering Hierárquico treinado, respetivamente, com os dados originais ao nível do minuto e com os dados agregados em janelas de 10 minutos. Estas curvas representam a evolução da soma dos quadrados intra-cluster (WCSS), métrica que avalia a coesão dos grupos. Quanto menor o WCSS, mais próximas se encontram as amostras dentro de cada cluster. Contudo, o objetivo não consiste em obter o menor valor possível de WCSS, uma vez que esta métrica diminui naturalmente à medida que aumenta o número de clusters. Assim, procura-se identificar o ponto a partir do qual a redução do WCSS deixa de ser significativa, conhecido como o "cotovelo". Em ambos os casos observa-se uma diminuição acentuada do WCSS à medida que aumenta o número de clusters, seguida de uma estabilização gradual da curva. Nos dados agregados por janelas, os valores de WCSS são inferiores, refletindo a redução da variabilidade dos sinais após a agregação temporal. Embora a curva não apresente um ponto de quebra perfeitamente definido, permitiu identificar uma região de estabilização posteriormente confirmada pela análise do Silhouette Score e do dendrograma.

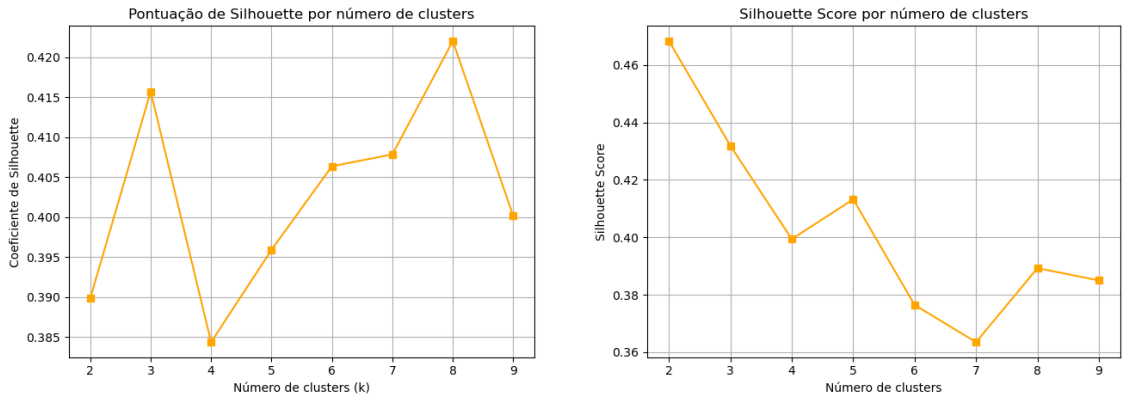


(a) Dados Originais (ao minuto) (b) Janelas de 10 Minutos

Figura 4.13: Curvas do cotovelo (Elbow Method) baseadas no WCSS obtidas para o Clustering Hierárquico.

As Figuras 4.14a e 4.14b apresentam a evolução do coeficiente de Silhouette para diferentes números de clusters nos conjuntos de dados originais e agregados por janelas temporais, respetivamente. Esta métrica avalia simultaneamente a coesão interna de cada cluster e a separação entre clusters distintos, assumindo valores entre -1 e 1, sendo que valores mais elevados indicam agrupamentos de melhor qualidade. Nos dados originais, o valor máximo é obtido para $k = 8$. No entanto, observa-se que, a partir de aproximadamente cinco clusters, o coeficiente entra numa região relativamente estável, apresentando apenas pequenas variações até ao valor máximo. Isto indica que diferentes soluções nesse intervalo

apresentam uma qualidade semelhante do ponto de vista geométrico. Nos dados agregados por janelas, o maior valor ocorre para $k = 2$, sugerindo uma divisão muito simples dos dados em dois grandes grupos. Contudo, essa solução revelou-se insuficiente para representar a diversidade dos estados fisiológicos observados ao longo do dia. Para $k = 5$, o coeficiente de Silhouette mantém um valor competitivo, permitindo simultaneamente uma descrição mais detalhada dos diferentes estados fisiológicos.



(a) Dados Originais (ao minuto)

(b) Janelas de 10 Minutos

Figura 4.14: Evolução do coeficiente de Silhouette para diferentes números de clusters (k).

As Figuras 4.15 e 4.16 apresentam os **dendrogramas** dos modelos de Clustering Hierárquico treinados, respetivamente, com os dados originais (ao nível do minuto) e com os dados agregados em janelas temporais de 10 minutos. O dendrograma representa o processo de agrupamento hierárquico, mostrando a distância a que os diferentes grupos são sucessivamente unidos: ligações a menores distâncias indicam grupos mais semelhantes, enquanto ligações a maiores distâncias correspondem a grupos mais distintos. Comparando ambos os modelos, observa-se que os dados originais apresentam uniões a distâncias mais elevadas, refletindo a maior variabilidade dos sinais fisiológicos. Já nos dados agregados em janelas temporais, essas uniões ocorrem a distâncias inferiores, originando uma estrutura mais compacta e homogénea, o que indica que a agregação temporal reduziu parte dessa variabilidade e favoreceu a formação de estados fisiológicos mais estáveis.

O dendrograma permite ainda explorar diferentes soluções de agrupamento (diferentes números de clusters, k) através da definição de um nível de corte horizontal. O número de ramos intercetados por essa linha corresponde ao número de grupos obtidos: um corte mais elevado produz poucos agrupamentos, mais gerais, enquanto um corte mais baixo origina um maior número de grupos e uma segmentação mais detalhada. No modelo treinado com os dados originais, por exemplo, um corte próximo da distância 100 resulta em dois grandes grupos, correspondendo provavelmente a uma separação entre períodos de sono e de vigília. Reduzindo o nível de corte para aproximadamente 40, obtêm-se cinco clusters, permitindo distinguir diferentes estados fisiológicos sem fragmentar excessivamente os dados. Assim, embora o dendrograma, por si só, não determine o número ótimo de clusters, a sua análise visual complementou a curva do cotovelo e o coeficiente de Silhouette, sustentando a adoção de uma configuração final de cinco clusters por representar o melhor compromisso entre a qualidade do agrupamento e a interpretação fisiológica dos estados identificados.

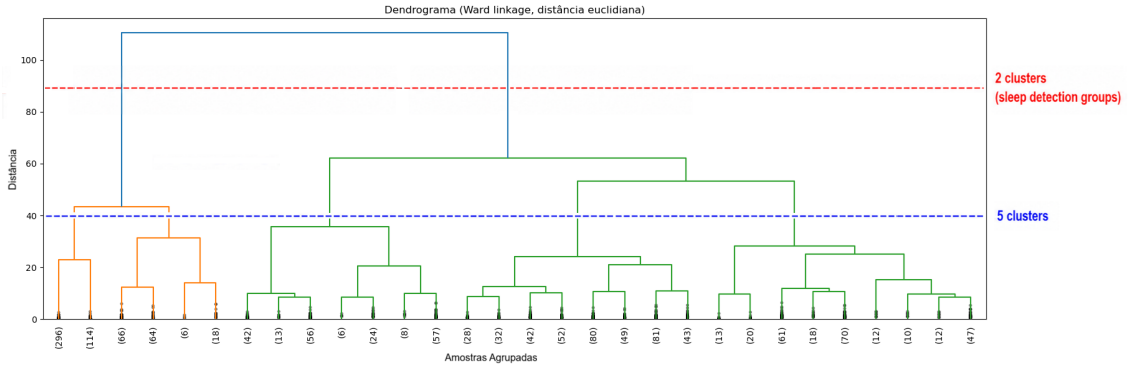


Figura 4.15: Dendrograma - Dados Originais

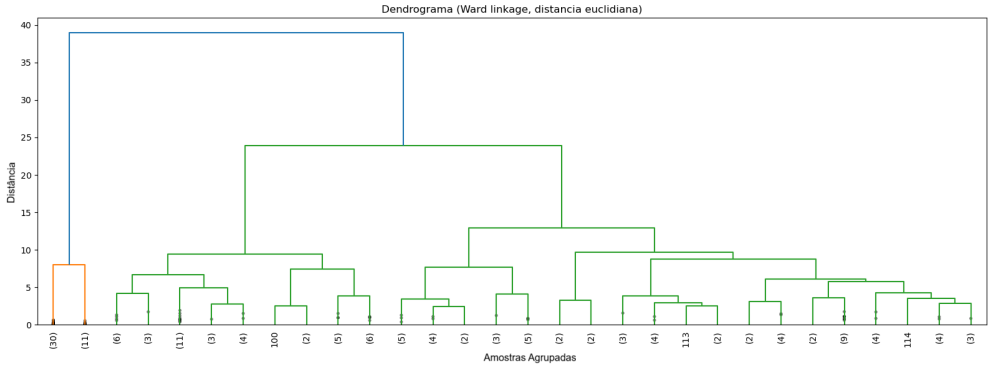


Figura 4.16: Dendrograma - Janelas de 10 minutos

Considerando em conjunto o Silhouette Score, a curva do cotovelo, o dendrograma e a necessidade de obter grupos com significado fisiológico, foi adotada uma configuração final de cinco clusters para o modelo hierárquico.

Interpretabilidade dos Clusters Hierárquicos (Árvores de Decisão) Para avaliar a consistência dos agrupamentos obtidos nas partições do Clustering Hierárquico Aglomerativo, foi treinada uma Árvore de Decisão utilizando as variáveis fisiológicas como atributos de entrada e os clusters produtos por esse algoritmo como variável-alvo. A Tabela 4.25 apresenta os resultados obtidos.

Tabela 4.25: Avaliação da Interpretabilidade através de Árvore de Decisão

Configuração	Profundidade Máxima	Accuracy Treino	Accuracy (5-Fold CV)
Dados Originais	8	98.61%	92.01% ± 4.44%
Janelas (10 min)	5	93.06%	83.92% ± 10.24%

Os resultados demonstram que os clusters obtidos apresentam fronteiras suficientemente consistentes para serem reproduzidas por um modelo supervisionado simples. Nos dados originais foi obtida uma *accuracy* de validação cruzada de 92.01%, enquanto a abordagem baseada em janelas temporais alcançou 83.92%. Embora este último valor seja inferior, continua a evidenciar uma boa capacidade de generalização, tendo em consideração que o número de observações foi reduzido de aproximadamente 1440 para apenas 144 amostras

após o processo de agregação temporal, correspondentes às 24 horas de uma jornada laboral completa.

A estrutura de decisão destas árvores, as quais indicam de forma explícita os caminhos e as regras de corte lógicas para a atribuição de cada cluster com base no critério de impureza de Gini, encontra-se representada graficamente nas Figuras 4.17 e 4.18. Através delas, é possível observar claramente como as regras lógicas são formadas sequencialmente a partir de variáveis fisiológicas e de movimento. Esta disparidade de complexidade estrutural possivelmente deve-se ao facto de o modelo original operar com dados ao nível do minuto, lidando com flutuações rápidas e maior ruído, o que fez com que a árvore de crescimento livre se expandisse até 8 níveis de profundidade real (ao contrário do modelo de janelas de 10 minutos, que alcançou apenas 5 níveis).

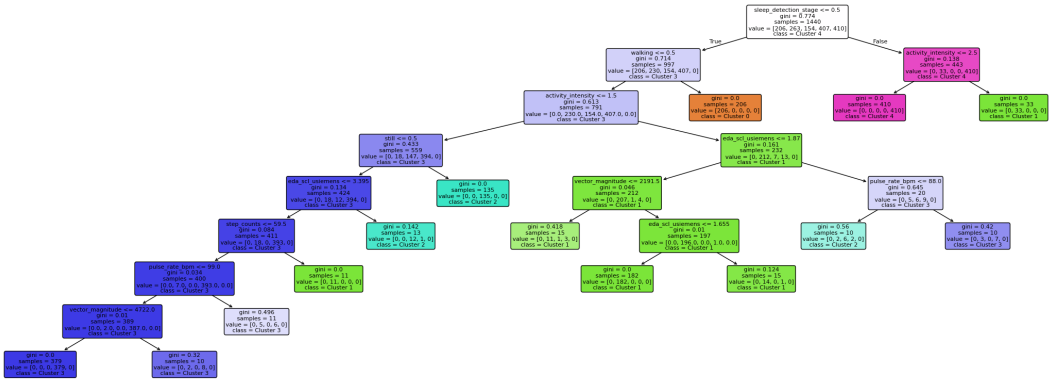


Figura 4.17: Árvore de Decisão treinada com base no índice de Gini usando os dados ao minuto.

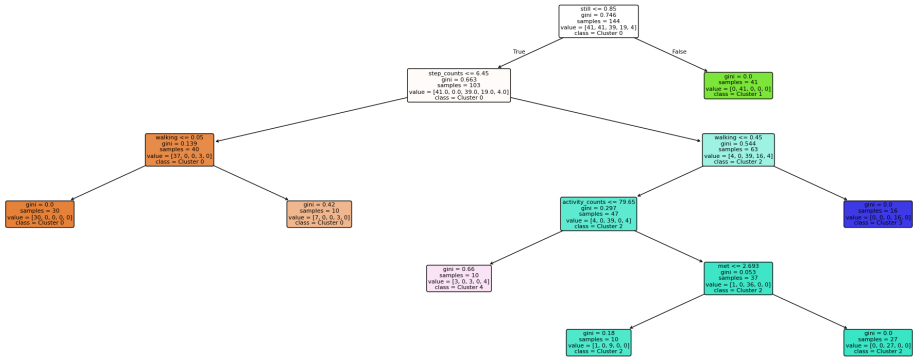


Figura 4.18: Árvore de Decisão detalhada com critério de Gini usando os dados em janelas de 10 minutos.

As regras de inferência lógica extraídas das árvores de decisão em ambos os cenários são apresentadas em formato textual a seguir. Na Tabela 4.26 constam as regras baseadas no conjunto de dados original de resolução de um minuto, onde sobressai a relevância da fase do sono e da intensidade de atividade na separação rápida dos agrupamentos. Por sua vez, a Tabela 4.27 ilustra os caminhos de decisão para o cenário de janelas de 10 minutos, consolidando como a lógica transita para limites baseados em quantidades cumulativas físicas de movimento e repouso de duração contínua.

Tabela 4.26: Regras de Decisão para a Identificação de Clusters (Dados Originais)

Regras Lógicas Extraídas (Resolução Temporal: 1 minuto)
Se `sleep_detection_stage` ≤ 0.50:
Se `walking` ≤ 0.50:
Se `activity_intensity` ≤ 1.50:
Se `still` ≤ 0.50:
Se `eda_scl_usiemens` ≤ 3.39:
Se `step_counts` ≤ 59.50:
Se `pulse_rate_bpm` ≤ 99.00:
Se `vector_magnitude` $\leq 4722.00 \rightarrow$ **Cluster 3** (Atividade de transição/baixo movimento)
Se `vector_magnitude` $> 4722.00 \rightarrow$ **Cluster 3** (Atividade residual física em repouso)
Se `pulse_rate_bpm` $> 99.00 \rightarrow$ **Cluster 3** (Ativação fisiológica pontual sem locomoção)
Se `step_counts` $> 59.50 \rightarrow$ **Cluster 1** (Fração de movimento transicional ligeiro)
Se `eda_scl_usiemens` $> 3.39 \rightarrow$ **Cluster 2** (Trabalho estático com elevada reatividade simpática)
Se `still` $> 0.50 \rightarrow$ **Cluster 2** (Trabalho sedentário/estático padrão)
Se `activity_intensity` > 1.50:
Se `eda_scl_usiemens` $\leq 1.87 \rightarrow$ **Cluster 1** (Esforço físico leve com baixa condutância eletrodérmica)
Se `eda_scl_usiemens` $> 1.87 \rightarrow$ **Cluster 3** (Esforço físico moderado com maior ativação simpática)
Se `walking` $> 0.50 \rightarrow$ **Cluster 0** (Atividade física de caminhada)
Se `sleep_detection_stage` > 0.50:
Se `activity_intensity` $\leq 2.50 \rightarrow$ **Cluster 4** (Fase de repouso ou sono profundo com baixa ativação)
Se `activity_intensity` $> 2.50 \rightarrow$ **Cluster 1** (Fase de repouso com transições de movimento leve)

Tabela 4.27: Regras de Decisão para a Identificação de Clusters (Janelas de 10 min)

Regras Lógicas Extraídas (Agregação Temporal: Janelas de 10 minutos)
Se `still` ≤ 0.85:
Se `step_counts` ≤ 6.45:
Se `walking` $\leq 0.05 \rightarrow$ **Cluster 0** (Transições breves de movimento sedentário)
Se `walking` $> 0.05 \rightarrow$ **Cluster 0** (Transições de caminhada muito leve pontual)
Se `step_counts` > 6.45:
Se `walking` ≤ 0.45:
Se `activity_counts` $\leq 79.65 \rightarrow$ **Cluster 4** (Trabalho com movimentação generalizada em ritmo calmo)
Se `activity_counts` > 79.65:
Se `met` $\leq 2.69 \rightarrow$ **Cluster 2** (Trabalho físico leve com carga metabólica controlada)
Se `met` $> 2.69 \rightarrow$ **Cluster 2** (Atividade laboral ativa integrada de movimento variado)
Se `walking` $> 0.45 \rightarrow$ **Cluster 3** (Atividade contínua ou prolongada de caminhada ativa)
Se `still` $> 0.85 \rightarrow$ **Cluster 1** (Estado estático dominante - repouso consolidado ou sono estável)

A Tabela 4.28 apresenta a importância relativa das principais variáveis fisiológicas, calculada através do índice de impureza de Gini (*Gini Importance* ou *Mean Decrease in Impurity*), utilizadas pela Árvore de Decisão para distinguir os diferentes clusters. Os resultados dividem-se entre os dados originais e após a agregação temporal de 10 minutos, ordenados de forma decrescente de importância.

Tabela 4.28: Importância Relativa das Variáveis na Árvore de Decisão (Ordenada)

Dados Originais		**Janelas Temporais (10 min)**	
Variável	Importância	Variável	Importância
`sleep_detection_stage`	31.47%	`still`	41.34%
`activity_intensity`	24.54%	`step_counts`	29.95%
`walking`	20.88%	`walking`	22.85%
`still`	17.06%	`activity_counts`	5.70%
`eda_scl_usiemens`	3.25%	`met`	0.15%
`step_counts`	1.90%	`pulse_rate_bpm`	0.00%
`pulse_rate_bpm`	0.68%	`eda_scl_usiemens`	0.00%
`vector_magnitude`	0.21%	`activity_intensity`	0.00%
`met`	0.00%	`vector_magnitude`	0.00%
`activity_counts`	0.00%	`sleep_detection_stage`	0.00%
`generic`	0.00%	`generic`	0.00%

A análise da importância das variáveis na Árvore de Decisão mostra que a explicação dos clusters permanece globalmente consistente entre as duas representações dos dados. Em ambos os casos, variáveis relacionadas com a atividade e o movimento, como `walking` e `still`, mantêm elevada relevância. Nos dados originais, a variável `sleep_detection_stage` assume a maior importância (31.47%), enquanto na abordagem baseada em janelas temporais a sua contribuição deixa de ser significativa, sendo substituída por indicadores mais agregados da atividade, como `step_counts`. De forma semelhante, a variável `activity_intensity` perde relevância, sendo substituída por métricas relacionadas com a quantidade de movimento, que representam informação semelhante sobre o nível de atividade do utilizador.

Esta alteração é consistente com o efeito da agregação temporal. Nos dados ao nível do minuto, a variável `sleep_detection_stage` identifica diretamente o estado de sono e, por isso, constitui o principal fator de decisão da árvore. No entanto, ao agregar os dados em janelas de 10 minutos, o comportamento do utilizador passa a ser descrito por indicadores mais estáveis, como a permanência em repouso (`still`) e o número de passos (`step_counts`), tornando a informação explícita sobre o estágio do sono menos determinante para distinguir os diferentes clusters. Estes resultados sugerem que a agregação temporal não altera significativamente os padrões fisiológicos identificados, mas modifica as variáveis mais relevantes para a sua interpretação, privilégindo medidas representativas do comportamento observado ao longo do janela temporal.

Classificação e Interpretação Fisiológica dos Clusters Um passo fundamental desta investigação consistiu na interpretação dos clusters gerados pelos diferentes modelos de agrupamento. Para além de identificar o número ótimo de grupos, foi necessário compreender o significado das divisões produzidas pelos algoritmos, analisando porque determinados registos fisiológicos eram agrupados entre si e que estados físicos ou comportamentais poderiam estar a ser representados. O objetivo não foi apenas avaliar o desempenho matemático dos modelos, mas também verificar se os clusters correspondiam a estados fisiológicos reais e interpretáveis, capazes de descrever diferentes momentos da rotina diária do indivíduo.

Para esse efeito, a interpretação dos clusters baseou-se em duas fontes de informação complementares:

- **A distribuição por percentis relativos (LOW, MED, HIGH)** de cada variável fisiológica e comportamental dentro do cluster, permitindo compreender a assinatura neurofisiológica biológica do estado.
- **A distribuição temporal diária dos clusters**, analisando a sua ocorrência ao longo das 24 horas e verificando se os estados identificados surgiam em períodos coerentes com atividades como o sono, o trabalho, os deslocamentos ou os momentos de maior esforço físico.

1. **Modelo GMM Original ($k = 9$):**

Para o modelo probabilístico inicial de referência, o **Gaussian Mixture Model (GMM) com dados originais ($k = 9$)**, este estudo permitiu cartografar com elevado detalhe a assinatura de cada agrupamento, conforme apresentado na Tabela 4.29.

Tabela 4.29: Assinatura Fisiológica e Sensibilidade dos Clusters para o GMM de Dados Originais ($k = 9$, Dados ao Minuto)

Cluster	EDA	Pulse Rate	MET	Act. Counts	Step Counts	Vec. Mag.	Act. Intensity	Sleep Stage	Significado Fisiológico Proposto
5	*LOW*	*MED*	*LOW*	*LOW*	*LOW*	*LOW*	*LOW*	*HIGH*	[Grupo de sono] início
0	*MED*	*LOW*	*LOW*	*LOW*	*LOW*	*LOW*	*LOW*	*HIGH*	[Grupo de sono] profundo
1	*LOW*	*MED*	*HIGH*	*MED*	*HIGH*	*HIGH*	*HIGH*	*HIGH*	[Grupo de despertar]
7	*HIGH*	*MED*	*MED*	*LOW*	*MED*	*MED*	*MED*	*HIGH*	[Grupo de sedentarismo/foco] estado base
2	*HIGH*	*MED*	*MED*	*MED*	*MED*	*MED*	*MED*	*LOW*	[Grupo de sedentarismo/foco] trabalho/concentração
6	*HIGH*	*LOW*	*MED*	*MED*	*MED*	*MED*	*MED*	*LOW*	[Grupo de sedentarismo/foco] pico stress
3	*LOW*	*HIGH*	*HIGH*	*HIGH*	*HIGH*	*HIGH*	*HIGH*	*LOW*	[Grupo de atividade física] caminhada
8	*LOW*	*MED*	*HIGH*	*HIGH*	*HIGH*	*HIGH*	*HIGH*	*LOW*	[Grupo de atividade física] movimento geral
4	*HIGH*	*HIGH*	*HIGH*	*HIGH*	*HIGH*	*HIGH*	*HIGH*	*LOW*	[Grupo de atividade física] atividade intensa

A Figura 4.19 ilustra a distribuição temporal dos clusters identificados pelo GMM com dados originais ao minuto ($k = 9$) ao longo de uma jornada laboral completa (00:00–23:59), permitindo observar como os diferentes estados fisiológicos se sucedem de forma coerente com o ritmo diário do trabalhador.

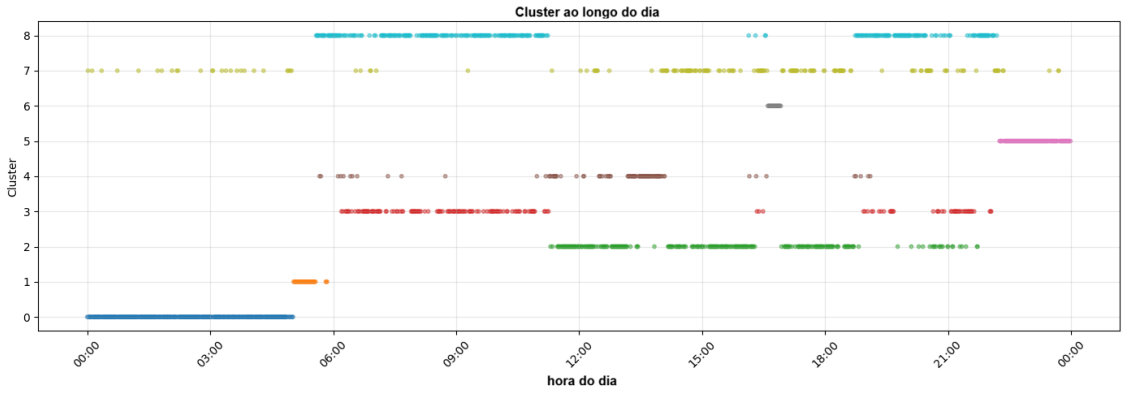


Figura 4.19: Distribuição temporal diária dos clusters do GMM (dados ao minuto) ao longo de uma jornada.

A análise da Tabela 4.29 evidencia que, embora o critério BIC tenha indicado nove clusters como a solução estatisticamente ótima para o GMM, essa segmentação revelou-se demasiado detalhada para uma interpretação fisiológica direta. Observa-se que vários clusters apresentam assinaturas muito semelhantes, diferindo apenas em pequenas variações de

algumas variáveis fisiológicas. Assim, em vez de representar nove estados fisiológicos completamente distintos, o modelo descreve diferentes variações de um conjunto mais reduzido de comportamentos.

Com base nas assinaturas fisiológicas e na distribuição temporal apresentada na Figura 4.19, foi possível organizar estes nove clusters em quatro grandes grupos funcionais: repouso, despertar, sedentarismo/concentração e atividade física. Dentro de cada grupo, os diferentes clusters representam variações do mesmo estado fisiológico, distinguindo-se sobretudo pela intensidade da atividade, pelo nível de stress ou pela fase do ciclo diário. Esta interpretação permitiu transformar uma solução matematicamente ótima, mas complexa, numa representação mais simples e coerente do comportamento fisiológico observado ao longo do dia.

2. **Modelo GMM Restrito ($k = 4$):**

   De forma complementar, o **GMM Restrito ($k = 4$)** com dados originais ao minuto foi analisado de forma análoga, conforme apresentado na Tabela 4.30.

Tabela 4.30: Assinatura Fisiológica dos Clusters para o GMM Restrito ($k = 4$, Dados ao Minuto)

Cluster	EDA	Pulse Rate	MET	Act. Counts	Step Counts	Vec. Mag.	Act. Intensity	Sleep Stage	Significado Fisiológico Proposto
0	*MED*	*LOW*	*LOW*	*LOW*	*LOW*	*LOW*	*LOW*	*HIGH*	Repouso e Sono Profundo
1	*HIGH*	*MED*	*HIGH*	*HIGH*	*HIGH*	*HIGH*	*HIGH*	*LOW*	Trabalho Ativo / Jornada Operativa
2	*HIGH*	*MED*	*MED*	*MED*	*HIGH*	*MED*	*MED*	*HIGH*	Sedentarismo em Alerta / Transições
3	*MED*	*HIGH*	*HIGH*	*HIGH*	*HIGH*	*HIGH*	*HIGH*	*LOW*	Atividade Física e Deslocamentos

A Figura 4.20 ilustra a distribuição temporal dos clusters do GMM Restrito ($k = 4$) ao longo de uma jornada completa.

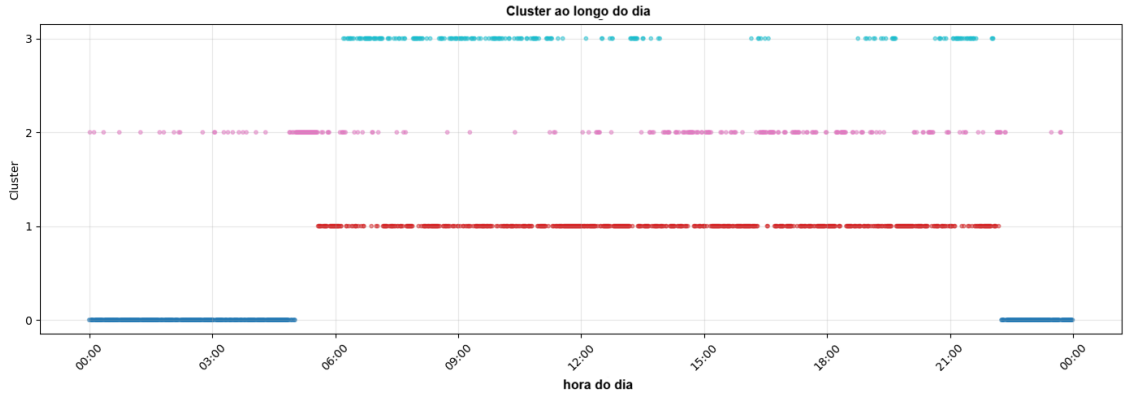


Figura 4.20: Distribuição temporal diária dos clusters do GMM Restrito ($k = 4$, dados ao minuto) ao longo de uma jornada.

O GMM Restrito ($k = 4$) foi desenvolvido com o objetivo de reduzir a fragmentação observada na solução original de nove clusters, fundindo automaticamente os clusters mais semelhantes numa representação mais simples e interpretável. A interpretação fisiológica resultou da combinação da assinatura das variáveis (Tabela 4.30) com a sua distribuição temporal (Figura 4.20). O cluster Repouso e Sono Profundo concentra-se durante a noite e caracteriza-se por baixa atividade e elevados valores de Sleep Stage. O cluster Atividade Física e Deslocamentos apresenta valores elevados de frequência cardíaca, MET e passos,

surgindo de forma intermitente ao longo do dia. O cluster Trabalho Ativo / Jornada Operativa predomina entre as 06:00 e as 22:00, combinando elevada atividade, passos e EDA, compatíveis com uma atividade laboral ativa. Por fim, o cluster Sedentarismo em Alerta / Transições apresenta atividade moderada, EDA elevada e valores elevados de Sleep Stage, sugerindo situações de reduzido movimento associadas a atividade cognitiva durante o dia ou a episódios de sono leve durante a noite.

De um modo geral, o GMM Restrito conseguiu reduzir a fragmentação observada na solução com nove clusters, fundindo automaticamente estados fisiológicos muito semelhantes e produzindo uma representação mais simples. A distinção entre os períodos de sono e vigília manteve-se clara, evidenciando que essa separação corresponde ao padrão fisiológico dominante dos dados. No entanto, os restantes clusters apresentam uma distribuição temporal bastante sobreposta, coexistindo frequentemente nos mesmos períodos do dia e alternando de forma muito rápida. Este comportamento sugere que a fusão dos clusters simplificou excessivamente a representação dos estados fisiológicos, reduzindo a capacidade do modelo para distinguir diferentes padrões de atividade ao longo da jornada.

3. **Modelo GMM em Janelas de 10 Minutos ($k = 5$):**

   Para os dados agregados em janelas de 10 minutos, o **GMM ($k = 5$)** produziu os agrupamentos caracterizados na Tabela 4.31.

Tabela 4.31: Assinatura Fisiológica dos Clusters para o GMM ($k = 5$, Janelas de 10 min)

Cluster	EDA	Pulse Rate	MET	Act. Counts	Step Counts	Vec. Mag.	Act. Intensity	Sleep Stage	Significado Fisiológico Proposto
0	*LOW*	*LOW*	*HIGH*	*MED*	*HIGH*	*MED*	*HIGH*	*HIGH*	"Salto" da Cama / Transição Matinal
1	*MED*	*LOW*	*LOW*	*LOW*	*LOW*	*LOW*	*LOW*	*HIGH*	Sono Estável / Estado de Repouso
2	*HIGH*	*HIGH*	*HIGH*	*HIGH*	*HIGH*	*HIGH*	*HIGH*	*LOW*	Picos de Intensidade Física
3	*HIGH*	*MED*	*MED*	*MED*	*MED*	*MED*	*MED*	*HIGH*	Jornada Laboral / Carga Cognitiva
4	*LOW*	*MED*	*HIGH*	*HIGH*	*HIGH*	*HIGH*	*HIGH*	*HIGH*	Rotina Ativa e Deslocamentos

A Figura 4.21 ilustra a distribuição temporal dos clusters do GMM com janelas de 10 minutos ao longo de uma jornada completa.

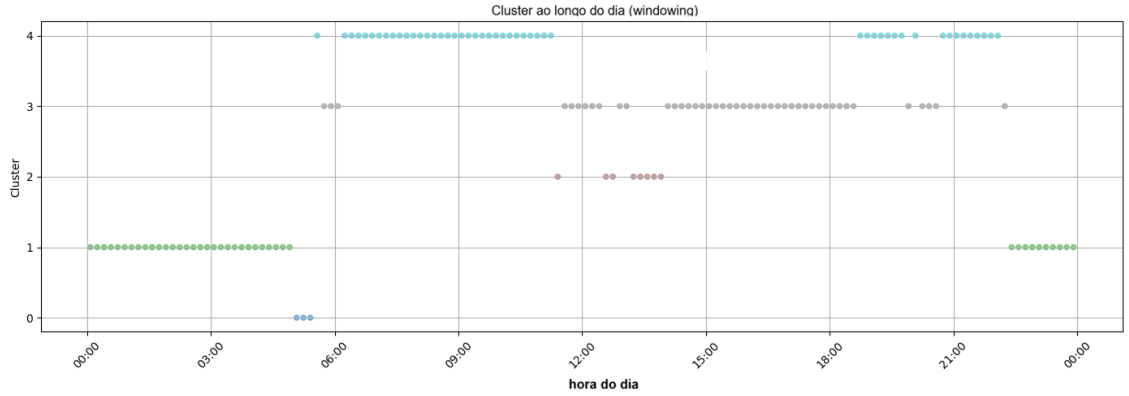


Figura 4.21: Distribuição temporal diária dos clusters do GMM ($k = 5$, janelas de 10 min) ao longo de uma jornada.

O GMM treinado com dados agregados em janelas de 10 minutos identificou cinco estados fisiológicos consistentes, interpretados a partir da assinatura das variáveis (Tabela 4.31) e

da sua distribuição temporal (Figura 4.21). O cluster *Sono Estável* concentra-se no período noturno, apresentando baixa atividade física, frequência cardíaca e gasto energético, juntamente com valores elevados de *Sleep Stage*, caracterizando o estado de repouso. Antes do despertar surge um breve cluster de *Transição Matinal*, com MET e passos elevados, mas frequência cardíaca e EDA ainda reduzidas, sugerindo o início do movimento antes da ativação fisiológica completa. Durante a manhã e o início da noite predomina o cluster *Rotina Ativa e Deslocamentos*, marcado por elevados indicadores de movimento e EDA reduzida, compatível com deslocações ou atividade física ligeira. No período central da jornada laboral observa-se o cluster *Jornada Laboral / Carga Cognitiva*, caracterizado por EDA elevada e atividade moderada, refletindo maior exigência mental. Por fim, o cluster *Picos de Intensidade* ocorre apenas pontualmente, apresentando valores elevados na maioria dos indicadores fisiológicos e de movimento, correspondendo aos momentos de maior exigência física.

Visualmente, este modelo apresenta uma evolução temporal mais organizada do que a obtida com os dados ao minuto. Os *clusters* surgem em blocos temporais mais bem definidos, reduzindo as mudanças rápidas entre estados observadas anteriormente. Esta melhoria resulta, provavelmente, da agregação dos dados em janelas de 10 minutos, que reduz as variações instantâneas e o efeito do ruído nas medições. Como consequência, os estados fisiológicos acompanham de forma mais clara a rotina diária do utilizador, passando do repouso para atividades ligeiras, depois para períodos de maior carga cognitiva e, apenas ocasionalmente, para momentos de elevada intensidade física. Esta distribuição está de acordo com o esperado numa jornada diária e mostra que a agregação temporal facilita a identificação de padrões fisiológicos mais estáveis e fáceis de interpretar.

4. **Modelo de Clustering Hierárquico Original ($k = 5$):**

   No que diz respeito ao **Clustering Hierárquico Aglomerativo com dados originais ao minuto ($k = 5$)**, a caracterização fisiológica dos agrupamentos obtidos é apresentada na Tabela 4.32.

Tabela 4.32: Assinatura Fisiológica dos Clusters para o Clustering Hierárquico ($k = 5$, Dados ao Minuto)

Cluster	EDA	Pulse Rate	MET	Act. Counts	Step Counts	Vec. Mag.	Act. Intensity	Sleep Stage	Significado Fisiológico Proposto
0	*MED*	*HIGH*	*HIGH*	*HIGH*	*HIGH*	*HIGH*	*HIGH*	*LOW*	Movimento Ativo e Caminhadas
1	*MED*	*MED*	*HIGH*	*HIGH*	*HIGH*	*HIGH*	*HIGH*	*HIGH*	Atividade com Presença de Sono
2	*HIGH*	*MED*	*MED*	*MED*	*MED*	*MED*	*MED*	*LOW*	Concentração / Carga Cognitiva
3	*HIGH*	*MED*	*MED*	*HIGH*	*HIGH*	*MED*	*MED*	*LOW*	Esforço Físico / Atividade Intensa
4	*MED*	*LOW*	*MED*	*LOW*	*MED*	*LOW*	*MED*	*HIGH*	Repouso ou Sono

A Figura 4.22 ilustra a distribuição temporal dos clusters do Clustering Hierárquico com dados ao minuto ao longo de uma jornada completa.

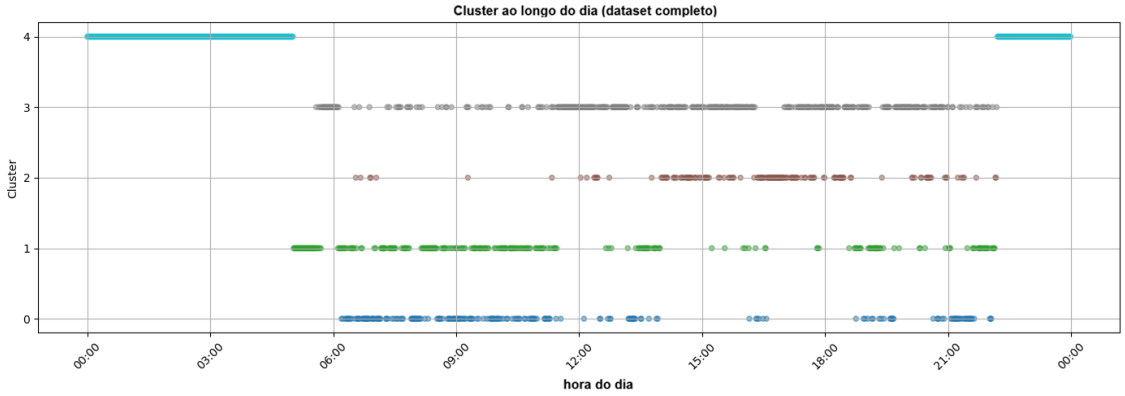


Figura 4.22: Distribuição temporal diária dos clusters do Clustering Hierárquico ($k = 5$, dados ao minuto) ao longo de uma jornada.

A Figura 4.22 apresenta a distribuição temporal dos *clusters* obtidos pelo Clustering Hierárquico com dados ao minuto. Em comparação com o GMM, observa-se uma maior alternância entre estados ao longo do dia, originando transições mais frequentes e uma evolução temporal menos contínua. Apesar de os clusters de *Repouso ou Sono* (Cluster 4) e *Concentração / Carga Cognitiva* (Cluster 2) apresentarem uma distribuição compatível com os períodos noturnos e laborais, respetivamente, os restantes grupos mostram maior dispersão temporal. Em particular, o cluster *Atividade com Presença de Sono* (Cluster 1) apresenta uma assinatura fisiológica pouco intuitiva, combinando elevados níveis de atividade física com valores elevados de *Sleep Stage*, o que dificulta a sua interpretação fisiológica. De forma geral, embora o modelo consiga distinguir estados de repouso, atividade e maior carga cognitiva, a elevada variabilidade temporal e a sobreposição entre alguns clusters tornam a segmentação menos consistente e menos interpretável do que a obtida com o GMM.

5. **Modelo de Clustering Hierárquico em Janelas de 10 Minutos ($k = 5$):**

   Por fim, para os dados agregados em janelas de 10 minutos, o **Clustering Hierárquico Aglomerativo ($k = 5$)** gerou os agrupamentos descritos na Tabela 4.33.

Tabela 4.33: Assinatura Fisiológica dos Clusters para o Clustering Hierárquico ($k = 5$, Janelas de 10 min)

Cluster	EDA	Pulse Rate	MET	Act. Counts	Step Counts	Vec. Mag.	Act. Intensity	Sleep Stage	Significado Fisiológico Proposto
0	*HIGH*	*MED*	*MED*	*MED*	*MED*	*MED*	*MED*	*LOW*	Concentração e Trabalho / Jornada Principal
1	*MED*	*LOW*	*LOW*	*LOW*	*LOW*	*LOW*	*LOW*	*HIGH*	Repouso Total / Sono Profundo
2	*MED*	*MED*	*HIGH*	*HIGH*	*HIGH*	*HIGH*	*HIGH*	*LOW*	Movimento Ativo / Caminhadas e Deslocamentos
3	*MED*	*HIGH*	*HIGH*	*MED*	*HIGH*	*HIGH*	*HIGH*	*LOW*	Picos de Esforço Físico
4	*LOW*	*MED*	*HIGH*	*MED*	*HIGH*	*MED*	*HIGH*	*HIGH*	O Despertar e Rotinas Matinais

A Figura 4.23 ilustra a distribuição temporal dos clusters do Clustering Hierárquico com janelas de 10 minutos ao longo de uma jornada completa.

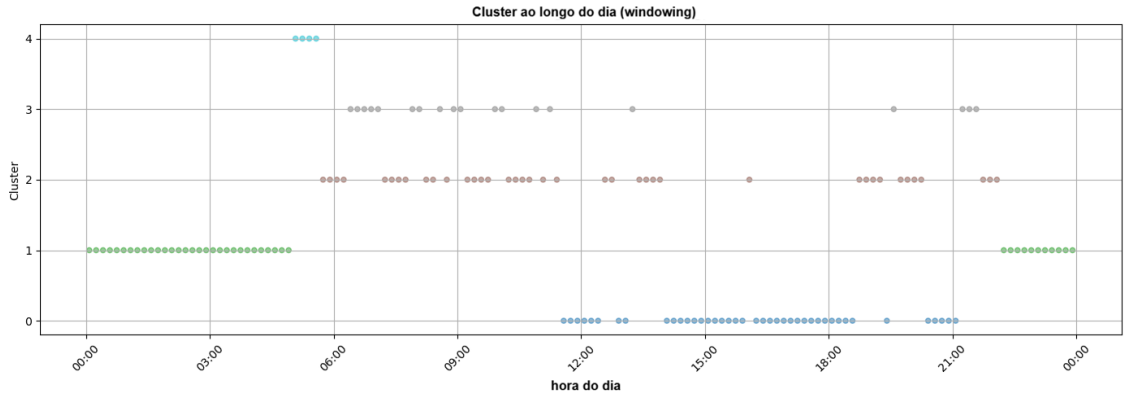


Figura 4.23: Distribuição temporal diária dos clusters do Clustering Hierárquico ($k = 5$, janelas de 10 min) ao longo de uma jornada.

O Clustering Hierárquico treinado com os dados agregados em janelas de 10 minutos identificou cinco estados fisiológicos coerentes, cuja interpretação resultou da análise conjunta da assinatura das variáveis e da respetiva distribuição temporal. O cluster *Repouso Total* concentra-se durante o período noturno, apresentando baixos níveis de atividade física e frequência cardíaca e elevados valores de *Sleep Stage*. Após o despertar surge o cluster *Despertar e Rotinas Matinais*, caracterizado por maior movimento, mas ainda com reduzida ativação fisiológica. Durante grande parte da jornada laboral predomina o cluster *Concentração e Trabalho*, distinguido pelo EDA elevado e níveis moderados de atividade, enquanto o cluster *Movimento Ativo* corresponde a deslocações e caminhadas distribuídas ao longo do dia. Por fim, o cluster *Picos de Esforço Físico* ocorre apenas de forma pontual, representando os momentos de maior intensidade física.

Tal como observado no GMM com janelas temporais, a agregação em intervalos de 10 minutos produziu uma evolução temporal dos clusters mais estável e organizada. Os diferentes estados distribuem-se em blocos relativamente bem definidos, reduzindo a alternância constante observada nos modelos treinados com dados ao minuto. Verifica-se ainda uma sequência coerente entre repouso, despertar, atividade moderada, período de trabalho e episódios ocasionais de maior esforço físico, sendo estes últimos os menos frequentes ao longo da jornada. Este comportamento sugere que a agregação temporal atenuou as flutuações instantâneas dos sinais fisiológicos, permitindo ao modelo identificar estados mais consistentes e facilmente interpretáveis.

Validação Externa com Dados Experimentais do Empatica

Para complementar a avaliação dos modelos de agrupamento, foi realizado um ensaio de validação externa com dados fisiológicos recolhidos diretamente através de um relógio Empatica EmbracePlus. O objetivo foi verificar se os estados fisiológicos identificados no conjunto de treino também eram reconhecidos em dados independentes, recolhidos de um participante diferente daquele cujos dados foram utilizados no treino. Esta abordagem permite avaliar a capacidade de generalização dos modelos para além da separação matemática observada nos dados originais.

Foram consideradas três situações experimentais distintas: **atividade física**, incluindo musculação e exercício cardiovascular de elevada intensidade; **trabalho em computador**, representativo de uma situação de concentração e carga cognitiva; e **sono**, correspondente a um

período prolongado de repouso. Os dados foram recolhidos nos dias 24 e 25 de abril de 2026, abrangendo aproximadamente duas horas de atividade física, duas horas de trabalho em computador e 5 h 46 min de sono.

Os dados experimentais foram submetidos ao mesmo *pipeline* de pré-processamento utilizado na construção dos modelos. Foram, assim, aplicados o tratamento de valores omissos, a deteção e o tratamento de anomalias e *outliers*, a normalização e o *scaling*, bem como a codificação das variáveis categóricas. Nos modelos GMM foi ainda aplicada a transformação PCA correspondente. Após este processamento, os dados foram introduzidos nas cinco configurações de inferência previamente preparadas: GMM com dados originais ($k = 9$), GMM Restrito com dados originais ($k = 4$), GMM com janelas de 10 minutos ($k = 5$), Árvore de Decisão treinada para reproduzir o Clustering Hierárquico com dados originais ($k = 5$) e Árvore de Decisão treinada para reproduzir o Clustering Hierárquico com janelas de 10 minutos ($k = 5$). Como o Clustering Hierárquico não permite atribuir diretamente novos dados a um cluster sem recalcular a estrutura de agrupamento, foram utilizadas as respetivas Árvores de Decisão para realizar a inferência nos dados experimentais. Os modelos não foram reajustados aos dados experimentais, permitindo avaliar diretamente a sua capacidade de generalização.

A avaliação foi baseada na interpretação fisiológica atribuída anteriormente a cada *cluster*. Para cada modelo e situação experimental foram definidos os *clusters* esperados. Por exemplo, no GMM com dados originais ($k = 9$), os *clusters* 0 e 5 foram associados ao sono profundo, os *clusters* 3, 4 e 8 à atividade física e os *clusters* 2, 6 e 7 ao trabalho ou à concentração. Uma previsão foi considerada correta quando pertencia ao conjunto de *clusters* compatível com a atividade experimental; caso contrário, foi considerada incorreta. Deste modo, a atribuição não supervisionada de *clusters* foi convertida numa medida de concordância entre o estado fisiológico esperado e o estado identificado pelo modelo.

Nos dados originais, o GMM obteve uma *accuracy* de 75,17% para a atividade física, 82,64% para o trabalho em computador e 46,09% para o sono. O GMM Restrito ($k = 4$) alcançou 60,40% na atividade física, 81,82% no trabalho em computador e 59,71% no sono. A Árvore de Decisão treinada para reproduzir o Clustering Hierárquico alcançou 59,73% na atividade física, 81,82% no trabalho em computador e 93,04% no sono. Assim, embora o GMM original tenha apresentado o desempenho mais elevado na identificação da atividade física e o GMM original e o GMM Restrito tenham obtido resultados semelhantes no trabalho em computador, a árvore associada ao modelo hierárquico revelou uma capacidade claramente superior para reconhecer o período de sono.

As Figuras 4.24, 4.25 e 4.26 apresentam a distribuição temporal das previsões do GMM com dados originais ($k = 9$) durante o trabalho em computador, a atividade física e o sono, respetivamente. Os pontos verdes representam previsões pertencentes aos *clusters* esperados para cada atividade, enquanto os pontos vermelhos correspondem a previsões fora desse conjunto. Durante o trabalho em computador, predominam as previsões associadas ao estado de trabalho ou concentração, em concordância com a *accuracy* de 82,64%. Na atividade física, a maioria das previsões concentra-se nos *clusters* associados à atividade física, embora ocorram intervalos classificados como trabalho ou concentração. Durante o sono, observa-se uma presença prolongada de previsões no *cluster* 0, mas também um número considerável de classificações em estados não associados ao sono profundo, o que explica a menor *accuracy* nesta situação.

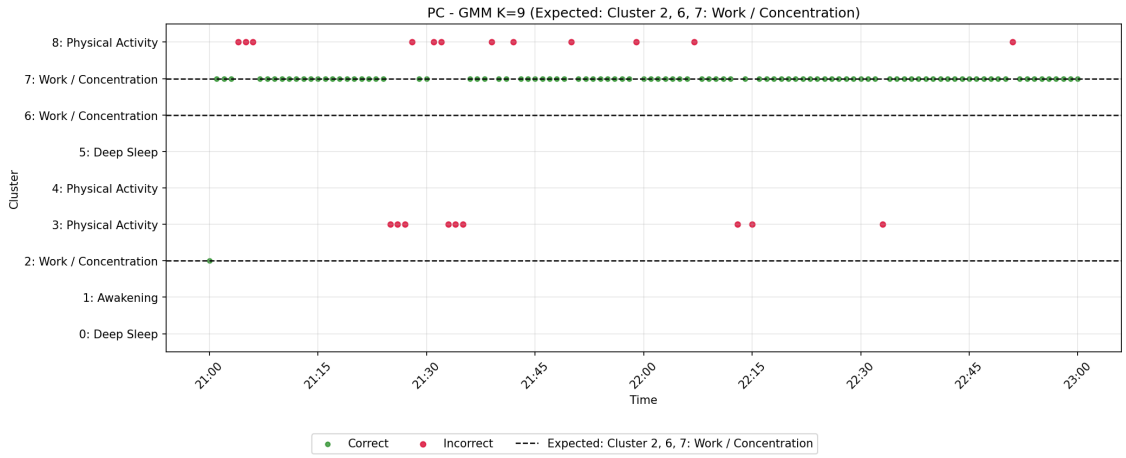


Figura 4.24: Distribuição temporal das previsões do GMM ($k = 9$) durante o trabalho em computador.

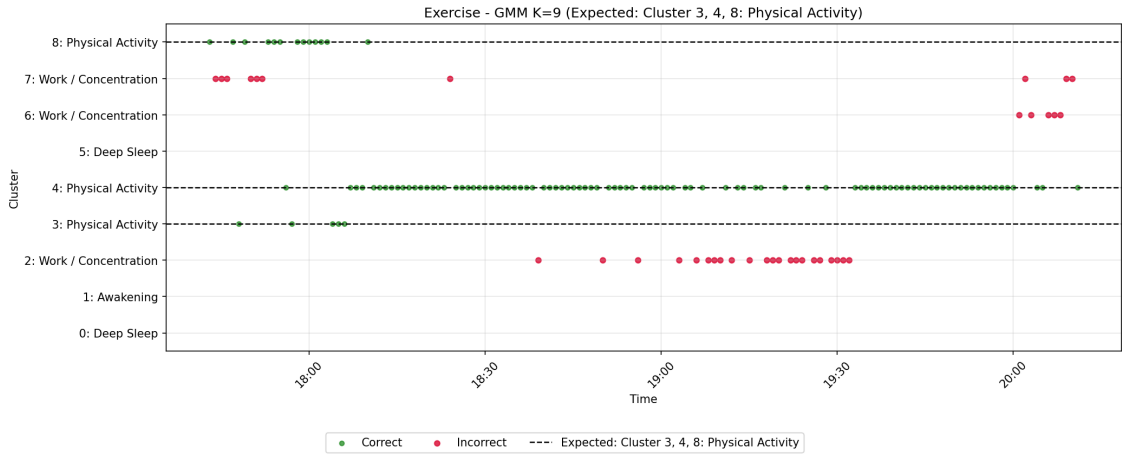


Figura 4.25: Distribuição temporal das previsões do GMM ($k = 9$) durante a atividade física.

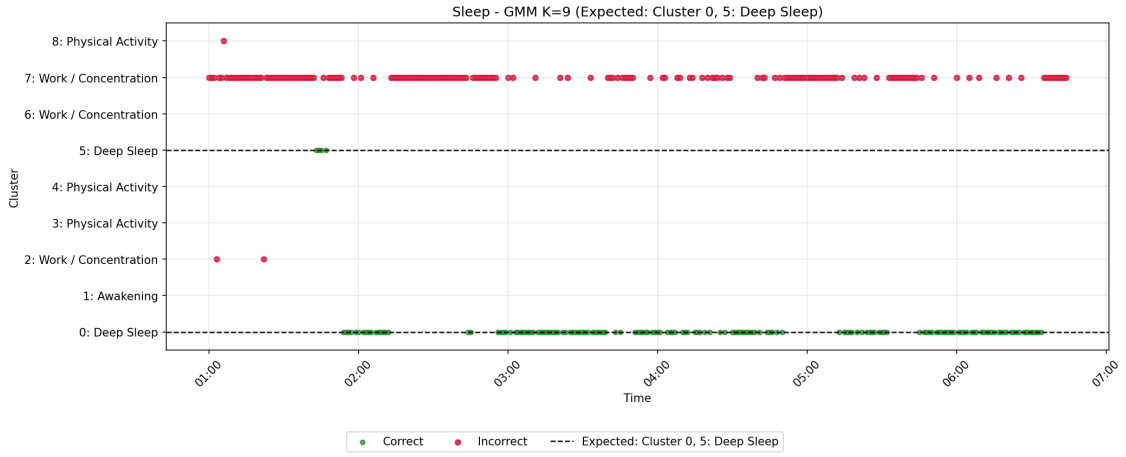


Figura 4.26: Distribuição temporal das previsões do GMM ($k = 9$) durante o período de sono.

As distribuições temporais das previsões relativas às restantes configurações dos modelos encontram-se disponíveis no **Apêndice B**.

Para os modelos baseados em janelas temporais de 10 minutos, o GMM obteve uma *accuracy* de 26,67% na atividade física, 76,92% no trabalho em computador e 51,43% no sono. A Árvore de Decisão treinada para reproduzir o Clustering Hierárquico com janelas apresentou 0,00% na atividade física, 23,08% no trabalho em computador e 100,00% no sono. A agregação temporal não produziu, portanto, uma melhoria uniforme no reconhecimento das atividades. Embora tenha favorecido claramente a identificação do sono através da árvore associada ao modelo hierárquico, que classificou corretamente as janelas avaliadas, a mesma representação dificultou a identificação da atividade física e do trabalho em computador. A tabela com todos os resultados da validação externa pode ser consultada na Tabela 4.34.

Tabela 4.34: Accuracy da validação externa para as diferentes configurações dos modelos.

Modelo	**Atividade física**	**Trabalho/PC**	**Sono**
GMM ($k = 9$)	75,17%	82,64%	46,09%
GMM Restrito ($k = 4$)	60,40%	81,82%	59,71%
Árvore de Decisão (Hierárquico, $k = 5$)	59,73%	81,82%	93,04%
GMM, janelas ($k = 5$)	26,67%	76,92%	51,43%
Árvore de Decisão (Hierárquico, janelas, $k = 5$)	0,00%	23,08%	100,00%

Em conjunto, os resultados da validação externa mostram que nenhuma configuração apresentou o melhor desempenho em todas as situações fisiológicas. O GMM com dados originais revelou o comportamento mais equilibrado na identificação da atividade física e do trabalho em computador, enquanto o Clustering Hierárquico com dados originais se destacou no reconhecimento do sono. O GMM Restrito ($k = 4$) apresentou um desempenho intermédio, melhorando a identificação do sono face ao GMM original, mas ficando abaixo do Clustering Hierárquico nessa atividade. A utilização de janelas de 10 minutos reforçou a identificação de estados prolongados de repouso no modelo hierárquico, mas prejudicou a discriminação de atividades de curta duração ou mais variáveis, como o exercício físico e determinadas situações de trabalho. Estes resultados confirmam que a qualidade dos modelos de agrupamento não deve ser avaliada exclusivamente através de métricas internas, como o *Silhouette Score* ou o WCSS, devendo incluir também a aplicação a dados independentes e experimentalmente controlados.

4.5 Análise e Conclusões de Resultados

Esta secção analisa e interpreta os principais resultados experimentais apresentados neste capítulo. Primeiro, são discutidos os modelos supervisionados de regressão e classificação desenvolvidos com os dados da banda peitoral Polar H10. De seguida, são analisados os modelos não supervisionados de agrupamento (*clustering*) aplicados aos dados multimodais e de atividade do relógio inteligente Empatica EmbracePlus.

Conclusões do Polar H10 (Modelos Supervisionados):

1. Interpretação do FatigueIndex

O desempenho excecional dos modelos de regressão, particularmente da Regressão Linear ($R^2 = 1.0$), explica-se pelo facto de o *FatigueIndex* ter sido construído através de uma **fórmula heurística** baseada nos próprios atributos do *dataset*. Uma vez que a variável alvo é uma combinação linear ponderada de métricas como `HR_mean`, `RMSSD` e `ECG_energy`, é expectável que os modelos consigam identificar e reconstruir esta relação matemática com facilidade.

Por isso, a questão principal não é apenas saber qual é o melhor algoritmo. Os resultados mostram que os modelos conseguem reproduzir com eficácia tanto o **valor contínuo** do *FatigueIndex* como as **categorias** definidas a partir desse índice. A capacidade de identificar corretamente diferentes níveis de ativação ou de fadiga depende sobretudo de quão bem o próprio índice representa esses estados na vida real do trabalhador. Ainda assim, os resultados do estudo com dados externos sugerem que as previsões e a representação do índice foram coerentes com diferenças entre períodos de menor ativação, atividade moderada e maior esforço físico.

O *FatigueIndex* deve, portanto, ser compreendido como uma tentativa heurística de representar diferentes níveis de fadiga e ativação, estando mais próximo de um identificador de níveis relativos de atividade física e estado fisiológico. As categorias LOW, MED e HIGH constituem uma referência que permite organizar os sinais numa escala comum, comparar participantes e modelos, bem como acompanhar alterações do estado fisiológico no Gémeo Digital.

2. Importância das Características *(estudo de Ablação)*

O estudo de ablação mostrou que a **combinação das características de ECG, HR/R-R e temporais** é a mais robusta para a generalização entre trabalhadores. No XGBoost, o cenário completo alcançou uma Accuracy média de 0,8817, uma Balanced Accuracy de 0,8547 e um Macro-F1 de 0,8310. Quando foram removidas as características de ECG, estes valores diminuíram para 0,6566, 0,6413 e 0,5991, respetivamente. Quando foram removidas as características de HR/R-R e temporais, mantendo apenas as características derivadas do ECG, a Accuracy foi de 0,6783, mas a Balanced Accuracy e o Macro-F1 diminuíram para 0,6136 e 0,5892.

Assim, as características derivadas do ECG podem manter alguma capacidade discriminativa quando utilizadas isoladamente, mas não substituem a combinação multimodal na avaliação LOSO. Por este motivo, no âmbito do projeto, não seria recomendável prescindir de nenhuma das principais medições fisiológicas (ECG, HR ou RR). Por sua vez, o resultado

intra-individual anterior, no qual o XGBoost atingiu 97,65% sem HR/R-R, deve ser interpretado como evidência de reprodução das categorias do *FatigueIndex* num único trabalhador, e não como prova de reconhecimento independente da fadiga ou de um alerta de segurança clinicamente fiável. A utilidade de características como `ECG_missing_peaks` e `ECG_samp_ent` deverá ser confirmada em avaliações com mais participantes e com referências fisiológicas independentes.

3. Generalização e Validação Externa

Na avaliação LOSO, o **XGBoost apresentou o melhor desempenho médio** entre os modelos testados, com Accuracy de 0,88, Balanced Accuracy de 0,85 e Macro-F1 de 0,83. A classe MED foi a mais difícil de identificar, com recall médio de 0,74, enquanto LOW e HIGH alcançaram recalls de 0,91 e 0,92. Esta diferença indica que os estados intermédios são mais difíceis de separar dos estados adjacentes, constituindo uma limitação importante para a interpretação das categorias derivadas do *FatigueIndex*.

A dificuldade na identificação da classe MED poderá estar parcialmente relacionada com a definição dos limiares P33 e P66. Como trabalho futuro, deverão ser avaliadas diferentes divisões percentílicas, verificando se a alteração dos limites permite melhorar a separação entre categorias sem introduzir desequilíbrio entre classes ou sobreajuste.

A validação externa com o Polar H10 permitiu observar o comportamento temporal dos modelos num novo participante, embora sem etiquetas independentes do nível real de fadiga. No registo completo `PC`, a Regressão Logística apresentou a maior concordância contextual (90,85%), enquanto no registo completo `EXERCISE` o melhor resultado foi obtido pelo SVM (78,15%). Na análise dos intervalos específicos, os quatro modelos foram compatíveis com o contexto em todas as janelas da caminhada na passadeira, enquanto no trote o Random Forest apresentou a maior concordância (90%), com apenas dez janelas avaliadas. Estes resultados reforçam a interpretação das categorias LOW, MED e HIGH como uma representação aproximada de diferentes estados físicos e níveis de atividade, mas devem ser entendidos como evidência de coerência contextual, e não como métricas de exatidão clínica ou validação independente da fadiga.

Em síntese, os modelos demonstraram capacidade para reconhecer padrões fisiológicos em trabalhadores diferentes, sobretudo quando combinam várias características, embora o desempenho varie entre pessoas e seja inferior na categoria intermédia MED. A utilidade destes modelos deverá ser confirmada em estudos com mais participantes e com medidas de referência independentes, capazes de avaliar de forma mais direta os diferentes níveis de fadiga.

4. Limitações dos Modelos e dos Dados

Apesar da capacidade de generalização observada na avaliação LOSO, a variabilidade entre trabalhadores continua a ser relevante: o desempenho do XGBoost foi elevado em vários participantes, mas diminuiu consideravelmente nos trabalhadores W07 e W08, enquanto o resultado perfeito de W09 deve ser interpretado com cautela devido às suas apenas 16 janelas. Esta heterogeneidade não invalida os resultados obtidos, mas mostra que o desempenho não é uniforme entre trabalhadores e que a aplicação a novos utilizadores poderá beneficiar de calibração ou validação adicional, reforçando a necessidade de personalizar os modelos de IA dentro do ecossistema do Gémeo Digital.

A qualidade dos dados constitui igualmente uma limitação importante. A presença de **valores omissos** pode reduzir o número de janelas disponíveis para análise e comprometer a estabilidade das características extraídas. Do mesmo modo, falhas na colocação do dispositivo, na transmissão dos dados ou na deteção dos sinais podem introduzir artefactos ou eliminar informação relevante dos sinais de ECG, HR e R-R. Como consequência, parte das diferenças observadas entre trabalhadores e entre modelos poderá estar relacionada com a qualidade da aquisição, e não apenas com os estados fisiológicos representados pelo *FatigueIndex*. Esta limitação é particularmente relevante porque o índice é calculado a partir das próprias características fisiológicas utilizadas pelos modelos.

Por isso, as próximas experiências deverão acompanhar de forma sistemática a quantidade e a origem dos valores omissos, bem como as falhas ocorridas durante a recolha. Será também necessário verificar se os modelos mantêm um desempenho estável quando os dados são obtidos em condições de aquisição mais controladas e com diferentes participantes. Esta análise permitirá distinguir melhor as limitações do modelo das limitações introduzidas pelo processo de recolha dos sinais.

5. Estratégia de Desenvolvimento dos Modelos

Os resultados mostram uma diferença importante entre os cenários intra-individual e inter-individual. Quando o modelo é treinado e testado com dados do mesmo trabalhador, o desempenho é elevado, mas isso não garante que o modelo reconheça corretamente os estados de outros trabalhadores. Na avaliação LOSO, os modelos demonstraram uma capacidade de generalização mais realista, embora o desempenho não tenha sido perfeito e tenha variado entre indivíduos.

Esta diferença deixa em aberto duas estratégias para o desenvolvimento do Gémeo Digital. Uma possibilidade consiste em treinar **modelos personalizados** para cada trabalhador, utilizando uma fase inicial de calibração. Outra consiste em continuar a recolher dados de mais participantes e a avaliar modelos com maior **capacidade de generalização**. A primeira estratégia poderá oferecer um desempenho mais elevado para cada utilizador, enquanto a segunda poderá facilitar a aplicação do sistema a novos trabalhadores sem depender de uma calibração extensa.

6. Outras Abordagens de Modelação e Trabalho Futuro

Até ao momento, esta investigação focou-se em métodos de aprendizagem supervisionada, que demonstraram resultados sólidos. Como trabalho futuro, poderão ser avaliados modelos de **Deep Learning**, como LSTM, Bi-LSTM e 1D-CNN, para extrair padrões temporais e morfológicos mais complexos das séries temporais do Polar H10. Estas arquiteturas são compatíveis com os dados de ECG, HR e RR, mas não foram implementadas nesta investigação e exigiriam uma amostra maior para avaliar o risco de sobreajuste e a capacidade de generalização para novos trabalhadores.

Em paralelo, a implementação de métodos de aprendizagem não supervisionada, como o **Clustering**, constituiria uma abordagem exploratória para organizar os dados sem depender diretamente de uma fórmula pré-definida. Ao agrupar os sinais por semelhança estatística, seria possível avaliar em que medida os grupos gerados pela máquina se correspondem com as categorias do *FatigueIndex* heurístico. Esta comparação entre métodos supervisionados e não supervisionados poderia complementar a análise atual, permitindo identificar padrões alternativos de categorização do estado do trabalhador.

Conclusões do Relógio EmbracePlus (Modelos Não Supervisionados):

1. Efeito da Agregação Temporal

A comparação entre os dados ao nível do minuto e os dados agregados em janelas temporais de 10 minutos permitiu avaliar o efeito da resolução temporal nos agrupamentos obtidos. Nos dados originais, os algoritmos de clustering foram expostos a maior variabilidade instantânea dos sinais. No GMM, a agregação temporal reduziu o número de agrupamentos de $k = 9$ para $k = 5$ e aumentou o Silhouette Score de 0.3475 para 0.3742. No Clustering Hierárquico, o Silhouette Score também aumentou de 0.3959 para 0.4132. Contudo, nos dados externos, a agregação não produziu ganhos uniformes: melhorou o reconhecimento do sono no Clustering Hierárquico, mas reduziu o desempenho na atividade física e no trabalho em computador. Assim, a **agregação temporal** pode tornar os agrupamentos mais compactos, mas o seu efeito na capacidade de distinguir diferentes atividades depende do modelo e da situação analisada.

2. Efeito da Redução de Dimensionalidade

A metodologia aplicada revelou um compromisso importante na fase de engenharia de características. Para o GMM, foi utilizado o *Principal Component Analysis* (PCA), uma técnica que reduz o número de variáveis sem eliminar a maior parte da informação presente nos dados. Nos dados ao minuto, foram suficientes 6 componentes principais, enquanto nas janelas temporais foram suficientes 4, mantendo-se em ambos os casos cerca de 90% da variância original. Esta redução tornou o conjunto de dados mais simples e facilitou o cálculo da distribuição probabilística utilizada pelo GMM, bem como a aplicação do critério BIC para comparar diferentes números de agrupamentos.

No caso do Clustering Hierárquico, não foi aplicada esta redução. O modelo foi treinado diretamente com as 12 características originais normalizadas, tanto nos dados ao minuto como nas janelas temporais. Neste caso, o valor mais elevado de Silhouette Score foi 0.4132, indicando uma melhor coesão interna dos agrupamentos quando o conjunto completo de características foi mantido. Assim, os resultados sugerem que o PCA foi útil para simplificar a modelação do GMM, enquanto o Clustering Hierárquico beneficiou da utilização das características originais.

3. Escolha do Número de Agrupamentos

Por fim, os resultados permitiram discutir a diferença entre a seleção do número de clusters com base em critérios matemáticos e a necessidade de obter agrupamentos fáceis de interpretar no contexto do Gémeo Digital Humano. Para os dados ao minuto, o critério BIC selecionou teoricamente $k = 9$ clusters para o GMM. Contudo, a análise das assinaturas sugeriu que esta configuração poderia fragmentar excessivamente os dados, criando grupos associados a pequenas variações entre estados semelhantes. A utilização de um número mais reduzido de clusters, como no GMM Restrito ($k = 4$) ou no Clustering Hierárquico ($k = 5$), facilitou a interpretação dos agrupamentos, embora com alguma redução do Silhouette Score. Estes resultados sugerem que, em aplicações de monitorização do estado fisiológico, a escolha do número de clusters deve considerar não apenas a qualidade matemática do agrupamento, mas também a **interpretabilidade e estabilidade em dados externos**.

4. Árvores de Decisão: Interpretação e Inferência dos Agrupamentos

Um dos desafios fulcrais na modelação não supervisionada consiste em traduzir limites multidimensionais em regras compreensíveis e utilizáveis. A validação paralela com **Árvores de Decisão** mostrou que é possível reproduzir com elevada concordância as decisões do Clustering Hierárquico. No cenário ao nível do minuto, a árvore de decisão necessitou de uma profundidade máxima de 8 níveis, atingindo 98.61% de precisão no treino e 92.01% em validação cruzada (5-Fold CV). Com janelas de 10 minutos, foi suficiente uma profundidade máxima de 5 níveis, com 93.06% de precisão no treino e 83.92% em validação. Estes resultados indicam que as árvores conseguem aproximar as fronteiras definidas pelo modelo hierárquico através de um conjunto reduzido de regras, mantendo uma elevada concordância com os agrupamentos de referência.

Esta propriedade é particularmente relevante para o projeto CRIARTE. Pela sua natureza, o Clustering Hierárquico não dispõe de uma operação direta de inferência para uma nova observação: para incorporar novos dados, é necessário recalcular ou reestruturar o agrupamento. Uma Árvore de Decisão treinada com as etiquetas produzidas pelo modelo hierárquico pode, por isso, funcionar como uma camada de inferência mais rápida, aplicável em tempo real e com menor custo computacional. As regras extraídas podem ainda servir de base à criação de regras heurísticas mais simples e eficientes para o Gémeo Digital, desde que a sua concordância com o modelo de referência seja monitorizada. Assim, as árvores constituem uma forma rápida e interpretável de reproduzir os agrupamentos identificados e de apoiar inferências operacionais no projeto.

5. Validação Externa

A validação externa demonstrou que as configurações de inferência conseguiram reconhecer, com diferentes níveis de desempenho, padrões fisiológicos presentes nos dados de um participante que não foi utilizado no treino. Este resultado é relevante, uma vez que as configurações foram aplicadas sem reajuste aos dados experimentais, permitindo avaliar a sua **capacidade de generalização** para além da estrutura observada no conjunto original. Ao mesmo tempo, nenhuma configuração apresentou o melhor desempenho nas três situações avaliadas. Isto mostra que os resultados variam consoante o participante e a atividade realizada, devido às diferenças fisiológicas e comportamentais entre as pessoas. Assim, a utilização das árvores como camada de inferência rápida é promissora, mas deve continuar a ser estudada e reforçada com dados independentes.

Entre os modelos GMM, a configuração original apresentou o desempenho mais equilibrado nas diferentes atividades, enquanto a versão restrita produziu resultados intermédios. A utilização de janelas de 10 minutos não melhorou de forma consistente o reconhecimento das atividades, embora o GMM possa realizar diretamente inferências sobre novos dados. Assim, o desempenho deste modelo dependeu tanto da atividade analisada como da representação temporal utilizada.

Nas configurações baseadas no Clustering Hierárquico, a inferência externa foi realizada pelas respetivas Árvores de Decisão. Estas apresentaram um comportamento particularmente favorável no reconhecimento do sono, sobretudo com janelas temporais, mas tiveram mais dificuldades na identificação da atividade física e do trabalho em computador. Apesar disso, mantêm interesse como uma forma rápida de reproduzir as decisões do clustering. Será necessário testar tanto as árvores como os modelos GMM com mais participantes e em

diferentes situações, para confirmar se conseguem manter um funcionamento consistente em tempo real.

Em conjunto, estes resultados sugerem que, no âmbito do projeto CRIARTE, poderá ser vantajoso adotar uma **abordagem híbrida de inferência**, combinando diferentes modelos em vez de utilizar uma única solução para todas as atividades. Por exemplo, o sistema poderia recorrer ao modelo que apresenta melhor comportamento em cada situação, utilizando o GMM quando este distinguir melhor uma determinada atividade e as Árvores de Decisão quando for necessária uma inferência rápida baseada nos agrupamentos hierárquicos. Esta estratégia poderá aumentar a flexibilidade do Gémeo Digital, mas deverá ser estudada com mais participantes e atividades antes de ser implementada como regra geral.

6. Limitações dos Dados e Trabalho Futuro

Apesar dos resultados promissores obtidos com os dados externos, a validação do Empatica EmbracePlus foi realizada com dados de um **único participante**. Isto aconteceu porque o projeto dispunha de apenas um relógio Empatica EmbracePlus e porque cada recolha exigia uma simulação experimental financiada pelo próprio projeto. Como o dispositivo tem um custo elevado e as simulações exigem recursos, não foi possível recolher dados de mais participantes nem repetir as experiências em muitas condições diferentes. Os resultados devem, por isso, ser interpretados como uma avaliação inicial, não sendo possível garantir que os agrupamentos e as regras das árvores apresentem o mesmo comportamento noutras pessoas.

Como trabalho futuro, será necessário aumentar gradualmente o número de participantes e repetir as recolhas em diferentes atividades e condições experimentais. Será também importante verificar se os agrupamentos identificados pelos modelos correspondem às atividades realmente realizadas durante as experiências, como períodos de repouso, trabalho, exercício físico e sono. Para isso, será necessário utilizar registos das atividades ou avaliações obtidas por outro procedimento, em vez de analisar apenas os sinais utilizados pelos próprios modelos. Esta comparação permitirá perceber se os modelos identificam padrões associados a diferentes atividades ou se estão apenas a organizar matematicamente os dados do participante analisado.

Outra possibilidade consiste em substituir ou complementar o *clustering* por modelos supervisionados de *Machine Learning* e *Deep Learning*, aproveitando a diversidade de variáveis recolhidas pelo relógio. Para isso, seria necessário recolher, durante a experiência, avaliações periódicas da fadiga, do stress ou de outro estado relevante, através de perguntas ou escalas respondidas pelo próprio participante. Essas respostas poderiam fornecer as etiquetas dos dados e permitir treinar modelos capazes de estimar diretamente os níveis de fadiga, stress ou outros estados definidos pelo projeto em tempo real.

Capítulo 5

Conclusões

Esta dissertação foi desenvolvida no âmbito do projeto CRIARTE, que procura integrar inteligência artificial, sensores portáteis e gémeos digitais humanos para apoiar a segurança dos trabalhadores num contexto de elevado risco, como o da construção. O trabalho analisou duas fontes de informação complementares: os sinais de ECG, frequência cardíaca e intervalos R-R recolhidos pela banda Polar H10, e as variáveis fisiológicas e comportamentais recolhidas pelo relógio Empatica EmbracePlus.

No Polar H10 foram avaliados modelos supervisionados para reproduzir um índice heurístico construído como aproximação a variações do estado fisiológico, inicialmente associado à fadiga, e as respetivas categorias. No Empatica EmbracePlus foram estudados modelos não supervisionados de agrupamento, complementados por Árvores de Decisão para permitir inferências rápidas dos agrupamentos hierárquicos. Os resultados mostram que estas abordagens são tecnicamente viáveis, mas também evidenciam a necessidade de mais dados e de validação com diferentes participantes antes de uma utilização generalizada.

5.1 Resposta aos Objetivos de Investigação

O desenvolvimento foi orientado pelo objetivo geral e pelos seis objetivos específicos apresentados no Capítulo 1. A resposta a cada objetivo é sintetizada nos pontos seguintes.

Objetivo geral: desenvolver e avaliar modelos para prever o estado fisiológico do trabalhador

O objetivo geral foi concretizado através da análise de dois dispositivos e de duas estratégias de modelação. Os modelos do Polar H10 reproduziram com elevado desempenho o *FatigueIndex* heurístico, enquanto os modelos aplicados ao Empatica EmbracePlus identificaram agrupamentos associados a diferentes padrões de repouso, trabalho e atividade física. Estes resultados contribuem para a construção de um módulo de análise para um gémeo digital humano, embora ainda não constituam uma validação clínica independente da fadiga, do stress, da atividade física ou de outros estados humanos.

Objetivo 1: analisar e caracterizar os dados fisiológicos

Este objetivo foi cumprido através da análise dos sinais recolhidos pela banda Polar H10 e pelo relógio Empatica EmbracePlus. Foram identificadas variáveis relacionadas com ECG, frequência cardíaca, intervalos R-R, atividade eletrodérmica, movimento, sono e atividade comportamental, entre outras. A revisão do estado da arte, apresentada no Capítulo 2,

confirmou que estas variáveis são amplamente utilizadas em estudos de monitorização fisiológica e de caracterização de estados humanos, o que apoiou a sua seleção e indicou a sua relevância para os objetivos desta investigação. A análise mostrou ainda que os dados apresentam variabilidade temporal e diferenças importantes entre participantes e atividades, fatores que influenciam diretamente o desempenho dos modelos.

Objetivo 2: preparar os dados para a modelação

Este objetivo foi cumprido através da investigação, identificação e aplicação de várias etapas de preparação, incluindo tratamento de valores omissos, deteção de anomalias, normalização, escalamento, codificação de variáveis e extração de características. Estas etapas permitiram melhorar a qualidade e a comparabilidade dos dados, reduzir o impacto de imperfeições nos registos e preparar representações adequadas às diferentes abordagens de modelação. Nos dados do Empatica EmbracePlus foram ainda comparadas duas resoluções temporais: dados ao minuto e janelas de 10 minutos. Nos dados do Polar H10 foram utilizadas janelas temporais de 30 e 60 segundos, consoante a experiência. No GMM foi utilizado PCA para reduzir a dimensionalidade, enquanto o Clustering Hierárquico utilizou as 12 características originais normalizadas. A preparação dos dados foi, assim, ajustada às características de cada dispositivo, à resolução temporal analisada e aos requisitos dos modelos avaliados.

Objetivo 3: explorar diferentes abordagens de modelação

Este objetivo foi explorado através de diferentes abordagens de modelação, cuja seleção foi orientada pela revisão do estado da arte apresentada no Capítulo 2. No Polar H10, foram avaliados modelos supervisionados, nomeadamente a Regressão Linear, a Regressão Logística, o SVM, o Random Forest e o XGBoost. Foram realizadas experiências com dados de um único trabalhador e com dados de vários trabalhadores, incluindo avaliações da capacidade de generalização. Foi ainda realizado um estudo de ablação, comparando a configuração completa com configurações baseadas apenas em características de ECG ou em características de HR/R-R e temporais. No relógio Empatica EmbracePlus, foram avaliados os métodos de agrupamento GMM e Clustering Hierárquico, também selecionados com base no estado da arte, com apoio de Árvores de Decisão para reproduzir as etiquetas dos agrupamentos hierárquicos.

Os resultados obtidos permitem ainda identificar uma questão relevante para a utilização futura destes modelos: o problema de *cold start*. Neste contexto, as regras extraídas através das Árvores de Decisão poderão constituir uma base para definir estimativas iniciais para novos trabalhadores, utilizando perfis de referência antes de existir um volume suficiente de dados individuais. À medida que novos dados forem recolhidos, estas estimativas poderão ser progressivamente substituídas por previsões adaptadas ao perfil de cada trabalhador.

Objetivo 4: avaliar e comparar o comportamento dos modelos

Este objetivo foi cumprido através da definição e aplicação de métricas, em linha com as práticas identificadas no estado da arte do Capítulo 2. Para os modelos supervisionados do Polar H10, foram utilizadas métricas de regressão (MSE, RMSE, MAE e R^2) e de classificação (Accuracy, Balanced Accuracy, Macro-F1, precisão, recall e matrizes de confusão). Na generalização entre trabalhadores através da estratégia LOSO, os modelos reproduziram as categorias do índice heurístico, embora a classe MED fosse mais difícil de distinguir das classes adjacentes. Compararam-se ainda janelas de 30 e 60 segundos no Polar H10 com

dados ao minuto e janelas de 10 minutos no Empatica EmbracePlus. No relógio, os agrupamentos foram analisados através do BIC, do Silhouette Score e da variabilidade intra-cluster, enquanto as Árvores de Decisão foram avaliadas pela reprodução das respetivas etiquetas. Os dados externos permitiram avaliar os modelos num novo participante e em diferentes contextos de atividade. A aplicação conjunta destas métricas permitiu avaliar e comparar o comportamento dos modelos e identificar as abordagens mais adequadas aos dados disponíveis e aos diferentes cenários analisados. Os resultados evidenciam também a necessidade de validações adicionais com mais participantes e referências independentes.

Objetivo 5: selecionar uma abordagem viável para utilização em tempo real

Este objetivo foi parcialmente cumprido, uma vez que foram exploradas abordagens com potencial para utilização em tempo real, embora ainda seja necessária validação adicional. O GMM permite realizar inferências diretamente sobre novos dados, enquanto as Árvores de Decisão podem reproduzir rapidamente as decisões do Clustering Hierárquico, que não dispõe de uma inferência direta para novas observações. Além disso, as Árvores de Decisão permitem extrair regras heurísticas simples e fáceis de implementar. Esta simplicidade pode ser particularmente relevante em contextos com um elevado fluxo de dados, nos quais decisões baseadas em regras podem permitir respostas rápidas, sem depender de processos de inferência mais complexos e reduzindo possíveis atrasos na identificação de situações de risco. No entanto, a eficácia destas abordagens e a sua capacidade de generalização ainda necessitam de uma avaliação mais aprofundada. Assim, uma abordagem híbrida, que selecione o modelo mais adequado para cada atividade ou estado, poderá ser uma solução interessante para o CRIARTE.

Objetivo 6: integrar o modelo num gémeo digital humano

Este objetivo foi parcialmente cumprido. Foram definidos os principais elementos do fluxo, desde a aquisição e preparação dos dados até à inferência e à sincronização dos resultados com a representação digital do trabalhador. Contudo, à data de conclusão desta dissertação, ainda não existe no projeto CRIARTE uma estrutura totalmente montada que permita unificar todos os dados do gémeo digital, encontrando-se essa estrutura atualmente em desenvolvimento. Assim, a integração dos modelos desenvolvidos na arquitetura do gémeo digital será desenvolvida em próximas atividades do projeto CRIARTE. Os modelos avaliados e as regras heurísticas extraídas fornecem uma base para a futura implementação de um módulo de inferência orientado para a monitorização contínua; no entanto, a integração completa destes modelos num sistema operacional, incluindo o processamento contínuo dos dados e a geração automática de alertas em contexto real, não foi implementada nem validada no âmbito desta dissertação.

5.2 Contribuições da Investigação

As principais contribuições desta investigação são a análise conjunta de dados da banda Polar H10 e do relógio Empatica EmbracePlus; a avaliação de modelos supervisionados e não supervisionados para diferentes tipos de dados fisiológicos; o estudo de ablação das características ECG, HR e R-R; a comparação entre dados ao minuto e janelas temporais; e a utilização de Árvores de Decisão como representação rápida e interpretável dos agrupamentos hierárquicos. Foi ainda formulada uma possível abordagem híbrida de inferência para

o projeto CRIARTE, combinando modelos de acordo com o seu comportamento em diferentes atividades. A metodologia e os resultados obtidos poderão servir como base e fonte de inspiração para investigadores que estudem a análise de dados fisiológicos e o treino de modelos para a previsão de estados humanos em contextos laborais, incluindo a construção, bem como para a sua adaptação a outros contextos.

No âmbito da disseminação científica, foi elaborado o artigo de revisão sistematizada intitulado "*A Review of Physiological Monitoring and Prediction in Workers in High-Risk Construction Environments*" [23], baseado no estado da arte desenvolvido nesta investigação. O artigo foi aceite e apresentado na conferência **INISTA 2026** [29] pelo autor desta dissertação, a 17 de setembro de 2026, em Guimarães, Portugal, constituindo uma contribuição para a divulgação dos fundamentos e resultados da investigação. Após a conferência, está prevista a sua inclusão nas atas e a disponibilização através da **IEEE Xplore** [28], biblioteca digital especializada em publicações científicas e técnicas. Esta apresentação é documentada na Figura 5.1.



Figura 5.1: Apresentação do artigo na conferência INISTA 2026, Guimarães, Portugal, 17 set 2026.

Foi também submetido à revista **Advanced Engineering Informatics** [17], publicada pela editora Elsevier, o artigo "*Unsupervised Physiological State Clustering for Construction Worker Fatigue Monitoring: Comparing GMM and Hierarchical Clustering Across Temporal Resolutions*". Este trabalho reúne os resultados da análise dos dados do relógio Empatica EmbracePlus, incluindo o GMM, o Clustering Hierárquico, as Árvores de Decisão e a avaliação com dados externos. No momento de redação desta dissertação, o artigo encontra-se em revisão por pares. Ainda não foi tomada qualquer decisão editorial quanto à sua aceitação ou rejeição, pelo que a submissão é apresentada apenas como uma contribuição potencial para a disseminação científica dos resultados obtidos.

5.3 Limitações Identificadas

Apesar dos resultados encorajadores, o trabalho desenvolvido apresenta algumas limitações relevantes, que devem ser consideradas na interpretação dos resultados e no planeamento de desenvolvimentos futuros:

- **Natureza heurística do FatigueIndex:** Uma limitação importante da metodologia está relacionada com a natureza heurística do *FatigueIndex* e com a ausência de etiquetas fisiológicas independentes para validação. O índice constitui uma representação quantitativa construída a partir de características fisiológicas, não correspondendo a uma medida clínica direta de fadiga, stress ou de outros estados psicofisiológicos. Assim, os resultados obtidos representam a capacidade dos modelos para estimar esta representação, não permitindo estabelecer, por si só, uma avaliação clínica desses estados sem validação adicional.
- **Dados em falta no Polar H10:** Uma limitação importante está relacionada com a quantidade significativa de dados em falta nos registos da banda Polar H10 de alguns trabalhadores, sobretudo nas variáveis de frequência cardíaca (HR) e nos intervalos RR. Esta perda pode estar associada a medições incorretas, ao movimento do trabalhador, às condições do contexto de obra, a problemas de calibração ou a falhas de ligação entre o dispositivo e o sistema de registo. O conforto e a interação natural do trabalhador também podem influenciar a recolha, uma vez que a transpiração, a irritação ou alterações na posição da cinta podem modificar o contacto com a pele e provocar valores em falta ou artefactos nos sinais. Estes efeitos podem ser confundidos pelos modelos com alterações fisiológicas reais, condicionando as características obtidas e os resultados. Embora os modelos tenham apresentado desempenho satisfatório e capacidade de generalização para trabalhadores não observados durante o treino, não é possível excluir a influência destas limitações. Este tipo de ruído é expectável em recolhas reais, pelo que os modelos devem ser preparados para lidar com estas imperfeições ou minimizar o seu impacto.
- **Restrições da recolha de dados:** Existiram algumas restrições associadas ao próprio projeto que condicionaram a recolha de dados. A utilização de um único relógio Empatica EmbracePlus limitou a possibilidade de recolher dados de vários trabalhadores em simultâneo durante as simulações. Além disso, o acesso ao ecossistema do dispositivo, incluindo a aplicação e a plataforma de gestão dos dados, envolve custos de licenciamento, o que dificultou a disponibilização de um maior número de equipamentos. A escolha deste dispositivo foi, contudo, justificada pela qualidade, robustez e fiabilidade dos dados recolhidos, pela sua menor suscetibilidade ao ruído e pelo reconhecimento destas características na literatura e na prática. A preparação dos cenários simulados e a compensação dos trabalhadores envolvidos limitaram também a realização de um maior número de experiências com ambos os dispositivos. Estas condições podem ter reduzido a diversidade dos dados disponíveis para o treino e dificultado a avaliação da capacidade de generalização dos modelos para trabalhadores não observados. Assim, será necessária uma recolha mais ampla e diversificada para confirmar estes resultados e melhorar o desempenho dos modelos.
- **Ausência de etiquetas independentes:** Outra limitação importante está relacionada com a ausência de etiquetas independentes para validar os estados psicofisiológicos analisados. Os agrupamentos obtidos foram interpretados com base nas características dos dados de cada *cluster* e na sua distribuição temporal, procurando identificar os possíveis estados representados. Embora esta análise tenha procurado ser objetiva e baseada nos padrões observados nos dados, a ausência de avaliações subjetivas ou fisiológicas recolhidas simultaneamente com os dados do Empatica EmbracePlus limita a validação independente destas interpretações. Assim, apesar de os agrupamentos poderem representar adequadamente os padrões presentes nos dados, existe a possibilidade de erros na interpretação dos estados a eles associados, sendo necessária uma validação adicional para confirmar estas interpretações.

5.4 Trabalho Futuro

Para superar estas limitações e aproximar o sistema de uma aplicação real, propõem-se as seguintes linhas de investigação:

- **Melhoria da recolha de dados:** Como trabalho futuro, será necessário recolher dados de mais participantes e em diferentes atividades, aumentar o número de dispositivos disponíveis e repetir as experiências em condições mais variadas. Deverão também ser reforçados os procedimentos de calibração, verificação da ligação e controlo de qualidade dos sinais, bem como definidos protocolos de colocação e utilização dos dispositivos adequados ao contexto de obra. Estas medidas poderão reduzir a perda de dados e permitir distinguir mais claramente os problemas de medição, movimento, ligação e recolha das variações fisiológicas reais.
- **Etiquetas e modelos:** Uma abordagem a testar consiste na recolha de autorrelatos dos trabalhadores durante a realização das atividades, através de níveis ou escalas definidos para avaliar estados psicofisiológicos relevantes. Estes relatos poderiam ser associados temporalmente às janelas dos sinais recolhidos pelos dispositivos, permitindo criar etiquetas baseadas na perceção dos próprios trabalhadores e treinar modelos supervisionados de *Machine Learning* e *Deep Learning*. Esta estratégia poderá reduzir a necessidade de construir índices heurísticos ou de definir os alvos exclusivamente através de métodos de agrupamento. Poderiam ainda ser avaliadas arquiteturas LSTM, Bi-LSTM e 1D-CNN, bem como outras arquiteturas identificadas no estado da arte que não foram testadas nesta investigação, desde que a quantidade de dados e os recursos computacionais disponíveis permitam controlar o risco de sobreajuste.
- **Distinção entre estados físicos e mentais:** Embora esta investigação tenha procurado caracterizar diferentes estados humanos, incluindo fadiga física e mental, stress e carga de trabalho, os resultados obtidos apontaram sobretudo para níveis de atividade física e esforço. No caso do Polar H10, os resultados permitiram caracterizar principalmente níveis relativos de atividade física e esforço. No caso do Empatica EmbracePlus, os agrupamentos identificados permitiram reconhecer diferentes estados físicos e contextuais, incluindo períodos associados ao trabalho e a possíveis situações de esforço cognitivo, mas não permitiram caracterizar de forma específica estados mentais. Como desenvolvimento futuro, poderá ser estudado um conjunto de modelos orientado especificamente para estados mentais, como fadiga mental, stress e carga de trabalho cognitiva, explorando diferentes abordagens de aprendizagem e diferentes formas de caracterizar estes estados.
- **Integração no gémeo digital:** Com base nos resultados obtidos e nos modelos treinados, poderá também avançar-se para o desenho de uma arquitetura de integração no gémeo digital do projeto CRIARTE. Esta arquitetura deverá estudar a integração dos modelos e das suas inferências no ecossistema baseado em ROS2 utilizado pelo projeto, permitindo partilhar os dados dos sensores, as previsões e os alertas com os restantes componentes do gémeo digital. Poderá ainda ser considerada uma solução distribuída, na qual as inferências mais rápidas e a geração de alarmes sejam realizadas localmente, através de aplicações em dispositivos de *edge* presentes na obra, enquanto os modelos mais pesados e as análises que não exigem resposta imediata sejam executados através de *cloud computing*. A comparação destas alternativas deverá considerar a latência, a conectividade, os recursos computacionais, o consumo energético, a privacidade dos dados e a fiabilidade dos alertas.

- **Validação do FatigueIndex:** Será igualmente importante realizar uma validação independente do *FatigueIndex*, recolhendo simultaneamente os dados do Polar H10 e avaliações validadas de fadiga e stress, complementadas, quando adequado, por avaliações de profissionais de saúde e testes de desempenho ou atenção. O *FatigueIndex* não deve ser interpretado como uma medida direta destes estados, uma vez que os resultados deste trabalho sugerem que representa sobretudo níveis relativos de atividade física, esforço e estado fisiológico. A comparação com referências externas permitirá avaliar a sua relação com a fadiga e o stress e verificar o significado das categorias LOW, MED e HIGH. Deverá também ser avaliado o efeito de diferentes pontos de corte na conversão do índice contínuo em categorias, uma vez que outras estratégias além dos percentis P33 e P66 podem produzir categorias com significado diferente e influenciar o desempenho dos modelos. Este tipo de estudo deverá ser realizado com aprovação ética e acompanhamento especializado.

5.5 Reflexões Finais

Esta dissertação reuniu esforços de investigação e desenvolvimento centrados na análise de dados fisiológicos recolhidos por dispositivos portáteis e na aplicação de modelos de inteligência artificial à segurança laboral. A utilização conjunta do Polar H10 e do Empatica EmbracePlus permitiu explorar duas estratégias complementares: a aprendizagem supervisionada para reproduzir o *FatigueIndex* e a aprendizagem não supervisionada para identificar agrupamentos associados a diferentes padrões de atividade e contexto. Os resultados mostram que estas abordagens podem contribuir para caracterizar o estado fisiológico do trabalhador e constituem uma base experimental relevante para o desenvolvimento do projeto CRIARTE.

O trabalho permitiu também evidenciar alguns dos desafios associados à aplicação destes sistemas em contextos reais. A qualidade e a disponibilidade dos sinais, a variabilidade entre trabalhadores, a ausência de etiquetas independentes e a dificuldade em distinguir atividade física de estados mentais limitam a interpretação dos resultados. Por isso, os modelos desenvolvidos não devem ser entendidos como instrumentos clínicos ou como substitutos da avaliação humana, mas como componentes de apoio à monitorização e à tomada de decisão, sujeitos a validação adicional e supervisão adequada.

A continuação deste trabalho deverá combinar uma recolha de dados mais ampla, avaliações reportadas diretamente pelos trabalhadores e modelos capazes de representar diferentes estados físicos e psicofisiológicos. A integração das inferências no ecossistema ROS2 do CRIARTE, complementada por arquiteturas de processamento local e em cloud, poderá aproximar os resultados experimentais de uma aplicação operacional. Neste contexto, o gémeo digital humano deverá ser concebido como uma ferramenta complementar, orientada para a prevenção e para o apoio à segurança, capaz de ampliar a capacidade de acompanhamento do trabalhador sem substituir o conhecimento, a responsabilidade e a decisão humanas.

Bibliografia

[1] Abuwarda, Z. et al. «Wearable devices: Cross benefits from healthcare to construction». Em: *Automation in Construction* 142 (2022), p. 104501. doi: 10.1016/j.autcon.2022.104501. url: https://doi.org/10.1016/j.autcon.2022.104501.

[2] Aishwarya, K. P. et al. «Multi-Purpose Wearable Biofeedback Accessories». Em: *ICPECTS* n.d. (2024), pp. 1–6. doi: 10.1109/ICPECTS62210.2024.10780294. url: https://ieeexplore.ieee.org/document/10780294/.

[3] Albarrán Morillo, C. et al. «Early detection of physical fatigue in industry using wearable sensors and contextual modeling». Em: *Safety Science* 194 (2025), p. 107041. doi: 10.1016/j.ssci.2025.107041. url: https://doi.org/10.1016/j.ssci.2025.107041.

[4] Anjum, S. et al. «Generalizing fatigue prediction models for construction workers: Cross-experiment evaluation with transfer learning across thermal and load conditions». Em: *Automation in Construction* 181 (2025), p. 106680. doi: 10.1016/j.autcon.2025.106680. url: https://doi.org/10.1016/j.autcon.2025.106680.

[5] Ardecani, F. B. et al. «Assessing workers' neuro-physiological stress responses to augmented reality safety warnings in immersive virtual roadway work zones». Em: *Automation in Construction* 180 (2025), p. 106565. doi: 10.1016/j.autcon.2025.106565. url: https://doi.org/10.1016/j.autcon.2025.106565.

[6] Arifin, Arifin et al. «Real-Time Physiological Activity and Sleep State Monitoring System Using TS2Vec Embeddings and DBSCAN Clustering for Heart Rate and Motor Response Analysis in IoMT». Em: *Signals* 6.4 (2025), p. 67. doi: 10.3390/signals6040067. url: https://doi.org/10.3390/signals6040067.

[7] Arya, S. M. et al. «Effective Driver Fatigue Management and Prevention Using Cloud-Integrated RNN Models». Em: *ICICEC* n.d. (2024), pp. 1–6. doi: 10.1109/ICICEC62498.2024.10808640. url: https://ieeexplore.ieee.org/document/10808640/.

[8] Behradfar, Mohsen e Nuamah, Joseph. «Mental Workload Classification Using Electrocardiogram Data». Em: *Proceedings of the Human Factors and Ergonomics Society Annual Meeting* (2025). doi: 10.1177/10711813251358786. url: https://doi.org/10.1177/10711813251358786.

[9] Chen, H. et al. «Biosignal measurement for human-robot collaboration in construction: A systematic review». Em: *Advanced Engineering Informatics* 68 (2025), p. 103652. doi: 10.1016/j.aei.2025.103652. url: https://doi.org/10.1016/j.aei.2025.103652.

[10] Cheng, M.-Y. et al. «Automated fall risk classification for construction workers using wearable devices, BIM, and optimized hybrid deep learning». Em: *Automation in Construction* 172 (2025), p. 106072. doi: 10.1016/j.autcon.2025.106072. url: https://doi.org/10.1016/j.autcon.2025.106072.

[11] Crista, V. et al. «A Hybrid Model to Classify Physical Activity Profiles». Em: *Highlights in Practical Applications of Agents, Multi-Agent Systems, and Complex Systems Simulation*. 2022, pp. 268–278. doi: 10.1007/978-3-031-18697-4_22. url: https://doi.org/10.1007/978-3-031-18697-4_22.

[12] Devi, R. D. H. et al. «An IoT Based Intelligent Watch to Promote Child Safety». Em: *ICISC* n.d. (2025), pp. 1277–1281. doi: 10.1109/ICISC65841.2025.11188271. url: https://ieeexplore.ieee.org/document/11188271/.

[13] Devi, V. A. et al. «Wearable Physiological IoT System with Neural Network to Detect an Individual IT Professional's Stress Emotion in Working Environments». Em: *2023 7th International Conference on Intelligent Computing and Control Systems (ICICCS)* n.d. (2023), pp. 1–7. doi: 10.1109/ICICCS56967.2023.10142219. url: https://ieeexplore.ieee.org/document/10142219.

[14] Dhanasekar, G. e Nageswaran, S. «NeuroAdapt: A Multimodal Emotion-Cognitive-Fatigue Adaptive BCI System for Robotic Upper-Limb Rehabilitation». Em: *SENNET* n.d. (2025), pp. 1–6. doi: 10.1109/SENNET64220.2025.11135962. url: https://ieeexplore.ieee.org/document/11135962/.

[15] Divyabharathi, S. e Madhavan, S. «An Explainable IoT-based Framework for Anomaly Detection and Emergency Decision Management in Smart Healthcare». Em: *ICSCDS* n.d. (2025), pp. 678–682. doi: 10.1109/ICSCDS65426.2025.11167637. url: https://ieeexplore.ieee.org/document/11167637/.

[16] Elmousalami, H. et al. «Electroencephalography (EEG) for psychological hazards and mental health in construction safety automation: Algorithmic Systematic Review (ASR)». Em: *Automation in Construction* 177 (2025), p. 106346. doi: 10.1016/j.autcon.2025.106346. url: https://doi.org/10.1016/j.autcon.2025.106346.

[17] Elsevier. *Advanced Engineering Informatics*. 2026. url: https://www.sciencedirect.com/journal/advanced-engineering-informatics (acedido em 24/09/2026).

[18] Empatica Inc. *EmbracePlus: Advanced wearable for physiological data collection*. Official website of Empatica. Product technical information. 2024. url: https://www.empatica.com/embraceplus/.

[19] Europa Press. *Empatica's EmbracePlus obtains CE mark for quality physiological data collection*. Europa Press. Press release. 2021. url: https://www.europapress.es/comunicados/internacional-00907/noticia-comunicado-embraceplus-empatica-obtiene-marca-ce-recopilacion-datos-fisiologicos-calidad-20210415080155.html.

[20] European Commission. *AI Act enters into force*. Official website of the European Commission. European Commission News. 2024. url: https://commission.europa.eu/news-and-media/news/ai-act-enters-force-2024-08-01_es.

[21] Fan, Jiaxing et al. «A Deep Learning Approach for Mental Fatigue State Assessment». Em: *Sensors* 25.2 (2025), p. 555. doi: 10.3390/s25020555. url: https://www.mdpi.com/1424-8220/25/2/555.

[22] Fasoyinu, A. A. et al. «Wearable sensing devices for construction safety: Research trends, applications, and future prospects». Em: *Automation in Construction* 179 (2025), p. 106424. doi: 10.1016/j.autcon.2025.106424. url: https://doi.org/10.1016/j.autcon.2025.106424.

[23] Freitas, Carlos, Martinho, Diogo e Marreiros, Goreti. «A Review of Physiological Monitoring and Prediction in Workers in High-Risk Construction Environments». Accepted and presented at the 20th International Conference on Innovations in Intelligent Systems and Applications (INISTA 2026), Guimarães, Portugal, 17–19 September 2026. Proceedings forthcoming. 2026.

[24] Georgiev, Stiliyan et al. «Differential Neurophysiological and Autonomic Responses to Electric, Hybrid, and Internal Combustion Engine Vehicles During Real-World Driving Testing: A Multimodal Psychophysiological Study». Em: *Applied Sciences* 16.15

(2026), p. 7649. doi: 10.3390/app16157649. url: https://doi.org/10.3390/app16157649.

[25] Georgieva-Tsaneva, Galya et al. «Physiological State Recognition via HRV and Fractal Analysis Using AI and Unsupervised Clustering». Em: *Information* 16.9 (2025), p. 718. doi: 10.3390/info16090718. url: https://doi.org/10.3390/info16090718.

[26] Goutham, D. et al. «AI-Driven Fatigue Prediction in Healthcare Professionals Using Wearable Sensor Data and Gradient-Boosted Machine Learning Models». Em: *2025 International Conference on Recent Innovations in Science, Engineering and Technology (ICRISET)* n.a. (2025), pp. 1–8. doi: 10.1109/ICRISET64803.2025.11254790. url: https://ieeexplore.ieee.org/document/11254790.

[27] He, X. et al. «Towards a nuanced classification of mental fatigue: A comprehensive review of detection techniques and prospective research». Em: *Biomedical Signal Processing and Control* 111 (2025), p. 108496. doi: 10.1016/j.bspc.2025.108496. url: https://doi.org/10.1016/j.bspc.2025.108496.

[28] IEEE. *IEEE Xplore Digital Library*. 2026. url: https://ieeexplore.ieee.org/Xplore/home.jsp (acedido em 24/09/2026).

[29] INISTA Conference. *INISTA 2026*. 2026. url: https://inista2026.di.uminho.pt/ (acedido em 24/09/2026).

[30] Jaros, R. et al. «Automated recognition of worker activity using machine learning and multi-sensor fusion». Em: *Applied Soft Computing* 189 (2025), p. 114473. doi: 10.1016/j.asoc.2025.114473. url: https://doi.org/10.1016/j.asoc.2025.114473.

[31] Jayaweera, K. N. et al. «An Integrated Framework for Predicting Health Based on Sensor Data Using Machine Learning». Em: *2020 International Conference on Advancements in Computing (ICAC)* n.d. (2020), pp. 43–48. doi: 10.1109/ICAC51239.2020.9357134. url: https://ieeexplore.ieee.org/document/9357134/.

[32] Kakhi, K. et al. «Fatigue monitoring using wearables and AI: Trends, challenges, and future opportunities». Em: *Computers in Biology and Medicine* 195 (2025), p. 110461. doi: 10.1016/j.compbiomed.2025.110461. url: https://doi.org/10.1016/j.compbiomed.2025.110461.

[33] Karim, R. et al. «Advancing physical and mental fatigue analysis in construction workers». Em: *Developments in the Built Environment* 24 (2025), p. 100808. doi: 10.1016/j.dibe.2025.100808. url: https://doi.org/10.1016/j.dibe.2025.100808.

[34] Karpagam, G. R. et al. «Physiological Data-Based Stress Detection: From Wrist Sensors to Cloud Computing and User Feedback Integration». Em: *2024 International Conference on Smart Systems for Electrical, Electronics, Communication and Computer Engineering (ICSSEECC)* n.d. (2024), pp. 1–6. doi: 10.1109/ICSSEECC61126.2024.10649521. url: https://ieeexplore.ieee.org/document/10649521.

[35] Karthikeyan, R., McDonald, A. D. e Mehta, R. K. «What's in a label? Annotation differences in forecasting mental fatigue using ECG data and Seq2Seq architectures». Em: *TechRxiv* (2023). doi: 10.36227/techrxiv.24501295.v1. url: https://doi.org/10.36227/techrxiv.24501295.v1.

[36] Kazar, G. et al. «Exploring the relations between the physiological factors and the likelihood of accidents on construction sites». Em: *Engineering, Construction and Architectural Management* 29 (2021), pp. 456–475. doi: 10.1108/ECAM-11-2020-0958. url: https://doi.org/10.1108/ECAM-11-2020-0958.

[37] Kiriti, G. et al. «Smart Band for Senior Citizens». Em: *2022 Third International Conference on Intelligent Computing Instrumentation and Control Technologies (ICICICT)*

n.d. (2022), pp. 1–6. doi: 10.1109/ICICICT54557.2022.9917804. url: https://ieeexplore.ieee.org/document/9917804.

[38] Kuzhaloli, S. «Wearable Tech for Mental Health Monitoring Real-Time Stress Detection Using Biometric Sensors». Em: *2025 Global Conference in Emerging Technology (GINOTECH)* n.d. (2025), pp. 1–6. doi: 10.1109/GINOTECH63460.2025.11076888. url: https://ieeexplore.ieee.org/abstract/document/11076888.

[39] Leng, J. «Unlocking the power of industrial artificial intelligence towards Industry 5.0: Insights, pathways, and challenges». Em: *Journal of Manufacturing Systems* 70 (2024), pp. 263–278. doi: 10.1016/j.jmsy.2024.02.010. url: https://doi.org/10.1016/j.jmsy.2024.02.010.

[40] Lin, Y. et al. «Human digital twin: a survey». Em: *Journal of Cloud Computing* 13 (2024), p. 131. doi: 10.1186/s13677-024-00691-z. url: https://doi.org/10.1186/s13677-024-00691-z.

[41] Marcora, Samuele. «Perception of effort during exercise is independent of afferent feedback from skeletal muscles, heart, and lungs». Em: *Journal of Applied Physiology* 106.6 (2009), pp. 2060–2062. doi: 10.1152/japplphysiol.90378.2008. url: https://doi.org/10.1152/japplphysiol.90378.2008.

[42] Martinho, D. et al. «An Architecture for a Coaching System to Support Type 2 Diabetic Patients». Em: *Ambient Intelligence—Software and Applications—13th International Symposium on Ambient Intelligence*. Lecture Notes in Networks and Systems. Springer International Publishing, 2023, pp. 167–178. doi: 10.1007/978-3-031-22356-3_16. url: https://doi.org/10.1007/978-3-031-22356-3_16.

[43] Martinho, D. et al. «Effects of a Gamified Agent-Based System for Personalized Elderly Care: Pilot Usability Study». Em: *JMIR Serious Games* 11 (2023). doi: 10.2196/48063. url: https://doi.org/10.2196/48063.

[44] Messaoud, Ines Belhaj et al. «Heart Rate Variability-Based Stress Detection and Fall Risk Monitoring During Daily Activities: A Machine Learning Approach». Em: *Computers* 14.2 (2025), p. 45. doi: 10.3390/computers14020045. url: https://doi.org/10.3390/computers14020045.

[45] Mohapatra, P. et al. «Wearable network for multilevel physical fatigue prediction in manufacturing workers». Em: *PNAS Nexus* 3 (2024), pgae421. doi: 10.1093/pnasnexus/pgae421. url: https://doi.org/10.1093/pnasnexus/pgae421.

[46] Narayana, I. L. et al. «IoT-Enabled Health Monitoring Glove with Machine Learning-Based Risk Classification». Em: *WAMS* n.d. (2025), pp. 1–5. doi: 10.1109/WAMS64402.2025.11158247. url: https://ieeexplore.ieee.org/document/11158247/.

[47] Ojha, A. et al. «Worker-centric heat strain analysis: Integrating physiological signals with ensemble learning and domain adaptation». Em: *Automation in Construction* 166 (2024), p. 105670. doi: 10.1016/j.autcon.2024.105670. url: https://doi.org/10.1016/j.autcon.2024.105670.

[48] Pan, Jiapu e Tompkins, Willis J. «A Real-Time QRS Detection Algorithm». Em: *IEEE Transactions on Biomedical Engineering* BME-32.3 (1985), pp. 230–236. doi: 10.1109/TBME.1985.325532. url: https://doi.org/10.1109/TBME.1985.325532.

[49] Parliament, European e European Union, Council of the. *Regulation (EU) 2016/679 of the European Parliament and of the Council of 27 April 2016 on the protection of natural persons with regard to the processing of personal data and on the free movement of such data (GDPR)*. Official PDF of the General Data Protection Regulation. Official Journal of the European Union. 2016. url: https://www.boe.es/doue/2016/119/L00001-00088.pdf.

[50] Parliament, European e European Union, Council of the. *Regulation (EU) 2024/1689 of the European Parliament and of the Council of 13 June 2024 laying down harmonised rules on artificial intelligence (AI Act)*. Official PDF of the EU Artificial Intelligence Regulation. Official Journal of the European Union. 2024. url: https://www.boe.es/doue/2024/1689/L00001-00144.pdf.

[51] Pichot, V. et al. «Autonomic adaptations to intensive and overload training periods: a laboratory study». Em: *Medicine and Science in Sports and Exercise* 34.10 (2002), pp. 1660–1666. doi: 10.1097/00005768-200210000-00019. url: https://doi.org/10.1097/00005768-200210000-00019.

[52] Polar Electro Oy. *Polar H10 Heart Rate Sensor*. Polar official website. Official product page. 2024. url: https://www.polar.com/pt/sensors/h10-heart-rate-sensor/.

[53] Rajas, N. P. et al. «IoT-based Mental Health Monitoring with Machine Learning». Em: *ICAISS* n.d. (2025), pp. 1150–1155. doi: 10.1109/ICAISS61471.2025.11042032. url: https://ieeexplore.ieee.org/document/11042032/.

[54] Rebergen, Dennis J. et al. «ADARRI: a novel method to detect spurious R-peaks in the electrocardiogram for heart rate variability analysis in the intensive care unit». Em: *Journal of Clinical Monitoring and Computing* 32.1 (2017), pp. 53–61. doi: 10.1007/s10877-017-9999-9. url: https://doi.org/10.1007/s10877-017-9999-9.

[55] Ribeiro, R. et al. «A systematic review on wearable-enabled remote health monitoring». Em: *Digital Health* 12 (2026). doi: 10.1177/20552076261428387. url: https://doi.org/10.1177/20552076261428387.

[56] Richman, Joshua S. e Moorman, J. Randall. «Physiological time-series analysis using approximate entropy and sample entropy». Em: *American Journal of Physiology-Heart and Circulatory Physiology* 278.6 (2000), H2039–H2049. doi: 10.1152/ajpheart.2000.278.6.H2039. url: https://doi.org/10.1152/ajpheart.2000.278.6.H2039.

[57] Rossi, Alessio et al. «Wellness Forecasting by External and Internal Workloads in Elite Soccer Players: A Machine Learning Approach». Em: *Frontiers in Physiology* 13 (2022). doi: 10.3389/fphys.2022.896928. url: https://doi.org/10.3389/fphys.2022.896928.

[58] Rothschild, Jeffrey A. et al. «Predicting daily recovery during long-term endurance training using machine learning analysis». Em: *European Journal of Applied Physiology* 124.11 (2024), pp. 3279–3290. doi: 10.1007/s00421-024-05530-2. url: https://pubmed.ncbi.nlm.nih.gov/38900201/.

[59] Sanjeevi, P. S. S. et al. «Smart Heart Monitor using Machine Learning». Em: *2024 IEEE International Conference on Signal Processing, Informatics, Communication and Energy Systems (SPICES)* n.d. (2024), pp. 1–6. doi: 10.1109/SPICES62143.2024.10779922. url: https://ieeexplore.ieee.org/document/10779922/.

[60] Schein, Andrew I. et al. «Methods and metrics for cold-start recommendations». Em: *Proceedings of the 25th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*. ACM, 2002, pp. 253–260. doi: 10.1145/564376.564421. url: https://doi.org/10.1145/564376.564421.

[61] scikit-learn developers. *sklearn.preprocessing.StandardScaler*. scikit-learn. 2021. url: https://scikit-learn.org/1.0/modules/generated/sklearn.preprocessing.StandardScaler.html (acedido em 22/09/2026).

[62] scikit-learn developers. *Importance of Feature Scaling*. scikit-learn. 2026. url: https://scikit-learn.org/dev/auto_examples/preprocessing/plot_scaling_importance.html (acedido em 24/09/2026).

[63] Shaffer, Fred e Ginsberg, J. P. «An Overview of Heart Rate Variability Metrics and Norms». Em: *Frontiers in Public Health* 5 (2017), p. 258. doi: 10.3389/fpubh.2017.00258. url: https://doi.org/10.3389/fpubh.2017.00258.

[64] Shao, Jie et al. «Is normalization indispensable for training deep neural network?» Em: *Advances in Neural Information Processing Systems*. Vol. 33. Curran Associates, Inc., 2020, pp. 13434–13444. url: https://proceedings.neurips.cc/paper_files/paper/2020/hash/9b8619251a19057cff70779273e95aa6-Abstract.html.

[65] Shim, Jinjoo, Fleisch, Elgar e Barata, Filipe. «Wearable-based accelerometer activity profile as digital biomarker of inflammation, biological age, and mortality using hierarchical clustering analysis in NHANES 2011-2014». Em: *Scientific Reports* 13.1 (2023), p. 9326. doi: 10.1038/s41598-023-36062-y. url: https://pubmed.ncbi.nlm.nih.gov/37291134/.

[66] Sim, S.-H. et al. «Exploring Edge Machine Learning-based Stress Prediction using Wearable Devices». Em: *2022 IEEE International Conference on Machine Learning and Applications (ICMLA)* n.a. (2023), pp. 1266–1273. doi: 10.1109/ICMLA55696.2022.00203. url: https://ieeexplore.ieee.org/document/10069495.

[67] Singh, N. T. et al. «AI-Powered Mental Health Tracking With Smartwatch Integration for Instantaneous Stress Assessment and Assistance». Em: *2025 6th International Conference on Intelligent Communication Technologies and Virtual Mobile Networks (ICICV)* n.d. (2025), pp. 228–234. doi: 10.1109/ICICV64824.2025.11085533. url: https://ieeexplore.ieee.org/document/11085533/.

[68] Smiley, Aref et al. «Exercise Exertion Levels Prediction Based on Real-Time Wearable Physiological Signal Monitoring». Em: *Studies in Health Technology and Informatics* 305 (2023), pp. 172–175. doi: 10.3233/SHTI230454. url: https://doi.org/10.3233/SHTI230454.

[69] Štuhec, Stanislav et al. «Multicomponent Velocity Measurement for Linear Sprinting: Usain Bolt's 100 m World-Record Analysis». Em: *Bioengineering* 10.11 (2023), p. 1254. doi: 10.3390/bioengineering10111254. url: https://doi.org/10.3390/bioengineering10111254.

[70] Subathra, P. et al. «A Wearable Electronic Band for Stress Understanding Using Machine Learning». Em: *IEEE Sensors Journal* n.d. (2025), n.d. doi: 10.1109/JSEN.2025.3590380. url: https://doi.org/10.1109/JSEN.2025.3590380.

[71] Thomas, J. S. et al. «IoT Wearable Devices to Detect and Monitor Mental Health and Stress». Em: vol. n.a. 2025, pp. 1–5. doi: 10.1109/SENNET64220.2025.11135933. url: https://ieeexplore.ieee.org/document/11135933.

[72] Tsao, Hsin-Yi, Chan, Pei-Ying e Su, Emily Chia-Yu. «Predicting diabetic retinopathy and identifying interpretable biomedical features using machine learning algorithms». Em: *BMC Bioinformatics* 19 (2018). doi: 10.1186/s12859-018-2277-0. url: https://doi.org/10.1186/s12859-018-2277-0.

[73] Umer, W. et al. «Deep learning-based fatigue monitoring of construction workers using physiological signals: A reassessment of the utility of deep learning models». Em: *Automation in Construction* 177 (2025), p. 106356. doi: 10.1016/j.autcon.2025.106356. url: https://doi.org/10.1016/j.autcon.2025.106356.

[74] Vinusha, B. V. et al. «Smartwatch-based Vomiting Sensation Detection using Heart Rate Analysis and Metaverse Integration». Em: *2023 14th International Conference on Computing Communication and Networking Technologies (ICCCNT)* n.d. (2023), pp. 1–7. doi: 10.1109/ICCCNT56998.2023.10306491. url: https://ieeexplore.ieee.org/document/10306491.

[75] Wang, M. et al. «Monitoring and evaluating the status and behaviour of construction workers using wearable sensing technologies: A review». Em: *Automation in Construction* 165 (2024), p. 105555. doi: 10.1016/j.autcon.2024.105555. url: https://doi.org/10.1016/j.autcon.2024.105555.

[76] Wathen, Mark S. et al. «Prospective randomized multicenter trial of empirical antitachycardia pacing versus shocks for spontaneous rapid ventricular tachycardia in patients with implantable cardioverter-defibrillators: Pacing Fast Ventricular Tachycardia Reduces Shock Therapies (PainFREE Rx II) trial results». Em: *Circulation* 110.17 (2004), pp. 2591–2596. doi: 10.1161/01.CIR.0000145610.64014.E4. url: https://doi.org/10.1161/01.CIR.0000145610.64014.E4.

[77] Xianyong, S. et al. «Wearable smart sensors integration with AI and machine learning for tracking human health». Em: *Biosensors and Bioelectronics: X* 27 (2025), p. 100711. doi: 10.1016/j.biosx.2025.100711. url: https://doi.org/10.1016/j.biosx.2025.100711.

Apêndice A

Avaliação Detalhada dos Estudos Incluídos

Tabela A.1: Avaliação da qualidade dos estudos incluídos (Parte 1)

ID	ESTUDO	AUTORES	QA1	QA2	QA3	QA4	TOTAL
[22]	Wearable sensing devices for construction safety: Research trends, applications, challenges, and future opportunities	Fasoyinu A. et al.	✓ +1	✓ +1 ML DL	✓ +1 Saúde Fadiga	✓ +1 Construção	4
[75]	Monitoring and evaluating the status and behaviour of construction workers using wearable sensing technologies	Wang M. et al.	✓ +1	✓ +1 ML DL	✓ +1 Fadiga	✓ +1 Construção	4
[4]	Generalizing fatigue prediction models for construction workers: Cross-experiment evaluation with transfer learning across thermal and load conditions	Anjum S. et al.	✓ +1	✓ +1 ML DL	✓ +1 Fadiga	✓ +1 Construção	4
[10]	Automated fall risk classification for construction workers using wearable devices, BIM, and optimized hybrid deep learning	Cheng M.-Y. et al.	✓ +1	✓ +1 DL NN GNN	✓ +1 segurança Fadiga	✓ +1 Construção	4
[32]	Fatigue monitoring using wearables and AI: Trends, challenges, and future opportunities	Kakhi K. et al.	✓ +1	✓ +1 ML DL	✓ +1 Fadiga	✓ +1 Construção	4
[73]	Deep learning-based fatigue monitoring of construction workers using physiological signals	Umer W. et al.	✓ +1	✓ +1 DL Bi-LSTM	✓ +1 Fadiga	✓ +1 Construção	4
[3]	Early detection of physical fatigue in industry using wearable sensors and contextual modeling	Morillo C. et al.	✓ +1 HR EDA Temp.	✓+1 ML	✓ +1 Fadiga Alertas	✓ +1 Industrial	4
[24]	Differential Neurophysiological and Autonomic Responses to Electric, Hybrid, and Internal Combustion Engine Vehicles During Real-World Driving Testing: A Multimodal Psychophysiological Study	Georgiev et al. (2026)	✓ +1 EEG HR HRV GSR SpO_2	✓ +1 Clustering K-Means GMM DBSCAN	✓ +1 Carga cognitiva Stress Fadiga	✓ +1 Condutores Tráfego real	4
[6]	Real-Time Physiological Activity and Sleep State Monitoring System Using TS2Vec Embeddings and DBSCAN Clustering for Heart Rate and Motor Response Analysis in IoMT	Arifin et al. (2025)	✓ +1 ECG HR Flexão motora	✓ +1 DL (TS2Vec) Clustering DBSCAN	✓ +1 Sono Consciência Atividade	✓ +1 Médico	4
[33]	Advancing physical and mental fatigue analysis in construction workers: Insights, technologies, and future directions	Karim R. et al.	✓ +1	✓ +1	✓ +1 Fadiga Alertas	✓ +1 Construção	4

Tabela A.2: Avaliação da qualidade dos estudos incluídos (Parte 2)

ID	ESTUDO	AUTORES	QA1	QA2	QA3	QA4	TOTAL
[47]	Worker-centric heat strain analysis: Integrating physiological signals with ensemble learning and domain adaptation	Ojha A. et al.	✓ +1	✓ +1 ML DL EL	✓ +1 Fadiga Stress	✓ +1 Industrial	4
[71]	IoT Wearable Devices to Detect and Monitor Mental Health and Stress - 2025 International Conference on Sensors and Related Networks (SENNET) Special Focus on Digital Healthcare(64220)	Thomas J. et al.	✓ +1 GSR ECG Temp. Acelerómetro	✓ +1 ML XGBoost	✓ +1 Stress Fadiga mental	✓ +1 Laboral	4
[26]	AI-Driven Fatigue Prediction in Healthcare Professionals Using Wearable Sensor Data and Gradient-Boosted Machine Learning Models - 2025 International Conference on Recent Innovation in Science Engineering and Technology (ICRISET)	D. Goutham et al.	✓ +1 HR HRV Temp. Acelerómetro EMA	✓ +1 ML XGBoost LightGBM	✓ +1 Stress Laboral Fadiga	✓ +1 Laboral	4
[66]	Exploring Edge Machine Learning-based Stress Prediction using Wearable Devices - 2022 21st IEEE International Conference on Machine Learning and Applications (ICMLA)	Sim et al.	✓ +1 HR (Fitbit)	✓ +1 ML DL XGBoost	✓ +1 Stress Laboral Fadiga	✓ +1 Treino Policial	4
[27]	Towards a nuanced classification of mental fatigue: A comprehensive review of detection techniques and prospective research	He X. et al.	✓ +1	✓ +1 DL	✓ +1 Fadiga	0.5 diverso	3.5
[16]	Electroencephalography (EEG) for psychological hazards and mental health in construction safety automation: Algorithmic Systematic Review (ASR)	Elmousalami H. et al.	✓ +1 EEG	0.5 Algoritmos	✓ +1 Stress Fadiga	✓ +1 Construção	3.5
[30]	Automated recognition of worker activity using machine learning and multi-sensor fusion	Jaros R. et al.	✓ +1 EMG Aceleró. Giroscopios	✓ +1 ML MLP	0.5 Monitorização	✓ +1 Construção	3.5
[36]	Exploring the relations between the physiological factors and the likelihood of accidents on construction sites	Kazar G. et al.	✓ +1 HR EDA Temp. Glicose	0.5 Estatístico	✓ +1 Fadiga Stress	✓ +1 Construção	3.5
[67]	AI-Powered Mental Health Tracking With Smartwatch Integration for Instantaneous Stress Assessment and Assistance - 2025 6th International Conference on Intelligent Communication Technologies and Virtual Mobile Networks (ICICV)	Singh N. et al.	✓ +1 Smartwatch	✓ +1 ML Random Forest Gradient Boost	✓ +1 Stress Fadiga	✓+0.5 Estudantes	3.5
[45]	Wearable network for multilevel physical fatigue prediction in manufacturing workers	Mohapatra et al.	✓ +1 HR HRV Temp. IMU	✓ +1ML	✓ +1 Fadiga	✓+0.5 Manufatura	3.5
[9]	Biosignal measurement for human-robot collaboration in construction: A systematic review	Chen H. et al.	✓ +1	× +0	✓ +1 Stress Fadiga	✓ +1 Construção	3
[5]	Assessing workers' neurophysiological stress reSpO$_2$nses to augmented reality safety warnings in immersive virtual roadway work zones	Banani Ardecani F. et al.	✓ +1 HRV EDA EEG	0.5 Estatístico	✓ +1 Stress	0.5 Ambiente VR	3

Tabela A.3: Avaliação da qualidade dos estudos incluídos (Parte 3)

ID	ESTUDO	AUTORES	QA1	QA2	QA3	QA4	TOTAL
[77]	Wearable smart sensors integration with AI and machine learning for tracking human health	Shi X. et al.	✓ +1	✓ +1 ML DL	✓ +1 Saúde Fadiga	× +0	3
[1]	Wearable devices: Cross benefits from healthcare to construction	Abuwarda Z. et al.	✓ +1	× +0 review métricas	✓ +1 Fadiga Stress	✓ +1 Construção	3
[14]	NeuroAdapt: A Multimodal Emotion-Cognitive-Fatigue Adaptive BCI System for Robotic Upper-Limb Rehabilitation - 2025 International Conference on Sensors and Related Networks (SENNET) Special Focus on Digital Healthcare(64220)	Dhanasekar et al.	✓ +1 EEG EMG	✓ +1 ML	✓ +1 Fadiga mental	× +0	3
[2]	Multi-Purpose Wearable Biofeedback Accessories - 2024 International Conference on Power, Energy, Control and Transmission Systems (ICPECTS)	Aishwarya et al.	✓ +1 HRV EDA Movimento	✓ +1 ML DL	✓ +1 Stress Fadiga ansiedade	× +0 General	3
[38]	Wearable Tech for Mental Health Monitoring Real-Time Stress Detection Using Biometric Sensors - 2025 Global Conference in Emerging Technology (GINOTECH)	Kuzhaloli et al.	✓ +1 HRV GSR EDA	✓ +1 ML DL	✓ +1 Stress Fadiga mental	× +0 General	3
[7]	Effective Driver Fatigue Management and Prevention Using Cloud-Integrated RNN Models - 2024 First International Conference on Innovations in Communications, Electrical and Computer Engineering (ICICEC)	Arya et al.	✓ +1 Movimentos Oculares	✓ +1RNN	✓ +1 Fadiga Stress	× +0 Condutores	3
[70]	A Wearable Electronic Band for Stress Understanding Using Machine Learning	Subathra et al.	✓ +1 HR PPG EDA GSR	✓ +1 DL Bi-LSTM	✓ +1 Stress Fadiga Cansaço	× +0 Laboral	3
[34]	Physiological Data-Based Stress Detection: From Wrist Sensors to Cloud Computing and User Feedback Integration	Karpagam et al.	✓ +1 GSR Temp. Aceler.	✓ +1 ML clássico RF Regressão logística	✓ +1 Stress	× +0	3
[46]	IoT-Enabled Health Monitoring Glove with Machine Learning-Based Risk Classification - 2025 IEEE Wireless Antenna and Microwave Symposium (WAMS)	Narayana et al.	✓ +1 HR GSR Temp. SpO_2	✓ +1 ML Random Forest	✓ +1 Stress	× +0 Saúde	3
[31]	An Integrated Framework for Predicting Health Based on Sensor Data Using Machine Learning - 2020 2nd International Conference on Advancements in Computing (ICAC)	Jayaweera et al.	✓ +1 PPG	✓ +1 ML RF KNN Regre. logística	✓ +1 Stress	× +0 Saúde	3
[44]	Heart Rate Variability-Based Stress Detection and Fall Risk Monitoring During Daily Activities: A Machine Learning Approach	Belhaj Messaoud & Thamsuwan (2025)	✓ +1 HR HRV SDNN RMSSD	✓ +1 ML Clustering	✓ +1 Stress Quedas	Não (0) Doméstico	3
[25]	Physiological State Recognition via HRV and Fractal Analysis Using AI and Unsupervised Clustering	Georgieva-Tsaneva et al. (2025)	✓ +1 HRV Entropia Fractais	✓ +1 Clustering K-Means DBSCAN	✓ +1 Stress Carga física Repouso	Não (0) Desportivo	3
[53]	IoT-based Mental Health Monitoring with Machine Learning - 2025 Third International Conference on Augmented Intelligence and Sustainable Systems (ICAISS)	Rajas et al.	✓ +1 HR	✓ +1 ML SVM NN	✓ +1 Stress ansiedade	× +0 Saúde	3

Tabela A.4: Avaliação da qualidade dos estudos incluídos (Parte 4)

ID	ESTUDO	AUTORES	QA1	QA2	QA3	QA4	TOTAL
[13]	Wearable Physiological IoT System with Neural Network to Detect an Individual IT Professional's Stress / Emotion in Working Environments - 2023 7th International Conference on Intelligent Computing and Control Systems (ICICCS)	Devi et al.	✓ +1 HR Temp. EMG	✓ +1 ML NN CNN	✓ +1 Stress emoções	× +0 Saúde	3
[15]	An Explainable IoT-based Framework for Anomaly Detection and Emergency Decision Management in Smart Healthcare - 2025 3rd International Conference on Sustainable Computing and Data Communication Systems (ICSCDS)	Divyabharathi et al.	✓ +1	✓ +1 ML XGBoost SVM CNN Bi-LSTM	0.5 Saúde Geral	× +0 Hospitalar	2.5
[37]	Smart Band for Senior Citizens - 2022 Third International Conference on Intelligent Computing Instrumentation and Control Technologies (ICICICT)	Kiriti et al.	✓ +1 HR Temp. SpO_2	✓ +1ML	0.5 Quedas	× +0	2.5
[74]	Smartwatch-based Vomiting Sensation Detection using Heart Rate Analysis and Metaverse Integration - 2023 14th International Conference on Computing Communication and Networking Technologies (ICCCNT)	Vinusha et al.	✓ +1 HR HRV PPG IMU Acelerómetro	✓ +1ML DL LSTM	× +0 Náuseas	× +0 Saúde	2
[12]	An IoT Based Intelligent Watch to Promote Child Safety - 2025 9th International Conference on Inventive Systems and Control (ICISC)	Devi et al.	✓ +1 HR respiração Temp. suor	✓ +1 DL ANN	× +0 segurança infantil	× +0 Crianças	2
[59]	Smart Heart Monitor using Machine Learning - 2024 IEEE International Conference on Signal Processing, Informatics, Communication and Energy Systems (SPICES)	Sanjeevi et al.	✓ +1 HR	✓ +1 ML	× +0 enfarte	× +0 enfarte	2

Apêndice B

Distribuições Temporais da Validação Externa do Relógio

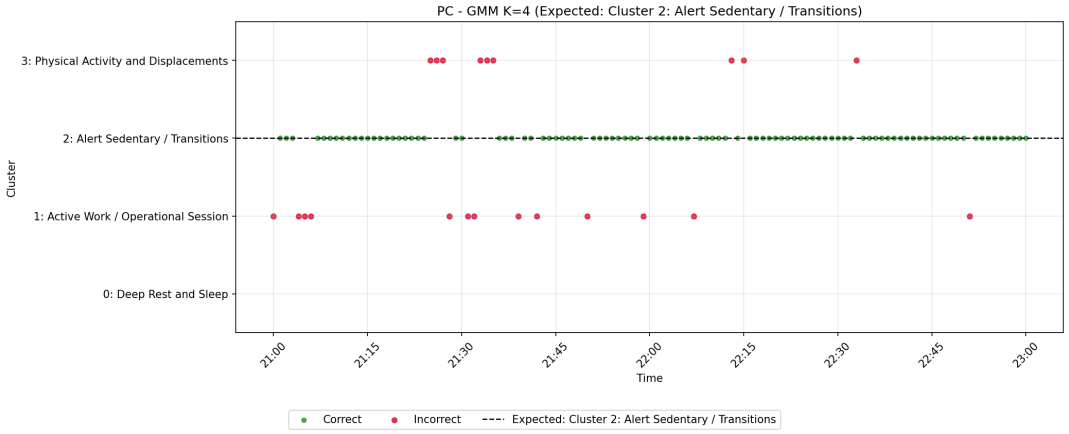
Este apêndice apresenta as distribuições temporais complementares das previsões obtidas durante a validação externa dos modelos de agrupamento treinados com dados do relógio Empatica EmbracePlus. São apresentados os resultados das configurações que não foram incluídas no corpo principal da tese, considerando três situações experimentais: trabalho em computador, atividade física e sono.

Por razões de legibilidade, no corpo principal da tese foram apresentadas apenas as distribuições temporais do GMM com dados originais. As figuras seguintes complementam essa análise e documentam o comportamento do GMM com janelas temporais de 10 minutos, do Clustering Hierárquico com dados originais e do Clustering Hierárquico com janelas temporais de 10 minutos. Em cada conjunto, as imagens correspondem, respetivamente, ao trabalho em computador, à atividade física e ao sono.

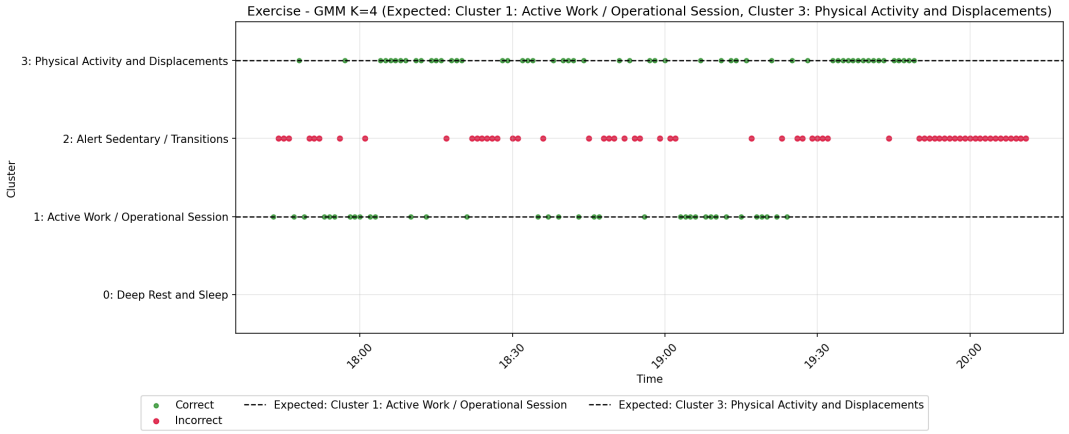
Os resultados encontram-se apresentados pela seguinte ordem:

1. **GMM Restrito com dados originais ($k = 4$):** modelo de GMM configurado para representar os dados em apenas quatro clusters. Imagens: a) trabalho em computador; b) atividade física; c) sono (Figura B.1).
2. **GMM com janelas de 10 minutos ($k = 5$):** modelo de GMM aplicado a janelas temporais de 10 minutos, com cinco clusters, selecionados pelo BIC mínimo. Imagens: a) trabalho em computador; b) atividade física; c) sono (Figura B.2).
3. **Clustering Hierárquico com dados originais ($k = 5$):** modelo de agrupamento hierárquico aplicado aos dados originais, com cinco clusters. Imagens: a) trabalho em computador; b) atividade física; c) sono (Figura B.3).
4. **Clustering Hierárquico com janelas de 10 minutos ($k = 5$):** modelo de agrupamento hierárquico aplicado a janelas temporais de 10 minutos, com cinco clusters. Imagens: a) trabalho em computador; b) atividade física; c) sono (Figura B.4).

B.1 GMM Restrito com Dados Originais ($k = 4$)



(a) Trabalho em computador



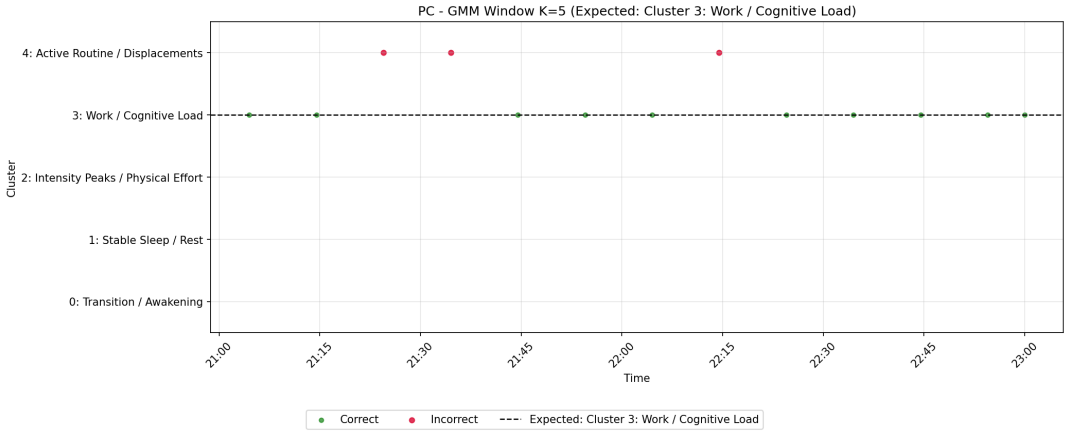
(b) Atividade física



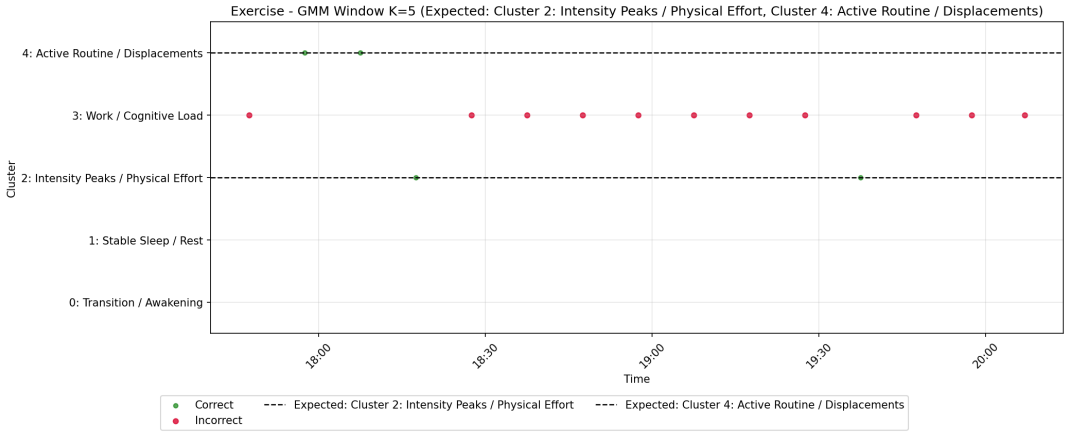
(c) Sono

Figura B.1: Distribuição temporal das previsões do GMM Restrito com dados originais ($k = 4$) durante as três atividades experimentais.

B.2 GMM com Janelas de 10 Minutos ($k = 5$)



(a) Trabalho em computador



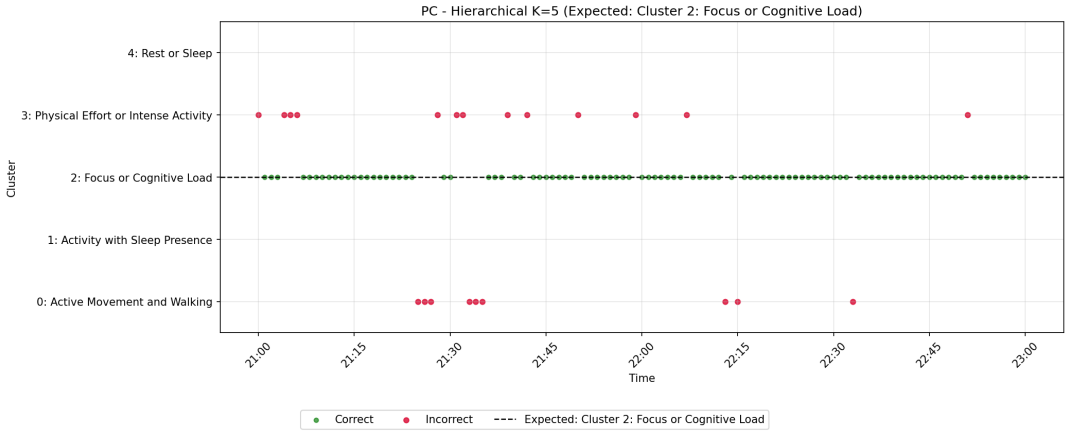
(b) Atividade física



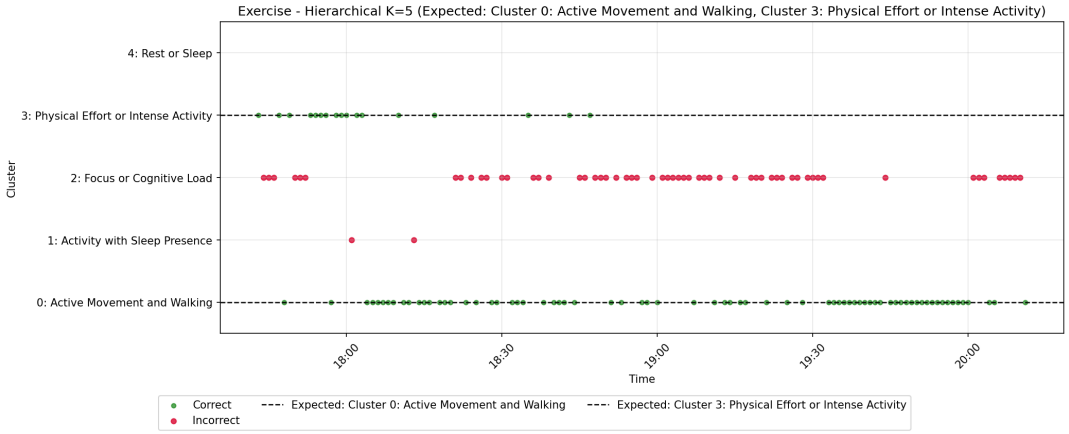
(c) Sono

Figura B.2: Distribuição temporal das previsões do GMM com janelas de 10 minutos ($k = 5$) durante as três atividades experimentais.

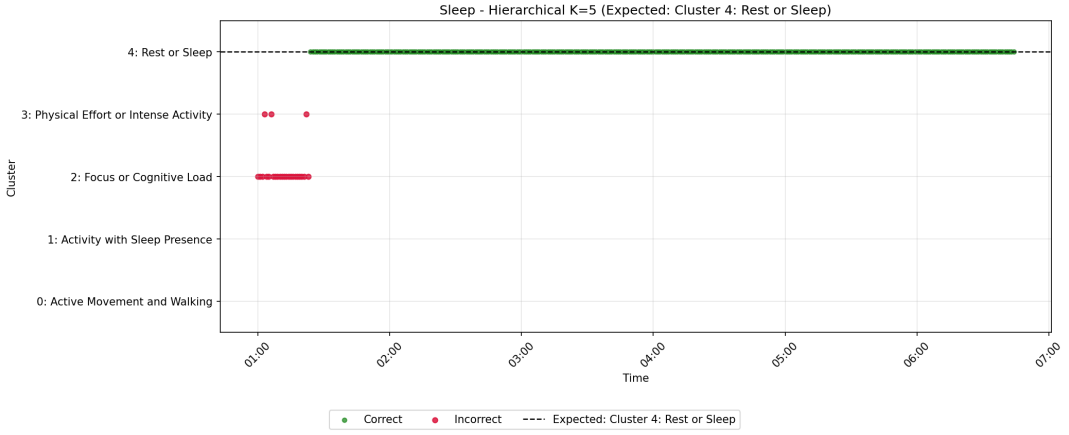
B.3 Clustering Hierárquico com Dados Originais ($k = 5$)



(a) Trabalho em computador



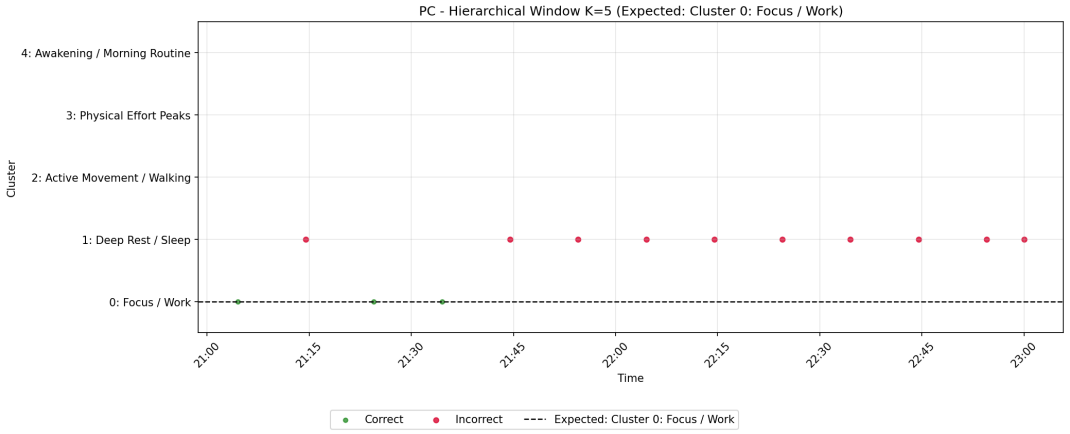
(b) Atividade física



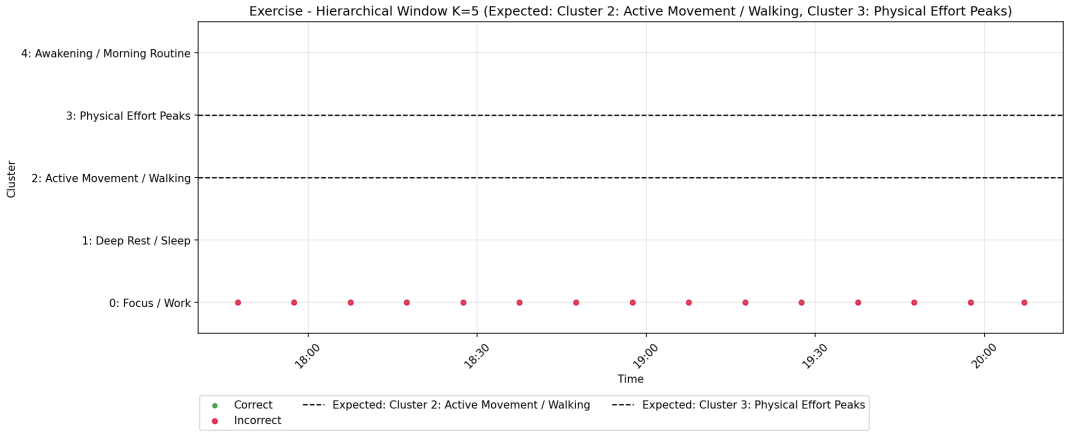
(c) Sono

Figura B.3: Distribuição temporal das previsões do Clustering Hierárquico com dados originais ($k = 5$) durante as três atividades experimentais.

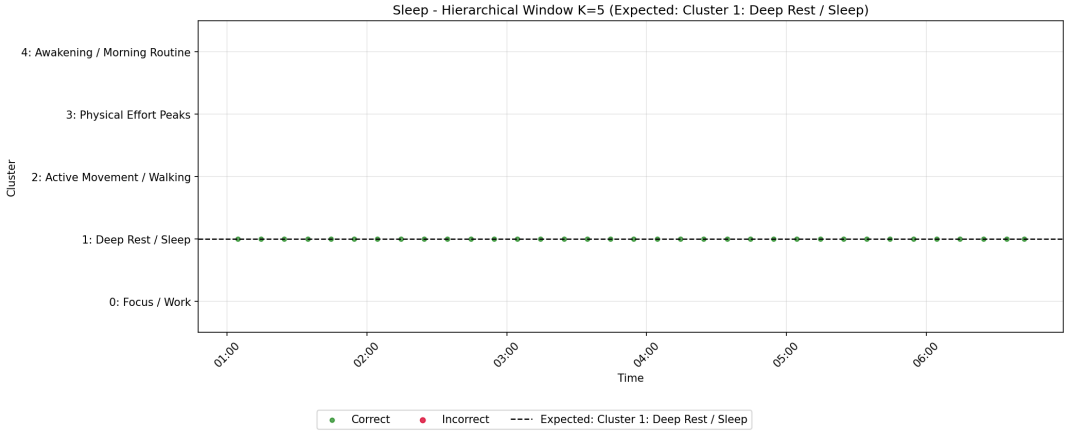
B.4 Clustering Hierárquico com Janelas de 10 Minutos ($k = 5$)



(a) Trabalho em computador



(b) Atividade física



(c) Sono

Figura B.4: Distribuição temporal das previsões do Clustering Hierárquico com janelas de 10 minutos ($k = 5$) durante as três atividades experimentais.

Apêndice C

Resultados Detalhados da Validação LOSO Polar H10

Este apêndice apresenta os resultados detalhados da validação *Leave-One-Subject-Out* (LOSO) dos modelos de classificação XGBoost, Random Forest, SVM e Regressão Logística. Incluem-se as tabelas de desempenho por trabalhador, os *Classification Reports* por classe e as matrizes de confusão individuais e agregadas, permitindo analisar de forma detalhada o desempenho de cada modelo.

C.1 Resultados: Modelo Random Forest

Os resultados seguintes apresentam o desempenho do modelo Random Forest na validação LOSO com dados do Polar H10. A análise inclui a Tabela C.1.1, que apresenta o desempenho por trabalhador, a Tabela C.1.2, correspondente ao relatório de classificação por classe, e a Tabela C.1.3, que apresenta a matriz de confusão agregada dos dez folds. A Figura C.1.4 apresenta as matrizes de confusão individuais para cada trabalhador utilizado como conjunto de teste.

C.1.1 Tabela de desempenho da validação LOSO

A tabela apresenta, para cada trabalhador utilizado como teste, o conjunto de trabalhadores utilizado no treino e as principais métricas de avaliação do modelo.

Tabela C.1.1: Validação LOSO do modelo Random Forest.

Teste	Treino	Recall LOW	Recall MED	Recall HIGH	Accuracy	Balanced Accuracy	Macro-F1
W00	W01–W09	0,952381	0,500000	0,642857	0,884615	0,698413	0,701451
W01	W00, W02–W09	0,980583	0,818898	0,982143	0,916797	0,927208	0,907259
W02	W00–W01, W03–W09	0,883721	0,841727	0,912134	0,875622	0,879194	0,852795
W03	W00–W02, W04–W09	0,876923	0,680000	0,990536	0,953317	0,849153	0,860202
W04	W00–W03, W05–W09	0,968421	0,784810	1,000000	0,943060	0,917744	0,844123
W05	W00–W04, W06–W09	0,952381	0,937500	0,904762	0,932432	0,931548	0,934436
W06	W00–W05, W07–W09	1,000000	0,666667	1,000000	0,942857	0,888889	0,917460
W07	W00–W06, W08–W09	1,000000	0,312500	0,860465	0,746269	0,724322	0,642868
W08	W00–W07, W09	0,385542	0,465116	0,571429	0,421053	0,474029	0,378676
W09	W00–W08	1,000000	1,000000	1,000000	1,000000	1,000000	1,000000
Média	*Média dos folds*	0,899995	0,700722	0,886433	0,861602	0,829050	0,803927

C.1.2 Relatório de classificação por classe

O relatório de classificação por classe apresenta o *support*, o *recall* e a *precision* obtidos para as categorias LOW, MED e HIGH na avaliação LOSO.

Tabela C.1.2: Relatório de Classificação por Classe (Classification Report) do modelo Random Forest na avaliação LOSO.

Classe	Support	Recall	Precision
Low	950	0,904	0,897
Medium	744	0,790	0,824
High	944	0,952	0,931

C.1.3 Matriz de confusão agregada

A matriz de confusão agregada reúne as previsões dos dez folds. As linhas representam as classes reais e as colunas representam as classes previstas pelo modelo.

Tabela C.1.3: Matriz de Confusão Agregada dos Dez Folds do Random Forest na avaliação LOSO.

	Low	Medium	High
Low	859	83	8
Medium	97	588	59
High	2	43	899

C.1.4 Matrizes de confusão por trabalhador

A figura apresenta as matrizes de confusão individuais obtidas para cada trabalhador utilizado como conjunto de teste.



Figura C.1.4: Matrizes de confusão do Random Forest por trabalhador de teste.

C.2 Resultados: Modelo SVM

Os resultados seguintes apresentam o desempenho do modelo SVM na validação LOSO com dados do Polar H10. A análise inclui a Tabela C.2.1, que apresenta o desempenho por trabalhador, a Tabela C.2.2, correspondente ao relatório de classificação por classe, e a Tabela C.2.3, que apresenta a matriz de confusão agregada dos dez folds. A Figura C.2.4 apresenta as matrizes de confusão individuais para cada trabalhador utilizado como conjunto de teste.

C.2.1 Tabela de desempenho da validação LOSO

A tabela apresenta, para cada trabalhador utilizado como teste, o conjunto de trabalhadores utilizado no treino e as principais métricas de avaliação do modelo.

Tabela C.2.1: Validação LOSO do modelo SVM.

Teste	Treino	Recall LOW	Recall MED	Recall HIGH	Accuracy	Balanced Accuracy	Macro-F1
W00	W01–W09	0,952381	0,666667	0,785714	0,913462	0,801587	0,762146
W01	W00, W02–W09	0,883495	0,862205	0,875000	0,871272	0,873567	0,858319
W02	W00–W01, W03–W09	0,813953	0,816547	0,979079	0,880597	0,869860	0,855888
W03	W00–W02, W04–W09	0,907692	0,600000	0,933754	0,909091	0,813815	0,766801
W04	W00–W03, W05–W09	0,957895	0,886076	0,750000	0,944840	0,864657	0,761599
W05	W00–W04, W06–W09	0,857143	0,843750	0,857143	0,851351	0,852679	0,855993
W06	W00–W05, W07–W09	0,850000	0,166667	1,000000	0,771429	0,672222	0,634801
W07	W00–W06, W08–W09	0,500000	0,500000	0,604651	0,567164	0,534884	0,495201
W08	W00–W07, W09	0,385542	0,162791	1,000000	0,345865	0,516111	0,320037
W09	W00–W08	1,000000	1,000000	1,000000	1,000000	1,000000	1,000000
Média	*Média dos folds*	0,810810	0,650470	0,878534	0,805507	0,779938	0,731079

C.2.2 Relatório de classificação por classe

O relatório de classificação por classe apresenta o *support*, o *recall* e a *precision* obtidos para as categorias LOW, MED e HIGH na avaliação LOSO.

Tabela C.2.2: Relatório de Classificação por Classe (Classification Report) do modelo SVM na avaliação LOSO.

Classe	Support	Recall	Precision
Low	950	0,875	0,895
Medium	744	0,784	0,795
High	944	0,909	0,879

C.2.3 Matriz de confusão agregada

A matriz de confusão agregada reúne as previsões dos dez folds. As linhas representam as classes reais e as colunas representam as classes previstas pelo modelo.

Tabela C.2.3: Matriz de Confusão Agregada dos Dez Folds do SVM na avaliação LOSO.

	Low	Medium	High
Low	831	84	35
Medium	78	583	83
High	20	66	858

C.2.4 Matrizes de confusão por trabalhador

A figura apresenta as matrizes de confusão individuais obtidas para cada trabalhador utilizado como conjunto de teste.



Figura C.2.4: Matrizes de confusão do SVM por trabalhador de teste.

C.3 Resultados: Modelo de Regressão Logística

Os resultados seguintes apresentam o desempenho do modelo de Regressão Logística na validação LOSO com dados do Polar H10. A análise inclui a Tabela C.3.1, que apresenta o desempenho por trabalhador, a Tabela C.3.2, correspondente ao relatório de classificação por classe, e a Tabela C.3.3, que apresenta a matriz de confusão agregada dos dez folds. A Figura C.3.4 apresenta as matrizes de confusão individuais para cada trabalhador utilizado como conjunto de teste.

C.3.1 Tabela de desempenho da validação LOSO

A tabela apresenta, para cada trabalhador utilizado como teste, o conjunto de trabalhadores utilizado no treino e as principais métricas de avaliação do modelo.

Tabela C.3.1: Validação LOSO do modelo de Regressão Logística.

Teste	Treino	Recall LOW	Recall MED	Recall HIGH	Accuracy	Balanced Accuracy	Macro-F1
W00	W01–W09	0,988095	0,500000	0,642857	0,913462	0,710317	0,719693
W01	W00, W02–W09	0,883495	0,917323	0,932143	0,918367	0,910987	0,916154
W02	W00–W01, W03–W09	0,825581	0,787770	0,974895	0,867330	0,862749	0,868084
W03	W00–W02, W04–W09	0,984615	0,600000	0,933754	0,921376	0,839456	0,791181
W04	W00–W03, W05–W09	0,842105	0,696203	0,750000	0,820285	0,762769	0,619439
W05	W00–W04, W06–W09	0,857143	0,812500	0,761905	0,810811	0,810516	0,815200
W06	W00–W05, W07–W09	0,850000	0,833333	0,666667	0,800000	0,783333	0,765598
W07	W00–W06, W08–W09	1,000000	0,062500	0,279070	0,313433	0,447190	0,283677
W08	W00–W07, W09	0,518072	0,976744	0,000000	0,639098	0,498272	0,437843
W09	W00–W08	1,000000	0,400000	1,000000	0,812500	0,800000	0,790476
Média	*Média dos folds*	0,874911	0,658637	0,694129	0,781666	0,742559	0,700735

C.3.2 Relatório de classificação por classe

O relatório de classificação por classe apresenta o *support*, o *recall* e a *precision* obtidos para as categorias LOW, MED e HIGH na avaliação LOSO.

Tabela C.3.2: Relatório de Classificação por Classe (Classification Report) da Regressão Logística na avaliação LOSO.

Classe	Support	Recall	Precision
Low	950	0,842	0,914
Medium	744	0,808	0,726
High	944	0,895	0,904

C.3.3 Matriz de confusão agregada

A matriz de confusão agregada reúne as previsões dos dez folds. As linhas representam as classes reais e as colunas representam as classes previstas pelo modelo.

Tabela C.3.3: Matriz de Confusão Agregada dos Dez Folds da Regressão Logística na avaliação LOSO.

	Low	Medium	High
Low	800	146	4
Medium	57	601	86
High	18	81	845

C.3.4 Matrizes de confusão por trabalhador

A figura apresenta as matrizes de confusão individuais obtidas para cada trabalhador utilizado como conjunto de teste.

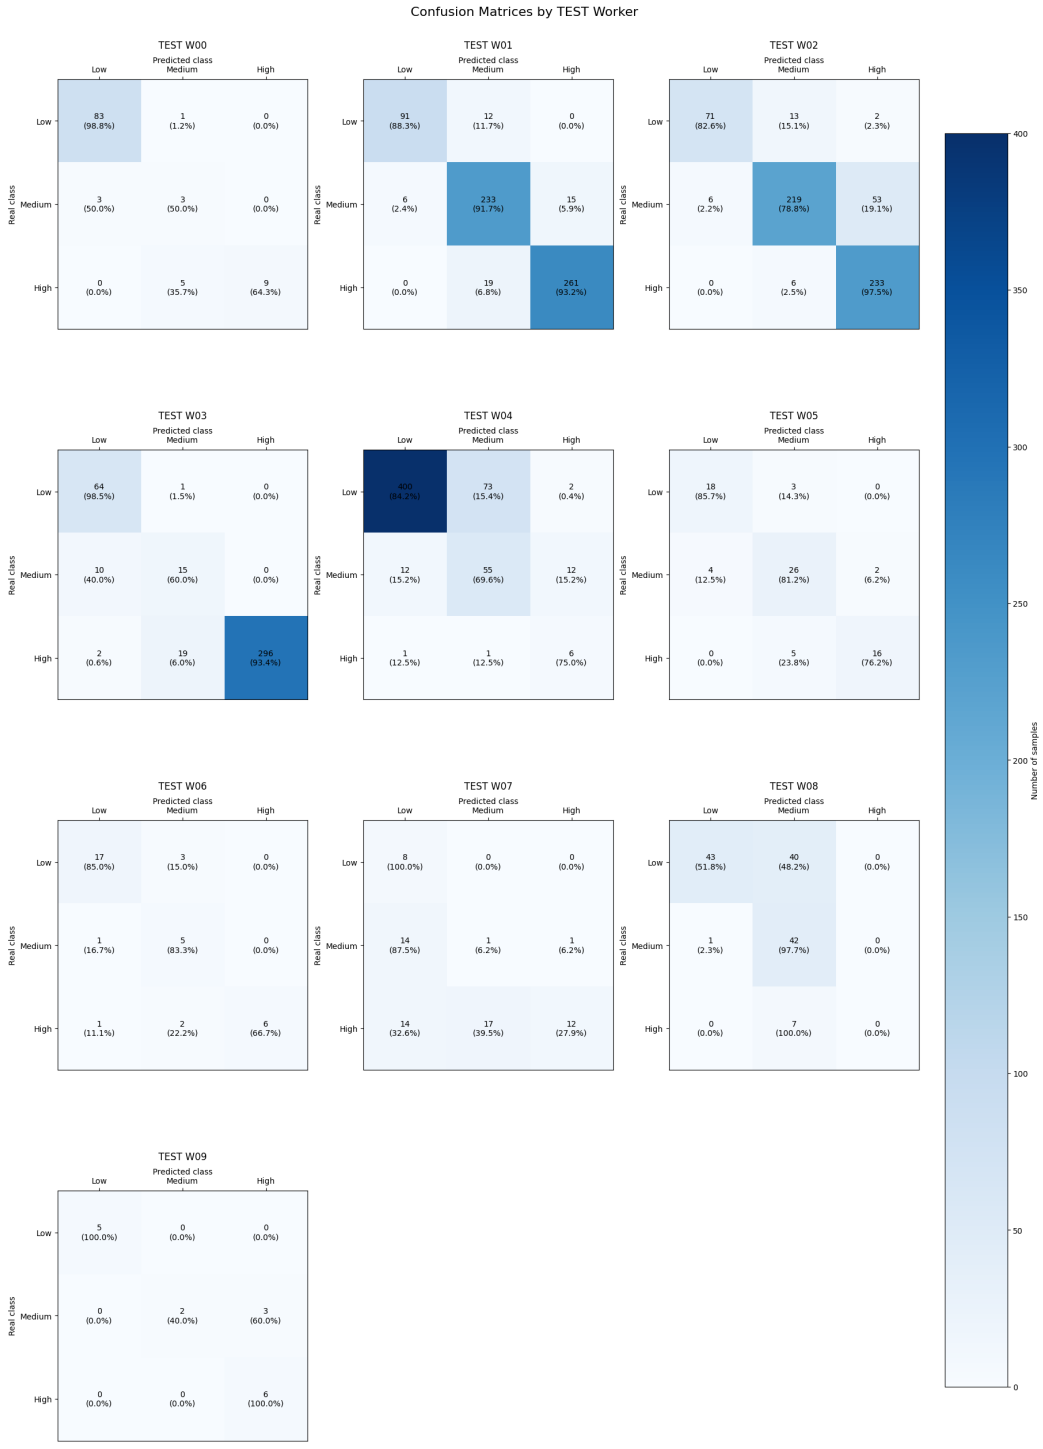


Figura C.3.4: Matrizes de confusão da Regressão Logística por trabalhador de teste.

C.4 Resultados: Modelo XGBoost

Os resultados seguintes apresentam, na Figura C.4.1, as matrizes de confusão do modelo XGBoost para os trabalhadores utilizados como conjunto de teste na validação LOSO com dados do Polar H10. As linhas representam as classes reais e as colunas representam as classes previstas pelo modelo.

C.4.1 Matrizes de confusão por trabalhador

A figura apresenta as matrizes de confusão individuais obtidas para cada trabalhador utilizado como conjunto de teste.



Figura C.4.1: Matrizes de confusão do XGBoost por trabalhador de teste.

Apêndice D

Importância das Características nos Modelos de Classificação

Este apêndice apresenta as figuras de importância das características dos modelos XGBoost, SVM, Regressão Logística e Random Forest nos três cenários do estudo de ablação. As figuras complementam a análise do XGBoost apresentada no Capítulo 4, permitindo comparar a forma como os diferentes modelos utilizam as características de ECG, HR/R-R e temporais. As importâncias apresentadas não devem ser comparadas diretamente entre modelos, uma vez que são calculadas através de métodos diferentes.

D.1 Importância das Características no XGBoost

No XGBoost, a importância das características é obtida através de `feature_importances_`. Esta medida resume a contribuição de cada variável no conjunto de árvores, de acordo com o critério interno do modelo, como a frequência de utilização ou o ganho das divisões. A Tabela D.1 apresenta os valores dos três cenários, enquanto a Figura 4.9, apresentada no Capítulo 4, ilustra a importância relativa das características.

Cenário A: ECG + HR/RR

Característica	Importância
HR_min_z	0,2576
ECG_energy_z	0,1248
cambio_HR_vs_baseline_z	0,0991
HR_mean_z	0,0871
RMSSD_z	0,0701
ECG_samp_ent_z	0,0679
pNN50_z	0,0626
HR_max_z	0,0542
SDNN_z	0,0392
ECG_std_z	0,0381
ECG_missing_peaks_z	0,0265
cambio_RMSSD_z	0,0168
ECG_mean_z	0,0154
HR_mean_ultimos_5min_z	0,0152
tendencia_HR_z	0,0143
ECG_range_z	0,0112

Cenário B: HR/RR + temporais

Característica	Importância
HR_min_z	0,3916
cambio_HR_vs_baseline_z	0,1847
HR_mean_z	0,1552
pNN50_z	0,0824
RMSSD_z	0,0597
SDNN_z	0,0409
HR_max_z	0,0286
cambio_RMSSD_z	0,0233
HR_mean_ultimos_5min_z	0,0196
tendencia_HR_z	0,0139

Cenário C: ECG

Característica	Importância
ECG_energy_z	0,2688
ECG_missing_peaks_z	0,2260
ECG_samp_ent_z	0,2080
ECG_std_z	0,1176
ECG_range_z	0,0899
ECG_mean_z	0,0898

Tabela D.1: Importância das características no XGBoost nos três cenários.

D.2 Importância das Características no SVM

No SVM, especialmente quando é utilizado um kernel não linear, não existe uma propriedade equivalente a `feature_importances_`. Por isso, foi utilizada a importância por permutação. O procedimento compara a *balanced accuracy* original com a obtida depois de permutar os valores de uma característica. Para a característica j, calcula-se:

$$I_j = S_{\text{original}} - S_{\text{permutada},j}, \tag{D.1}$$

onde S representa a *balanced accuracy*. Foram utilizadas cinco repetições por característica, com `random_state=42`. Os valores obtidos nos três cenários são apresentados na Tabela D.2.

Cenário A: ECG + HR/RR

Característica	Importância
ECG_samp_ent_z	0,2523
ECG_energy_z	0,2033
pNN50_z	0,1293
HR_mean_z	0,1216
cambio_HR_vs_baseline_z	0,1216
ECG_std_z	0,1197
HR_min_z	0,1031
SDNN_z	0,0803
tendencia_HR_z	0,0726
HR_max_z	0,0720
ECG_missing_peaks_z	0,0665
HR_mean_ultimos_5min_z	0,0592
RMSSD_z	0,0580
ECG_range_z	0,0390
ECG_mean_z	0,0223
cambio_RMSSD_z	0,0216

Cenário B: HR/RR + temporais

Característica	Importância
pNN50_z	0,0610
HR_mean_z	0,0478
cambio_HR_vs_baseline_z	0,0478
HR_min_z	0,0450
RMSSD_z	0,0355
HR_max_z	0,0270
HR_mean_ultimos_5min_z	0,0225
SDNN_z	0,0198
tendencia_HR_z	0,0150
cambio_RMSSD_z	0,0127

Cenário C: ECG

Característica	Importância
ECG_samp_ent_z	0,2985
ECG_energy_z	0,2239
ECG_std_z	0,1761
ECG_missing_peaks_z	0,1423
ECG_mean_z	0,1114
ECG_range_z	0,0852

Tabela D.2: Importância por permutação das características no SVM nos três cenários.

A Figura D.2 apresenta a importância das características no SVM, calculada através de importância por permutação. No cenário A, `ECG_samp_ent_z` e `ECG_energy_z` apresentam os maiores valores. No cenário B, a maior importância é atribuída a `pNN50_z`, seguida de `cambio_HR_vs_baseline_z` e `HR_mean_z`. No cenário C, constituído apenas por características de ECG, destacam-se `ECG_samp_ent_z` e `ECG_energy_z`.

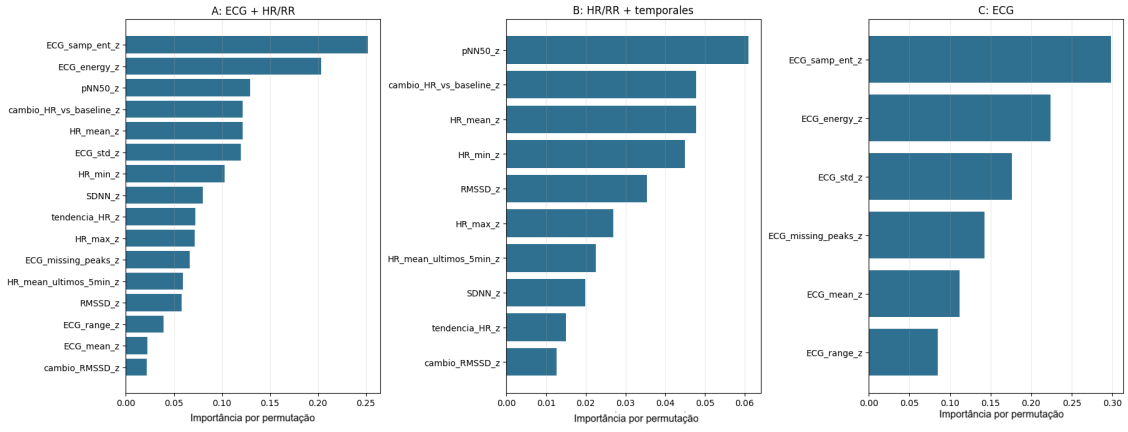


Figura D.2: Importância das características por permutação no SVM nos três cenários do estudo de ablação.

D.3 Importância das Características na Regressão Logística

Na Regressão Logística, a importância de cada característica foi calculada através da média do valor absoluto dos seus coeficientes nas três classes:

$$I_j = \frac{1}{K} \sum_{k=1}^{K} |\beta_{k,j}|, \tag{D.2}$$

onde K é o número de classes e $\beta_{k,j}$ é o coeficiente da característica j para a classe k. O valor absoluto mede a magnitude da influência, independentemente do seu sinal. Os valores calculados para os três cenários encontram-se na Tabela D.3.

Cenário A: ECG + HR/RR

Característica	Importância
ECG_energy_z	116,6476
ECG_std_z	11,5302
RMSSD_z	3,3559
ECG_samp_ent_z	2,7714
SDNN_z	1,7453
ECG_mean_z	1,6520
ECG_range_z	1,6235
ECG_missing_peaks_z	1,2880
pNN50_z	1,1531
cambio_RMSSD_z	1,0886
HR_max_z	0,8627
HR_min_z	0,5526
cambio_HR_vs_baseline_z	0,5490
HR_mean_z	0,5490
tendencia_HR_z	0,1431
HR_mean_ultimos_5min_z	0,0796

Cenário B: HR/RR + temporais

Característica	Importância
HR_min_z	0,9839
RMSSD_z	0,6872
pNN50_z	0,5506
cambio_HR_vs_baseline_z	0,3099
HR_mean_z	0,3099
HR_mean_ultimos_5min_z	0,2558
cambio_RMSSD_z	0,2480
SDNN_z	0,1190
HR_max_z	0,1183
tendencia_HR_z	0,0611

Cenário C: ECG

Característica	Importância
ECG_energy_z	44,8192
ECG_std_z	5,2296
ECG_range_z	1,8034
ECG_samp_ent_z	1,4279
ECG_mean_z	1,2172
ECG_missing_peaks_z	0,1657

Tabela D.3: Importância média absoluta dos coeficientes da Regressão Logística nos três cenários.

A Figura D.3 apresenta os coeficientes médios em valor absoluto da Regressão Logística nos três cenários. No cenário A, `ECG_energy_z` apresenta uma importância claramente superior às restantes características. No cenário B, as maiores contribuições correspondem a `HR_min_z`, `RMSSD_z` e `pNN50_z`. No cenário C, `ECG_energy_z` volta a destacar-se, enquanto as restantes características de ECG apresentam contribuições bastante inferiores.

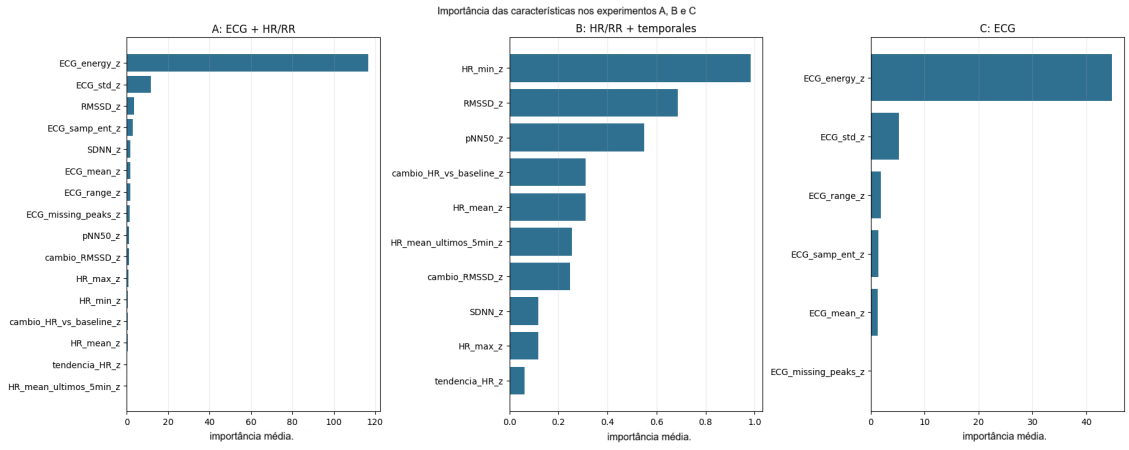


Figura D.3: Importância média das características, em valor absoluto dos coeficientes, na Regressão Logística nos três cenários do estudo de ablação.

D.4 Importância das Características no Random Forest

No Random Forest, utiliza-se diretamente `feature_importances_`. Esta medida corresponde à redução média de impureza produzida por cada característica nas árvores do bosque. Embora seja útil para descrever a forma como o modelo utiliza as variáveis, pode ser influenciada por características contínuas, por muitos pontos de separação e por variáveis correlacionadas, não constituindo uma relação causal. Os valores obtidos nos três cenários são apresentados na Tabela D.4.

Cenário A: ECG + HR/RR

Característica	Importância
ECG_energy_z	0,2006
ECG_samp_ent_z	0,1937
ECG_std_z	0,1197
HR_min_z	0,0834
cambio_HR_vs_baseline_z	0,0675
HR_mean_z	0,0629
ECG_range_z	0,0522
RMSSD_z	0,0478
pNN50_z	0,0429
ECG_mean_z	0,0410
SDNN_z	0,0308
HR_mean_ultimos_5min_z	0,0186
HR_max_z	0,0126
ECG_missing_peaks_z	0,0099
cambio_RMSSD_z	0,0094
tendencia_HR_z	0,0069

Cenário B: HR/RR + temporais

Característica	Importância
HR_min_z	0,2269
HR_mean_z	0,1918
cambio_HR_vs_baseline_z	0,1854
pNN50_z	0,1188
RMSSD_z	0,1140
SDNN_z	0,0575
HR_mean_ultimos_5min_z	0,0517
HR_max_z	0,0246
cambio_RMSSD_z	0,0184
tendencia_HR_z	0,0109

Cenário C: ECG

Característica	Importância
ECG_samp_ent_z	0,2485
ECG_energy_z	0,2352
ECG_missing_peaks_z	0,1664
ECG_std_z	0,1441
ECG_mean_z	0,1040
ECG_range_z	0,1017

Tabela D.4: Importância das características no Random Forest nos três cenários.

A Figura D.4 apresenta a importância das características no Random Forest. No cenário A, `ECG_energy_z` e `ECG_samp_ent_z` são as características mais relevantes. No cenário B, a importância concentra-se em `HR_min_z`, `HR_mean_z` e `cambio_HR_vs_baseline_z`. No cenário C, as características mais relevantes são `ECG_samp_ent_z`, `ECG_energy_z` e `ECG_missing_peaks_z`. Estes resultados confirmam que a importância relativa das variáveis depende do conjunto de características disponível em cada cenário.

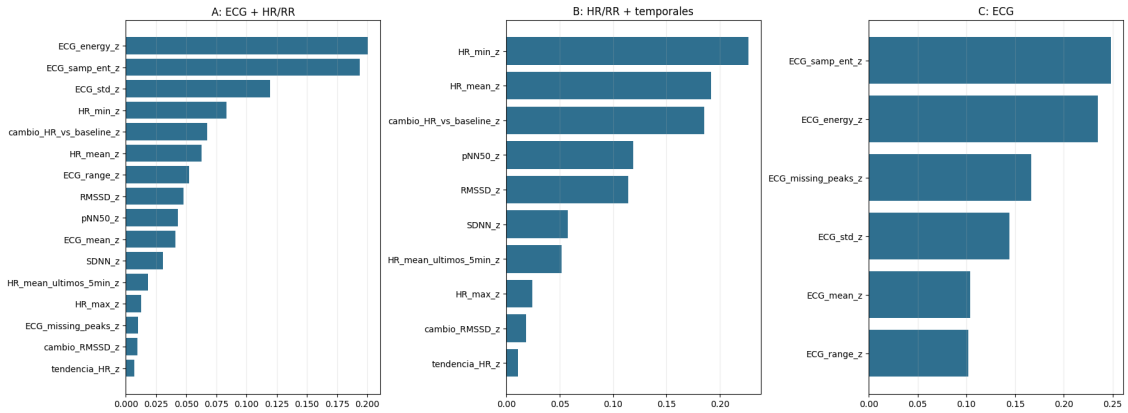


Figura D.4: Importância relativa das características no Random Forest nos três cenários do estudo de ablação.